Compléments de Statistiques (STA01, CC3) – Recueil d'exercices

Luca Ganassali

Université Paris-Saclay

(Last update: October 16, 2026)

1. Espérance et loi conditionnelle

Exercice 1.1 (Canaux gaussiens)**.** Supposons que $Y \sim \mathcal{N}(t, \tau^2)$ et que, conditionnellement à $Y = y$, $X_1, \dots, X_n$ soient i.i.d. de loi $\mathcal{N}(y, \sigma^2)$. Montrer que

$$Y \,|\, (X_1, \dots, X_n) \sim \mathcal{N}\left(\frac{t/\tau^2 + n\bar{X}_n/\sigma^2}{1/\tau^2 + n/\sigma^2}, \frac{1}{1/\tau^2 + n/\sigma^2} \right).$$

Pour une variable gaussienne, on appelle *précision* l'inverse de sa variance. Quelle propriété de la précision a-t-on mise en évidence ici ? *Solution. La densité de $X = (X_1, \dots, X_n)$ conditionnellement à $Y = y$ est donnée par*

$$\begin{aligned} p_{X|Y}(x_1, \dots, x_n, y) &= \prod_{i=1}^{n} \frac{1}{\sqrt{2\pi\sigma^2}} \exp\left(-\frac{(x_i - y)^2}{2\sigma^2} \right) \\ &= \frac{1}{(2\pi\sigma^2)^{n/2}} \exp\left(-\frac{1}{2\sigma^2} \sum_{i=1}^{n} (x_i - y)^2 \right), \end{aligned}$$

d'où la densité jointe

$$\begin{aligned} p_{X,Y}(x_1, \dots, x_n, y) &= \frac{1}{\sqrt{2\pi\tau^2}(2\pi\sigma^2)^{n/2}} \exp\left(-\frac{1}{2\tau^2}(y - t)^2 - \frac{1}{2\sigma^2} \sum_{i=1}^{n} (x_i - y)^2 \right) \\ &\propto_y \exp\left(-\frac{1}{2} \left[(1/\tau^2 + n/\sigma^2) y^2 - (2/\tau^2 + 2n\bar{X}_n/\sigma^2) y \right] \right) \\ &\propto_y \exp\left(-\frac{1}{2(1/\tau^2 + n/\sigma^2)^{-1}} \left[y - \frac{1/\tau^2 + n\bar{X}_n/\sigma^2}{1/\tau^2 + n/\sigma^2} \right]^2 \right), \end{aligned}$$

d'où

$$p_{Y|X}(y, x_1, \dots, x_n) = \frac{p_{X,Y}(x_1, \dots, x_n, y)}{p_X(x_1, \dots, x_n)} \propto_y p_{X,Y}(x_1, \dots, x_n, y),$$

ce qui donne le résultat voulu. Nous venons de montrer que la précision de la loi conditionnelle est la somme des précisions sur X_i et Y (et la moyenne est une moyenne pondérée par les précisions).

Exercice 1.2 (Loi et espérance conditionnelle)**.** Soit $X \sim \mathrm{Exp}(1)$, et Y une variable aléatoire dont la densité conditionnelle par rapport à la mesure de comptage sur $\mathbb{N}$ est donnée par :

$$p_{Y \,|\, X}(y \,|\, x) = \frac{x^y e^{-x}}{y!}.$$

1. Trouver la densité jointe de (X, Y) et identifier la mesure dominante. *Solution. La densité jointe est donnée par*

$$p_{X,Y}(x, y) = p_X(x) p_{Y|X}(y, x) = \frac{x^y e^{-2x}}{y!}.$$

   La mesure dominante est ici $\mathrm{Leb}_{\mathbb{R}_+} \times \mu_{\mathbb{N}}$, où $\mu_{\mathbb{N}}$ désigne la mesure de comptage sur $\mathbb{N}$.

2. Quelle est la densité marginale de Y ? En déduire $\mathbb{E}[Y]$. *Solution. On obtient la densité marginale de Y comme suit :*

$$p_Y(y) = \int_{\mathbb{R}_+} p_{X,Y}(x, y) dx = \int_{\mathbb{R}_+} \frac{x^y e^{-2x}}{y!} dx = \frac{1}{y!} \int_{\mathbb{R}_+} (u/2)^y e^{-u} (du/2) = \frac{\Gamma(y+1)}{2^{y+1} y!} = \frac{1}{2^{y+1}}.$$

On a donc $Y \sim \mathcal{G}(1/2)$, la loi géométrique sur $\mathbb{N}$ de paramètre de probabilité de succès $p = 1/2$. Ainsi $\mathbb{E}[Y] = \frac{1-p}{p} = 1$.

3. Reconnaissez-vous la loi de Y conditionnellement à X ? Vérifier que la loi de l'espérance totale donne la même valeur pour $\mathbb{E}[Y]$. *Solution. On voit que $Y|X \sim \mathrm{Poi}(X)$, donc $\mathbb{E}[Y|X] = X$ et $\mathbb{E}[\mathbb{E}[Y|X]] = \mathbb{E}[X] = 1$, ce qui donne le même résultat.*

4. Trouver la densité conditionnelle de X sachant $Y = y$. *Solution. On a*

$$p_{X|Y}(x,y) = \frac{p_{X,Y}(x,y)}{p_Y(y)} = \frac{2^{y+1}x^y e^{-2x}}{y!}\,.$$

On reconnaît (peut-être) une loi Gamma : on peut noter $X|Y \sim \Gamma(Y+1, 1/2)$.

Exercice 1.3 (Loi bêta)**.** Supposons que X et Y sont des v.a. réelles positives et indépendantes.

1. Montrer que pour tout $0 < x < 1$,

$$\mathbb{P}\left(\frac{X}{X+Y} \le x\right) = \mathbb{E}\left[F_X\left(\frac{xY}{1-x}\right)\right].$$

Solution. C'est simplement la loi de l'espérance totale, et comme X et Y sont indépendantes,

$$\mathbb{P}\left(\frac{X}{X+Y} \le x \,|\, Y = y\right) = \mathbb{E}\left[\mathbb{1}_{X \le \frac{xY}{1-x}} \,|\, Y = y\right] = \mathbb{E}\left[\mathbb{1}_{X \le \frac{xy}{1-x}}\right] = F_X\left(\frac{xy}{1-x}\right).$$

2. Supposons que $\mathbb{E}[Y] < \infty$ et que X admette une densité p_X par rapport à μ. On suppose p_X bornée sur $\mathbb{R}_+$. Montrer que $V = X/(X+Y)$ admet aussi une densité p_V par rapport à μ, donnée par

$$p_V(x) = \mathbb{E}\left[\frac{Y}{(1-x)^2} p_X\left(\frac{xY}{1-x}\right)\right].$$

Solution. C'est parce qu'on peut dériver sous le signe intégral à la question 1. C'est une conséquence du théorème de convergence dominée (version différentiable), puisque pour tout $0 < x < b < 1$,

$$\left|\frac{Y}{(1-x)^2} p_X\left(\frac{xY}{1-x}\right)\right| \le \frac{Y\|p_X\|_\infty}{(1-b)^2},$$

ce qui est intégrable.

Pour $\alpha, \beta > 0$, la loi Gamma $\Gamma(\alpha, \beta)$ est la loi de densité

$$x \mapsto \frac{1}{\Gamma(\alpha)} \beta^\alpha x^{\alpha-1} e^{-\beta x}$$

par rapport à $\mathrm{Leb}_{\mathbb{R}_+}$, et la loi bêta $\mathrm{Beta}(\alpha, \beta)$ est la loi de densité

$$x \mapsto \frac{\Gamma(\alpha+\beta)}{\Gamma(\alpha)\Gamma(\beta)} x^{\alpha-1}(1-x)^{\beta-1}$$

par rapport à $\mathrm{Leb}_{[0,1]}$.

3. Montrer que si $X \sim \Gamma(\alpha, 1)$ et $Y \sim \Gamma(\alpha', 1)$ sont indépendantes, alors $\frac{X}{X+Y} \sim \mathrm{Beta}(\alpha, \alpha')$.
Solution. Par le changement de variables $u = \frac{y}{1-x}$ dans la densité précédente, on obtient

$$\begin{aligned} p_V(x) &= \frac{1}{\Gamma(\alpha)\Gamma(\alpha')} \int_{\mathbb{R}_+} \frac{y}{(1-x)^2} \left(\frac{xy}{1-x}\right)^{\alpha-1} e^{-x} y^{\alpha'-1} e^{-y} dy \\ &= \frac{x^{\alpha-1}(1-x)^{\alpha'-1}}{\Gamma(\alpha)\Gamma(\alpha')} \int_{\mathbb{R}_+} u^{\alpha+\alpha'-1} e^{-u} du \\ &= \frac{\Gamma(\alpha+\alpha')}{\Gamma(\alpha)\Gamma(\alpha')} x^{\alpha-1}(1-x)^{\alpha'-1}, \end{aligned}$$

qui est bien la densité voulue.

Exercice 1.4 (Absence de géométrie dans les graphes d'Erdős-Rényi)**.** Pour $n \geq 1$ on note $[n] = \{1, 2, \ldots, n\}$. Soit $G \sim G(n, p)$ un graphe aléatoire Erdős-Rényi d'ensemble de sommets $[n]$, où chaque arête $e = \{u, v\} \in \binom{[n]}{2}$ est présente dans G indépendamment avec probabilité $p \in [0, 1]$. On note $e(G)$ le nombre d'arêtes de G.

1. Existe-t-il une valeur de p telle que $G \sim G(n, p)$ soit uniforme sur l'ensemble des graphes d'ensemble de sommets $[n]$? *Solution. Pour tout graphe g de sommet $[n]$,*

$$\mathbb{P}(G = g) = p^{e(g)}(1-p)^{\binom{n}{2} - e(g)}.$$

Si $p = 1/2$, $\mathbb{P}(G = g)$ est constante égale à $1/2^{\binom{n}{2}}$, c'est-à-dire uniforme sur l'ensemble des graphes sur $[n]$, qui a taille $1/2^{\binom{n}{2}}$.

2. Pour $G \sim G(n, p)$, quelle est la loi de $e(G)$? *Solution. Chaque arête suit une loi $\mathrm{Ber}(p)$, les arêtes sont indépendantes, donc $e(G) \sim \mathrm{Bin}(\binom{n}{2}, p)$.*

3. Pour $G \sim G(n, p)$, quelle est la loi conditionnelle de G sachant $e(G)$? *Solution. Elle est donnée par*

$$\begin{aligned} \mathbb{P}(G = g \,|\, e(G) = m) &= \frac{\mathbb{P}(G = g, e(G) = m)}{\mathbb{P}(e(G) = m)} \\ &= \mathbb{1}_{e(g)=m} \frac{p^m (1-p)^{\binom{n}{2}-m}}{\binom{\binom{n}{2}}{m} p^m (1-p)^{\binom{n}{2}-m}} \\ &= \mathbb{1}_{e(g)=m} \frac{1}{\binom{\binom{n}{2}}{m}}, \end{aligned}$$

ce qui est la loi uniforme sur l'ensemble des graphes de sommet $[n]$ et comportant $m = e(G)$ arêtes.

4. Expliquer le titre de l'exercice. *Solution. Une fois le nombre d'arêtes fixé, le graphe est uniforme : aucune contrainte géométrique particulière n'est imposée. Cela vient du fait que les arêtes sont i.i.d.*

2. Suffisance, complétude, Rao-Blackwell

Exercice 2.1. On considère le modèle où $(X_1, \ldots, X_n)$ sont i.i.d. avec $X_1 \sim \mathrm{Unif}([\theta, \theta+1])$, avec $\theta > 0$ inconnu.

1. Écrire le modèle sous la forme canonique du cours. Montrer qu'il est identifiable.

2. Montrer que $S(X) = (\min_i X_i, \max_i X_i)$ est suffisante. *Solution. On utilise la factorisation de Neyman–Fisher, la densité jointe s'écrit $\prod_{i=1}^n \mathbb{1}_{[\theta,\theta+1]}(x_i) = \mathbf{1}_{\min x_i \geq \theta} \mathbb{1}_{\max x_i \leq \theta+1}$.*

3. Montrer que $A(X) = \max_i X_i - \min_i X_i$ est auxiliaire. *On pourra chercher la loi de $X_1 - \theta$ sous $\mathbb{P}_\theta$.* *Solution.* *Posons $Y_1 = X_1 - \theta$. Notons que $Y_1 \in [0,1]$, $\mathbb{P}_\theta$−p.s. Pour tout $t \in [0,1]$, $\mathbb{P}_\theta(Y_1 \le t) = \mathbb{P}_\theta(X_1 \le t + \theta) = t$, donc $X_1 \sim \mathrm{Unif}([0,1])$ (remarque : ce n'est pas une statistique, car l'opération appliquée à X_1 pour obtenir Y_1 dépend de θ). En notant $Y = (Y_1, \dots, Y_n) = (X_1 - \theta, \dots, X_n - \theta)$, on a que sous $\mathbb{P}_\theta$, $Y \sim \mathrm{Unif}([0,1])^{\otimes n}$. Or*

$$A(X) = \max_i (X_i - \theta) - \min_i (X_i - \theta) = \max_i Y_i - \min_i Y_i,$$

variables aléatoire dont la loi ne dépend pas de θ : $A(X)$ est donc auxiliaire.

4. En déduire que $S(X) = (\min_i X_i, \max_i X_i)$ n'est pas complète. *Solution.* *Supposons que $S(X)$ est complète. D'après la question précédente, $\mathbb{E}_\theta[f(S(X)] = 0$, où $f(s_1, s_2) = s_2 - s_1 - \alpha$ avec $\alpha = \mathbb{E}_\theta[\max_i Y_i - \min_i Y_i]$ (qui ne dépend pas de θ). Donc, comme $S(X)$ est complète, $\mathcal{M}$-p.s., $f(S(X)) = 0$ i.e. $\max_i X_i - \min_i X_i = \alpha$. Montrons que cela est absurde. Si $\alpha = 0$, alors $\max_i X_i = \min_i X_i$, tous les X_i sont égaux p.s., ce qui est absurde car les X_i sont à densité. Si $\alpha > 0$,*

$$\begin{aligned}\mathbb{P}_\theta(\min_i X_i - \max_i X_i \le \alpha/2) &\ge \mathbb{P}_\theta(\theta \le X_1 \le \theta + \alpha/2, \dots, \theta \le X_n \le \theta + \alpha/2) \\ &= (\alpha/2)^n > 0,\end{aligned}$$

et donc $\min_i X_i - \max_i X_i$ n'est pas constant à α p.s. et f n'est pas nulle, contradiction.

Exercice 2.2. On considère le modèle où $(X_1, \dots, X_n)$ sont i.i.d. avec densité $x \mapsto C(\theta)\, x \mathbb{1}_{[0,\theta]}(x)$ pour un certain paramètre $\theta > 0$.

1. Trouver la valeur de $C(\theta)$ pour tout $\theta > 0$. *Solution.* *Une intégration simple montre que $C(\theta) = \frac{2}{\theta^2}$.*

2. Trouver la densité de X_1/θ. *Solution.* *Avec la fonction de répartition. Pour tout $x \in [0,1]$,*

$$\mathbb{P}_\theta(X_1/\theta \le x) = \mathbb{P}_\theta(X_1 \le x\theta) = \frac{2}{\theta^2} \int_0^{x\theta} u \, du = \frac{2(x\theta)^2}{2\theta^2} = x^2 .$$

Donc, en dérivant, X_1/θ a pour densité $x \mapsto 2x \mathbb{1}_{[0,1]}(x)$.

3. On trie les X_i par ordre croissant : $X_{(1)} \le \dots \le X_{(n)}$ sont appelées les statistiques d'ordre de l'échantillon. Montrer que $X_{(n)}$ et $X_{(1)}/X_{(n)}$ sont indépendantes. *On utilisera le théorème de Basu, après avoir montré que $X_{(1)}/X_{(n)}$ est auxiliaire à l'aide de la question précédente.* *Solution.* *Montrons que $X_{(1)}/X_{(n)}$ est auxiliaire. Comme diviser par $\theta > 0$ ne change pas l'ordre des variables, on peut poser $Y_i = X_i/\theta$. Dans ce modèle, les Y_i sont i.i.d et la loi de Y ne dépend plus de θ. De plus, $Y_{(1)}/Y_{(n)} = X_{(1)}/X_{(n)}$ en loi. La loi du membre de gauche ne dépend pas de θ, donc $X_{(1)}/X_{(n)}$ est auxiliaire. Il reste à montrer que $X_{(n)} = \max_i X_i$ est suffisante et complète. On peut le démontrer directement en écrivant d'abord la densité jointe de X sous $\mathbb{P}_\theta$, qui s'écrit*

$$\frac{2^n}{\theta^{2n}} \prod_{i=1}^n x_i \mathbb{1}_{[0,\theta]}(x_i) = 2^n \Big(\prod_{i=1}^n x_i \Big) \mathbb{1}_{\min_i x_i \ge 0} \frac{1}{\theta^{2n}} \mathbb{1}_{\max_i x_i \le \theta}.$$

Puis, via la fonction de répartition, comme dans l'exemple du cours, on obtient que $X_{(n)}$ a pour densité $u \mapsto \frac{2nu^{2n-1}}{\theta^{2n}} \mathbb{1}_{[0,\theta]}(u)$, et l'argument est similaire à celui du cours : si f est telle que $\int_0^\theta f(u) u^{2n-1} \, \mathrm{d}u = 0$ pour tout θ, alors la fonction $h : s \mapsto f(s) s^{2n-1}$ a intégrale nulle sur tout intervalle de $\mathbb{R}_+$, donc sur tout borélien par le lemme de la classe monotone, en particulier sur le borélien $B = \{s : f(s) > 0\}$. Comme $\int \mathbf{1}_B(s) f(s) s^{2n-1} ds = 0$ implique que $f = 0$ presque sûrement au sens de Lebesgue.

Exercice 2.3. On observe une réalisation de $G \sim G(n,p)$, c'est-à-dire un graphe aléatoire à n sommets (n est connu) dont chaque arête est présente indépendamment avec probabilité $p \in [0,1]$ inconnu. Trouver une statistique suffisante et complète. Interpréter.

Exercice 2.4 ($\star$)**.** Reprendre l'exemple du modèle uniforme i.i.d. du cours. Montrer que $S(X) = \max_i(X_i)$ est suffisante sans Neyman-Fisher, en donnant directement la distribution de X sachant $S(X)$. Interpréter la forme de cette distribution.

Exercice 2.5 (Une Rao-Blackwellisation)**.** On considère le modèle où $X_1, \dots, X_n$ sont i.i.d. de loi[1] $\mathrm{Poi}(\lambda)$, avec $\lambda > 0$ inconnu. On souhaite estimer $\varphi(\lambda) = e^{-\lambda}$.

1. Montrer que $T(X) = \mathbb{1}_{X_1=0}$ est un estimateur sans biais de $\varphi(\lambda)$. Calculer sa variance. Est-ce un bon estimateur ? *Solution. On a, pour tout $\lambda > 0$, $\mathbb{E}_\lambda[T(X)] = \mathbb{P}_\lambda(X_1 = 0) = \varphi(\lambda)$, $T(X)$ est donc sans biais. On a $\mathrm{Var}_\lambda(T(X)) = \mathbb{E}_\lambda[T(X)^2] - \mathbb{E}_\lambda[T(X)]^2 = \varphi(\lambda)(1-\varphi(\lambda)) = e^{-\lambda}(1-e^{-\lambda}) > 0$, qui est d'ordre 1 et ne tend pas vers 0 avec n (logique, on a pris qu'une des n observations pour construire T). Ce n'est donc pas un bon estimateur.*

2. Prouver que $S(X) = \sum_{i=1}^n X_i$ est une statistique complète et suffisante pour le modèle. *On pourra utiliser sans démonstration que si $Y_1 \sim \mathrm{Poi}(\lambda_1)$ et $Y_2 \sim \mathrm{Poi}(\lambda_2)$ sont indépendants, alors $Y_1 + Y_2 \sim \mathrm{Poi}(\lambda_1 + \lambda_2)$.* *Solution. La densité de X (par rapport à $\mu^{\otimes n}$ où μ est la mesure de comptage sur $\mathbb{N}$) s'écrit, pour tout $k \in \mathbb{N}^n$,*

$$p_X(k) = e^{-\lambda n} \prod_{i=1}^n \frac{\lambda^{k_i}}{(k_i)!} = \underbrace{\prod_{i=1}^n \frac{1}{(k_i)!}}_{=:h(k)} \underbrace{e^{-\lambda n + S(k)\log\lambda}}_{=:g_\lambda(S(k))}.$$

$S(X)$ est donc suffisante par le théorème de Neyman-Fisher. Montrons qu'elle est complète. Soit $f : \mathbb{N} \to \mathbb{R}$ telle que pour tout $\lambda > 0$, $\mathbb{E}_\lambda[f(S(X))] = 0$. D'après l'indication, on a que sous $\mathbb{P}_\lambda$, $S(X) \sim \mathrm{Poi}(\lambda n)$, donc ce qui précède équivaut à

$$\forall \lambda > 0,\ e^{-\lambda n} \sum_{k \geq 0} f(k) \frac{(\lambda n)^k}{k!} = 0$$

et par unicité des coefficients de la série entière

$$z \mapsto \sum_{k \geq 0} f(k) \frac{z^k}{k!},$$

de rayon infini, on a pour tout $k \geq 0$, $\frac{f(k)}{k!} = 0$, c'est-à-dire $f(S(X)) = 0$, $\mathcal{M}-$p.s. $S(X)$ est complète.

3. Calculer l'estimateur Rao-Blackwellisé T^* de T par S, et montrer que T^* est UVMB[2] pour l'estimation de $\varphi(\lambda)$. *Solution. Calculons l'espérance conditionnelle de T sachant S. Celle-ci vaut $\mathbb{E}_\lambda[T(X) \,|\, S(X)] = \mathbb{P}_\lambda(X_1 = 0 \,|\, S(X))$. Fixons $s \in \mathbb{N}$ et $\lambda > 0$. On a*

$$\begin{aligned}\mathbb{P}_\lambda(X_1 = 0 \,|\, S(X) = s) &= \frac{\mathbb{P}_\lambda(X_1 = 0, S(X) = s)}{\mathbb{P}_\lambda(S(X) = s)} \\ &= \frac{\mathbb{P}_\lambda(X_1 = 0, X_2 + \ldots + X_n = s)}{\mathbb{P}_\lambda(S(X) = s)}\end{aligned}$$

[1] rappel : c'est la loi telle que pour tout $k \in \mathbb{N}$, $\mathbb{P}(X = k) = e^{-\lambda}\frac{\lambda^k}{k!}$.
[2] UVMB : sans biais et uniformément de variance minimale.

$$= \frac{e^{-\lambda} e^{-\lambda(n-1)} \frac{(\lambda(n-1))^s}{s!}}{e^{-\lambda n} \frac{(\lambda n)^s}{s!}}$$
$$= (1-1/n)^s .$$

On a donc $T^*(X) = (1-1/n)^{S(X)}$. T^* étant le Rao-Blackwellisé de T par S qui est sans biais, complète et suffisante, on sait qu'il est UVMB par le théorème de Lehman-Scheffé.

4. Montrer que T^* est asymptotiquement efficace. *Solution. T^* est-il de variance comparable à la borne de Cramer-Rao ? Calculons la. L'information de Fisher vaut $n \times I_1(\lambda) = n/\lambda$ (simple calcul via la vraisemblance). La borne de CR vaut donc $\frac{\varphi'(\lambda)^2}{I(\lambda)} = \frac{\lambda e^{-2\lambda}}{n}$. On utilise ensuite la transformée de Laplace d'une Loi de Poisson : si $X \sim \mathrm{Poi}(\lambda)$, $\mathbb{E}[e^{tX}] = e^{\lambda(e^\top - 1)}$. Cela donne $\mathbb{E}_\lambda[T^*] = e^{-\lambda}$, on le savait, mais surtout $\mathbb{E}_\lambda[(T^*)^2] = e^{\lambda n \times (e^{2\log(1-1/n)} - 1)} = e^{-2\lambda + \lambda/n}$. Cela donne*

$$\mathrm{Var}_\lambda(T^\star) = e^{-2\lambda}(e^{\lambda/n} - 1) \sim \frac{\lambda e^{-2\lambda}}{n} .$$

5. Montrer que T^* est fortement consistant. *Solution. $T^* = (1-1/n)^{S_n} = \exp(n \log(1-1/n) \times (S_n/n))$ et on applique la loi des grands nombres.*

6. ($\star$, car un peu technique) Montrer que T^* est asymptotiquement normal en précisant les paramètres asymptotiques. *Solution. Le TCL appliqué à S_n/n, avec $S = S_n$, donne*

$$\sqrt{n}\left(\frac{S_n}{n} - \lambda\right) \to \mathcal{N}(0, \lambda) .$$

On aimerait écrire $T^* = g(S_n/n)$, mais ici g dépendrait de n:

$$T^* = (1-1/n)^{S_n} = \exp(n \log(1-1/n) \times (S_n/n)) .$$

On sait appliquer la méthode Delta à $V_n = \exp(-S_n/n)$, ici $g(x) = \exp(-x)$ et elle donne

$$\sqrt{n}(V_n - e^{-\lambda}) \xrightarrow[n\to\infty]{(d)} -e^{-\lambda}\mathcal{N}(0,\lambda) = \mathcal{N}(0, \lambda e^{-2\lambda}) .$$

Il ne resterait qu'à montrer que $\sqrt{n}(T^* - V_n) \xrightarrow[n\to\infty]{(d)} 0$ et appliquer le lemme de Slutsky.

3. Compléments sur l'information de Fisher

Exercice 3.1 (Additivité de l'information de Fisher)**.** Soient $\mathcal{M}_1 = (\mathbb{R}^n, \mathcal{B}(\mathbb{R}^n), (\mathbb{P}_\theta)_{\theta\in\Theta})$ and $\mathcal{M}_2 = (\mathbb{R}^n, \mathcal{B}(\mathbb{R}^n), (\mathbb{Q}_\theta)_{\theta\in\Theta})$ des modèles réguliers et à densité par rapport à la mesure de Lebesgue. On considère leurs matrices d'information de Fisher respectives, $I_1(\theta)$ et $I_2(\theta)$ respectively. On s'intéresse au modèle "produit":

$$\mathcal{M}_1 \otimes \mathcal{M}_2 := (\mathbb{R}^{n+m}, \mathcal{B}(\mathbb{R}^{n+m}), (\mathbb{P}_\theta \otimes \mathbb{Q}_\theta)_{\theta\in\Theta}) .$$

On admet qu'il est régulier et on note $I(\theta)$ la matrice d'information de Fisher dans $\mathcal{M}_1 \otimes \mathcal{M}_2$. Montrer que pour tout $\theta \in \Theta$,

$$I(\theta) = I_1(\theta) + I_2(\theta) .$$

Interpréter.

Exercice 3.2. Dans le modèle linéaire Gaussien identifiable noté classiquement $Y = X\theta + \varepsilon$, calculer la matrice d'information de Fisher pour le paramètre joint (θ, σ^2). L'estimateur

des moindres carrés atteint-il la borne de Cramer-Rao? *Solution. Comme sour $\mathbb{P}_{\theta,\sigma^2}$, $y \sim \mathcal{N}(X\theta, \sigma^2 I_n)$, la log-vraisemblance s'écrit*

$$\ell(\theta, \sigma^2; y) = -\frac{n}{2}\log(2\pi\sigma^2) - \frac{1}{2\sigma^2}\|Y - X\theta\|^2,$$

et le score est donc, en développant $\|Y - X\theta\|^2 = Y^\top Y - Y^\top X\theta - \theta^\top X^\top Y + \theta^\top X^\top X\theta$, comme dans le cours,

$$\nabla_{\theta,\sigma^2}\ell(\theta, \sigma^2; y) = \left(-\frac{1}{2\sigma^2}(-2X^\top Y + 2X^\top X\theta), -\frac{n}{2\sigma^2} + \frac{1}{2\sigma^4}\|Y - X\theta\|^2\right)^\top,$$

où l'on a isolé le dernier coefficient du reste. En prenant le jacobien de la quantité ci-dessus, il vient

$$\nabla^2_{\theta,\sigma^2}\ell(\theta, \sigma^2; y) = \begin{pmatrix} \frac{X^\top X}{\sigma^2} & -\frac{1}{\sigma^4}(X^\top Y - X^\top X\theta) \\ -\frac{1}{\sigma^4}(X^\top Y - X^\top X\theta)^\top & \frac{n}{2\sigma^4} - \frac{1}{\sigma^6}\|Y - X\theta\|^2 \end{pmatrix}$$

où, de même, on a représenté la matrice par blocs : le bloc $p \times p$ correspondant à θ et le bloc 1×1 pour σ^2. l'on a isolé le premier coefficient du reste. On a donc finalement

$$I(\theta, \sigma^2) = -\mathbb{E}_{\theta,\sigma^2}[\nabla^2_{\theta,\sigma^2}\ell(\theta, \sigma^2; Y)] = \begin{pmatrix} \frac{X^\top X}{\sigma^2} & 0 \\ 0 & \frac{n}{2\sigma^4} \end{pmatrix}$$

La borne de Cramer-Rao pour estimer $h(\theta, \sigma^2) = \theta$ avec T sans biais s'écrit

$$\mathrm{Var}_{\theta,\sigma^2}(T) \succeq J^\top [I(\theta, \sigma^2)]^{-1} J,$$

where J is the jacobian of $h : \mathbb{R}^{p+1} \to \mathbb{R}^p$, here given by

$$J = \begin{pmatrix} 1 & & 0 \\ & \ddots & \vdots \\ & 1 & 0 \end{pmatrix} \in \mathbb{R}^{(p+1)\times p},$$

ce qui donne

$$\mathrm{Var}_{\theta,\sigma^2}(T) \succeq \sigma^2 (X^\top X)^{-1},$$

qui est exactement la variance de l'estimateur des moindres carrés, qui est de plus non biaisé. Il est donc efficace.

Exercice 3.3 (Information de Fisher et identifiabilité locale)**.** Soit $\mathcal{M} = (\mathcal{X}, \mathcal{F}, (\mathbb{P}_\theta)_{\theta\in\Theta})$ modèle paramétrique avec $\Theta \subseteq \mathbb{R}^p$. On dit que $\mathcal{M}$ est *localement identifiable* en $\theta \in \Theta$ si il existe un voisinage U de θ dans Θ tel que

$$\forall \theta' \in U, (\mathbb{P}_{\theta'} = \mathbb{P}_\theta) \implies \theta = \theta'.$$

On suppose que le modèle est régulier. On fait une hypothèse supplémentaire, un peu plus forte que la régularité du cours :

(H1) la log-vraisemblance ℓ est deux fois différentiable en θ sur Θ, et ses dérivées secondes sont localement dominées uniformément en θ.

(H2) la Hessienne $\theta \mapsto \nabla^2\ell(\theta, x)$ est localement Lispchitz, uniformément en x au sens ou pour tout $\theta \in \Theta$, il existe V voisinage de θ, $C_\theta > 0$ tels que pour tous $\theta' \in V$, $x \in \mathcal{X}$,

$$-C_\theta\|\theta' - \theta\| \preceq \nabla^2\ell(\theta', x) - \nabla^2\ell(\theta, x) \preceq C_\theta\|\theta' - \theta\|.$$

Le but de cet exercice est de démontrer, sous (H1) et (H2), que si l'information de Fisher

$I(\theta)$ est inversible en θ, alors le modèle est localement identifiable en θ.

1. Montrer que sous (H1), pour tout $\theta \in \Theta$,
$$I(\theta) = -\mathbb{E}_\theta[\nabla^2 \ell(\theta, X)]\,.$$

2. Montrer que pour $\theta \in \Theta$ et $v \in \mathbb{R}^p$ assez petit, un développement de Taylor de $\ell(\theta+v, x)$ autour de $\ell(\theta, x)$ donne
$$\ell(\theta + v, x) = \ell(\theta, x) + v^\top \nabla_\theta \ell(\theta, x) + \frac{1}{2} v^\top \nabla^2_\theta \ell(\theta, x) v + R(v, \theta, x),$$
avec
$$R(v, \theta, x) = \frac{1}{2} \int_0^1 (1-t) v^\top (\nabla^2_\theta \ell(\theta + tv, x) - \nabla^2_\theta \ell(\theta, x)) v \, dt.$$

Pour $\theta, \theta' \in \Theta$, on définit la divergence de Kullback-Leibler entre $\mathbb{P}_\theta$ et $\mathbb{P}_{\theta'}$ par:
$$\mathrm{KL}(\mathbb{P}_\theta \| \mathbb{P}_{\theta'}) := \mathbb{E}_\theta \left[\ell(\theta, X) - \ell(\theta', X) \right] .$$

3. Soit $\theta \in \Theta$. Montrer qu'avec ce qui précède, pour v tel que $\|v\|$ est assez petit,
$$\mathrm{KL}(\mathbb{P}_\theta \| \mathbb{P}_{\theta+v}) = v^\top I(\theta) v + o(\|v\|^2),$$
où $o(\|v\|^2)$ est une fonction de la forme $\|v\|^2 \varepsilon(v)$ tel que $\varepsilon(v) \to 0$ quand $v \to 0$. *On justifiera également que le membre de gauche est bien défini pour v assez petit.* *Solution. Le membre de gauche est bien défini pour v assez petit car Θ est un ouvert de $\mathbb{R}^p$. On a*
$$\mathrm{KL}(\mathbb{P}_\theta \| \mathbb{P}_{\theta+v}) = \int (\ell(\theta, x) - \ell(\theta + v, x))\, L(\theta, x)\, d\nu(x).$$
En substituant le développement limité de $\ell(\theta + v, x)$:
$$\mathrm{KL}(P_\theta \| P_{\theta+v}) = -\int \left(v^\top \nabla_\theta \ell(\theta, x) + \frac{1}{2} v^\top \nabla^2_\theta \ell(\theta, x) v + R(v, \theta, x) \right) L(\theta, x)\, dx.$$
Le premier terme est nul car le score est centré. Le second terme vaut, d'après la question 1,
$$-\int \frac{1}{2} v^\top \nabla^2_\theta \ell(\theta, x) v L(\theta, x)\, dx = -\frac{1}{2} v^\top \mathbb{E}_\theta[\nabla^2_\theta \ell(\theta, x)] v = \frac{1}{2} v^\top I(\theta) v.$$
Pour le troisième terme, on conclut via (H2) et le TCD.

4. Conclure. *Solution. Nullité de la KL ssi égalité dans Jensen $x \log x \geq 0$ avec égalité ssi $x = 1$.*

5. ($\star$) On se place dans le modèle ou l'on observe X qui a pour loi $\mathcal{N}(a, 1)$ avec probabilité $1/2$, et $\mathcal{N}(b, 1)$ avec probabilité $1/2$. On se place dans l'espace des paramètres $\Theta = \mathbb{R}^2 \backslash \{(a, a), a \in \mathbb{R}\}$. On admet que ce modèle est régulier. Montrer que $I(\theta)$ est inversible en tout point de Θ, mais que le modèle n'est pas identifiable globalement (c'est-à-dire au sens du cours). *Solution. globalement : symétrie $(a, b) \to (b, a)$ mais localement, identifiable dans des intervalles de rayon $< |a - b|/2$ autour de a et de b.*

Exercice 3.4 (Information de Fisher dans un modèle induit)**.** Soit $\mathcal{M} = (\mathbb{R}^n, \mathcal{B}(\mathbb{R}^n), (\mathbb{P}_\theta)_{\theta \in \Theta})$ un modèle régulier et à densité par rapport à la mesure de Lebesgue. On note ℓ la log-vraisemblance et $I(\theta)$ la matrice d'information de Fisher dans $\mathcal{M}$. Soit $T : (\mathbb{R}^n, \mathcal{B}(\mathbb{R}^n)) \to$

$(\mathbb{R}^m, \mathcal{B}(\mathbb{R}^m))$ une statistique. On définit $\mathcal{M}_T$ le *modèle induit par* T:

$$\mathcal{M}_T = (\mathbb{R}^m, \mathcal{B}(\mathbb{R}^m), (\mathbb{P}_\theta \circ T^{-1})_{\theta\in\Theta}) .$$

C'est le modèle où $T(X(\omega)))$ est observée plutôt que $X(\omega)$. On suppose que $\mathcal{M}_T$ est encore régulier et à densité par rapport à la mesure de Lebesgue. On note ℓ_T la log-vraisemblance et $I_T(\theta)$ la matrice d'information de Fisher dans $\mathcal{M}_T$.

1. Montrer que pour tout $\theta \in \Theta$, $\mathbb{E}[\dot\ell(\theta, X) \,|\, T(X)] = \dot\ell_T(\theta, T(X))$. *On pourra montrer que pour tout* $A \in \mathcal{B}(\mathbb{R}^m)$, *pour tout* $\theta \in \Theta$, $\mathbb{E}_\theta[\dot\ell(\theta, x)\mathbf{1}_A(T(X))] = \mathbb{E}_\theta[\dot\ell_T(\theta, T(X))\mathbf{1}_A(T(X))]$.

   Solution. Notons $L := \exp(\ell)$ *et* $L_T := \exp(\ell_T)$ *les vraisemblances. Soit* $A \in \mathcal{B}(\mathbb{R}^m)$. *Par définition,*

$$\int_{T^{-1}(A)} L(\theta, x)\, dx = \mathbb{P}_\theta(T(X) \in A) = \mathbb{P}_\theta \circ T^{-1}(A) = \int_A L_T(\theta, t)\, dt .$$

   Par régularité du modèle, on peut différentier en θ *des deux côtés, et intervertir l'intégration et la dérivation. Cela donne*

$$\int_{T^{-1}(A)} \nabla_\theta L(\theta, x)\, dx = \int_A \nabla_\theta L_T(\theta, t)\, dt,$$

   puis, en multipliant et divisant par L *(gauche) and* L_T *(droite):*

$$\int_{T^{-1}(A)} \dot\ell(\theta, x)\, L(\theta, x)\, \nu(dx) = \int_A \dot\ell_T(\theta, t)\, L_T(\theta, t)\, \nu_T(dt) .$$

   En réécrivant l'égalité ci-dessus avec des espérances, nous avons donc montré que

$$\mathbb{E}_\theta[\dot\ell(\theta, X)\mathbf{1}_A(T(X))] = \mathbb{E}_\theta[\dot\ell_T(\theta, T(X))\mathbf{1}_A(T(X))],$$

   et ce pour tout $A \in \mathcal{B}(\mathbb{R}^m)$. *Par définition de l'espérance conditionnelle, cela implique* $\mathbb{E}[\dot\ell(\theta, X) \,|\, T(X)] = \dot\ell_T(\theta, T(X))$.

2. En déduire que pour tout $\theta \in \Theta$, $I_T(\theta) \preceq I(\theta)$. Interpréter. *On pourra calculer* $\mathbb{E}[\dot\ell_T(\theta, T(X))\dot\ell(\theta, X)^\top]$ *puis* $\mathrm{Var}_\theta(\dot\ell(\theta, X) - \dot\ell_T(\theta, T(X)))$. *Solution. D'après la question précédent et par la loi de l'espérance totale,*

$$\begin{aligned}\mathbb{E}[\dot\ell_T(\theta, T(X))\dot\ell(\theta, X)^\top] &= \mathbb{E}[\dot\ell_T(\theta, T(X))\mathbb{E}[\dot\ell(\theta, X) \,|\, T(X)]^\top] \\ &= \mathbb{E}[\dot\ell_T(\theta, T(X))\dot\ell_T(\theta, T(X))^\top] \\ &= I_T(\theta),\end{aligned}$$

   et donc

$$\begin{aligned}\mathrm{Var}_\theta(\dot\ell(\theta, X) - \dot\ell_T(\theta, T(X))) &= \mathbb{E}[(\dot\ell(\theta, X) - \dot\ell_T(\theta, T(X)))(\dot\ell(\theta, X) - \dot\ell_T(\theta, T(X)))^\top] \\ &= I(\theta) + I_T(\theta) - 2\mathbb{E}[\dot\ell_T(\theta, T(X))\dot\ell(\theta, X)^\top] \\ &= I(\theta) + I_T(\theta) - 2I_T(\theta) \\ &= I(\theta) - I_T(\theta),\end{aligned}$$

   et une matrice de covariance est toujours symétrique positive, ce qui prouve $I_T(\theta) \preceq I(\theta)$. *Cel traduit le fait que l'information sur* θ *ne peut que se réduire lorsqu'on observe une transformée de* X, $T(X)$ *par rapport à la donnée "brute"* X.

3. Montrer enfin que ($I_T(\theta) = I(\theta)$ pour tout $\theta \in \Theta$) $\iff$ $T(X)$ est suffisante dans $\mathcal{M}$. Interpréter. *On pourra utiliser Neyman-Fisher. Solution. D'après la question précé-*

dente,

$$(\forall \theta \in \Theta,\, I_T(\theta) = I(\theta)) \iff (\forall \theta \in \Theta,\, \dot{\ell}(\theta, X) = \dot{\ell}_T(\theta, T(X)), \quad \mathbb{P}_\theta - a.s.)$$

En intégrant en θ, cette dernière condition est équivalent à dire que la log-vraisemblance est de la forme

$$\ell(\theta, x) = \ell_T(\theta, T(x)) + k(x), \quad \mathcal{M} - p.s.$$

En prenant l'exponentielle et en appliquant le théorème de Neyman-Fisher Theorem (qui donne bien une équivalence) on conclut que tout cela est vrai si et seuelment si $T(X)$ est suffisante. On remarque que cela est compatible avec l'idée que l'on se fait de la suffisance : une statistique suffisante $T(X)$ dévoile autant d'information sur θ que X lui-même.

4. Point de vue informationnel sur les tests, bornes inférieures minimax