Statistique mathématique – recueil d'exercices

Luca Ganassali

Université Paris-Saclay

2025 – 2026

(Last update: March 27, 2026)

1. Outils probabilistes pour le statisticien

Cette première feuille d'exercices est particulièrement longue. Il n'est pas attendu de tout traiter.

Exercice 1.1 (Maximum de variables exponentielles i.i.d.)**.** Soient $(X_n)_{n\geq 1}$ sont i.i.d. et distribuées exponentiellement avec paramètre $\lambda > 0$, c'est-à-dire de densité $x \mapsto \lambda e^{-\lambda x}\mathbb{1}_{x>0}$ par rapport à la mesure de Lebesgue sur $\mathbb{R}$. Pour tout $n \geq 1$, on définit

$$M_n := \max(X_1, \dots, X_n)\,.$$

Equivalent presque sûr de M_n (optionnel).

1. À l'aide du Lemme de Borel-Cantelli, montrer que $\liminf \frac{M_n}{\log n} \geq 1/\lambda$, p.s.
2. À l'aide du Lemme de Borel-Cantelli, montrer que $\limsup \frac{X_n}{\log n} = 1/\lambda$ p.s.
3. Montrer finalement que $\frac{M_n}{\log n} \xrightarrow[n\to\infty]{p.s.} 1/\lambda$. *On pourra faire une preuve "à la Cesaro".*

Développement limité de M_n puis de $1/M_n$.

4. Montrer que $M_n - \frac{\log n}{\lambda}$ converge en loi vers une loi notée G_λ que vous caractériserez. *On passera par la fonction de répartition.*
5. En appliquant la méthode Delta et la question précédente, montrer que

$$\log n \times \left(\frac{\log n}{M_n} - \lambda\right) \xrightarrow[n\to\infty]{(d)} H_\lambda,$$

   et préciser la fonction de répartition de H_λ.

Application: intervalle de confiance pour λ.

6. Pour $\beta \in]0,1[$, calculer explicitement le quantile d'ordre β de la loi de H_λ, noté $h_{\lambda,\beta}$.
7. Montrer avec tout ce qui précède que pour tout $\alpha \in]0,1[$, en notant

$$I_1(X_1, \dots, X_n; \alpha) := \left[\frac{\frac{\log n}{M_n}}{1 + \frac{\log(-\log(\alpha/2))}{\log n}}, \frac{\frac{\log n}{M_n}}{1 + \frac{\log(-\log(1-\alpha/2))}{\log n}}\right],$$

   on a

$$\mathbb{P}\left(I_1(X_1, \dots, X_n; \alpha) \ni \lambda\right) \xrightarrow[n\to\infty]{} 1 - \alpha\,.$$

   $I_1(X_1, \dots, X_n)$ est un intervalle aléatoire appelé intervalle de confiance asymptotique pour λ de probabilité de couverture $1 - \alpha$.
8. Quel est l'équivalent presque sûr de $\mathrm{diam}(I_1(X_1, \dots, X_n; \alpha))$?
9. ($\star$ car moins guidé) Pourrait-on trouver un autre intervalle de confiance dont le diamètre décroit sensiblement plus vite en n que l'intervalle précédent ?

Exercice 1.2 (Empirical risk minimisation)**.** On observe $(X_1, Y_1), \dots, (X_n, Y_n)$ i.i.d., de loi inconnue, avec X_i vecteurs aléatoires de $\mathbb{R}^d$ (*features*), et $Y_i \in \{0, 1\}$ (*labels*). On appelle *classifieur* une fonction mesurable $h : \mathbb{R}^d \to \{0, 1\}$. Soit $\mathcal{H}$ un ensemble fini de classifieurs. On considère le *classification loss* ℓ défini par

$$\ell(h(X), Y) = \mathbb{1}_{\{h(X)\neq Y\}}\,.$$

Pour $h \in \mathcal{H}$, on définit son *risque* $R(h)$ et son *risque empirique* $\widehat{R}_n(h)$, donnés par :

$$R(h) = \mathbb{E}[\ell(h(X), Y)], \qquad \widehat{R}_n(h) = \frac{1}{n}\sum_{i=1}^{n} \ell(h(X_i), Y_i)\,.$$

Le but du statisticien est de trouver le meilleur classifieur $h \in \mathcal{H}$ au sens du risque R:

$$h^\star \in \arg\min_{h \in \mathcal{H}} R(h)\,.$$

Problème : R dépend de la loi des données qui est inconnue : on ne peut pas calculer $R(h)$. La seule chose à laquelle nous avons accès, ce sont les données. On définit l'estimateur ERM $\hat{h}_n$ (empirical risk minimizer) par :

$$\hat{h}_n \in \arg\min_{h \in \mathcal{H}} \widehat{R}_n(h)\,.$$

Notons qu'on a par définition $R(h^\star) \leq R(\hat{h}_n)$. Le but de l'exercice est d'établir une inégalité dans l'autre sens (avec des termes en plus) afin de montrer que $\hat{h}_n$ n'est pas trop mauvais par rapport à $h^\star$ au sens du risque R.

1. A l'aide de l'inégalité de Hoeffding, montrer que pour tout $h \in \mathcal{H}$ et tout $\varepsilon > 0$,

$$\mathbb{P}\Big(\Big|\widehat{R}_n(h) - R(h)\Big| \geq \varepsilon\Big) \leq 2e^{-2n\varepsilon^2}.$$

2. En utilisant une *union bound*, montrer que pour tout $\varepsilon > 0$,

$$\mathbb{P}\Big(\sup_{h \in \mathcal{H}} \Big|\widehat{R}_n(h) - R(h)\Big| \geq \varepsilon\Big) \leq 2|\mathcal{H}|\, e^{-2n\varepsilon^2}.$$

   En déduire qu'avec probabilité au moins $1 - \delta$,

$$\sup_{h \in \mathcal{H}} \Big|\widehat{R}_n(h) - R(h)\Big| \leq \sqrt{\frac{1}{2n}\log\left(\frac{2|\mathcal{H}|}{\delta}\right)}\,.$$

3. Montrer enfin qu'avec probabilité au moins $1 - \delta$,

$$R(\hat{h}_n) \leq R(h^\star) + 2\sqrt{\frac{1}{2n}\log\left(\frac{2|\mathcal{H}|}{\delta}\right)}.$$

   Interpréter.

Exercice 1.3 (Loi et espérance conditionnelle)**.** Soit $X \sim \mathrm{Exp}(1)$, et Y une variable aléatoire dont la densité conditionnelle par rapport à la mesure de comptage sur $\mathbb{N}$ est donnée par :

$$p_{Y\,|\,X}(y\,|\,x) = \frac{x^y e^{-x}}{y!}\,.$$

1. Trouver la densité jointe de (X, Y) et identifier la mesure dominante.
2. Quelle est la densité marginale de Y ? En déduire $\mathbb{E}[Y]$.
3. Reconnaissez-vous la loi de Y conditionnellement à X ? Vérifier que la loi de l'espérance totale donne la même valeur pour $\mathbb{E}[Y]$.
4. Trouver la densité conditionnelle de X sachant $Y = y$.

Exercice 1.4 (Fonction caractéristique des variables gaussiennes)**.** Nous voulons montrer que si $X \sim \mathcal{N}(\mu, \sigma^2)$, alors pour tout $t \in \mathbb{R}$,

$$\Phi_X(t) := \mathbb{E}[e^{itX}] = \exp\left(i\mu t - \frac{\sigma^2}{2}t^2\right).$$

0. Montrer le résultat lorsque X est dégénérée ($\sigma = 0$). Nous supposons désormais $\sigma > 0$.
1. Montrer que pour tout $t \in \mathbb{R}$, $\Phi_X(t) = e^{it\mu} f_\sigma(t)$, où
$$f_\sigma(t) := \frac{1}{\sqrt{2\pi}} \int_{\mathbb{R}} e^{i\sigma t y - y^2/2} dy\,.$$
2. Montrer que pour tout $t \in \mathbb{R}$, $f_\sigma(t) \in \mathbb{R}$, que f_σ est différentiable et trouver une équation différentielle qu'elle satisfait.
3. Conclure.
4. En déduire que si $X \sim \mathcal{N}(\mu, \sigma^2)$, et $a, b \in \mathbb{R}$, alors $aX + b \sim \mathcal{N}(a\mu + b, a^2\sigma^2)$.
5. En déduire que, si $X_1 \sim \mathcal{N}(\mu_1, \sigma_1^2)$, $X_2 \sim \mathcal{N}(\mu_2, \sigma_2^2)$ et X_1 et X_2 sont indépendantes, alors
$$X_1 + X_2 \sim \mathcal{N}(\mu_1 + \mu_2, \sigma_1^2 + \sigma_2^2)\,.$$

Exercice 1.5 (Méthode Delta pour une loi multinomiale)**.** *Cet exercice suppose une connaissance préalables des propriétés des vecteurs gaussiens (que nous reverrons plus tard dans le cours).* Soit
$$(A_n, B_n, C_n) \sim \text{Multinomial}(n;\, p_1, p_2, 1 - p_1 - p_2)$$
avec $p_1, p_2 \in (0, 1)$ et $p_1 + p_2 < 1$. Pour tout $n \geq 1$, on définit

$$U_n := \frac{A_n}{n}, \quad V_n := \frac{B_n}{n}, \quad Z_n := \log\left(\frac{U_n}{V_n}\right).$$

1. Montrer que
$$\sqrt{n}\big((U_n, V_n) - (p_1, p_2)\big) \xrightarrow[n\to\infty]{(d)} \mathcal{N}\big(0, \Sigma\big),$$
où
$$\Sigma = \begin{pmatrix} p_1(1-p_1) & -p_1p_2 \\ -p_1p_2 & p_2(1-p_2) \end{pmatrix}.$$
2. En appliquant la méthode Delta à la fonction
$$g(x, y) = \log(x) - \log(y),$$
montrer que
$$\sqrt{n}\left(Z_n - \log\left(\frac{p_1}{p_2}\right)\right) \xrightarrow[n\to\infty]{(d)} \mathcal{N}\Big(0, \frac{1}{p_1} + \frac{1}{p_2}\Big).$$
Interpréter la symétrie dans la variance limite en p_1, p_2.

Exercice 1.6 (Plus rapide que $1/\sqrt{n}$?)**.** Supposons que $X_1, \ldots, X_n$ sont i.i.d., centrées, de variance finie $\sigma^2 > 0$ inconnue. On note classiquement $\bar{X}_n$ la moyenne empirique des X_i et

$$\hat{\sigma}^2 := \frac{1}{n}\sum_{i=1}^n X_i^2 - \left(\frac{1}{n}\sum_{i=1}^n X_i\right)^2.$$

1. Étudier la convergence presque sûre de $\bar{X}_n$ et de $\hat{\sigma}^2$.
2. Montrer que
$$\frac{\sqrt{n}\bar{X}_n}{\sqrt{\hat{\sigma}^2}} \xrightarrow[n\to\infty]{(d)} \mathcal{N}(0,1)\,.$$

Dans toute la suite, on suppose que $\sigma^2 = 1$ et qu'il est connu.

3. Quelle est la limite en loi de $\sqrt{n}(\cos(\bar{X}_n) - 1)$?
4. Trouver une suite $(a_n)_{n\geq 1}$ telle que $a_n(\cos(\bar{X}_n) - 1)$ converge en loi vers une v.a. Z qui n'est pas presque sûrement constante. Caractériser la loi de Z.

Exercice 1.7 (Une inégalité de type Bennett)**.** On note h la fonction définie sur $\mathbb{R}_+$ par $h(x) = (1+x)\log(1+x) - x$, et ϕ définie sur $\mathbb{R}$ par $\phi(x) = \exp(x) - x - 1$. Soit $X \sim \mathrm{Poi}(\theta)$ avec $\theta > 0$.

1. Pour tout $\lambda \in \mathbb{R}$, calculer $\mathbb{E}[\exp(\lambda(X-\theta))]$ en fonction de ϕ.
2. Montrer que pour tout $x > 0$,
$$\mathbb{P}(X - \theta \geq x) \leq \exp(-\theta h(x/\theta))\,.$$
3. On donne $e^{-2h(4)} \sim 0.003$. Comment cette inégalité se compare-t-elle à Bienaymé–Tchebychev pour $\mathbb{P}(X \geq 10)$ lorsque $\theta = 2$?

Exercice 1.8 (Canaux gaussiens)**.** Supposons que $Y \sim \mathcal{N}(t, \tau^2)$ et que, conditionnellement à $Y = y$, $X_1, \ldots, X_n$ soient i.i.d. de loi $\mathcal{N}(y, \sigma^2)$. Montrer que
$$Y \mid (X_1, \ldots, X_n) \sim \mathcal{N}\left(\frac{t/\tau^2 + n\bar{X}_n/\sigma^2}{1/\tau^2 + n/\sigma^2}, \frac{1}{1/\tau^2 + n/\sigma^2}\right)\,.$$

Pour une variable gaussienne, on appelle *précision* l'inverse de sa variance. Quelle propriété de la précision a-t-on mise en évidence ici ?

Exercice 1.9 (Loi bêta)**.** Supposons que X et Y sont des v.a. réelles positives et indépendantes.

1. Montrer que pour tout $0 < x < 1$,
$$\mathbb{P}\left(\frac{X}{X+Y} \leq x\right) = \mathbb{E}\left[F_X\left(\frac{xY}{1-x}\right)\right]\,.$$
2. Supposons que $\mathbb{E}[Y] < \infty$ et que X admette une densité p_X par rapport à μ. Montrer que $V = X/(X+Y)$ admet aussi une densité p_V par rapport à μ, donnée par
$$p_V(x) = \mathbb{E}\left[\frac{Y}{(1-x)^2} p_X\left(\frac{xY}{1-x}\right)\right]\,.$$

Pour $\alpha, \beta > 0$, la loi Gamma $\Gamma(\alpha, \beta)$ est la loi de densité
$$x \mapsto \frac{1}{\Gamma(\alpha)}\beta^\alpha x^{\alpha-1} e^{-\beta x}$$
par rapport à $\mathrm{Leb}_{\mathbb{R}_+}$, et la loi bêta $\mathrm{Beta}(\alpha, \beta)$ est la loi de densité
$$x \mapsto \frac{\Gamma(\alpha+\beta)}{\Gamma(\alpha)\Gamma(\beta)} x^{\alpha-1}(1-x)^{\beta-1}$$
par rapport à $\mathrm{Leb}_{[0,1]}$.

3. Montrer que si $X \sim \Gamma(\alpha, 1)$ et $Y \sim \Gamma(\alpha', 1)$ sont indépendantes, alors $\frac{X}{X+Y} \sim \mathrm{Beta}(\alpha, \alpha')$.

Exercice 1.10 (Absence de géométrie dans les graphes d'Erdős-Rényi)**.** Pour $n \geq 1$ on note $[n] = \{1, 2, \ldots, n\}$. Soit $G \sim G(n, p)$ un graphe aléatoire Erdős-Rényi d'ensemble de sommets $[n]$, où chaque arête $e = \{u, v\} \in \binom{[n]}{2}$ est présente dans G indépendamment avec probabilité $p \in [0, 1]$. On note $e(G)$ le nombre d'arêtes de G.

1. Existe-t-il une valeur de p telle que $G \sim G(n, p)$ soit uniforme sur l'ensemble des graphes d'ensemble de sommets $[n]$?

2. Pour $G \sim G(n, p)$, quelle est la loi de $e(G)$?

3. Pour $G \sim G(n, p)$, quelle est la loi conditionnelle de G sachant $e(G)$?

4. Expliquer le titre de l'exercice.

2. Modélisation statistique, suffisance et complétude

Exercice 2.1. On considère le modèle où $(X_1, \ldots, X_n)$ sont i.i.d. avec $X_1 \sim \mathrm{Unif}([\theta, \theta+1])$, avec $\theta > 0$ inconnu.

1. Écrire le modèle sous la forme canonique du cours. Montrer qu'il est identifiable.
2. Montrer que $S(X) = (\min_i X_i, \max_i X_i)$ est suffisante.
3. Montrer que $A(X) = \max_i X_i - \min_i X_i$ est auxiliaire. *On pourra chercher la loi de $X_1 - \theta$ sous $\mathbb{P}_\theta$.*
4. En déduire que $S(X) = (\min_i X_i, \max_i X_i)$ n'est pas complète.

Exercice 2.2. On considère un modèle dans lequel l'observation X est de la forme $X = a(Y - Z)$ avec $Y \sim \mathrm{Exp}(\lambda)$ et $Z \sim \mathrm{Exp}(\mu)$ indépendantes, $\lambda, \mu > 0$ inconnus.

On suppose d'abord a connu et $a = 1$.

1. Quels sont ici les paramètres du modèle ?
2. En posant $b = 1/\lambda$ et $c = 1/\mu$, trouver deux équations satisfaites par b et c. En raisonnant sur ces équations, montrer que le modèle est identifiable.

Supposons à présent que a est inconnu dans $\mathbb{R}$.

3. En raisonnant sur la transformation $(Y, Z) \mapsto (Z, Y)$, montrer que le modèle n'est pas identifiable.

Supposons finalement que a est inconnu dans $\mathbb{R}_+$. L'argument précédent ne tient plus.

4. Montrer que si $Y \sim \mathrm{Exp}(\lambda)$ et $\alpha > 0$, $Y \sim \mathrm{Exp}(\lambda/\alpha)$.
5. En déduire que le modèle n'est pas identifiable.

Exercice 2.3. On considère le modèle où $(X_1, \ldots, X_n)$ sont i.i.d. avec densité $x \mapsto C(\theta)\, x \mathbb{1}_{[0,\theta]}(x)$ pour un certain paramètre $\theta > 0$.

1. Trouver la valeur de $C(\theta)$ pour tout $\theta > 0$.
2. Trouver la densité de X_1/θ.
3. On trie les X_i par ordre croissant : $X_{(1)} \leq \ldots \leq X_{(n)}$ sont appelées les statistiques d'ordre de l'échantillon. Montrer que $X_{(n)}$ et $X_{(1)}/X_{(n)}$ sont indépendantes. *On utilisera le théorème de Basu, après avoir montré que $X_{(1)}/X_{(n)}$ est auxiliaire à l'aide de la question précédente.*

Exercice 2.4 (Identifier une direction causale, $\star$)**.** On considère un modèle avec deux variables aléatoires X_1, X_2. On dit que X_1 *cause* X_2 si la loi du modèle est de la forme suivante :

$$X_1 = U_1 \quad X_2 = f(X_1, U_2),$$

où U_1 et U_2 sont des bruits indépendants et f est une fonction mesurable.

Une question fondamentale est la suivante : *en général, peut-on inférer quoi que ce soit sur la direction du lien causal entre X_1 et X_2 en observant quelques réalisations ?*

L'objectif de cet exercice est de répondre à la négative via un contre-exemple à ce fait. On considère le modèle

$$X_1 = U_1 \quad X_2 = X_1 + U_2,$$

où U_1 et U_2 sont des variables i.i.d. de loi $\mathrm{Exp}(1)$. Montrer qu'il existe un modèle causal inversé de la forme

$$X_2 = U_2' \quad X_1 = h(X_2, U_1'),$$

où U_1' et U_2' sont indépendants, et qui préserve la loi jointe de (X_1, X_2).

Exercice 2.5. On observe une réalisation de $G \sim G(n,p)$, c'est-à-dire un graphe aléatoire à n sommets (n est connu) dont chaque arête est présente indépendamment avec probabilité $p \in [0,1]$ inconnu. Trouver une statistique suffisante et complète. Interpréter.

Exercice 2.6. On considère le modèle $(\mathbb{R}, \mathcal{B}(\mathbb{R}), (\mathrm{Unif}([0,\theta]))_{\theta \geq 0})$. Trouver une mesure dominante minimale pour ce modèle.

Exercice 2.7 ($\star$)**.** Reprendre l'exemple du modèle uniforme i.i.d. du cours. Montrer que $S(X) = \max_i(X_i)$ est suffisante sans utiliser le théorème de Neyman-Fisher, en donnant la distribution de X sachant $S(X)$. Interpréter la forme de cette distribution.

3. Estimation paramétrique

Dans ces exercices, l'abbréviation UVMB désigne "uniformément de variance minimale et sans biais".

Exercice 3.1 (Deux estimateurs dans le modèle i.i.d. uniforme)**.** On considère le modèle où $X_1, \dots, X_n$ sont i.i.d. de loi $\mathrm{Unif}([0,\theta])$, avec $\theta > 0$ inconnu.

1. Trouver un estimateur $\hat{\theta}_1$ de θ en utilisant la méthode des moments appliquée au premier moment.
2. Déterminer la vraisemblance dans ce modèle et montrer qu'il existe un estimateur du maximum de vraisemblance unique $\hat{\theta}_2$. Trouver son expression.
3. Calculer le biais, la variance et le risque quadratique de $\hat{\theta}_1$.
4. Calculer la densité de $\hat{\theta}_2$. En déduire son biais, sa variance et son risque quadratique.
5. Quel est le meilleur estimateur pour n assez grand ? Y a-t-il une grande différence ?

Exercice 3.2 (Information de Fisher dans un modèle linéaire à deux paramètres)**.** On considère le modèle statistique où $X_1, \dots, X_n$ sont des variables réelles indépendantes, avec pour tout $1 \leq i \leq n$, $X_i \sim \mathcal{N}(\alpha + \beta t_i, 1)$, où les $(t_i)_{1 \leq i \leq n}$ sont des réels *connus* et $\alpha, \beta \in \mathbb{R}$ sont des paramètres *inconnus*. On admettra que ce modèle est régulier.

1. Déterminer une condition nécessaire et suffisante sur les $(t_i)_{1 \leq i \leq n}$ pour que ce modèle soit identifiable.
2. Montrer que la matrice d'information de Fisher $I(\alpha, \beta)$ s'écrit
$$I(\alpha, \beta) = \begin{pmatrix} n & \sum_{i=1}^n t_i \\ \sum_{i=1}^n t_i & \sum_{i=1}^n t_i^2 \end{pmatrix}.$$
3. Déterminer une condition nécessaire et suffisante sur les $(t_i)_{1 \leq i \leq n}$ pour que $I(\alpha, \beta)$ soit inversible. Que remarque-t-on ?

Exercice 3.3 (Un modèle autorégressif)**.** Nous considérons un modèle avec $(X_1, \dots, X_n)$ tels que $X_1 = \theta + Z_1$, et récursivement, $X_{j+1} = \rho(X_j - \theta) + \theta + Z_{j+1}$ avec les Z_j i.i.d. de loi $\mathcal{N}(0, \sigma^2)$. Nous supposons que $\rho \in [0,1]$ est un paramètre connu, et que $\theta \in \mathbb{R}$ et $\sigma^2 > 0$ sont inconnus. On admettra la régularité de ce modèle.

1. Calculer la matrice d'information de Fisher $I(\theta, \sigma^2)$ en fonction de θ, σ^2, ρ et n.
2. Donner une borne inférieure pour la variance d'un estimateur sans biais et lisse de θ. Commenter et interpréter les valeurs de cette borne lorsque $\rho = 0$, et lorsque $\rho = 1$.

Exercice 3.4 (Une Rao-Blackwellisation)**.** On considère le modèle où $X_1, \dots, X_n$ sont i.i.d. de loi[1] $\mathrm{Poi}(\lambda)$, avec $\lambda > 0$ inconnu. On souhaite estimer $\varphi(\lambda) = e^{-\lambda}$.

1. Montrer que $T(X) = \mathbb{1}_{X_1 = 0}$ est un estimateur sans biais de $\varphi(\lambda)$. Calculer sa variance. Est-ce un bon estimateur ?
2. Prouver que $S(X) = \sum_{i=1}^n X_i$ est une statistique complète et suffisante pour le modèle. *On pourra utiliser sans démonstration que si* $Y_1 \sim \mathrm{Poi}(\lambda_1)$ *et* $Y_2 \sim \mathrm{Poi}(\lambda_2)$ *sont indépendants, alors* $Y_1 + Y_2 \sim \mathrm{Poi}(\lambda_1 + \lambda_2)$.

[1] rappel : c'est la loi telle que pour tout $k \in \mathbb{N}$, $\mathbb{P}(X = k) = e^{-\lambda} \frac{\lambda^k}{k!}$.

3. Calculer l'estimateur Rao-Blackwellisé T^* de T par S, et montrer que T^* est UVMB[2] pour l'estimation de $\varphi(\lambda)$.

4. Montrer que T^* est UVMB et qu'il est asymptotiquement efficace.

5. Montrer que T^* est fortement consistant.

6. ($\star$, car un peu technique) Montrer que T^* est asymptotiquement normal en précisant les paramètres asymptotiques.

Exercice 3.5 (Information de Fisher et identifiabilité locale)**.** Soit $\mathcal{M} = (\mathcal{X}, \mathcal{F}, (\mathbb{P}_\theta)_{\theta\in\Theta})$ modèle paramétrique avec $\Theta \subseteq \mathbb{R}^p$. On dit que $\mathcal{M}$ est *localement identifiable* en $\theta \in \Theta$ si il existe un voisinage U de θ dans Θ tel que

$$\forall \theta' \in U, (\mathbb{P}_{\theta'} = \mathbb{P}_\theta) \implies \theta = \theta' .$$

On suppose que le modèle est régulier. On fait une hypothèse supplémentaire, un peu plus forte que la régularité du cours :

(H1) la log-vraisemblance ℓ est deux fois différentiable en θ sur Θ, et ses dérivées secondes sont localement dominées uniformément en θ.

(H2) la Hessienne $\theta \mapsto \nabla^2\ell(\theta, x)$ est localement Lispchitz, uniformément en x au sens ou pour tout $\theta \in \Theta$, il existe V voisinage de θ, $C_\theta > 0$ tels que pour tous $\theta' \in V$, $x \in \mathcal{X}$,

$$-C_\theta\|\theta' - \theta\| \preceq \nabla^2\ell(\theta', x) - \nabla^2\ell(\theta, x) \preceq C_\theta\|\theta' - \theta\| .$$

Le but de cet exercice est de démontrer que sous (H1), si l'information de Fisher $I(\theta)$ est inversible en θ, alors le modèle est localement identifiable en θ.

1. Montrer que sous (H1), pour tout $\theta \in \Theta$,

$$I(\theta) = -\mathbb{E}_\theta[\nabla^2\ell(\theta, X)] .$$

2. Montrer que pour $\theta \in \Theta$ et $v \in \mathbb{R}^p$ assez petit, un développement de Taylor de $\ell(\theta+v, x)$ autour de $\ell(\theta, x)$ donne

$$\ell(\theta + v, x) = \ell(\theta, x) + v^T\nabla_\theta\ell(\theta, x) + \frac{1}{2}v^T\nabla^2_\theta\ell(\theta, x)v + R(v, \theta, x),$$

avec

$$R(v, \theta, x) = \frac{1}{2}\int_0^1 (1 - t)v^\top(\nabla^2_\theta\ell(\theta + tv, x) - \nabla^2_\theta\ell(\theta, x))v\, dt.$$

Pour $\theta, \theta' \in \Theta$, on définit la divergence de Kullback-Leibler entre $\mathbb{P}_\theta$ et $\mathbb{P}_{\theta'}$ par:

$$\mathrm{KL}(\mathbb{P}_\theta\|\mathbb{P}_{\theta'}) := \mathbb{E}_\theta\left[\ell(\theta, X) - \ell(\theta', X)\right] .$$

3. Soit $\theta \in \Theta$. Montrer qu'avec ce qui précède, pour v tel que $\|v\|$ est assez petit,

$$\mathrm{KL}(\mathbb{P}_\theta\|\mathbb{P}_{\theta+v}) = v^T I(\theta)v + o(\|v\|^2),$$

où $o(\|v\|^2)$ est une fonction de la forme $\|v\|^2\varepsilon(v)$ tel que $\varepsilon(v) \to 0$ quand $v \to 0$. *On justifiera également que le membre de gauche est bien défini pour v assez petit.*

4. Conclure.

[2] UVMB : sans biais et uniformément de variance minimale.

5. ($\star$) On se place dans le modèle ou l'on observe X qui a pour loi $\mathcal{N}(a,1)$ avec probabilité $1/2$, et $\mathcal{N}(b,1)$ avec probabilité $1/2$. On se place dans l'espace des paramètres $\Theta = \mathbb{R}^2 \backslash \{(a,a), a \in \mathbb{R}\}$. On admet que ce modèle est régulier. Montrer que $I(\theta)$ est inversible en tout point de Θ, mais que le modèle n'est pas identifiable globalement (c'est-à-dire au sens du cours).

Exercice 3.6 (Lois de puissance)**.** La loi de puissance de paramètre $\alpha > 1$, notée $\mathrm{Pow}(\alpha)$ ci-après, a pour densité de Lebesgue $f_\alpha : x \mapsto C_\alpha x^{-\alpha} \mathbb{1}_{[1,\infty)}(x)$, où C_α est une constante. On observe $X_1, \ldots, X_n$ i.i.d. $\sim \mathrm{Pow}(\alpha)$ où $\alpha > 1$ est inconnu.

1. Calculer C_α pour tout $\alpha > 1$.
2. Pour $X \sim \mathrm{Pow}(\alpha)$, X a-t-il une espérance finie ? Une variance finie ? Si oui, les donner.
3. Si $\alpha > 2$, en utilisant le premier moment, fournir un estimateur $\widehat{\alpha}_1$ de α. Montrer que $\widehat{\alpha}_1$ est fortement consistant.
4. Montrer que l'estimateur du maximum de vraisemblance $\widehat{\alpha}_2$ est donné par :
$$\widehat{\alpha}_2 = 1 + \left(\frac{1}{n} \sum_{i=1}^{n} \log X_i \right)^{-1}.$$
Montrer que $\widehat{\alpha}_2$ est également consistant. *Indice : on peut étudier la distribution de* $\log X_1$ *quand* $X_1 \sim Pow(\alpha)$.
5. Montrer que $\widehat{\alpha}_2$ est asymptotiquement normal, et donner les caractéristiques de la loi limite. Faire de même pour $\widehat{\alpha}_2$ sous une hypothèse appropriée sur α.
6. Sur la base des résultats précédents, quel estimateur préféreriez-vous pour n grand ?
7. Déterminer l'information de Fisher $I(\alpha)$. Comparer avec les résultats précédents. Que pouvez-vous en conclure ?

Exercice 3.7 (Non-existence d'un UVMB)**.** L'objet de cet exercice est l'étude d'un exemple où des estimateurs sans biais existent, mais où il n'existe pas d'estimateur sans biais de variance uniformément minimale (UVMB). Soit X prenant ses valeurs dans $\{-1, 0, 1, 2, \ldots\}$ avec la distribution suivante de paramètre $p \in (0,1)$: $\mathbb{P}_p(X = -1) = p$, $\mathbb{P}_p(X = k) = (1-p)^2 p^k$, $k = 0, 1, 2, \ldots$ On cherche à estimer p.

1. Montrer que $\mathbb{1}_{\{X=-1\}}$ est un estimateur sans biais de p.
2. Montrer que la classe de tous les estimateurs sans biais de p est un espace affine de dimension 1 que vous décrirez.
3. Pour $p \in (0,1)$, trouver T estimateur non biaisé de p qui minimise $\mathrm{Var}_p(T)$. *On donne, pour* $|p| < 1$,
$$\sum_{k=0}^{+\infty} k^2 p^k = \frac{p(1+p)}{(1-p)^3}.$$
4. Conclure qu'il n'existe pas d'UVMB pour p.

Exercice 3.8 (Fonctions estimables sans biais)**.** On travaille dans un modèle paramétrique et l'on note $\mathcal{U}$ l'ensemble des fonctions de θ à valeurs dans $\mathbb{R}^\ell$ qui sont estimables sans biais, c'est-à-dire
$$\mathcal{U} := \left\{ \varphi : \Theta \to \mathbb{R}^\ell, \exists T : \mathcal{X} \to \mathbb{R}^\ell \text{ mesurable, intégrable, t.q.}, \forall \theta \in \Theta, \mathbb{E}_\theta[T(X)] = \varphi(\theta) \right\}.$$

1. Montrer que $\mathcal{U}$ est un sous-espace vectoriel du $\mathbb{R}-$espace vectoriel des fonctions de Θ dans $\mathbb{R}^\ell$.

2. Montrer que si $\mathcal{X}$ est fini, alors $\dim \mathcal{U} \leq |\mathcal{X}|$.

Dans toute la fin de l'exercice, on se place dans le modèle à une seule observation $X \sim \mathrm{Unif}([0,\theta])$, avec $\theta > 0$ inconnu. On considère le cas $\ell = 1$.

3. ($\star$) Montrer que
$$\mathcal{U} = \left\{\varphi : \mathbb{R}_+^* \to \mathbb{R}, \varphi \text{ absolument continue}\right\}.$$
on pourra utiliser le théorème fondamental du calcul intégral (de Lebesgue): pour $f : [a,b] \to \mathbb{R}$ Lebesgue-intégrable sur $[a,b]$ et $F : x \mapsto \int_a^x f(t)\,dt$, F est absolument continue donc dérivable presque partout sur $[a,b]$ et, pour presque tout $x \in [a,b]$, $F'(x) = f(x)$.

4. Intervalles et régions de confiance

Exercice 4.1 (Intervalles de confiance dans le modèle i.i.d. uniforme)**.** On se place dans le modèle où $(X_n)_{n\geq 1}$ sont i.i.d. de loi $\mathrm{Unif}([0,\theta])$, avec $\theta > 0$ inconnu. Pour tout $n \geq 1$, on définit $M_n := \max(X_1, \dots, X_n)$.

1. Montrer que pour tout $n \geq 1$, $h_n(X,\theta) := \left(\frac{M_n}{\theta}\right)^n$ est pivotale.

2. Soit $\alpha \in]0,1[$. Déduire de ce qui précède un intervalle de confiance $I^{(1)}_{\alpha,n}$ de probabilité de couverture $1-\alpha$ pour θ basé sur M_n.

3. Trouver un équivalent presque sûr du diamètre de $I^{(1)}_{\alpha,n}$ lorsque $n \to \infty$, à $\alpha \in]0,1[$ fixé. *On pourra réutiliser le fait que $M_n \to \theta$ $\mathcal{M}-p.s.$*

4. Montrer que sous $\mathbb{P}_\theta$,
$$n(1 - M_n/\theta) \xrightarrow[n\to\infty]{(d)} \mathrm{Exp}(1).$$

5. Calculer *explicitement* la fonction quantile de la loi $\mathrm{Exp}(1)$.

6. Déduire des deux questions précédentes un intervalle de confiance asymptotique $I^{(2)}_{\alpha,n}$ de probabilité de couverture $1-\alpha$ pour θ, basé sur M_n.

7. Trouver un équivalent presque sûr du diamètre de $I^{(2)}_{\alpha,n}$ lorsque $n \to \infty$, à $\alpha \in]0,1[$ fixé. Comparer avec le résultat de la question 3.

Exercice 4.2 (Concentration et intervalles de confiance dans le modèle de Poisson)**.** On suppose que les $(X_n)_{n\geq 1}$ sont i.i.d. $\mathrm{Poi}(\lambda)$ avec $\lambda > 0$.

1. En utilisant l'inégalité de Bienaymé-Tchebychev, dérivez un intervalle de confiance (non asymptotique) pour λ avec une probabilité de couverture $1-\alpha$.

2. En utilisant le théorème central limite, trouvez un intervalle de confiance asymptotique pour λ avec une probabilité de couverture $1-\alpha$.

Exercice 4.3 (Ellipsoïdes contre Bonferroni)**.** Nous reprenons l'exemple du cours du modèle gaussien i.i.d. dans $\mathbb{R}^p$ avec $X_1, \dots X_n$ i.i.d. $\mathcal{N}(\mu, \Sigma^2)$. On suppose Σ connu. On a défini deux régions de confiances données par

$$C^{(1)}_\alpha(X) = \prod_{j=1}^{p} \left[[\bar{X}_n]_j \pm \frac{\sqrt{\Sigma_{jj}}\, z_{1-\frac{\alpha}{2p}}}{\sqrt{n}} \right],$$

et

$$C^{(2)}_\alpha(X) = \left\{ \mu \in \mathbb{R}^p : n(\bar{X}_n - \mu)^T \Sigma^{-1} (\bar{X}_n - \mu) \leq q^{(p)}_{1-\alpha} \right\}.$$

On rappelle que z_β (resp. $q^{(p)}_\beta$) désigne le quantile d'ordre $\beta \in]0,1[$ de la distribution $\mathcal{N}(0,1)$ (resp. $\chi^2(p)$). Le but de cet exercice est de comparer les volumes de ces deux régions de confiance, lorsque p grandit.

On note Φ la fonction de répartition d'une loi normale standard, et on admettra que

$$1 - \Phi(x) \underset{x\to+\infty}{\sim} \frac{1}{\sqrt{2\pi}x} e^{-x^2/2}.$$

1. Montrer que lorsque $\beta \to 0$,
$$z_{1-\beta} \sim \sqrt{2\log(1/\beta)}.$$

2. En utilisant le théorème central limite, montrer que pour $\alpha \in]0,1[$ fixé, lorsque $p \to +\infty$,

$$q_{1-\alpha}^{(p)} = p + \sqrt{2p} z_{1-\alpha} + o(\sqrt{p})\,.$$

On note Leb la mesure de Lebesgue dans $\mathbb{R}^p$. On donne la formule suivante, qui résulte d'un changement de variable en intégration. Pour $\mathcal{E}$ une ellipsoide définie par

$$\mathcal{E} := \left\{ y \in \mathbb{R}^p,\ (y-y_0)^T M^{-1} (y-y_0) \leq 1, \right\}$$

avec $M \in \mathbb{R}^{p\times p}$ symétrique définie positive, $\mathrm{Leb}(\mathcal{E}) = \sqrt{\det M} \times V_p$, où V_p est le volume de la boule unité dans $\mathbb{R}^p$, donné par $V_p = \frac{\pi^{p/2}}{\Gamma(p/2+1)}$.

3. Prenons $\alpha \in]0,1[$ fixé. Montrer que

$$\frac{\mathrm{Leb}(C_\alpha^{(2)}(X))}{\mathrm{Leb}(C_\alpha^{(1)}(X))} = \frac{\pi^{p/2}\sqrt{\det(\Sigma)}(q_{1-\alpha}^{(p)})^{p/2}}{\Gamma(p/2+1)\prod_{j=1}^p \sqrt{\Sigma_{jj}}\left(2z_{1-\alpha/(2p)}\right)^p}$$

4. En déduire que lorsque $p \to +\infty$,

$$\log \frac{\mathrm{Leb}(C_\alpha^{(2)}(X))}{\mathrm{Leb}(C_\alpha^{(1)}(X))} \leq -(1+o(1))\frac{p}{2}\log\log p\,.$$

   Commenter.

Exercice 4.4 (Quantile et optimisation)**.** Soit X une variable aléatoire réelle intégrable de fonction de répartition F. On fixe $\alpha \in]0,1[$. On considère la fonction ψ définie sur $\mathbb{R}$ par

$$\psi_\alpha : t \mapsto \mathbb{E}\left[\alpha(X-t)_+ + (1-\alpha)(t-X)_+\right],$$

où $(x)_+ = \max(x,0)$.

1. Montrer que la fonction ψ_α est bien définie, continue et convexe sur $\mathbb{R}$.
2. Montrer que ψ_α est coercive, i.e. que

$$\psi_\alpha(t) \underset{t\to\pm\infty}{\longrightarrow} +\infty\,.$$

3. En déduire que ψ_α admet au moins un minimiseur, et que tout minimiseur u de ψ_α vérifie :

$$F(u) \geq \alpha \quad \text{et} \quad F(u^-) \leq \alpha,$$

   où $F(u^-)$ désigne la limite à gauche de F en u.
4. Comment relier le quantile q_α à l'ensemble des minimiseurs de ψ_α ?

5. Tests d'hypothèses

Exercice 5.1 (Test du temps d'attente du RER B)**.** Nous analysons le temps d'attente du train RER B à la station Orsay-Ville, dont on soupçonne qu'il est supérieur à 5 minutes en espérance. Soit X la variable aléatoire modélisant le temps d'attente en minutes. Il est courant de supposer que $X \sim \mathrm{Exp}(1/\theta)$, où $\theta > 0$ représente le temps d'attente moyen (on rappelle que $\mathbb{E}_\theta[X] = \theta$).

Nous voulons tester si $\theta = 5$ afin de vérifier notre soupçon. Pour cela, nous répétons l'expérience n fois indépendamment et nous notons les temps d'attente obtenus $(X_1, \ldots, X_n)$. Pour $n = 10$, les temps d'attente observés sont :

$$(4, 10, 3, 8, 7, 12, 9, 11, 6, 2).$$

Soit q_α le quantile d'ordre α de la loi Binomiale $\mathrm{Bin}(10, 1/e)$. On donne $q_{0.025} = 1$, $q_{0.95} = 6$, et $q_{0.975} = 7$. Nous notons $S(X) := \sum_{i=1}^n \mathbb{1}_{X_i > 5}$.

1. Proposer un test de niveau $\alpha = 0.05$ pour $\mathcal{H}_0 : \theta \leq 5$ contre $\mathcal{H}_1 : \theta > 5$ basé sur la statistique $S(X)$. Quelle est la décision du test avec nos données ?
2. Proposer un test de niveau $\alpha = 0.05$ pour $\mathcal{H}_0 : \theta = 5$ contre $\mathcal{H}_1 : \theta \neq 5$ basé sur la statistique $S(X)$. Quelle est la décision du test avec nos données ?
3. Discuter les résultats obtenus aux questions précédentes.

Exercice 5.2 (Test du rapport de vraisemblance dans le modèle uniforme)**.** Nous considérons le modèle où $X_1, \ldots, X_n$ sont i.i.d. uniformément distribuées sur $[0, \theta]$. Nous cherchons à tester :

$$\mathcal{H}_0 : \theta = \theta_0 \quad \text{contre} \quad \mathcal{H}_1 : \theta \neq \theta_0.$$

1. Calculer la statistique du rapport de vraisemblance associée à ce test. Nous adoptons la convention que $\frac{1}{0} = +\infty$.
2. Soit $\alpha \in]0, 1[$. Montrer que le test du rapport de vraisemblance de niveau α pour $\mathcal{H}_0$ contre $\mathcal{H}_1$ s'écrit $\psi(X) = \mathbb{1}_{\max X_i < \tau_0} + \mathbb{1}_{\max X_i > \tau_1}$, pour $\tau_0 < \tau_1$ que l'on précisera.
3. En utilisant la dualité entre tests d'hypothèses et régions de confiance, déduire une région de confiance pour θ de niveau $1 - \alpha$. Vérifier que l'on retrouve l'intervalle de confiance établi dans un exercice précédent.

Exercice 5.3 (Test optimal pour la loi exponentielle)**.** Soient $X_1, \ldots, X_n$ des variables aléatoires i.i.d. de loi exponentielle de paramètre[3] $\lambda > 0$. On souhaite tester les hypothèses simples $\mathcal{H}_0 : \lambda = \lambda_0$ contre $\mathcal{H}_1 : \lambda = \lambda_1$ avec $\lambda_1 > \lambda_0$.

On donne la propriété suivante : la somme de n variables aléatoires indépendantes de loi exponentielle de paramètre $\lambda = 1$ suit une loi Gamma $\Gamma(n, 1)$, dont on notera $\gamma_{n,\beta}$ le quantile d'ordre β.

1. Déterminer un test uniformément plus puissant de niveau $\alpha \in]0, 1[$ (UPP(α)) pour ce problème (on montrera qu'il est p.p. unique). Montrer que c'est le test dont la région de rejet peut s'écrire
$$\mathcal{R} = \left\{ \sum_{i=1}^n X_i < u \right\},$$
où u est une constante dépendant a priori de $\lambda_0, \lambda_1, \alpha$ et n, dont on ne demande pas l'expression dans cette question. hhhh

[3] on rappelle que c'est loi à densité $x \mapsto \mathbb{1}_{x \geq 0} \lambda e^{-\lambda x}$.

2. Montrer que sous $\mathcal{H}_0$, $\lambda_0 X_1 \sim \mathrm{Exp}(1)$. En déduire la valeur de u en fonction de $\lambda_0, \lambda_1, \alpha$ et n.

3. On notera F_n la fonction de répartition de la loi $\Gamma(n,1)$. Exprimer la puissance $\pi(\lambda_1)$ du test précédent pour toute valeur de $\lambda_1 > \lambda_0$, en fonction de F_n. Commenter sa monotonie en λ_1.

4. Montrer (à la main) que le test de la question précédente est en fait $\mathrm{UPP}(\alpha)$ pour tester $\mathcal{H}_0 : \lambda = \lambda_0$ contre $\mathcal{H}_1' : \lambda > \lambda_0$.

Exercice 5.4 (Tests UPP dans le cas où le rapport de vraisemblance est monotone)**.** Dans cet exercice, on montre une extension du théorème de Neyman-Pearson au cas où le rapport de vraisemblance est monotone.

On se place dans le cadre du cours où $\mathcal{M}$ est un modèle où la vraisemblance $L(\theta, X)$ est bien définie. Soit $\preceq$ une relation d'ordre sur Θ. On suppose qu'il existe une statistique $T(X)$ à valeurs réelles, telle que pour tous $\theta, \theta' \in \Theta$ vérifiant $\theta \preceq \theta'$, il existe $A_{\theta,\theta'} : \mathbb{R} \to \mathbb{R}_+ \cup \{+\infty\}$ croissante[4] telle que

$$\forall x \in \mathcal{X},\ \frac{L(\theta', x)}{L(\theta, x)} = A_{\theta,\theta'}(T(x)),$$

avec la convention $1/0 = +\infty$. On dit que le modèle est *à rapport de vraisemblance monotone.*

Pour $t \in \mathbb{R}, c \in [0,1]$, on note $\psi_{t,c}$ le test randomisé :

$$\psi_{t,c}(X) = \mathbb{1}_{T(X)>t} + c\mathbb{1}_{T(X)=t},$$

Soient $t \in \mathbb{R}, c \in [0,1]$. On se donne d'abord θ dans Θ, tel que $0 < \mathbb{E}_\theta[\psi_{t,c}(X)] < 1$, ainsi que $\theta' \succeq \theta$.

1. Montrer que $\lambda := A_{\theta,\theta'}(t)$ est fini. *On montrera que l'ensemble* $\{x : L(\theta, x) > 0\} \cap \{x : T(x) \geq t\}$ *est non vide en utilisant que* $\mathbb{E}_\theta[\psi_{t,c}(X)] > 0$.

2. Déduire de la question précédente que $\psi_{t,c}$ défini précédemment est $\mathrm{UPP}(\mathbb{E}_\theta[\psi_{t,c}(X)])$ pour $\mathcal{H}_0 : \theta = \theta$ contre $\mathcal{H}_1 : \theta = \theta'$. *On montrera que* $\psi_{t,c} \in \mathrm{NP}(\mathbb{P}_\theta, \mathbb{P}_{\theta'})$.

Dans la suite, fixons $\alpha \in]0,1[$ et $\theta_0 \in \Theta$.

3. Montrer qu'il existe $t \in \mathbb{R}, c \in [0,1]$ tel que $\mathbb{E}_{\theta_0}[\psi_{t,c}(X)] = \alpha$. *On raisonnera exactement comme dans la preuve du théorème de Neyman-Pearson, en considérant un bon quantile de* T.

4. Montrer que $\psi_{t,c}$ défini précédemment est $\mathrm{UPP}(\alpha)$ pour $\mathcal{H}_0 : \theta = \theta_0$ contre $\mathcal{H}_1 : \theta \succ \theta_0$.

5. Montrer enfin que la fonction $\theta \mapsto \mathbb{E}_\theta[\psi_{t,c}(X)]$ est croissante (au sens de l'ordre $\preceq$ sur Θ et de l'ordre usuel sur $\mathbb{R}$). *On pourra appliquer les questions 1 et 2.* En déduire que $\psi_{t,c}$ est $\mathrm{UPP}(\alpha)$ pour $\mathcal{H}_0 : \theta \preceq \theta_0$ contre $\mathcal{H}_1 : \theta \succ \theta_0$. C'est le *Théorème de Karlin-Rubin.*

6. *Application.* Considérons le modèle i.i.d. uniforme sur $[0, \theta]$, avec $\theta \geq 0$. Soit $\theta_0 > 0$. Construire un test uniformément plus puissant de niveau $\alpha \in]0,1[$ pour $\mathcal{H}_0 : \theta \leq \theta_0$ contre $\mathcal{H}_1 : \theta > \theta_0$.

Exercice 5.5 (Test de variance symétrique à deux échantillons)**.** *On admettra dans cet exercice que si* Z_1, Z_2 *sont deux variables i.i.d. gaussiennes standard, alors* Z_1/Z_2 *suit une loi de Cauchy de densité sur* $\mathbb{R}$ *donnée par* $x \mapsto \frac{1}{\pi(1+x^2)}$.

[4] ou décroissante, quitte à changer T en $-T$. C'est la monotonie qui est importante ici, pas le sens de variation.

On travaille avec deux échantillons indépendants, X_1 et X_2. On suppose que $0 < \sigma_1^2 < \sigma_2^2$, et on souhaite tester

$$\mathcal{H}_0 : X_1 \sim \mathcal{N}(0, \sigma_1^2),\ X_2 \sim \mathcal{N}(0, \sigma_2^2) \quad \text{vs.} \quad \mathcal{H}_1 : X_1 \sim \mathcal{N}(0, \sigma_2^2),\ X_2 \sim \mathcal{N}(0, \sigma_1^2)\,.$$

On souhaite travailler avec des tests symétriques ψ, tels que $\psi(x_1, x_2) = 1 - \psi(x_2, x_1)$ presque partout.

1. Montrer que si ψ est un test symétrique de taille α et de puissance $1 - \beta$ pour ce problème, alors $\alpha = 1 - \beta$.

2. Écrire le rapport de vraisemblance T, et construire un estimateur symétrique ψ_0 basé sur T pour ce problème.

3. Montrer que le niveau α_{ψ_0} et la puissance $1 - \beta_{\psi_0}$ de ψ_0 vérifient :

$$\alpha_{\psi_0} = 1 - \beta_{\psi_0} = \frac{2}{\pi} \tan^{-1}\left(\frac{\sigma_1}{\sigma_2}\right)\,.$$

Exercice 5.6 (Test de variance à deux échantillons, bis)**.** On se place dans le modèle de l'exercice précédent. On suppose que $0 < \sigma_1^2 < \sigma_2^2$, et on souhaite tester

$$\mathcal{H}_0 : X_1 \sim \mathcal{N}(0, \sigma_1^2),\ X_2 \sim \mathcal{N}(0, \sigma_2^2) \quad \text{vs.} \quad \mathcal{H}_1 : X_1 \sim \mathcal{N}(0, \sigma_2^2),\ X_2 \sim \mathcal{N}(0, \sigma_1^2)\,.$$

Calculer

$$\mathrm{TV}\left(\mathcal{N}\left(0, \begin{pmatrix} \sigma_1^2 & 0 \\ 0 & \sigma_2^2 \end{pmatrix}\right), \mathcal{N}\left(0, \begin{pmatrix} \sigma_2^2 & 0 \\ 0 & \sigma_1^2 \end{pmatrix}\right)\right)$$

et en déduire la valeur minimale de $\alpha_\psi + \beta_\psi$ pour tout test ψ. Comparer avec le test ψ_0 trouvé dans l'exercice précédent.

Exercice 5.7 (p-valeurs)**.** Supposons que nous ayons une famille de tests $(\psi_\alpha)_{\alpha \in [0,1]}$ telle que chaque ψ_α est de niveau α. Une telle famille est dite *emboîtée* si, de plus, pour presque tout $x \in \mathcal{X}$, $\psi_\alpha(x)$ est une fonction non décroissante de α. En présence d'une famille emboîtée de tests, on peut définir la *p-valeur* p comme suit :

$$\mathrm{p}(X) := \inf\{\alpha \in [0,1], \psi_\alpha(X) = 1\}\,.$$

Supposons maintenant que nous soyons dans un modèle paramétrique, où l'on teste $\mathcal{H}_0 : \theta \leq \theta_0$ contre $\mathcal{H}_1 : \theta > \theta_0$ et que les densités des données X possèdent un rapport de vraisemblance monotone dans la statistique T (cf exercice 5.4). On suppose que T admet une loi continue.

1. Montrer que la famille des tests uniformément les plus puissants (pour tous les niveaux $\alpha \in]0,1[$) est emboîtée au sens ci-dessus.

2. Montrer que la p-valeur s'écrit

$$\forall x \in \mathcal{X},\ \mathrm{p}(x) = \mathbb{P}_{\theta_0}(T(X) > T(x))\,.$$

3. Trouver la loi de la p-valeur $\mathrm{p}(X)$ lorsque $\theta = \theta_0$.

6. Modèle linéaire et modèle linéaire gaussien

Exercice 6.1 (La fonction de régression passe-t-elle par le barycentre?)**.** On considère un modèle linéaire $Y = X\theta + \varepsilon$. On cherche une condition nécessaire et suffisante pour que la fonction de régression $f : x \in \mathbb{R}^p \mapsto \langle x, \theta_{MC} \rangle$ vérifie $f(\bar{x}) = \bar{y}$, où $\bar{x} = \frac{1}{n}\sum_{i=1}^n X_{i,\cdot}$ et $\bar{y} = \frac{1}{n}\sum_{i=1}^n Y_i$.

1. Vérifier que $f(\bar{x}) = \frac{1}{n}\mathbf{1}_n^\top \Pi(Y)$, où Π désigne le projecteur orthogonal de $\mathbb{R}^n$ sur $\mathrm{Im}(X)$.
2. En déduire que $f(\bar{x}) = \bar{y}$ si et seulement si $\mathbf{1}_n \in \mathrm{Im}(X)$.
3. Comment imposer cette condition en pratique ?

Exercice 6.2 (Exemple de régression linéaire à la main)**.** On considère le modèle linéaire qui s'écrit matriciellement $Y = \theta_0 e + \theta_1 Z + \varepsilon$, avec $Y \in \mathbb{R}^n$, e le vecteur de $\mathbb{R}^n$ dont les coordonnées valent toutes 1, $Z = (z_1\, z_2\, \dots\, z_n)^\top \in \mathbb{R}^n$, et ε un bruit centré.

1. Donner une condition nécéssaire et suffisante (explicite) sur le vecteur Z pour que le modèle soit identifiable. Interpréter.
2. On se place sous la condition d'identifiabilité de la question 1. On introduit la covariance empirique entre Y et Z définie par $C_n(Y, Z) := \frac{1}{n}\sum_{i=1}^n z_i Y_i - \overline{Z}_n \overline{Y}_n$, ainsi que la variance empirique de Z, $S_n^2(Z) := \frac{1}{n}\sum_{i=1}^n z_i^2 - (\frac{1}{n}\sum_{i=1}^n z_i)^2$.

   Calculer à la main l'estimateur des moindres carrés $\hat{\theta}_{MC} = (\hat{\theta}_0, \hat{\theta}_1)^\top$. On écrira $\hat{\theta}_1$ en fonction de C_n et S_n^2, puis $\hat{\theta}_0$ en fonction de θ_0.

Exercice 6.3 (Equivalence Student/Fischer pour la nullité d'un coefficient)**.** Dans cet exercice souhaite montrer l'équivalence entre les tests de Student et de Fisher pour la nullité d'un paramètre. On considère donc le modèle linéaire Gaussien identifiable $Y = X\theta + \varepsilon$ pour lequel on veut tester la nullité du dernier coefficient θ_p.

1. Donner la statistique T du test de Student pour le test de nullité du dernier coefficient θ_p.
2. Donner la statistique F du test de Fisher pour les modèles emboîtés correspondants. On fera apparaître $\hat{\sigma}^2$ au dénominateur.
3. Soit T_d une variable suivant une loi de Student à d degrés de liberté. Rappeler sa définition et en déduire la loi suivie par la variable $F_d = T_d^2$.
4. On note la matrice du plan d'expérience sous forme de bloc $X = [X_0 \,|\, X_p]$, où $X_0 = [X_1 \,|\, \dots \,|X_{p-1}]$ est la matrice de taille $n \times (p-1)$ des $(p-1)$ premières colonnes de X, et X_p est sa dernière colonne. Ecrire la matrice $X^\top X$ sous forme de 4 blocs.
5. On donne (on on rappelle) le lemme suivant :

   Lemme. Soit A une matrice inversible s'écrivant par blocs $A = \begin{bmatrix} T & U \\ V & W \end{bmatrix}$ avec T inversible. Alors $Q = W - VT^{-1}U$ est inversible et l'inverse de A est :

   $$A^{-1} = \begin{bmatrix} T^{-1} + T^{-1}UQ^{-1}VT^{-1} & -T^{-1}UQ^{-1} \\ -Q^{-1}VT^{-1} & Q^{-1} \end{bmatrix}.$$

   Grâce à la formule d'inversion matricielle par blocs, en déduire que

   $$[(X^\top X)^{-1}]_{i,i} = (X_p^\top (I_n - \Pi_0) X_p)^{-1},$$

où Π_0 est la matrice $n \times n$ de projection orthogonale sur l'esapce engendré par les colonnes de X_0.

6. En reprenant les notations du cours $\hat{Y}$ et $\hat{Y}_0$, vérifier que $\hat{Y}_0 = \Pi_0 \hat{Y}$ puis montrer que

$$\hat{Y} - \hat{Y}_0 = (\hat{\theta}_{MC})_p (I_n - \Pi_0) X_p \,.$$

7. En déduire que dans ce cas $F = T^2$. Conclure.

Exercice 6.4 (Les eucalyptus)**.** On souhaite expliquer la hauteur y (en mètres) d'un eucalyptus en fonction de sa circonférence x (en centimètres) à 1 mètre 30 du sol, et de la racine carrée de celle-ci. On a relevé $n = 1429$ mesures de couples (x_i, y_i), le nuage de points étant représenté sur la figure 1 ci-contre.

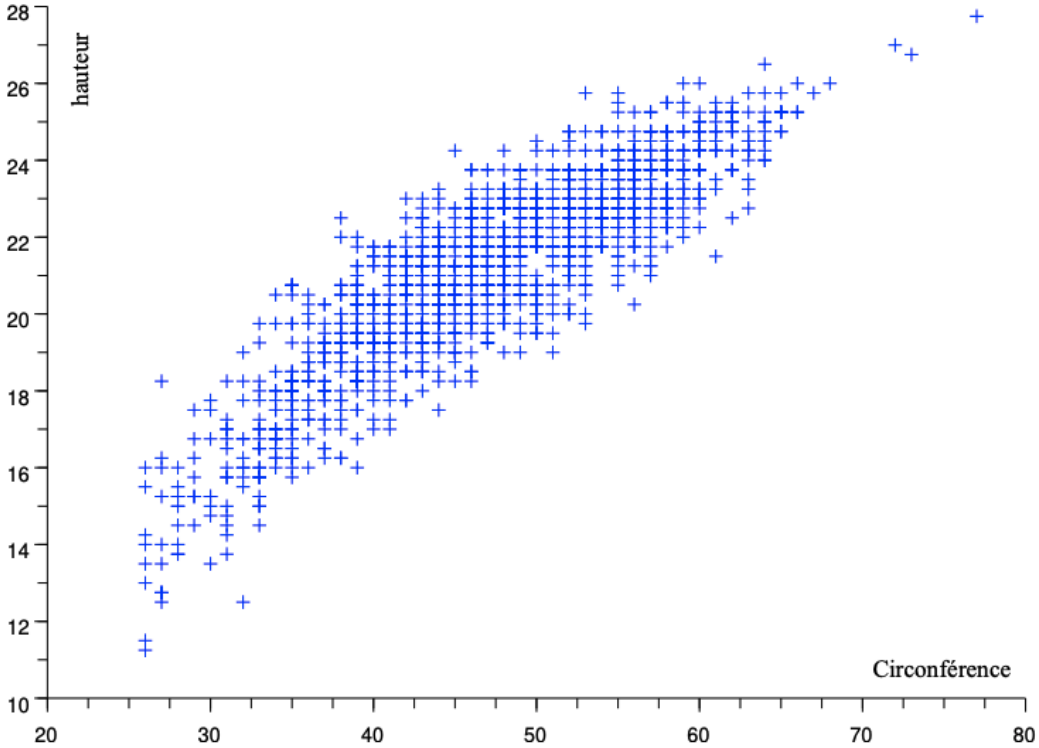

Figure 1 – *Données de hauteurs d'eucalyptus (m) en fonction de leur circonférence (cm).*

On propose donc le modèle linéaire suivant : pour tout $1 \leq i \leq n$, $Y_i = \beta_1 + \beta_2 X_i + \beta_3 \sqrt{X_i} + \varepsilon_i$, où les ε_i sont gaussiennes i.i.d. $\mathcal{N}(0, \sigma^2)$. On pose

$$X = \begin{bmatrix} 1 & x_1 & \sqrt{x_1} \\ \vdots & \vdots & \vdots \\ 1 & x_n & \sqrt{x_n} \end{bmatrix} \quad \text{et} \quad Y = \begin{bmatrix} y_1 \\ \vdots \\ y_n \end{bmatrix} .$$

Nous avons observé

$$X^{=} \begin{bmatrix} ? & ? & 9792 \\ ? & 3306000 & ? \\ ? & 471200 & 67660 \end{bmatrix}, \quad X^{=} \begin{bmatrix} 30310 \\ 1462000 \\ 209700 \end{bmatrix} \quad \text{et} \quad Y^{=} 651900.$$

1. Compléter la matrice X.

2. Que vaut la circonférence moyenne empirique $\overline{x}$?

3. Les calculs donnent en arrondissant :

$$(X^{)-1} = \begin{bmatrix} 4.646 & 0.101 & -1.379 \\ 0.101 & 0.002 & -0.030 \\ -1.379 & -0.030 & 0.411 \end{bmatrix} \quad \text{et} \quad (X^{)-1} X^\top Y = \begin{bmatrix} -16.8 \\ -0.30 \\ 7.62 \end{bmatrix}.$$

   Que valent les estimateurs $\hat{\beta}_1, \hat{\beta}_2, \hat{\beta}_3$ par la méthode des moindres carrés ? Grâce au calcul de quelques points, représenter la courbe obtenue sur la figure 1.

4. Vérifier que $Y^{\hat{\beta}=\|X\hat{\beta}\|^2}$. Calculer l'estimateur de σ^2 débiaisé et en donner une intervalle de confiance de niveau 95%. On utilisera l'approximation suivante : quand m est grand, une variable $\chi^2(m)$ est proche d'une variable $\mathcal{N}(m, 2m)$. On donne le quantile gaussien standard à 97.5% : $q = 1.96$.

5. Donner un IC(0.95) pour β_3. On approchera la loi $\mathcal{T}(m)$ par la loi $\mathcal{N}(0,1)$, quand m est grand.

6. Tester l'hypothèse $\beta_2 = 0$ au niveau de risque 10%. On fera les mêmes approximations que précédemment. On donne le quantile gaussien standard à 95% : $z_{0.95} = 1.645$. Interpréter.

Exercice 6.5 (Régression linéaire et projection dans L^2)**.** Soit $f \in L^2([0,1])$. On observe $Y_i = f(t_i) + \varepsilon_i$ aux points $t_i = \frac{i}{n}$ pour $1 \leq i \leq n$, avec ε_i bruits satisfaisant les hypothèses du modèle linéaire.

Soit $(\varphi_k)_{k\geq 0}$ une base orthonormée de $L^2([0,1])$. Pour $K \geq 0$ fixé, on suppose que f est de la forme $f = \sum_{k=0}^{K} \theta_k \varphi_k$.

1. Ecrire ce modèle sous la forme matricielle $Y = X\theta + \varepsilon$. On précisera les dimensions, et les entrée de la matrice X.

2. Montrer la convergence

$$\frac{1}{n} X^\top X \underset{n\to\infty}{\longrightarrow} I_{K+1}.$$

On note $\widehat{\theta}$ l'estimateur des moindres carrés.

3. Montrer que, pour tout $0 \leq k \leq K$,

$$\frac{1}{n} \sum_{i=1}^{n} Y_i \varphi_k(t_i) \underset{n\to\infty}{\overset{p.s.}{\longrightarrow}} \int_0^1 f(t)\varphi_k(t),$$

   et en déduire que

$$\widehat{\theta}_k \underset{n\to\infty}{\overset{p.s.}{\longrightarrow}} \int_0^1 f(t)\varphi_k(t)dt.$$

4. Interpréter ce résultat.

Exercice 6.6 (Comparaison de modèles)**.** On effectue une régression de y sur deux variables explicatives x et z à partir d'un échantillon de n individus, c'est-à-dire que $X = [\mathbf{1} \,|\, x \,|\, z]$, où $\mathbf{1}$ est le vecteur de taille n composé de 1. On a obtenu le résultat suivant :

$$X^T X = \begin{bmatrix} 5 & 3 & 0 \\ 3 & 3 & 1 \\ 0 & 1 & 1 \end{bmatrix}.$$

1. Que vaut n ?

2. Le coefficient de corrélation linéaire empirique $\hat{\rho}(a,b)$ entre deux réalisations a, b est défini par :
$$\hat{\rho}(a,b) := \frac{\sum_{i=1}^n a_i b_i - \bar{a} \times \bar{b}}{\sqrt{\sum_{i=1}^n a_i^2 - (\bar{a})^2}\sqrt{\sum_{i=1}^n b_i^2 - (\bar{b})^2}}\,.$$
Que vaut $\hat{\rho}(x,z)$?

3. La régréssion par moindres carrés a donné le résultat suivant :
$$y_i = -1 + 3x_i + 4z_i + \varepsilon_i,$$
et la somme des carrés résiduels vaut $\|\hat{\varepsilon}\|^2 = 3$.

   3.(a). En repartant de l'expression de $\hat{\theta}_{MC}$, exprimer X^TY en fonction de X^TX et $\hat{\theta}_{MC}$. Calculer X^TY et en déduire la moyenne emprique $\overline{y}$.

   3.(b). Vérifier que $\|X\hat{\theta}_{MC}\|^2 = Y^TX\hat{\theta}_{MC} = \hat{\theta}_{MC}^TX^TY$. Calculer alors $\|\hat{Y}\|^2$ et en déduire $\|Y\|^2$.

   3.(c). Calculer la somme des carrés totale $\|Y - \overline{y}\mathbf{1}\|^2$, puis déterminer le coefficient de détermination R^2 ainsi que le coefficient de détermination ajusté.

4. On s'intéresse maintenant au modèle privé du régresseur z, c'est-à-dire $Y = X_0\theta_0 + \varepsilon_0$ avec $X_0 = [\mathbf{1} \,|\, x]$.

   4.(a). Déterminer $X_0^TX_0$ et X_0^TY. En déduire $(\hat{\theta_0})_{MC}$.

   4.(b). Calculer $\|\hat{Y}_0\|^2$.

   4.(c). Justifier l'égalité $\|\hat{Y}_0\|^2 + \|\varepsilon_0\|^2 = \|\hat{Y}\|^2 + \|\varepsilon\|^2$. En déduire la somme des carrés résiduels $\|\varepsilon_0\|^2$ dans ce nouveau modèle. Déterminer le coefficient de détermination R_0^2 ainsi que le coefficient de détermination ajusté.

5. On suppose désormais que le modèle est gaussien. On veut comparer les deux modèles précédents.

   5.(a). Effectuer un test de Fisher entre ces deux modèles grâce aux coefficients de détermination. Montrer que la statistique de Fisher s'écrit aussi
$$F = \frac{n-p}{p-p_0}\frac{R^2 - R_0^2}{1 - R^2}\,.$$
Calculer F dans notre cas. Qu'en concluez-vous au niveau de risque 5% ? On donne $f^{1,2}(0.95) = 18.5$.

   5.(b). Proposer un autre moyen d'arriver au même résultat.

Exercice 6.7 (Régression ridge)**.** On considère le modèle linéaire classique $Y = X\theta + \varepsilon$ avec n observations et p variables explicatives. On ne suppose pas que ce modèle est gaussien et on ne le suppose pas identifiable a priori. Soit $\lambda > 0$. On considère l'estimateur Ridge défini par :
$$\hat{\theta}_\lambda := \underset{\theta \in \mathbb{R}^p}{\arg\min}\left(\|Y - X\theta\|^2 + \lambda\|\theta\|^2\right)\,.$$
Le paramètre λ est appelé paramètre de régularisation.

1. En écrivant proprement le gradient de la fonction à minimiser, déterminer une condition sous laquelle $\hat{\theta}_\lambda$ est uniquement déterminé, et donner sa forme close en fonction de X, Y, et λ.

2. Montrer que quand $\lambda > 0$ est assez petit mais non nul, $\hat{\theta}_\lambda$ est uniquement déterminé, même si le modèle n'est pas identifiable. Interpréter.

3. Montrer que quand $\lambda > 0$ est assez grand, $\hat{\theta}_\lambda$ est uniquement déterminé. Quelle est la limite de $\hat{\theta}_\lambda$ quand $\lambda \to +\infty$? Interpréter.

4. Calculer l'espérance et la matrice de covariance de l'estimateur Ridge notée V_λ. Est-il sans biais ?

5. On se place dans le cas identifiable et on note V la matrice de covariance de l'estimateur des moindre carrés. En étudiant les valeurs propres de l'une en fonction de celles de l'autres, montrer que pour tout $\lambda > 0$, $V_\lambda \prec V$ au sens strict, pour l'ordre $\prec$ défini en cours. Commenter.