Statistique mathématique – exercices et problèmes

Luca Ganassali

Université Paris-Saclay

2025 – 2026

(Last update: April 11, 2026)

Contents

1 Outils probabilistes pour le statisticien **3**

2 Modélisation statistique, suffisance et complétude **13**

3 Estimation paramétrique **16**

4 Intervalles et régions de confiance **24**

5 Tests d'hypothèses **28**

6 Modèle linéaire et modèle linéaire gaussien **35**

A Plantons des étoiles **41**

B Minimisation de l'erreur de prédiction **48**

1. Outils probabilistes pour le statisticien

Cette première feuille d'exercices est particulièrement longue. Il n'est pas attendu de tout traiter.

Exercice 1.1 (Maximum de variables exponentielles i.i.d.)**.** Soient $(X_n)_{n\geq 1}$ sont i.i.d. et distribuées exponentiellement avec paramètre $\lambda > 0$, c'est-à-dire de densité $x \mapsto \lambda e^{-\lambda x}\mathbb{1}_{x>0}$ par rapport à la mesure de Lebesgue sur $\mathbb{R}$. Pour tout $n \geq 1$, on définit

$$M_n := \max(X_1, \dots, X_n)\,.$$

Equivalent presque sûr de M_n (optionnel).

1. À l'aide du Lemme de Borel-Cantelli, montrer que $\liminf \frac{M_n}{\log n} \geq 1/\lambda$, p.s. *Solution. Pour 1., prenons $\varepsilon > 0$. On a*

$$\begin{aligned}\mathbb{P}\left(\frac{M_n}{\log n} \leq \frac{1}{\lambda} - \varepsilon\right) &= \mathbb{P}(M_n \leq (1/\lambda - \varepsilon)\log n)\\ &= \mathbb{P}(X_1 \leq (1/\lambda - \varepsilon)\log n)^n\\ &= (1 - n^{-1+\lambda\varepsilon})^n\\ &= \exp(-n^{\lambda\varepsilon}(1 + o(1))).\end{aligned}$$

Le terme ci-dessus est sommable en n, donc d'après Borel–Cantelli, p.s, $\frac{M_n}{\log n} \leq \frac{1}{\lambda} - \varepsilon$ n'arrive qu'un nombre fini de fois. En "rationnalisant" les ε, on obtient, que p.s., pour tout $m \geq 0$, $\frac{M_n}{\log n} \leq \frac{1}{\lambda} - 2^{-m}$ n'arrive qu'un nombre fini de fois, i.e., p.s. pour tout $m \geq 0$, $\liminf \frac{M_n}{\log n} \leq \frac{1}{\lambda} - 2^{-m}$, i.e. p.s. $\liminf \frac{M_n}{\log n} \geq 1/\lambda$, p.s., comme voulu.

2. À l'aide du Lemme de Borel-Cantelli, montrer que $\limsup \frac{X_n}{\log n} = 1/\lambda$ p.s. *Solution. Pour la borne supérieure, prenons $\varepsilon > 0$. On a*

$$\mathbb{P}(X_n/\log(n) \geq 1/\lambda + \varepsilon) = \mathbb{P}(X_n \geq (1/\lambda + \varepsilon)\log(n)) = n^{-(1+\lambda\varepsilon)},$$

qui est sommable en n: par Borel–Cantelli avec les mêmes étapes que précédemment, on a que $\limsup \frac{X_n}{\log n} \leq 1/\lambda$ p.s. Pour la borne inférieure, il faut utiliser Borel-Cantelli avec l'indépendance: pour $0 < \varepsilon < 1/\lambda$,

$$\mathbb{P}(X_n/\log(n) \geq 1/\lambda - \varepsilon) = \mathbb{P}(X_n \geq (1/\lambda - \varepsilon)\log(n)) = n^{-(1-\lambda\varepsilon)},$$

qui somme en n à $+\infty$. Par Borel-Cantelli, comme les X_n sont indépendants, on a que p.s., $X_n/\log(n) \geq 1/\lambda - \varepsilon$ une infinité de fois, i.e. p.s., $\limsup X_n/\log(n) \geq 1/\lambda - \varepsilon$. En rationnalisant les ε comme précédemment, on obtient que p.s., $\limsup X_n/\log(n) \geq 1/\lambda$. Cela conclut la question.

3. Montrer finalement que $\frac{M_n}{\log n} \xrightarrow[n\to\infty]{p.s.} 1/\lambda$. *On pourra faire une preuve "à la Cesaro". Solution. Au vu de 1., il ne nous reste qu'à montrer que $\limsup \frac{M_n}{\log n} \leq 1/\lambda$, p.s. Notons qu'on ne peut pas utiliser B-C ici car les M_n ne sont pas indépendants ! On utilise la question 2., Pour tout $\omega \in \Omega$ sauf sur un ensemble de mesure nulle, pour tout $\varepsilon > 0$, il existe une constante $N_\omega = N_\omega(\varepsilon)$ telle que $\frac{X_k(\omega)}{\log k} - 1/\lambda \leq \varepsilon$ pour tout $k \geq N_\omega$. Fixons un tel ω et prenons $\varepsilon > 0$ quelconque. Ensuite, "à la Cesàro",*

$$\frac{M_n(\omega)}{\log n} \leq \frac{\max_{1\leq k\leq N_\omega} X_k(\omega)}{\log n} + \max_{N_\omega+1\leq k\leq n} \frac{X_k(\omega)}{\log k}\,,$$

le premier terme converge p.s. vers 0 *car* N_ω *est fini et est donc* $\leq \varepsilon$ *pour* n *assez grand, et le second terme est* $\leq \frac{1}{\lambda} + \varepsilon$ *pour* n *assez grand. On a donc* $\frac{M_n(\omega)}{\log n} \leq 1/\lambda + 2\varepsilon$ *pour* n *assez grand. Ceci pour tout* ε*, donc* $\limsup \frac{M_n(\omega)}{\log n} \leq 1/\lambda$*. Finalement,* $\limsup \frac{M_n}{\log n} \leq 1/\lambda$*, p.s. et on a la limite presque sûre voulue.*

Développement limité de M_n puis de $1/M_n$.

4. Montrer que $M_n - \frac{\log n}{\lambda}$ converge en loi vers une loi notée G_λ que vous caractériserez. *On passera par la fonction de répartition.* *Solution. En regardant la limite de la f.d.r., on obtient que*

$$\begin{aligned}\mathbb{P}(M_n - \log n/\lambda \leq t) &= \mathbb{P}(M_n \leq t - \log n/\lambda) = \mathbb{P}(X_1 \leq t - \log n/\lambda)^n \\ &= \left(1 - e^{-\lambda t}/n\right)^n \to e^{-e^{-\lambda t}}.\end{aligned}$$

La limite en loi $M_n - \log n/\lambda$ *est la loi sur* $\mathbb{R}$ *de f.d.r.* $x \mapsto e^{-e^{-\lambda x}}$ *(on parle de loi de Gumbel).*

5. En appliquant la méthode Delta et la question précédente, montrer que

$$\log n \times \left(\frac{\log n}{M_n} - \lambda\right) \xrightarrow[n\to\infty]{(d)} H_\lambda,$$

et préciser la fonction de répartition de H_λ. *Solution. On a établi que*

$$\log n \times (M_n/\log n - 1/\lambda) \xrightarrow[n\to\infty]{(d)} G_\lambda.$$

applique la méthode Delta pour la transformation $g : u \mapsto 1/u$*, dérivable en* $1/\lambda$*. On a alors :*

$$\log n \times ((\log n)/M_n - \lambda) \xrightarrow[n\to\infty]{(d)} g'(1/\lambda) \times G_\lambda = -\lambda^2 G_\lambda,$$

d'où

$$\frac{\log^2 n}{M_n} - \lambda \log n \xrightarrow[n\to\infty]{(d)} H_\lambda,$$

avec $H_\lambda \overset{(d)}{=} -\lambda^2 G_\lambda$ *(égalité en loi). On peut calculer la f.d.r. de la loi* H_λ*: si* $Y \sim G_\lambda$ *et* $t \in \mathbb{R}$*, on a*

$$\mathbb{P}(-\lambda^2 Y \leq t) = \mathbb{P}(Y \geq -t/\lambda^2) = 1 - e^{-e^{\lambda t/\lambda^2}} = 1 - e^{-e^{t/\lambda}}.$$

Application: intervalle de confiance pour λ.

6. Pour $\beta \in]0,1[$, calculer explicitement le quantile d'ordre β de la loi de H_λ, noté $h_{\lambda,\beta}$. *Solution. On a la fonction de répartition, il suffit de l'inverser :*

$$1 - e^{-e^{t/\lambda}} = \beta \iff -e^{t/\lambda} = \log(1-\beta) \iff t = \lambda \log(-\log(1-\beta)),$$

d'où $h_{\lambda,\beta} = \lambda \log(-\log(1-\beta))$.

7. Montrer avec tout ce qui précède que pour tout $\alpha \in]0,1[$, en notant

$$I_1(X_1, \ldots, X_n; \alpha) := \left[\frac{\frac{\log n}{M_n}}{1 + \frac{\log(-\log(\alpha/2))}{\log n}}, \frac{\frac{\log n}{M_n}}{1 + \frac{\log(-\log(1-\alpha/2))}{\log n}}\right],$$

on a

$$\mathbb{P}\left(I_1(X_1,\dots,X_n;\alpha) \ni \lambda\right) \underset{n\to\infty}{\longrightarrow} 1-\alpha\,.$$

$I_1(X_1,\dots,X_n)$ est un intervalle aléatoire appelé intervalle de confiance asymptotique pour λ de probabilité de couverture $1-\alpha$. *Solution. D'après ce qui précède, pour tout* $\alpha \in]0,1[$,

$$\begin{aligned}
&\mathbb{P}\left(I_1(X_1,\dots,X_n;\alpha) \ni \lambda\right)\\
&= \mathbb{P}\left(\lambda\log(-\log(1-\alpha/2)) \le \frac{\log^2 n}{M_n} - \lambda\log n \le \lambda\log(-\log(\alpha/2))\right)\\
&\underset{n\to\infty}{\longrightarrow} \mathbb{P}\left(h_{\lambda,\alpha/2} \le H_\lambda \le h_{\lambda,1-\alpha/2}\right) = 1-\alpha\,.
\end{aligned}$$

8. Quel est l'équivalent presque sûr de $\mathrm{diam}(I_1(X_1,\dots,X_n;\alpha))$? *Solution. On utilise tous les résultats précédents, et p.s.,*

$$\begin{aligned}
\mathrm{diam}(I_1(X_1,\dots,X_n;\alpha)) &= \frac{\log n}{M_n}\left[\frac{1}{1+\frac{\log(-\log(1-\alpha/2))}{\log n}} - \frac{1}{1+\frac{\log(-\log(\alpha/2))}{\log n}}\right]\\
&\sim \lambda\frac{\log(-\log(\alpha/2)) - \log(-\log(1-\alpha/2))}{\log n}
\end{aligned}$$

(NB : les limites sont p.s. et constantes ici, pas besoin du Lemme de Slutsky).

9. ($\star$ car moins guidé) Pourrait-on trouver un autre intervalle de confiance dont le diamètre décroit sensiblement plus vite en n que l'intervalle précédent ?

Exercice 1.2 (Empirical risk minimisation)**.** On observe $(X_1,Y_1),\dots,(X_n,Y_n)$ i.i.d., de loi inconnue, avec X_i vecteurs aléatoires de $\mathbb{R}^d$ (*features*), et $Y_i \in \{0,1\}$ (*labels*). On appelle *classifieur* une fonction mesurable $h : \mathbb{R}^d \to \{0,1\}$. Soit $\mathcal{H}$ un ensemble fini de classifieurs. On considère le *classification loss* ℓ défini par

$$\ell(h(X),Y) = \mathbb{1}_{\{h(X)\neq Y\}}\,.$$

Pour $h \in \mathcal{H}$, on définit son *risque* $R(h)$ et son *risque empirique* $\widehat{R}_n(h)$, donnés par :

$$R(h) = \mathbb{E}[\ell(h(X),Y)], \qquad \widehat{R}_n(h) = \frac{1}{n}\sum_{i=1}^n \ell(h(X_i),Y_i)\,.$$

Le but du statisticien est de trouver le meilleur classifieur $h \in \mathcal{H}$ au sens du risque R:

$$h^\star \in \arg\min_{h\in\mathcal{H}} R(h)\,.$$

Problème : R dépend de la loi des données qui est inconnue : on ne peut pas calculer $R(h)$. La seule chose à laquelle nous avons accès, ce sont les données. On définit l'estimateur ERM $\hat{h}_n$ (empirical risk minimizer) par :

$$\hat{h}_n \in \arg\min_{h\in\mathcal{H}} \widehat{R}_n(h)\,.$$

Notons qu'on a par définition $R(h^\star) \le R(\hat{h}_n)$. Le but de l'exercice est d'établir une inégalité dans l'autre sens (avec des termes en plus) afin de montrer que $\hat{h}_n$ n'est pas trop mauvais par rapport à $h^\star$ au sens du risque R.

1. A l'aide de l'inégalité de Hoeffding, montrer que pour tout $h \in \mathcal{H}$ et tout $\varepsilon > 0$,

$$\mathbb{P}\Big(\Big|\widehat{R}_n(h) - R(h)\Big| \geq \varepsilon\Big) \leq 2e^{-2n\varepsilon^2}.$$

Solution. Les variables $\ell(h(X_i), Y_i)$ est bornée entre 0 et 1 et indépendantes. L'inégalité d'Hoeffding donne directement le résultat.

2. En utilisant une *union bound*, montrer que pour tout $\varepsilon > 0$,

$$\mathbb{P}\Big(\sup_{h\in\mathcal{H}}\Big|\widehat{R}_n(h) - R(h)\Big| \geq \varepsilon\Big) \leq 2|\mathcal{H}|\, e^{-2n\varepsilon^2}.$$

En déduire qu'avec probabilité au moins $1-\delta$,

$$\sup_{h\in\mathcal{H}}\Big|\widehat{R}_n(h) - R(h)\Big| \leq \sqrt{\frac{1}{2n}\log\left(\frac{2|\mathcal{H}|}{\delta}\right)}.$$

Solution. On applique l'union bound :

$$\mathbb{P}\Big(\exists h \in \mathcal{H} : \Big|\widehat{R}_n(h) - R(h)\Big| \geq \varepsilon\Big) \leq \sum_{h\in\mathcal{H}} 2e^{-2n\varepsilon^2} = 2|\mathcal{H}|e^{-2n\varepsilon^2}.$$

On inverse la borne pour écrire l'inégalité avec probabilité $1-\delta$.

3. Montrer enfin qu'avec probabilité au moins $1-\delta$,

$$R(\hat{h}_n) \leq R(h^\star) + 2\sqrt{\frac{1}{2n}\log\left(\frac{2|\mathcal{H}|}{\delta}\right)}.$$

Interpréter. *Solution. On note que par définition de $\hat{h}_n$, $\widehat{R}_n(\hat{h}_n) \leq \widehat{R}_n(h^\star)$. On ajoute et soustrait des termes de risque et on utilise par deux fois la borne uniforme de la question 2. :*

$$\begin{aligned} R(\hat{h}_n) &\leq \widehat{R}_n(\hat{h}_n) + \sup_{h\in\mathcal{H}}|R(h) - \widehat{R}_n(h)| \leq \widehat{R}_n(h^\star) + \sup_{h\in\mathcal{H}}|R(h) - \widehat{R}_n(h)| \\ &\leq R(h^\star) + 2\sup_{h\in\mathcal{H}}|R(h) - \widehat{R}_n(h)|. \end{aligned}$$

*En remplaçant par la borne de 2., on obtient l'inégalité annoncée. L'erreur $R(h^\star)$ correspond à l'*erreur d'approximation *(limite imposée par $\mathcal{H}$), tandis que le terme supplémentaire correspond à l'*erreur d'estimation du risque.

Exercice 1.3 (Loi et espérance conditionnelle)**.** Soit $X \sim \mathrm{Exp}(1)$, et Y une variable aléatoire dont la densité conditionnelle par rapport à la mesure de comptage sur $\mathbb{N}$ est donnée par :

$$p_{Y\,|\,X}(y\,|\,x) = \frac{x^y e^{-x}}{y!}.$$

1. Trouver la densité jointe de (X, Y) et identifier la mesure dominante. *Solution. La densité jointe est donnée par*

$$p_{X,Y}(x,y) = p_X(x)p_{Y|X}(y,x) = \frac{x^y e^{-2x}}{y!}.$$

La mesure dominante est ici $\mathrm{Leb}_{\mathbb{R}_+} \times \mu_{\mathbb{N}}$, où $\mu_{\mathbb{N}}$ désigne la mesure de comptage sur $\mathbb{N}$.

2. Quelle est la densité marginale de Y ? En déduire $\mathbb{E}[Y]$. *Solution. On obtient la densité marginale de Y comme suit :*

$$p_Y(y) = \int_{\mathbb{R}_+} p_{X,Y}(x,y)dx = \int_{\mathbb{R}_+} \frac{x^y e^{-2x}}{y!}dx = \frac{1}{y!}\int_{\mathbb{R}_+} (u/2)^y e^{-u}(du/2) = \frac{\Gamma(y+1)}{2^{y+1}y!} = \frac{1}{2^{y+1}}\,.$$

On a donc $Y \sim \mathcal{G}(1/2)$, la loi géométrique sur $\mathbb{N}$ de paramètre de probabilité de succès $p = 1/2$. Ainsi $\mathbb{E}[Y] = \frac{1-p}{p} = 1$.

3. Reconnaissez-vous la loi de Y conditionnellement à X ? Vérifier que la loi de l'espérance totale donne la même valeur pour $\mathbb{E}[Y]$. *Solution. On voit que $Y|X \sim \mathrm{Poi}(X)$, donc $\mathbb{E}[Y|X] = X$ et $\mathbb{E}[\mathbb{E}[Y|X]] = \mathbb{E}[X] = 1$, ce qui donne le même résultat.*

4. Trouver la densité conditionnelle de X sachant $Y = y$. *Solution. On a*

$$p_{X|Y}(x,y) = \frac{p_{X,Y}(x,y)}{p_Y(y)} = \frac{2^{y+1}x^y e^{-2x}}{y!}\,.$$

On reconnaît (peut-être) une loi Gamma : on peut noter $X|Y \sim \Gamma(Y+1, 1/2)$.

Exercice 1.4 (Fonction caractéristique des variables gaussiennes)**.** Nous voulons montrer que si $X \sim \mathcal{N}(\mu, \sigma^2)$, alors pour tout $t \in \mathbb{R}$,

$$\Phi_X(t) := \mathbb{E}[e^{itX}] = \exp\left(i\mu t - \frac{\sigma^2}{2}t^2\right)\,.$$

0. Montrer le résultat lorsque X est dégénérée ($\sigma = 0$). Nous supposons désormais $\sigma > 0$.

1. Montrer que pour tout $t \in \mathbb{R}$, $\Phi_X(t) = e^{it\mu} f_\sigma(t)$, où

$$f_\sigma(t) := \frac{1}{\sqrt{2\pi}}\int_{\mathbb{R}} e^{i\sigma t y - y^2/2}dy\,.$$

Solution. il suffit d'écrire la définition et de faire le changement de variables $y = \frac{x-\mu}{\sigma}$.

2. Montrer que pour tout $t \in \mathbb{R}$, $f_\sigma(t) \in \mathbb{R}$, que f_σ est différentiable et trouver une équation différentielle qu'elle satisfait. *Solution. on prend le conjugué et on fait le changement $y \to -y$. On peut utiliser la convergence dominée : chaque intégrande est dérivable en t et $|-\sigma\sin(\sigma t y)ye^{-y^2/2}|$ est facilement dominé. Par intégration par parties (on intègre $ye^{-y^2/2}$),*

$$\begin{aligned} f'_\sigma(t) &= -\frac{\sigma}{\sqrt{2\pi}}\int_{\mathbb{R}} \sin(\sigma t y)ye^{-y^2/2}dy \\ &= 0 + \frac{\sigma}{\sqrt{2\pi}}\int_{\mathbb{R}} \sigma t\cos(\sigma t y)(-e^{-y^2/2})dy \\ &= -\sigma^2 t f_\sigma(t)\,. \end{aligned}$$

3. Conclure. *Solution. nous avons la condition initiale $f_\sigma(0) = 1$. C'est terminé.*

4. En déduire que si $X \sim \mathcal{N}(\mu, \sigma^2)$, et $a, b \in \mathbb{R}$, alors $aX + b \sim \mathcal{N}(a\mu + b, a^2\sigma^2)$.

5. En déduire que, si $X_1 \sim \mathcal{N}(\mu_1, \sigma_1^2)$, $X_2 \sim \mathcal{N}(\mu_2, \sigma_2^2)$ et X_1 et X_2 sont indépendantes, alors

$$X_1 + X_2 \sim \mathcal{N}(\mu_1 + \mu_2, \sigma_1^2 + \sigma_2^2)\,.$$

Exercice 1.5 (Méthode Delta pour une loi multinomiale)**.** *Cet exercice suppose une connaissance préalables des propriétés des vecteurs gaussiens (que nous reverrons plus tard dans le cours).* Soit

$$(A_n, B_n, C_n) \sim \text{Multinomial}(n;\, p_1, p_2, 1 - p_1 - p_2)$$

avec $p_1, p_2 \in (0,1)$ et $p_1 + p_2 < 1$. Pour tout $n \geq 1$, on définit

$$U_n := \frac{A_n}{n}, \quad V_n := \frac{B_n}{n}, \quad Z_n := \log\left(\frac{U_n}{V_n}\right).$$

1. Montrer que

$$\sqrt{n}\big((U_n, V_n) - (p_1, p_2)\big) \xrightarrow[n\to\infty]{(d)} \mathcal{N}\big(0, \Sigma\big),$$

   où

$$\Sigma = \begin{pmatrix} p_1(1-p_1) & -p_1p_2 \\ -p_1p_2 & p_2(1-p_2) \end{pmatrix}.$$

2. En appliquant la méthode Delta à la fonction

$$g(x,y) = \log(x) - \log(y),$$

   montrer que

$$\sqrt{n}\left(Z_n - \log\left(\frac{p_1}{p_2}\right)\right) \xrightarrow[n\to\infty]{(d)} \mathcal{N}\Big(0, \frac{1}{p_1} + \frac{1}{p_2}\Big).$$

   Interpréter la symétrie dans la variance limite en p_1, p_2.

<u>Solution.</u> Pour 1., on utilise le théorème central limite multidimensionnel pour les composantes d'une loi multinomiale. En effet, la covariance entre A_n et B_n est $-np_1p_2$, et les variances sont $np_1(1-p_1)$ et $np_2(1-p_2)$, d'où le résultat après normalisation par n. Pour 2., la fonction g est différentiable en (p_1, p_2) avec gradient

$$\nabla g(p_1, p_2) = \left(\frac{1}{p_1}, -\frac{1}{p_2}\right).$$

Par la méthode Delta multidimensionnelle,

$$\sqrt{n}\big(g(U_n, V_n) - g(p_1, p_2)\big) \xrightarrow[n\to\infty]{(d)} \mathcal{N}\Big(0, \nabla g(p_1, p_2)^\top \Sigma \nabla g(p_1, p_2)\Big).$$

On calcule

$$\nabla g(p_1, p_2)^\top \Sigma \nabla g(p_1, p_2) = \frac{1}{p_1^2} p_1(1-p_1) + \frac{1}{p_2^2} p_2(1-p_2) + 2\frac{-1}{p_1p_2}(-p_1p_2) = \frac{1}{p_1} + \frac{1}{p_2}.$$

Ainsi,

$$\sqrt{n}\left(Z_n - \log\left(\frac{p_1}{p_2}\right)\right) \xrightarrow[n\to\infty]{(d)} \mathcal{N}\Big(0, \frac{1}{p_1} + \frac{1}{p_2}\Big),$$

comme souhaité.

Exercice 1.6 (Plus rapide que $1/\sqrt{n}$?)**.** Supposons que $X_1, \ldots, X_n$ sont i.i.d., centrées, de variance finie $\sigma^2 > 0$ inconnue. On note classiquement $\bar{X}_n$ la moyenne empirique des X_i et

$$\hat{\sigma}^2 := \frac{1}{n}\sum_{i=1}^n X_i^2 - \left(\frac{1}{n}\sum_{i=1}^n X_i\right)^2.$$

1. Étudier la convergence presque sûre de $\bar{X}_n$ et de $\hat{\sigma}^2$.

2. Montrer que
$$\frac{\sqrt{n}\bar{X}_n}{\sqrt{\hat{\sigma}^2}} \xrightarrow[n\to\infty]{(d)} \mathcal{N}(0,1)\,.$$

Dans toute la suite, on suppose que $\sigma^2 = 1$ et qu'il est connu.

3. Quelle est la limite en loi de $\sqrt{n}(\cos(\bar{X}_n) - 1)$?

4. Trouver une suite $(a_n)_{n\geq 1}$ telle que $a_n(\cos(\bar{X}_n) - 1)$ converge en loi vers une v.a. Z qui n'est pas presque sûrement constante. Caractériser la loi de Z. *Solution. On revient à la preuve du théorème de la méthode Delta, mais on va jusqu'à l'ordre 2 ! On a* $\cos(x) - 1 = -x^2/2 + x^2\varepsilon(x)$, *avec* ε *continue sur* $\mathbb{R}\setminus\{0\}$, *et* $\varepsilon(x) \xrightarrow[x\to 0]{} 0$. *On peut alors prolonger* ε *par continuité en* 0. *Puisque* $\bar{X}_n \to 0$ *p.s., alors par continuité,* $\varepsilon(\bar{X}_n) \to \varepsilon(0) = 0$ *p.s., donc aussi en probabilité. Ainsi, pour tout* n,
$$\cos(\bar{X}_n) = 1 + 0 - \frac{(\bar{X}_n)^2}{2}(1 + \varepsilon(\bar{X}_n))\,,$$
avec $1 + \varepsilon(\bar{X}_n) \xrightarrow[n\to\infty]{\mathbb{P}} 1$. *On applique de nouveau le lemme de Slutsky pour conclure :*
$$n(\cos(\bar{X}_n) - 1) = -(1 + \varepsilon(\bar{X}_n)) \times \frac{(n\bar{X}_n)^2}{2} \xrightarrow[n\to\infty]{(d)} -Z^2/2,$$
avec $Z \sim \mathcal{N}(0,1)$. *Remarquons pour les plus sagaces qu'en appliquant une nouvelle fois la méthode Delta avec* arccos, *on pourrait obtenir* $n\bar{X}_n \to Z'$, *ce qui contredirait le résultat de 3. Mais, bien sûr, on ne peut pas faire cela (voyez-vous pourquoi ?).*

Exercice 1.7 (Une inégalité de type Bennett)**.** On note h la fonction définie sur $\mathbb{R}_+$ par $h(x) = (1+x)\log(1+x) - x$, et ϕ définie sur $\mathbb{R}$ par $\phi(x) = \exp(x) - x - 1$. Soit $X \sim \mathrm{Poi}(\theta)$ avec $\theta > 0$.

1. Pour tout $\lambda \in \mathbb{R}$, calculer $\mathbb{E}[\exp(\lambda(X-\theta))]$ en fonction de ϕ. *Solution. On obtient directement*
$$\mathbb{E}[\exp(\lambda(X-\theta))] = e^{-\theta}\sum_{k\geq 0}\frac{\theta^k e^{\lambda(k-\theta)}}{k!} = e^{-\theta-\lambda\theta+\theta e^{\lambda}} = e^{\theta\phi(\lambda)}$$

2. Montrer que pour tout $x > 0$,
$$\mathbb{P}(X - \theta \geq x) \leq \exp(-\theta h(x/\theta))\,.$$
Solution. Par la méthode de Chernoff,
$$\mathbb{P}(X - \theta \geq x) \leq \exp(-\theta \sup_{\lambda\geq 0}(\lambda x/\theta - \phi(\lambda)))$$
et ce sup est atteint en étudiant $f(\lambda) = \lambda y - \phi(\lambda)$, $f'(\lambda) = y + 1 - e^{\lambda} > 0 \iff \lambda < \log(y+1)$. *Il y a donc un maximum global en* $\lambda = \log(y+1) > 0$ *et ce maximum vaut*
$$y\log(y+1) - \phi(\log(y+1)) = y\log(y+1) - (y+1) + \log(y+1) + 1 = h(y)\,.$$

3. On donne $e^{-2h(4)} \sim 0.003$. Comment cette inégalité se compare-t-elle à Bienaymé–Tchebychev

pour $\mathbb{P}(X \geq 10)$ lorsque $\theta = 2$? *Solution. Ici, $\theta = 2$ et $x = 10 - 2 = 8$. Bennett donne*

$$\mathbb{P}(X \geq 10) \leq e^{-2h(4)} \sim 0.003$$

tandis que Bienaymé–Tchebychev donne

$$\mathbb{P}(X \geq 10) \leq \mathbb{P}(|X - \theta| \geq 8) \leq \frac{\theta}{8^2} = \frac{1}{32},$$

ce qui est (nettement) moins bon.

Exercice 1.8 (Canaux gaussiens)**.** Supposons que $Y \sim \mathcal{N}(t, \tau^2)$ et que, conditionnellement à $Y = y$, $X_1, \ldots, X_n$ soient i.i.d. de loi $\mathcal{N}(y, \sigma^2)$. Montrer que

$$Y \,|\, (X_1, \ldots, X_n) \sim \mathcal{N}\left(\frac{t/\tau^2 + n\bar{X}_n/\sigma^2}{1/\tau^2 + n/\sigma^2}, \frac{1}{1/\tau^2 + n/\sigma^2}\right).$$

Pour une variable gaussienne, on appelle *précision* l'inverse de sa variance. Quelle propriété de la précision a-t-on mise en évidence ici ? *Solution. La densité de $X = (X_1, \ldots, X_n)$ conditionnellement à $Y = y$ est donnée par*

$$\begin{aligned} p_{X|Y}(x_1, \ldots, x_n, y) &= \prod_{i=1}^{n} \frac{1}{\sqrt{2\pi\sigma^2}} \exp\left(-\frac{(x_i - y)^2}{2\sigma^2}\right) \\ &= \frac{1}{(2\pi\sigma^2)^{n/2}} \exp\left(-\frac{1}{2\sigma^2}\sum_{i=1}^{n}(x_i - y)^2\right), \end{aligned}$$

d'où la densité jointe

$$\begin{aligned} p_{X,Y}(x_1, \ldots, x_n, y) &= \frac{1}{\sqrt{2\pi\tau^2}(2\pi\sigma^2)^{n/2}} \exp\left(-\frac{1}{2\tau^2}(y - t)^2 - \frac{1}{2\sigma^2}\sum_{i=1}^{n}(x_i - y)^2\right) \\ &\propto_y \exp\left(-\frac{1}{2}\left[(1/\tau^2 + n/\sigma^2)y^2 - (2/\tau^2 + 2n\bar{X}_n/\sigma^2)y\right]\right) \\ &\propto_y \exp\left(-\frac{1}{2(1/\tau^2 + n/\sigma^2)^{-1}}\left[y - \frac{1/\tau^2 + n\bar{X}_n/\sigma^2}{1/\tau^2 + n/\sigma^2}\right]^2\right), \end{aligned}$$

d'où

$$p_{Y|X}(y, x_1, \ldots, x_n) = \frac{p_{X,Y}(x_1, \ldots, x_n, y)}{p_X(x_1, \ldots, x_n)} \propto_y p_{X,Y}(x_1, \ldots, x_n, y),$$

ce qui donne le résultat voulu. Nous venons de montrer que la précision de la loi conditionnelle est la somme des précisions sur X_i et Y (et la moyenne est une moyenne pondérée par les précisions).

Exercice 1.9 (Loi bêta)**.** Supposons que X et Y sont des v.a. réelles positives et indépendantes.

1. Montrer que pour tout $0 < x < 1$,

$$\mathbb{P}\left(\frac{X}{X + Y} \leq x\right) = \mathbb{E}\left[F_X\left(\frac{xY}{1 - x}\right)\right].$$

Solution. C'est simplement la loi de l'espérance totale, et comme X et Y sont indépen-

dantes,

$$\mathbb{P}\left(\frac{X}{X+Y} \leq x \,|\, Y = y\right) = \mathbb{E}\left[\mathbb{1}_{X \leq \frac{xY}{1-x}} \,|\, Y = y\right] = \mathbb{E}\left[\mathbb{1}_{X \leq \frac{xy}{1-x}}\right] = F_X\left(\frac{xy}{1-x}\right).$$

2. Supposons que $\mathbb{E}[Y] < \infty$ et que X admette une densité p_X par rapport à μ. Montrer que $V = X/(X+Y)$ admet aussi une densité p_V par rapport à μ, donnée par

$$p_V(x) = \mathbb{E}\left[\frac{Y}{(1-x)^2} p_X\left(\frac{xY}{1-x}\right)\right].$$

Solution. C'est parce qu'on peut dériver sous le signe intégral à la question 1. C'est une conséquence du théorème de convergence dominée (version différentiable), puisque pour tout $0 < x < b < 1$,

$$\left|\frac{Y}{(1-x)^2} p_X\left(\frac{xY}{1-x}\right)\right| \leq \frac{Y}{(1-b)^2},$$

ce qui est intégrable.

Pour $\alpha, \beta > 0$, la loi Gamma $\Gamma(\alpha, \beta)$ est la loi de densité

$$x \mapsto \frac{1}{\Gamma(\alpha)} \beta^\alpha x^{\alpha-1} e^{-\beta x}$$

par rapport à $\mathrm{Leb}_{\mathbb{R}_+}$, et la loi bêta $\mathrm{Beta}(\alpha, \beta)$ est la loi de densité

$$x \mapsto \frac{\Gamma(\alpha+\beta)}{\Gamma(\alpha)\Gamma(\beta)} x^{\alpha-1}(1-x)^{\beta-1}$$

par rapport à $\mathrm{Leb}_{[0,1]}$.

3. Montrer que si $X \sim \Gamma(\alpha, 1)$ et $Y \sim \Gamma(\alpha', 1)$ sont indépendantes, alors $\frac{X}{X+Y} \sim \mathrm{Beta}(\alpha, \alpha')$.
Solution. Par le changement de variables $u = \frac{y}{1-x}$ dans la densité précédente, on obtient

$$\begin{aligned} p_V(x) &= \frac{1}{\Gamma(\alpha)\Gamma(\alpha')} \int_{\mathbb{R}_+} \frac{y}{(1-x)^2} \left(\frac{xy}{1-x}\right)^{\alpha-1} e^{-x} y^{\alpha'-1} e^{-y} dy \\ &= \frac{x^{\alpha-1}(1-x)^{\alpha'-1}}{\Gamma(\alpha)\Gamma(\alpha')} \int_{\mathbb{R}_+} u^{\alpha+\alpha'-1} e^{-u} du \\ &= \frac{\Gamma(\alpha+\alpha')}{\Gamma(\alpha)\Gamma(\alpha')} x^{\alpha-1}(1-x)^{\alpha'-1}, \end{aligned}$$

qui est bien la densité voulue.

Exercice 1.10 (Absence de géométrie dans les graphes d'Erdős-Rényi)**.** Pour $n \geq 1$ on note $[n] = \{1, 2, \ldots, n\}$. Soit $G \sim G(n, p)$ un graphe aléatoire Erdős-Rényi d'ensemble de sommets $[n]$, où chaque arête $e = \{u, v\} \in \binom{[n]}{2}$ est présente dans G indépendamment avec probabilité $p \in [0, 1]$. On note $e(G)$ le nombre d'arêtes de G.

1. Existe-t-il une valeur de p telle que $G \sim G(n, p)$ soit uniforme sur l'ensemble des graphes d'ensemble de sommets $[n]$? *Solution. Pour tout graphe g de sommet $[n]$,*

$$\mathbb{P}(G = g) = p^{e(g)}(1-p)^{\binom{n}{2} - e(g)}.$$

Si $p = 1/2$, $\mathbb{P}(G = g)$ est constante égale à $1/2^{\binom{n}{2}}$, c'est-à-dire uniforme sur l'ensemble des graphes sur $[n]$, qui a taille $1/2^{\binom{n}{2}}$.

2. Pour $G \sim G(n,p)$, quelle est la loi de $e(G)$? *Solution. Chaque arête suit une loi* $\mathrm{Ber}(p)$, *les arêtes sont indépendantes, donc* $e(G) \sim \mathrm{Bin}(\binom{n}{2}, p)$.

3. Pour $G \sim G(n,p)$, quelle est la loi conditionnelle de G sachant $e(G)$? *Solution. Elle est donnée par*

$$\begin{aligned}
\mathbb{P}(G = g \,|\, e(G) = m) &= \frac{\mathbb{P}(G = g, e(G) = m)}{\mathbb{P}(e(G) = m)} \\
&= \mathbb{1}_{e(g)=m} \frac{p^m (1-p)^{\binom{n}{2}-m}}{\binom{\binom{n}{2}}{m} p^m (1-p)^{\binom{n}{2}-m}} \\
&= \mathbb{1}_{e(g)=m} \frac{1}{\binom{\binom{n}{2}}{m}},
\end{aligned}$$

ce qui est la loi uniforme sur l'ensemble des graphes de sommet $[n]$ et comportant $m = e(G)$ arêtes.

4. Expliquer le titre de l'exercice. *Solution. Une fois le nombre d'arêtes fixé, le graphe est uniforme : aucune contrainte géométrique particulière n'est imposée. Cela vient du fait que les arêtes sont i.i.d.*

2. Modélisation statistique, suffisance et complétude

Exercice 2.1. On considère le modèle où $(X_1, \dots, X_n)$ sont i.i.d. avec $X_1 \sim \mathrm{Unif}([\theta, \theta+1])$, avec $\theta > 0$ inconnu.

1. Écrire le modèle sous la forme canonique du cours. Montrer qu'il est identifiable.

2. Montrer que $S(X) = (\min_i X_i, \max_i X_i)$ est suffisante. *Solution. On utilise la factorisation de Neyman–Fisher, la densité jointe s'écrit* $\prod_{i=1}^n \mathbb{1}_{[\theta,\theta+1]}(x_i) = \mathbb{1}_{\min x_i \geq \theta} \mathbb{1}_{\max x_i \leq \theta+1}$.

3. Montrer que $A(X) = \max_i X_i - \min_i X_i$ est auxiliaire. *On pourra chercher la loi de* $X_1 - \theta$ *sous* $\mathbb{P}_\theta$. *Solution. Posons* $Y_1 = X_1 - \theta$. *Notons que* $Y_1 \in [0,1]$, $\mathbb{P}_\theta$*−p.s. Pour tout* $t \in [0,1]$, $\mathbb{P}_\theta(Y_1 \leq t) = \mathbb{P}_\theta(X_1 \leq t + \theta) = t$, *donc* $X_1 \sim \mathrm{Unif}([0,1])$ *(remarque : ce n'est pas une statistique, car l'opération appliquée à* X_1 *pour obtenir* Y_1 *dépend de* θ*). En notant* $Y = (Y_1, \dots, Y_n) = (X_1 - \theta, \dots, X_n - \theta)$, *on a que sous* $\mathbb{P}_\theta$, $Y \sim \mathrm{Unif}([0,1])^{\otimes n}$. *Or*
$$A(X) = \max_i (X_i - \theta) - \min_i (X_i - \theta) = \max_i Y_i - \min_i Y_i,$$
variables aléatoire dont la loi ne dépend pas de θ *:* $A(X)$ *est donc auxiliaire.*

4. En déduire que $S(X) = (\min_i X_i, \max_i X_i)$ n'est pas complète. *Solution. Supposons que* $S(X)$ *est complète. D'après la question précédente,* $\mathbb{E}_\theta[f(S(X)] = 0$, *où* $f(s_1, s_2) = s_2 - s_1 - \alpha$ *avec* $\alpha = \mathbb{E}_\theta[\max_i Y_i - \min_i Y_i]$ *(qui ne dépend pas de* θ*). Donc, comme* $S(X)$ *est complète,* $\mathcal{M}$*-p.s.,* $f(S(X)) = 0$ *i.e.* $\max_i X_i - \min_i X_i = \alpha$. *Montrons que cela est absurde. Si* $\alpha = 0$, *alors* $\max_i X_i = \min_i X_i$, *tous les* X_i *sont égaux p.s., ce qui est absurde car les* X_i *sont à densité. Si* $\alpha > 0$,
$$\begin{aligned}\mathbb{P}_\theta(\min_i X_i - \max_i X_i \leq \alpha/2) &\geq \mathbb{P}_\theta(\theta \leq X_1 \leq \theta + \alpha/2, \dots, \theta \leq X_n \leq \theta + \alpha/2) \\ &= (\alpha/2)^n > 0,\end{aligned}$$
et donc $\min_i X_i - \max_i X_i$ *n'est pas constant à* α *p.s. et* f *n'est pas nulle, contradiction.*

Exercice 2.2. On considère un modèle dans lequel l'observation X est de la forme $X = a(Y - Z)$ avec $Y \sim \mathrm{Exp}(\lambda)$ et $Z \sim \mathrm{Exp}(\mu)$ indépendantes, $\lambda, \mu > 0$ inconnus.

On suppose d'abord a connu et $a = 1$.

1. Quels sont ici les paramètres du modèle ? *Solution. On a ici* $\theta = (\lambda, \mu)$ *et* $\Theta = (\mathbb{R}_+^*)^2$.

2. En posant $b = 1/\lambda$ et $c = 1/\mu$, trouver deux équations satisfaites par b et c. En raisonnant sur ces équations, montrer que le modèle est identifiable. *Solution. Les équations sont* $b - c = \mathbb{E}[X] =: A$ *et* $b^2 + c^2 = \mathrm{Var}(X) =: B$. *Il s'agit de trouver un point* (b, c) *sur le cercle centré d'équation* $b^2 + c^2 = B$ *à l'intersection avec la droite* $c = b - A$. *On voit facilement que si ces lieux géométriques s'intersectent, ils le font au plus une fois dans le quadrant positif ; comme* $b = 1/\lambda$ *et* $c = 1/\mu$ *doivent être des solutions, il y a une solution unique. Le modèle est identifiable.*

Supposons à présent que a est inconnu dans $\mathbb{R}$.

3. En raisonnant sur la transformation $(Y, Z) \mapsto (Z, Y)$, montrer que le modèle n'est pas identifiable. *Solution. Quand* $\alpha \in \mathbb{R}$, *les lois* $\mathbb{P}_{(\alpha,\lambda,\mu)}$ *et* $\mathbb{P}_{(-\alpha,\mu,\lambda)}$ *sont les mêmes, donc le modèle n'est pas identifiable.*

Supposons finalement que a est inconnu dans $\mathbb{R}_+$. L'argument précédent ne tient plus.

4. Montrer que si $Y \sim \mathrm{Exp}(\lambda)$ et $\alpha > 0$, $Y \sim \mathrm{Exp}(\lambda/\alpha)$. *Solution. via la fonction de répartition.*

5. En déduire que le modèle n'est pas identifiable. *Solution. La question 4. montre qu'i y a encore une symétrie $(\alpha, \lambda, \mu) \mapsto (1, \lambda/\alpha, \mu/\alpha)$ lorsque $\alpha > 0$. Le modèle n'est pas identifiable.*

Exercice 2.3. On considère le modèle où $(X_1, \ldots, X_n)$ sont i.i.d. avec densité $x \mapsto C(\theta)\, x \mathbb{1}_{[0,\theta]}(x)$ pour un certain paramètre $\theta > 0$.

1. Trouver la valeur de $C(\theta)$ pour tout $\theta > 0$. *Solution. Une intégration simple montre que $C(\theta) = \frac{2}{\theta^2}$.*

2. Trouver la densité de X_1/θ. *Solution. Avec la fonction de répartition. Pour tout $x \in [0, 1]$,*
$$\mathbb{P}_\theta(X_1/\theta \leq x) = \mathbb{P}_\theta(X_1 \leq x\theta) = \frac{2}{\theta^2} \int_0^{x\theta} u\, du = \frac{2(x\theta)^2}{2\theta^2} = x^2\,.$$
Donc, en dérivant, X_1/θ a pour densité $x \mapsto 2x\mathbb{1}_{[0,1]}(x)$.

3. On trie les X_i par ordre croissant : $X_{(1)} \leq \ldots \leq X_{(n)}$ sont appelées les statistiques d'ordre de l'échantillon. Montrer que $X_{(n)}$ et $X_{(1)}/X_{(n)}$ sont indépendantes. *On utilisera le théorème de Basu, après avoir montré que $X_{(1)}/X_{(n)}$ est auxiliaire à l'aide de la question précédente. Solution. Montrons que $X_{(1)}/X_{(n)}$ est auxiliaire. Comme diviser par $\theta > 0$ ne change pas l'ordre des variables, on peut poser $Y_i = X_i/\theta$. Dans ce modèle, les Y_i sont i.i.d et la loi de Y ne dépend plus de θ. De plus, $Y_{(1)}/Y_{(n)} = X_{(1)}/X_{(n)}$ en loi. La loi du membre de gauche ne dépend pas de θ, donc $X_{(1)}/X_{(n)}$ est auxiliaire. Il reste à montrer que $X_{(n)} = \max_i X_i$ est suffisante et complète. On peut le démontrer directement en écrivant d'abord la densité jointe de X sous $\mathbb{P}_\theta$, qui s'écrit*
$$\frac{2^n}{\theta^{2n}} \prod_{i=1}^n x_i \mathbb{1}_{[0,\theta]}(x_i) = 2^n \Big(\prod_{i=1}^n x_i \Big) \mathbb{1}_{\min_i x_i \geq 0} \frac{1}{\theta^{2n}} \mathbb{1}_{\max_i x_i \leq \theta}.$$
Puis, via la fonction de répartition, comme dans l'exemple du cours, on obtient que $X_{(n)}$ a pour densité $u \mapsto \frac{2nu^{2n-1}}{\theta^{2n}} \mathbb{1}_{[0,\theta]}(u)$, et l'argument est similaire à celui du cours : si f est telle que $\int_0^\theta f(u) u^{2n-1}\, \mathrm{d}u = 0$ pour tout θ, alors la fonction $h : s \mapsto f(s)s^{2n-1}$ a intégrale nulle sur tout intervalle de $\mathbb{R}_+$, donc sur tout borélien par le lemme de la classe monotone, en particulier sur le borélien $B = \{s : f(s) > 0\}$. Comme $\int \mathbb{1}_B(s) f(s) s^{2n-1} ds = 0$ implique que $f = 0$ presque sûrement au sens de Lebesgue.

Exercice 2.4 (Identifier une direction causale, $\star$)**.** On considère un modèle avec deux variables aléatoires X_1, X_2. On dit que X_1 *cause* X_2 si la loi du modèle est de la forme suivante :
$$X_1 = U_1 \quad X_2 = f(X_1, U_2),$$
où U_1 et U_2 sont des bruits indépendants et f est une fonction mesurable.

Une question fondamentale est la suivante : *en général, peut-on inférer quoi que ce soit sur la direction du lien causal entre X_1 et X_2 en observant quelques réalisations ?*

L'objectif de cet exercice est de répondre à la négative via un contre-exemple à ce fait. On considère le modèle
$$X_1 = U_1 \quad X_2 = X_1 + U_2,$$
où U_1 et U_2 sont des variables i.i.d. de loi $\mathrm{Exp}(1)$. Montrer qu'il existe un modèle causal inversé de la forme
$$X_2 = U_2' \quad X_1 = h(X_2, U_1'),$$
où U_1' et U_2' sont indépendants, et qui préserve la loi jointe de (X_1, X_2). *Solution. On peut savoir que $X_2 \sim \Gamma(2, 1)$, donc la loi de U_2' est fixée. Si l'on ne le sait pas, on peut la retrouver*

à partir de la densité jointe que l'on calcule. Pour toute fonction continue bornée f,

$$\begin{aligned}\mathbb{E}[f(X_1, X_2)] &= \mathbb{E}[f(U_1, U_1 + U_2)] \\ &= \int_0^{+\infty} \int_0^{+\infty} f(u_1, u_1 + u_2) e^{-u_1 - u_2} \, du_1 \, du_2 \\ &= \int_0^{+\infty} \int_{x_1}^{+\infty} f(x_1, x_2) e^{-x_2} \mathbb{1}_{x_2 \geq x_1} \, dx_1 \, dx_2.\end{aligned}$$

On en déduit que la densité jointe est $p(x_1, x_2) = e^{-x_2} \mathbb{1}_{x_2 \geq x_1 \geq 0}$ et que la seconde marginale est $p(x_2) = x_2 e^{-x_2} \mathbb{1}_{x_2 \geq 0}$. À présent, la densité conditionnelle de X_1 sachant X_2 est donnée par

$$p(x_1 \mid x_2) = \frac{p(x_1, x_2)}{p(x_2)} = \frac{e^{-x_2} \mathbb{1}_{x_2 \geq x_1 \geq 0}}{x_2 e^{-x_2} \mathbb{1}_{x_2 \geq 0}} = \frac{1}{x_2} \mathbb{1}_{x_1 \in [0, x_2]} \, .$$

Il s'agit d'une loi uniforme sur $[0, x_2]$; on peut donc définir $X_2 = U_2' \sim \Gamma(2, 1)$ et $X_1 = X_2 U_1'$, où $U_1' \sim \mathrm{Unif}([0, 1])$ est indépendante de X_2.

Exercice 2.5. On observe une réalisation de $G \sim G(n, p)$, c'est-à-dire un graphe aléatoire à n sommets (n est connu) dont chaque arête est présente indépendamment avec probabilité $p \in [0, 1]$ inconnu. Trouver une statistique suffisante et complète. Interpréter.

Exercice 2.6. On considère le modèle $(\mathbb{R}, \mathcal{B}(\mathbb{R}), (\mathrm{Unif}([0, \theta]))_{\theta \geq 0})$. Trouver une mesure dominante minimale pour ce modèle. *Solution. Nous allons montrer que $\lambda = \mathrm{Leb}_{\mathbb{R}_+}$, la mesure de Lebesgue sur $\mathbb{R}_+$, est une mesure dominante minimale. Tout d'abord, il est clair que λ domine le modèle. Ensuite, soit une mesure μ telle que $\mathcal{M} \ll \mu$ mais $\lambda \not\ll \mu$. Il existe donc un borélien $A \subseteq \mathbb{R}_+$ tel que $\mu(A) = 0$ et $\lambda(A) > 0$. Comme $\lambda(A) > 0$, il existe $t > 0$ tel que $\lambda(A \cap [0, t]) > 0$, et donc $P_t(A) > 0$, où P_t désigne la loi uniforme sur $[0, t]$. Mais dans le même temps, $P_t(A) = \int_A \frac{dP_t}{d\mu} \, d\mu = 0$ puisque $\mu(A) = 0$.*

Exercice 2.7 ($\star$)**.** Reprendre l'exemple du modèle uniforme i.i.d. du cours. Montrer que $S(X) = \max_i(X_i)$ est suffisante sans utiliser le théorème de Neyman-Fisher, en donnant la distribution de X sachant $S(X)$. Interpréter la forme de cette distribution.

3. Estimation paramétrique

Dans ces exercices, l'abbréviation UVMB désigne "uniformément de variance minimale et sans biais".

Exercice 3.1 (Deux estimateurs dans le modèle i.i.d. uniforme)**.** On considère le modèle où $X_1, \dots, X_n$ sont i.i.d. de loi $\mathrm{Unif}([0,\theta])$, avec $\theta > 0$ inconnu.

1. Trouver un estimateur $\hat{\theta}_1$ de θ en utilisant la méthode des moments appliquée au premier moment. *Solution. Puisque $\mathbb{E}_\theta[X_1] = \theta/2$, la méthode des moments donne l'estimateur $\hat{\theta}_1 = 2\bar{X}_n$.*

2. Déterminer la vraisemblance dans ce modèle et montrer qu'il existe un estimateur du maximum de vraisemblance unique $\hat{\theta}_2$. Trouver son expression. *Solution. La vraisemblance s'écrit*

$$L(\theta, x) = \prod_{i=1}^{n} \frac{1}{\theta} \mathbb{1}_{[0,\theta]}(x_i) = \frac{1}{\theta^n} \mathbb{1}_{\{0 \le \min x_i\}} \mathbb{1}_{\{\max x_i \le \theta\}} \overset{\mathbb{P}_\theta - p.s.}{=} \begin{cases} 0 & si\ \theta < \max x_i, \\ \frac{1}{\theta^n} & si\ \theta \ge \max x_i, \end{cases}$$

ce qui possède un maximum global unique pour $\theta = \max_i x_i$. Ainsi, l'estimateur du maximum de vraisemblance est unique et s'écrit

$$\hat{\theta}_2 = \max_i X_i.$$

3. Calculer le biais, la variance et le risque quadratique de $\hat{\theta}_1$. *Solution. Pour $\hat{\theta}_1$, on a $\mathbb{E}_\theta[\hat{\theta}_1] = \theta$ pour tout $\theta > 0$, donc il est non biaisé. Sa variance est*

$$\mathrm{Var}_\theta(\hat{\theta}_1) = \frac{4}{n}\mathrm{Var}_\theta(X_1) = \frac{\theta^2}{3n},$$

d'où

$$R_\theta(\hat{\theta}_1) = 0 + \frac{\theta^2}{3n} = \frac{\theta^2}{3n}.$$

4. Calculer la densité de $\hat{\theta}_2$. En déduire son biais, sa variance et son risque quadratique. *Solution. Pour $\hat{\theta}_2$, la densité s'obtient via la fonction de répartition :*

$$g_\theta(x) = \frac{nx^{n-1}}{\theta^n} \mathbb{1}_{[0,\theta]}(x).$$

Ensuite,

$$\mathbb{E}_\theta[\hat{\theta}_2] = \int_0^\theta x\, g_\theta(x)dx = \frac{n}{n+1}\theta, \quad \mathbb{E}_\theta[\hat{\theta}_2^2] = \int_0^\theta x^2\, g_\theta(x)dx = \frac{n}{n+2}\theta^2,$$

ce qui donne

$$b_\theta(\hat{\theta}_2) = -\frac{\theta}{n+1}, \quad \mathrm{Var}_\theta(\hat{\theta}_2) = \frac{n}{n+2}\theta^2 - \left(\frac{n}{n+1}\theta\right)^2 = \frac{n}{(n+1)^2(n+2)}\theta^2,$$

et finalement

$$R_\theta(\hat{\theta}_2) = \left(\frac{\theta}{n+1}\right)^2 + \frac{n}{(n+1)^2(n+2)}\theta^2 = \frac{2}{(n+1)(n+2)}\theta^2.$$

5. Quel est le meilleur estimateur pour n assez grand ? Y a-t-il une grande différence ? *Solution. On remarque facilement que $R_\theta(\hat\theta_2) \le R_\theta(\hat\theta_1)$ dès que $n \ge 2$, donc $\hat\theta_2$ est meilleur que $\hat\theta_1$. En fait, il est encore bien meilleur puisque lorsque $n \to \infty$, $R_\theta(\hat\theta_2) \sim \frac{2\theta^2}{n^2}$ tandis que $R_\theta(\hat\theta_1) \sim \frac{\theta^2}{3n}$, beaucoup plus grand.*

Exercice 3.2 (Information de Fisher dans un modèle linéaire à deux paramètres)**.** On considère le modèle statistique où $X_1, \dots, X_n$ sont des variables réelles indépendantes, avec pour tout $1 \le i \le n$, $X_i \sim \mathcal{N}(\alpha + \beta t_i, 1)$, où les $(t_i)_{1\le i\le n}$ sont des réels *connus* et $\alpha, \beta \in \mathbb{R}$ sont des paramètres *inconnus*. On admettra que ce modèle est régulier.

1. Déterminer une condition nécessaire et suffisante sur les $(t_i)_{1\le i\le n}$ pour que ce modèle soit identifiable. *Solution. On peut commencer par regarder ce que donnent les moments d'ordre 1. L'application*

$$(\alpha,\beta) \mapsto \begin{pmatrix} \mathbb{E}_{(\alpha,\beta)}[X_1] \\ \vdots \\ \mathbb{E}_{(\alpha,\beta)}[X_n] \end{pmatrix} = \begin{pmatrix} \alpha + \beta t_1 \\ \vdots \\ \alpha + \beta t_n \end{pmatrix} = \underbrace{\begin{pmatrix} 1 & t_1 \\ \vdots & \vdots \\ 1 & t_n \end{pmatrix}}_{=:X} \begin{pmatrix} \alpha \\ \beta \end{pmatrix}$$

est injective si et seulement si la matrice X a un noyau réduit à $\{0_2\}$, ce qui arrive si et seulement si elle est de rang 2, ssi les t_i ne sont pas constants. Réciproquement, si les t_i sont constants, l'identifiabilité est alors mise en défaut : toutes les variables sont i.i.d. $\mathcal{N}(\alpha + \beta t, 1)$ et on a une symétrie $(\alpha,\beta) \mapsto (0, \alpha + \beta t)$.

2. Montrer que la matrice d'information de Fisher $I(\alpha,\beta)$ s'écrit

$$I(\alpha,\beta) = \begin{pmatrix} n & \sum_{i=1}^n t_i \\ \sum_{i=1}^n t_i & \sum_{i=1}^n t_i^2 \end{pmatrix}.$$

Solution. On écrit la log-vraisemblance qui est bien définie et vaut $\ell(\alpha,\beta,x) = -\frac{n}{2}\log(2\pi) - \frac{1}{2}\sum_{i=1}^n (x_i - \alpha - t_i\beta)^2$, différentiable sur $\mathbb{R}^2$ et de gradient donné par $\nabla_{\alpha,\beta}\ell(\alpha,\beta,x) = \begin{pmatrix} \sum_{i=1}^n (x_i - \alpha - t_i\beta) \\ \sum_{i=1}^n t_i(x_i - \alpha - t_i\beta). \end{pmatrix}$ La matrice de covariance de $\nabla_{\alpha,\beta}\ell(\alpha,\beta,X)$ existe et vaut

$$I(\alpha,\beta) = \begin{pmatrix} n & \sum_{i=1}^n t_i \\ \sum_{i=1}^n t_i & \sum_{i=1}^n t_i^2 \end{pmatrix}.$$

On pouvait calculer la matrice d'information de Fisher pour un seul X_1 et utiliser l'additivité de I.

3. Déterminer une condition nécessaire et suffisante sur les $(t_i)_{1\le i\le n}$ pour que $I(\alpha,\beta)$ soit inversible. Que remarque-t-on ? *Solution. A noter que l'information de Fisher est ici constante. Cela est du au fait que pour passer toutes les lois considérées sont reliées par translation : $X_i = \alpha + \beta t_i + Z_i$ avec l'aléa seulement dans Z_i, ne dépendant pas de α ni de β. La matrice $I(\alpha,\beta)$ est (symétrique) et inversible si et seulement si $\det I(\alpha,\beta) \neq 0$ i.e.*

$$n\sum_{i=1}^n t_i^2 \neq \left(\sum_{i=1}^n t_i\right)^2.$$

Mais par Cauchy-Schwarz, $n\sum_{i=1}^n t_i^2 \ge (\sum_{i=1}^n t_i)^2$ avec égalité si et seulement si $(t_1,\dots,t_n)$ et $(1,\dots,1)$ sont colinéaires c'est-à-dire si les t_i sont constants. $I(\alpha,\beta)$ est inversible

sous les mêmes conditions que la question 1. On pourra creuser ce lien entre identifiabilité et information de Fisher dans l' exo:fisher$_i$dentifiabilite.

Exercice 3.3 (Un modèle autorégressif)**.** Nous considérons un modèle avec $(X_1, \dots, X_n)$ tels que $X_1 = \theta + Z_1$, et récursivement, $X_{j+1} = \rho(X_j - \theta) + \theta + Z_{j+1}$ avec les Z_j i.i.d. de loi $\mathcal{N}(0, \sigma^2)$. Nous supposons que $\rho \in [0, 1]$ est un paramètre connu, et que $\theta \in \mathbb{R}$ et $\sigma^2 > 0$ sont inconnus. On admettra la régularité de ce modèle.

1. Calculer la matrice d'information de Fisher $I(\theta, \sigma^2)$ en fonction de θ, σ^2, ρ et n. *Solution. Le modèle est markovien, et log-vraisemblance s'écrit :*

$$\ell(\theta, \sigma^2) = -\frac{n}{2} \log\left(2\pi\sigma^2\right) - \frac{(X_1 - \theta)^2}{2\sigma^2} - \frac{1}{2\sigma^2} \sum_{j=1}^{n-1} (X_{j+1} - \theta - \rho(X_j - \theta))^2 .$$

Son gradient vaut

$$\nabla_{\theta,\sigma^2} \ell(\theta, \sigma^2) = \begin{pmatrix} \frac{1}{\sigma^2} \left[(X_1 - \theta) + (\rho + 1) \sum_{j=1}^{n-1} (X_{j+1} - \theta - \rho(X_j - \theta)) \right] \\ \frac{1}{2\sigma^2} \left[-n + \frac{(X_1 - \theta)^2}{\sigma^2} + \frac{1}{\sigma^2} \sum_{j=1}^{n-1} (X_{j+1} - \theta - \rho(X_j - \theta))^2 \right] \end{pmatrix} .$$

Pour calculer la matrice de covariance associée, il peut être bon de le reformuler en fonction des Z_j :

$$\nabla_{\theta,\sigma^2} \ell(\theta, \sigma^2) = \begin{pmatrix} \frac{1}{\sigma^2} \left[Z_1 + (1 - \rho) \sum_{j=2}^{n} Z_j \right] \\ \frac{1}{2\sigma^2} \left[-n + \frac{1}{\sigma^2} \sum_{j=1}^{n} Z_j^2 \right] \end{pmatrix} .$$

En utilisant que les Z_j sont i.i.d., que moments impairs d'une gaussienne centrée sont nuls, et $\mathrm{Var}(Z_1^2) = \sigma^4(3 - 1^2) = 2\sigma^4$, on a :

$$I(\theta, \sigma^2) = \begin{pmatrix} \frac{1 + (n-1)(1-\rho)^2}{\sigma^2} & 0 \\ 0 & \frac{n}{2\sigma^4} \end{pmatrix} .$$

Notons qu'elle ne dépend pas de θ : l'estimation de θ est de la même difficulté partout.

2. Donner une borne inférieure pour la variance d'un estimateur sans biais et lisse de θ. Commenter et interpréter les valeurs de cette borne lorsque $\rho = 0$, et lorsque $\rho = 1$. *Solution. La borne de Cramér-Rao pour un estimateur sans biais $\hat{\theta}$ de θ est l'inverse de l'information de Fisher en θ, donc :*

$$\mathrm{Var}(\hat{\theta}) \geq \left[I(\theta, \sigma^2)^{-1} \right]_{1,1} = \frac{\sigma^2}{1 + (n-1)(1-\rho)^2} .$$

On retrouve d'ailleurs la borne classique de Cramer-Rao lorsque $\rho = 0$: les variables sont alors i.i.d. $\mathcal{N}(\theta, \sigma^2)$. Lorsque $\rho = 1$, en reprenant l'énoncé on $X_{j+1} = X_j + Z_{j+1}$, le bruit ne fait que s'ajouter, et on ne peut pas estimer σ^2 mieux qu'avec X_1, donc avec erreur σ^2, qui ne décroit pas en n. De façon générale, cette borne croît avec ρ, on estime plus difficilement θ quand ρ augmente. En fait tout se passe comme si on travaillait dans le cadre i.i.d. avec une taille effective d'échantillon

$$n_{\text{eff}} = 1 + (n-1)(1-\rho)^2 \leq n .$$

Cette taille effective est inférieure à n car le cas dépendant n'amortit pas autant le bruit que le cas i.i.d., plus favorable.

Exercice 3.4 (Une Rao-Blackwellisation)**.** On considère le modèle où $X_1, \ldots, X_n$ sont i.i.d. de loi[1] $\mathrm{Poi}(\lambda)$, avec $\lambda > 0$ inconnu. On souhaite estimer $\varphi(\lambda) = e^{-\lambda}$.

1. Montrer que $T(X) = \mathbb{1}_{X_1=0}$ est un estimateur sans biais de $\varphi(\lambda)$. Calculer sa variance. Est-ce un bon estimateur ? *Solution. On a, pour tout $\lambda > 0$, $\mathbb{E}_\lambda[T(X)] = \mathbb{P}_\lambda(X_1 = 0) = \varphi(\lambda)$, $T(X)$ est donc sans biais. On a $\mathrm{Var}_\lambda(T(X)) = \mathbb{E}_\lambda[T(X)^2] - \mathbb{E}_\lambda[T(X)]^2 = \varphi(\lambda)(1 - \varphi(\lambda)) = e^{-\lambda}(1 - e^{-\lambda}) > 0$, qui est d'ordre 1 et ne tend pas vers 0 avec n (logique, on a pris qu'une des n observations pour construire T). Ce n'est donc pas un bon estimateur.*

2. Prouver que $S(X) = \sum_{i=1}^n X_i$ est une statistique complète et suffisante pour le modèle. *On pourra utiliser sans démonstration que si $Y_1 \sim \mathrm{Poi}(\lambda_1)$ et $Y_2 \sim \mathrm{Poi}(\lambda_2)$ sont indépendants, alors $Y_1 + Y_2 \sim \mathrm{Poi}(\lambda_1 + \lambda_2)$. Solution. La densité de X (par rapport à $\mu^{\otimes n}$ où μ est la mesure de comptage sur $\mathbb{N}$) s'écrit, pour tout $k \in \mathbb{N}^n$,*

$$p_X(k) = e^{-\lambda n} \prod_{i=1}^n \frac{\lambda^{k_i}}{(k_i)!} = \underbrace{\prod_{i=1}^n \frac{1}{(k_i)!}}_{=:h(k)} \underbrace{e^{-\lambda n + S(k)\log\lambda}}_{=:g_\lambda(S(k))}.$$

$S(X)$ est donc suffisante par le théorème de Neyman-Fisher. Montrons qu'elle est complète. Soit $f : \mathbb{N} \to \mathbb{R}$ telle que pour tout $\lambda > 0$, $\mathbb{E}_\lambda[f(S(X))] = 0$. D'après l'indication, on a que sous $\mathbb{P}_\lambda$, $S(X) \sim \mathrm{Poi}(\lambda n)$, donc ce qui précède équivaut à

$$\forall \lambda > 0,\ e^{-\lambda n} \sum_{k \geq 0} f(k) \frac{(\lambda n)^k}{k!} = 0$$

et par unicité des coefficients de la série entière

$$z \mapsto \sum_{k \geq 0} f(k) \frac{z^k}{k!},$$

de rayon infini, on a pour tout $k \geq 0$, $\frac{f(k)}{k!} = 0$, c'est-à-dire $f(S(X)) = 0$, $\mathcal{M}-$p.s. $S(X)$ est complète.

3. Calculer l'estimateur Rao-Blackwellisé T^* de T par S, et montrer que T^* est UVMB[2] pour l'estimation de $\varphi(\lambda)$. *Solution. Calculons l'espérance conditionnelle de T sachant S. Celle-ci vaut $\mathbb{E}_\lambda[T(X) \,|\, S(X)] = \mathbb{P}_\lambda(X_1 = 0 \,|\, S(X))$. Fixons $s \in \mathbb{N}$ et $\lambda > 0$. On a*

$$\begin{aligned}
\mathbb{P}_\lambda(X_1 = 0 \,|\, S(X) = s) &= \frac{\mathbb{P}_\lambda(X_1 = 0, S(X) = s)}{\mathbb{P}_\lambda(S(X) = s)} \\
&= \frac{\mathbb{P}_\lambda(X_1 = 0, X_2 + \ldots + X_n = s)}{\mathbb{P}_\lambda(S(X) = s)} \\
&= \frac{e^{-\lambda} e^{-\lambda(n-1)} \frac{(\lambda(n-1))^s}{s!}}{e^{-\lambda n} \frac{(\lambda n)^s}{s!}} \\
&= (1 - 1/n)^s.
\end{aligned}$$

On a donc $T^*(X) = (1-1/n)^{S(X)}$. T^* étant le Rao-Blackwellisé de T par S qui est sans biais, complète et suffisante, on sait qu'il est UVMB par le théorème de Lehman-Scheffé.

[1] rappel : c'est la loi telle que pour tout $k \in \mathbb{N}$, $\mathbb{P}(X = k) = e^{-\lambda} \frac{\lambda^k}{k!}$.
[2] UVMB : sans biais et uniformément de variance minimale.

4. Montrer que T^* est UVMB et qu'il est asymptotiquement efficace. *Solution. on sait qu'il est UVMB par Lehman-Scheffé, mais est-il de variance comparable à la borne de Cramer-Rao ? Calculons la. L'information de Fisher vaut $n \times I_1(\lambda) = n/\lambda$ (simple calcul via la vraisemblance). La borne de CR vaut donc $\frac{\varphi'(\lambda)^2}{I(\lambda)} = \frac{\lambda e^{-2\lambda}}{n}$. On utilise ensuite la transformée de Laplace d'une Loi de Poisson : si $X \sim \mathrm{Poi}(\lambda)$, $\mathbb{E}[e^{tX}] = e^{\lambda(e^t-1)}$. Cela donne $\mathbb{E}_\lambda[T^*] = e^{-\lambda}$, on le savait, mais surtout $\mathbb{E}_\lambda[(T^*)^2] = e^{\lambda n \times (e^{2\log(1-1/n)}-1)} = e^{-2\lambda+\lambda/n}$. Cela donne*

$$\mathrm{Var}_\lambda(T^\star) = e^{-2\lambda}(e^{\lambda/n} - 1) \sim \frac{\lambda e^{-2\lambda}}{n}\,.$$

5. Montrer que T^* est fortement consistant. *Solution. $T^* = (1-1/n)^{S_n} = \exp(n\log(1-1/n) \times (S_n/n))$ et on applique la loi des grands nombres.*

6. ($\star$, car un peu technique) Montrer que T^* est asymptotiquement normal en précisant les paramètres asymptotiques. *Solution. Le TCL appliqué à S_n/n, avec $S = S_n$, donne*

$$\sqrt{n}\left(\frac{S_n}{n} - \lambda\right) \to \mathcal{N}(0,\lambda)\,.$$

On aimerait écrire $T^* = g(S_n/n)$, mais ici g dépendrait de n:

$$T^* = (1-1/n)^{S_n} = \exp(n\log(1-1/n) \times (S_n/n))\,.$$

On sait appliquer la méthode Delta à $V_n = \exp(-S_n/n)$, ici $g(x) = \exp(-x)$ et elle donne

$$\sqrt{n}(V_n - e^{-\lambda}) \xrightarrow[n\to\infty]{(d)} -e^{-\lambda}\mathcal{N}(0,\lambda) = \mathcal{N}(0,\lambda e^{-2\lambda})\,.$$

Il ne resterait qu'à montrer que $\sqrt{n}(T^* - V_n) \xrightarrow[n\to\infty]{(d)} 0$ et appliquer le lemme de Slutsky.

Exercice 3.5 (Information de Fisher et identifiabilité locale)**.** Soit $\mathcal{M} = (\mathcal{X}, \mathcal{F}, (\mathbb{P}_\theta)_{\theta\in\Theta})$ modèle paramétrique avec $\Theta \subseteq \mathbb{R}^p$. On dit que $\mathcal{M}$ est *localement identifiable* en $\theta \in \Theta$ si il existe un voisinage U de θ dans Θ tel que

$$\forall \theta' \in U, (\mathbb{P}_{\theta'} = \mathbb{P}_\theta) \implies \theta = \theta'\,.$$

On suppose que le modèle est régulier. On fait une hypothèse supplémentaire, un peu plus forte que la régularité du cours :

(H1) la log-vraisemblance ℓ est deux fois différentiable en θ sur Θ, et ses dérivées secondes sont localement dominées uniformément en θ.

(H2) la Hessienne $\theta \mapsto \nabla^2\ell(\theta, x)$ est localement Lispchitz, uniformément en x au sens ou pour tout $\theta \in \Theta$, il existe V voisinage de θ, $C_\theta > 0$ tels que pour tous $\theta' \in V$, $x \in \mathcal{X}$,

$$-C_\theta\|\theta' - \theta\| \preceq \nabla^2\ell(\theta', x) - \nabla^2\ell(\theta, x) \preceq C_\theta\|\theta' - \theta\|\,.$$

Le but de cet exercice est de démontrer que sous (H1), si l'information de Fisher $I(\theta)$ est inversible en θ, alors le modèle est localement identifiable en θ.

1. Montrer que sous (H1), pour tout $\theta \in \Theta$,

$$I(\theta) = -\mathbb{E}_\theta[\nabla^2\ell(\theta, X)]\,.$$

2. Montrer que pour $\theta \in \Theta$ et $v \in \mathbb{R}^p$ assez petit, un développement de Taylor de $\ell(\theta+v,x)$ autour de $\ell(\theta,x)$ donne

$$\ell(\theta+v,x) = \ell(\theta,x) + v^T\nabla_\theta \ell(\theta,x) + \frac{1}{2}v^T\nabla_\theta^2\ell(\theta,x)v + R(v,\theta,x),$$

avec

$$R(v,\theta,x) = \frac{1}{2}\int_0^1 (1-t)v^\top(\nabla_\theta^2\ell(\theta+tv,x) - \nabla_\theta^2\ell(\theta,x))v\,dt.$$

Pour $\theta,\theta' \in \Theta$, on définit la divergence de Kullback-Leibler entre $\mathbb{P}_\theta$ et $\mathbb{P}_{\theta'}$ par:

$$\mathrm{KL}(\mathbb{P}_\theta\|\mathbb{P}_{\theta'}) := \mathbb{E}_\theta\left[\ell(\theta,X) - \ell(\theta',X)\right].$$

3. Soit $\theta \in \Theta$. Montrer qu'avec ce qui précède, pour v tel que $\|v\|$ est assez petit,

$$\mathrm{KL}(\mathbb{P}_\theta\|\mathbb{P}_{\theta+v}) = v^T I(\theta)v + o(\|v\|^2),$$

où $o(\|v\|^2)$ est une fonction de la forme $\|v\|^2\varepsilon(v)$ tel que $\varepsilon(v) \to 0$ quand $v \to 0$. *On justifiera également que le membre de gauche est bien défini pour v assez petit.* *Solution. Le membre de gauche est bien défini pour v assez petit car Θ est un ouvert de $\mathbb{R}^p$. On a*

$$\mathrm{KL}(\mathbb{P}_\theta\|\mathbb{P}_{\theta+v}) = \int (\ell(\theta,x) - \ell(\theta+v,x))\,L(\theta,x)\,d\nu(x).$$

En substituant le développement limité de $\ell(\theta+v,x)$:

$$\mathrm{KL}(P_\theta\|P_{\theta+v}) = -\int\left(v^T\nabla_\theta\ell(\theta,x) + \frac{1}{2}v^T\nabla_\theta^2\ell(\theta,x)v + R(v,\theta,x)\right)L(\theta,x)\,dx.$$

Le premier terme est nul car le score est centré. Le second terme vaut, d'après la question 1,

$$-\int \frac{1}{2}v^T\nabla_\theta^2\ell(\theta,x)vL(\theta,x)\,dx = -\frac{1}{2}v^T\mathbb{E}_\theta[\nabla_\theta^2\ell(\theta,x)]v = \frac{1}{2}v^T I(\theta)v.$$

Pour le troisième terme, on conclut via (H2) et le TCD.

4. Conclure. *Solution. Nullité de la KL ssi égalité dans Jensen $x\log x \geq 0$ avec égalité ssi $x = 1$.*

5. ($\star$) On se place dans le modèle ou l'on observe X qui a pour loi $\mathcal{N}(a,1)$ avec probabilité $1/2$, et $\mathcal{N}(b,1)$ avec probabilité $1/2$. On se place dans l'espace des paramètres $\Theta = \mathbb{R}^2\backslash\{(a,a), a \in \mathbb{R}\}$. On admet que ce modèle est régulier. Montrer que $I(\theta)$ est inversible en tout point de Θ, mais que le modèle n'est pas identifiable globalement (c'est-à-dire au sens du cours). *Solution. globalement : symétrie $(a,b) \to (b,a)$ mais localement, identifiable dans des intervalles de rayon $< |a-b|/2$ autour de a et de b.*

Exercice 3.6 (Lois de puissance)**.** La loi de puissance de paramètre $\alpha > 1$, notée $\mathrm{Pow}(\alpha)$ ci-après, a pour densité de Lebesgue $f_\alpha : x \mapsto C_\alpha x^{-\alpha}\mathbb{1}_{[1,\infty)}(x)$, où C_α est une constante. On observe $X_1,\dots,X_n$ i.i.d. $\sim \mathrm{Pow}(\alpha)$ où $\alpha > 1$ est inconnu.

1. Calculer C_α pour tout $\alpha > 1$. *Solution. L'intégration montre que $C_\alpha = \alpha - 1$.*

2. Pour $X \sim \mathrm{Pow}(\alpha)$, X a-t-il une espérance finie ? Une variance finie ? Si oui, les donner. *Solution. Espérance finie seulement si $\alpha > 2$, dans ce cas $\mathbb{E}_\alpha[X] = \frac{\alpha-1}{\alpha-2}$, le second moment est fini si et seulement si $\alpha > 3$ et $\mathbb{E}_\alpha[X^2] = \frac{\alpha-1}{\alpha-3}$, et la variance est $\mathrm{Var}_\alpha(X) = \frac{(\alpha-1)[(\alpha-2)^2-(\alpha-1)(\alpha-3)]}{(\alpha-3)(\alpha-2)^2} = \frac{\alpha-1}{(\alpha-3)(\alpha-2)^2}$.*

3. Si $\alpha > 2$, en utilisant le premier moment, fournir un estimateur $\widehat{\alpha}_1$ de α. Montrer que $\widehat{\alpha}_1$ est fortement consistant. *Solution.* $\widehat{\alpha}_1 = \frac{1}{\overline{X}_n - 1} + 2$. *On applique la loi forte des grands nombres pour prouver la forte consistance.*

4. Montrer que l'estimateur du maximum de vraisemblance $\widehat{\alpha}_2$ est donné par :

$$\widehat{\alpha}_2 = 1 + \left(\frac{1}{n} \sum_{i=1}^{n} \log X_i \right)^{-1}.$$

Montrer que $\widehat{\alpha}_2$ est également consistant. *Indice : on peut étudier la distribution de* $\log X_1$ *quand* $X_1 \sim Pow(\alpha)$.

Solution. La log-vraisemblance s'écrit

$$\ell(\alpha, x) = n \log(\alpha - 1) - \alpha \sum \log x_i,$$

qui est concave en α. *Résoudre les conditions du premier ordre donne le résultat désiré. On peut calculer l'espérance de* $\log X_1$ *pour montrer la forte consistance par la loi forte des grands nombres. Mais suivant l'indice, on peut trouver la distribution de* $\log X_1$ *avec une fonction test :*

$$\begin{aligned}
\mathbb{E}_\alpha[\varphi(\log X_1))] &= (\alpha - 1) \int_1^{+\infty} \varphi(\log x) x^{-\alpha} dx \\
&\underset{u = \log x}{=} (\alpha - 1) \int_0^{+\infty} \varphi(u) e^{-u\alpha} e^u du \\
&= \int_0^{+\infty} \varphi(u)(\alpha - 1) e^{-(\alpha-1)u} du,
\end{aligned}$$

ce qui montre que $\log X_1 \sim \mathrm{Exp}(\alpha - 1)$.

5. Montrer que $\widehat{\alpha}_2$ est asymptotiquement normal, et donner les caractéristiques de la loi limite. Faire de même pour $\widehat{\alpha}_2$ sous une hypothèse appropriée sur α.

6. Sur la base des résultats précédents, quel estimateur préféreriez-vous pour n grand ?

7. Déterminer l'information de Fisher $I(\alpha)$. Comparer avec les résultats précédents. Que pouvez-vous en conclure ? *Solution.* $\ell(\alpha, x) = n \log(\alpha - 1) - \alpha \sum_i^n \log x_i$ *et* $\dot{\ell}(\alpha, x) = \frac{n}{\alpha - 1} - \sum_i^n \log x_i$, *et* $I(\alpha) = \mathrm{Var}_\alpha(\dot{\ell}(\alpha, X)) = \frac{n}{(\alpha-1)^2}$, *sachant que* $\log X_1 \sim \mathrm{Exp}(\alpha - 1)$. *On voit que l'estimateur MV atteint la borne de Cramér-Rao asymptotiquement.*

Exercice 3.7 (Non-existence d'un UVMB)**.** L'objet de cet exercice est l'étude d'un exemple où des estimateurs sans biais existent, mais où il n'existe pas d'estimateur sans biais de variance uniformément minimale (UVMB). Soit X prenant ses valeurs dans $\{-1, 0, 1, 2, \ldots\}$ avec la distribution suivante de paramètre $p \in (0, 1)$: $\mathbb{P}_p(X = -1) = p$, $\mathbb{P}_p(X = k) = (1 - p)^2 p^k$, $k = 0, 1, 2, \ldots$ On cherche à estimer p.

1. Montrer que $\mathbb{1}_{\{X=-1\}}$ est un estimateur sans biais de p. *Solution. Oui,* $\mathbb{1}_{\{X=-1\}}$ *est sans biais puisque* $\mathbb{E}_p[\mathbb{1}_{\{X=-1\}}] = \mathbb{P}_p(X = -1) = p$.

2. Montrer que la classe de tous les estimateurs sans biais de p est un espace affine de dimension 1 que vous décrirez. *Solution. On commence par caractériser l'ensemble des estimateurs sans biais de zéro,* $\mathcal{U}_0$, *et on montre que* $U(k) = -kU(-1)$ *pour tout* $k \geq 0$. *Maintenant, comme tout estimateur sans biais peut s'écrire comme* $\mathbb{1}_{\{X=-1\}} + U$ *avec* $U \in \mathcal{U}_0$, *en posant* $U(-1) = a$, *on obtient la forme:*

$$T_a(X) = (1 + a)\mathbb{1}_{\{X=-1\}} - aX\mathbb{1}_{\{X \geq 0\}},$$

ou

$$T_a(X) = \mathbb{1}_{\{X=-1\}} - aX\,.$$

La synthèse découle de ce que $\mathbb{E}_p[X]$ est toujours nul.

3. Pour $p \in (0,1)$, trouver T estimateur non biaisé de p qui minimise $\mathrm{Var}_p(T)$. *On donne, pour $|p| < 1$,*

$$\sum_{k=0}^{+\infty} k^2 p^k = \frac{p(1+p)}{(1-p)^3}\,.$$

<u>Solution.</u> On minimise : $\mathrm{Var}_p(T_a) = \mathbb{E}_p(T_a^2) = (1+a)^2 p + (1-p)^2 a^2 \sum_{k=0}^{\infty} k^2 p^k = (1+a)^2 p + a^2 \frac{p(p+1)}{1-p}$. En dérivant par rapport à a et en annulant la dérivée, on obtient : $a = -\frac{p}{p+\frac{p(p+1)}{1-p}} = -\frac{1-p}{2}$. Ainsi, l'optimal a dépend de p.

4. Conclure qu'il n'existe pas d'UVMB pour p.

Exercice 3.8 (Fonctions estimables sans biais)**.** On travaille dans un modèle paramétrique et l'on note $\mathcal{U}$ l'ensemble des fonctions de θ à valeurs dans $\mathbb{R}^\ell$ qui sont estimables sans biais, c'est-à-dire

$$\mathcal{U} := \left\{\varphi : \Theta \to \mathbb{R}^\ell, \exists T : \mathcal{X} \to \mathbb{R}^\ell \text{ mesurable, intégrable, t.q.}, \forall \theta \in \Theta, \mathbb{E}_\theta[T(X)] = \varphi(\theta)\right\}.$$

1. Montrer que $\mathcal{U}$ est un sous-espace vectoriel du $\mathbb{R}-$espace vectoriel des fonctions de Θ dans $\mathbb{R}^\ell$.

2. Montrer que si $\mathcal{X}$ est fini, alors $\dim \mathcal{U} \leq |\mathcal{X}|$.

Dans toute la fin de l'exercice, on se place dans le modèle à une seule observation $X \sim \mathrm{Unif}([0,\theta])$, avec $\theta > 0$ inconnu. On considère le cas $\ell = 1$.

3. ($\star$) Montrer que

$$\mathcal{U} = \left\{\varphi : \mathbb{R}_+^* \to \mathbb{R}, \varphi \text{ absolument continue}\right\}.$$

on pourra utiliser le théorème fondamental du calcul intégral (de Lebesgue): pour $f : [a,b] \to \mathbb{R}$ Lebesgue-intégrable sur $[a,b]$ et $F : x \mapsto \int_a^x f(t)\,dt$, F est absolument continue donc dérivable presque partout sur $[a,b]$ et, pour presque tout $x \in [a,b]$, $F'(x) = f(x)$. <u>Solution.</u> Si $\varphi \in \mathcal{U}$ alors pour tout $\theta > 0$, $\varphi(\theta) = \frac{1}{\theta}\int_0^\theta T(x)dx$. Par le théorème de Lebesgue, φ est absolument continue. Réciproquement, si φ est absolument continue, alors $x \mapsto x\varphi(x)$ l'est aussi, et est dérivable presque partout. En posant $T(x) = [x\varphi(x)]' = \varphi(x) + x\varphi'(x)$ quand cela existe, et 0 ailleurs, T estime $\varphi(\theta)$ sans biais. Notons qu'une fonction discontinue avec un saut, comme $\mathbb{1}_{\theta>1}$ n'est pas dans $\mathcal{U}$, car pas absolument continue. Si elle l'était, elle serait égale à l'intégrale de sa dérivée, c'est à dire 0, absurde.

4. Intervalles et régions de confiance

Exercice 4.1 (Intervalles de confiance dans le modèle i.i.d. uniforme)**.** On se place dans le modèle où $(X_n)_{n\geq 1}$ sont i.i.d. de loi $\mathrm{Unif}([0,\theta])$, avec $\theta > 0$ inconnu. Pour tout $n \geq 1$, on définit $M_n := \max(X_1, \dots, X_n)$.

1. Montrer que pour tout $n \geq 1$, $h_n(X,\theta) := \left(\frac{M_n}{\theta}\right)^n$ est pivotale. *Solution. Trouvons la loi de $h_n(X,\theta) := \left(\frac{M_n}{\theta}\right)^n$. On note que presque sûrement, $0 \leq h_n(X,\theta) \leq 1$. Pour tout $0 \leq u \leq 1$, $\mathbb{P}(h_n(X,\theta) \leq u) = \mathbb{P}(M_n \leq u^{1/n}\theta) = (u^{1/n}\theta/\theta)^n = u$, donc $h_n(X,\theta) \sim \mathrm{Unif}([0,1])$: c'est une quantité pivotale (ou un pivot).*

2. Soit $\alpha \in]0,1[$. Déduire de ce qui précède un intervalle de confiance $I^{(1)}_{\alpha,n}$ de probabilité de couverture $1-\alpha$ pour θ basé sur M_n. *Solution. On applique la méthode pivotale : pour tout $\theta > 0$, $1-\alpha = \mathbb{P}_\theta(h_n(X,\theta) \in [\alpha,1]) = \mathbb{P}_\theta(\theta \in [M_n, M_n\alpha^{-1/n}])$, ce qui donne l'intervalle de confiance $I^{(1)}_{\alpha,n} = [M_n, M_n\alpha^{-1/n}]$ avec les propriétés désirées.*

3. Trouver un équivalent presque sûr du diamètre de $I^{(1)}_{\alpha,n}$ lorsque $n \to \infty$, à $\alpha \in]0,1[$ fixé. *On pourra réutiliser le fait que $M_n \to \theta$ $\mathcal{M}-p.s.$ Solution. Le diamètre de $I^{(1)}_{\alpha,n}$ est $M_n(\alpha^{-1/n}-1) \sim \frac{M_n}{n}\log(1/\alpha)$, ce qui est presque sûrement équivalent à $\frac{\theta}{n}\log(1/\alpha)$ (on a déjà vu que $M_n \to \theta$ $\mathcal{M}-p.s.$)*

4. Montrer que sous $\mathbb{P}_\theta$,
$$n(1-M_n/\theta) \xrightarrow[n\to\infty]{(d)} \mathrm{Exp}(1).$$
Solution. Avec la fonction de répartition, on obtient pour tout $u \geq 0$,
$$\mathbb{P}_\theta(n(1-M_n/\theta) \geq u) = \mathbb{P}_\theta(M_n \leq \theta - u\theta/n) = \left(\frac{\theta - u\theta/n}{\theta}\right)^n = (1-u/n)^n \to e^{-u},$$
ce qui prouve la convergence en loi désirée.

5. Calculer *explicitement* la fonction quantile de la loi $\mathrm{Exp}(1)$. *Solution. Si $X \sim \mathrm{Exp}(1)$, alors pour tout $t \geq 0$, $F_X(t) = 1-e^{-t}$, et $\alpha = F_X(t) \iff t = \log(1/(1-\alpha)) =: q_\alpha$.*

6. Déduire des deux questions précédentes un intervalle de confiance asymptotique $I^{(2)}_{\alpha,n}$ de probabilité de couverture $1-\alpha$ pour θ, basé sur M_n. *Solution. D'après les questions 4 et 5, pour tout $\alpha \in]0,1[$, lorsque $n \to \infty$, pour tout $\theta > 0$,*
$$\mathbb{P}_\theta\left(M_n \leq \theta \leq \frac{M_n}{1-\frac{1}{n}\log\alpha}\right) = \mathbb{P}_\theta\left(n(1-M_n/\theta) \leq \log(1/\alpha)\right) \to 1-\alpha,$$
donc l'intervalle $I^{(2)}_{\alpha,n} = \left[M_n, \frac{M_n}{1-\frac{1}{n}\log\alpha}\right]$ convient.

7. Trouver un équivalent presque sûr du diamètre de $I^{(2)}_{\alpha,n}$ lorsque $n \to \infty$, à $\alpha \in]0,1[$ fixé. Comparer avec le résultat de la question 3. *Solution. On obtient exactement le même équivalent qu'en question 3.*

Exercice 4.2 (Concentration et intervalles de confiance dans le modèle de Poisson)**.** On suppose que les $(X_n)_{n\geq 1}$ sont i.i.d. $\mathrm{Poi}(\lambda)$ avec $\lambda > 0$.

1. En utilisant l'inégalité de Bienaymé-Tchebychev, dérivez un intervalle de confiance (non asymptotique) pour λ avec une probabilité de couverture $1-\alpha$. *Solution. L'inégalité*

de B-T donne, pour tout $t > 0$,

$$\mathbb{P}\left(\left|\frac{1}{n}\sum_{i=1}^{n} X_i - \lambda\right| \geq t\right) \leq \frac{\lambda}{nt^2},$$

et le côté droit est égal à α pour $t = \sqrt{\lambda/(n\alpha)}$. Il faut résoudre pour λ l'inégalité

$$\begin{aligned}
\left|\bar{X}_n - \lambda\right| < \sqrt{\lambda/(n\alpha)} &\iff \lambda^2 - \lambda\left(2\bar{X}_n + \frac{1}{n\alpha}\right) + \bar{X}_n^2 < 0 \\
&\iff \lambda \in \left[\bar{X}_n - \frac{1}{n\alpha} \pm \sqrt{\frac{\bar{X}_n}{n\alpha} + \frac{1}{4(n\alpha)^2}}\right],
\end{aligned}$$

ce qui donne l'intervalle de confiance :

$$\left[\bar{X}_n - \frac{1}{n\alpha} \pm \sqrt{\frac{\bar{X}_n}{n\alpha} + \frac{1}{4(n\alpha)^2}}\right].$$

2. En utilisant le théorème central limite, trouvez un intervalle de confiance asymptotique pour λ avec une probabilité de couverture $1 - \alpha$. *Solution. Le théorème central limite donne*

$$\sqrt{n}\frac{\bar{X}_n - \lambda}{\sqrt{\lambda}} \xrightarrow[n\to\infty]{(d)} \mathcal{N}(0,1)$$

et il y a deux façons de procéder. Soit on applique le lemme de Slutsky, qui implique que

$$\sqrt{n}\frac{\bar{X}_n - \lambda}{\sqrt{\bar{X}_n}} \xrightarrow[n\to\infty]{(d)} \mathcal{N}(0,1),$$

ce qui donne un intervalle de confiance asymptotique de la forme

$$\left[\bar{X}_n \pm \frac{\sqrt{\bar{X}_n} q_{1-\alpha/2}}{\sqrt{n}}\right],$$

soit on résout

$$\begin{aligned}
\sqrt{n}|\bar{X}_n - \lambda|/\sqrt{\lambda} < q &\iff \lambda^2 - \lambda\left(2\bar{X}_n + \frac{q^2}{n}\right) + \bar{X}_n^2 < 0 \\
&\iff \lambda \in \left[\bar{X}_n - \frac{q^2}{n} \pm \sqrt{\frac{\bar{X}_n q^2}{n} + \frac{q^4}{4n^2}}\right],
\end{aligned}$$

ce qui donne un autre intervalle de confiance en prenant $q = q_{1-\alpha/2}$. On observe que les extrémités de ces intervalles sont équivalentes lorsque n est grand.

Exercice 4.3 (Ellipsoïdes contre Bonferroni)**.** Nous reprenons l'exemple du cours du modèle gaussien i.i.d. dans $\mathbb{R}^p$ avec $X_1, \ldots X_n$ i.i.d. $\mathcal{N}(\mu, \Sigma^2)$. On suppose Σ connu. On a défini deux régions de confiances données par

$$C_\alpha^{(1)}(X) = \prod_{j=1}^{p}\left[[\bar{X}_n]_j \pm \frac{\sqrt{\Sigma_{jj}} z_{1-\frac{\alpha}{2p}}}{\sqrt{n}}\right],$$

et

$$C_\alpha^{(2)}(X) = \left\{\mu \in \mathbb{R}^p : n(\bar{X}_n - \mu)^T \Sigma^{-1}(\bar{X}_n - \mu) \leq q_{1-\alpha}^{(p)}\right\}.$$

On rappelle que z_β (resp. $q_\beta^{(p)}$) désigne le quantile d'ordre $\beta \in]0,1[$ de la distribution $\mathcal{N}(0,1)$ (resp. $\chi^2(p)$). Le but de cet exercice est de comparer les volumes de ces deux régions de confiance, lorsque p grandit.

On note Φ la fonction de répartition d'une loi normale standard, et on admettra que

$$1-\Phi(x) \underset{x\to+\infty}{\sim} \frac{1}{\sqrt{2\pi}x}e^{-x^2/2}\,.$$

1. Montrer que lorsque $\beta \to 0$,
$$z_{1-\beta} \sim \sqrt{2\log(1/\beta)}\,.$$

   Solution. Comme Φ est continue, on a par définition
$$1-\Phi(z_{1-\beta}) = \beta\,.$$
   Lorsque $\beta \to 0$, il est clair que $z_{1-\beta} \to +\infty$ et d'après l'équivalent donné dans l'énoncé :
$$\beta = 1-\Phi(z_{1-\beta}) \sim \frac{1}{\sqrt{2\pi}z_{1-\beta}}e^{-z_{1-\beta}^2/2}\,.$$
   Les termes tendent vers 0, on peut passer au log *dans l'équivalent:*
$$\log(\beta) \sim -\log(\sqrt{2\pi}z_{1-\beta}) - z_{1-\beta}^2/2,$$
   et comme $z_{1-\beta} \to +\infty$, on ne garde que le terme dominant, soit $\log(\beta) \sim -z_{1-\beta}^2/2$, ce qui donne bien
$$z_{1-\beta} \sim \sqrt{2\log(1/\beta)}\,.$$

2. En utilisant le théorème central limite, montrer que pour $\alpha \in]0,1[$ fixé, lorsque $p \to +\infty$,
$$q_{1-\alpha}^{(p)} = p + \sqrt{2p}z_{1-\alpha} + o(\sqrt{p})\,.$$

   Solution. Ecrire simplement $\chi^2(p) \sim p + \sqrt{2p}\mathcal{N}(0,1)$ en loi lorsque $p \to \infty$.

On note Leb la mesure de Lebesgue dans $\mathbb{R}^p$. On donne la formule suivante, qui résulte d'un changement de variable en intégration. Pour $\mathcal{E}$ une ellipsoide définie par

$$\mathcal{E} := \left\{y \in \mathbb{R}^p,\ (y-y_0)^T M^{-1}(y-y_0) \le 1,\right\}$$

avec $M \in \mathbb{R}^{p\times p}$ symétrique définie positive, $\mathrm{Leb}(\mathcal{E}) = \sqrt{\det M} \times V_p$, où V_p est le volume de la boule unité dans $\mathbb{R}^p$, donné par $V_p = \frac{\pi^{p/2}}{\Gamma(p/2+1)}$.

3. Prenons $\alpha \in]0,1[$ fixé. Montrer que
$$\frac{\mathrm{Leb}(C_\alpha^{(2)}(X))}{\mathrm{Leb}(C_\alpha^{(1)}(X))} = \frac{\pi^{p/2}\sqrt{\det(\Sigma)}(q_{1-\alpha}^{(p)})^{p/2}}{\Gamma(p/2+1)\prod_{j=1}^p \sqrt{\Sigma_{jj}}\left(2z_{1-\alpha/(2p)}\right)^p}$$

4. En déduire que lorsque $p \to +\infty$,
$$\log\frac{\mathrm{Leb}(C_\alpha^{(2)}(X))}{\mathrm{Leb}(C_\alpha^{(1)}(X))} \le -(1+o(1))\frac{p}{2}\log\log p\,.$$

   Commenter. *Solution. Notons $\Delta = \frac{\mathrm{Leb}(C_\alpha^{(2)}(X))}{\mathrm{Leb}(C_\alpha^{(1)}(X))}$. On a, en utilisant l'inégalité d'Hadamard,*

Stirling et ce qui précède,

$$\begin{aligned}\log \Delta &\leq \frac{p}{2}\log \pi + \frac{p}{2}\log(p+\sqrt{2p}z_{1-\alpha}+o(\sqrt{p})) - \frac{p}{2}\log(p/2) + \frac{p}{2} + o(p) - p\log 2 - \frac{p}{2}\log\log(2p/\alpha)\\ &= \frac{p}{2}\log p - \frac{p}{2}\log p + O(p) - \frac{p}{2}\log\log p\\ &= -(1+o(1))\frac{p}{2}\log\log p\,.\end{aligned}$$

Le rapport des volumes décroit super-exponentiellement lorsque p est grand. L'ellipsoïde est clairement de volume moindre que le pavé.

Exercice 4.4 (Quantile et optimisation)**.** Soit X une variable aléatoire réelle intégrable de fonction de répartition F. On fixe $\alpha \in]0,1[$. On considère la fonction ψ définie sur $\mathbb{R}$ par

$$\psi_\alpha : t \mapsto \mathbb{E}\left[\alpha(X-t)_+ + (1-\alpha)(t-X)_+\right],$$

où $(x)_+ = \max(x,0)$.

1. Montrer que la fonction ψ_α est bien définie, continue et convexe sur $\mathbb{R}$. *Solution. bien définie et continue par domination sur tout compact $[0,T]$: par $\alpha X + T$ qui est bien intégrable. Convexe, car le max de deux fonctions convexe est convexe, et que toutes les fonctions affines sont convexes.*

2. Montrer que ψ_α est coercive, i.e. que

$$\psi_\alpha(t) \underset{t\to\pm\infty}{\longrightarrow} +\infty\,.$$

   Solution. Pour $t \geq 0$ on pourra remarquer que $\psi_\alpha(t) \geq (1-\alpha)t\mathbb{P}(X \leq t) - \mathbb{E}[X]$, et pour $t \leq 0$ on a $\psi_\alpha(t) \geq \alpha\mathbb{E}[X] - t\mathbb{P}(X \geq t)$.

3. En déduire que ψ_α admet au moins un minimiseur, et que tout minimiseur u de ψ_α vérifie :

$$F(u) \geq \alpha \quad \text{et} \quad F(u^-) \leq \alpha,$$

   où $F(u^-)$ désigne la limite à gauche de F en u. *Solution. Toute fonction convexe coercive et continue admet au moins un minimiseur.*

4. Comment relier le quantile q_α à l'ensemble des minimiseurs de ψ_α ? *Solution. Il suffit de prendre l'inf, pardi.*

5. Tests d'hypothèses

Exercice 5.1 (Test du temps d'attente du RER B)**.** Nous analysons le temps d'attente du train RER B à la station Orsay-Ville, dont on soupçonne qu'il est supérieur à 5 minutes en espérance. Soit X la variable aléatoire modélisant le temps d'attente en minutes. Il est courant de supposer que $X \sim \mathrm{Exp}(1/\theta)$, où $\theta > 0$ représente le temps d'attente moyen (on rappelle que $\mathbb{E}_\theta[X] = \theta$).

Nous voulons tester si $\theta = 5$ afin de vérifier notre soupçon. Pour cela, nous répétons l'expérience n fois indépendamment et nous notons les temps d'attente obtenus $(X_1, \ldots, X_n)$. Pour $n = 10$, les temps d'attente observés sont :

$$(4, 10, 3, 8, 7, 12, 9, 11, 6, 2).$$

Soit q_α le quantile d'ordre α de la loi Binomiale $\mathrm{Bin}(10, 1/e)$. On donne $q_{0.025} = 1$, $q_{0.95} = 6$, et $q_{0.975} = 7$. Nous notons $S(X) := \sum_{i=1}^n \mathbb{1}_{X_i > 5}$.

1. Proposer un test de niveau $\alpha = 0.05$ pour $\mathcal{H}_0 : \theta \leq 5$ contre $\mathcal{H}_1 : \theta > 5$ basé sur la statistique $S(X)$. Quelle est la décision du test avec nos données ?

   Solution. Sous $\mathbb{P}_\theta$, la statistique de test $S(X) = \sum_{i=1}^n \mathbf{1}_{X_i > 5}$ suit une loi $\mathrm{Bin}(n, p(\theta))$, où $p(\theta) = \mathbb{P}_\theta(X_1 > 5) = e^{-5/\theta}$. Si $\mathcal{H}_1$ est vraie, $S(X)$ est censée prendre des valeurs plus grandes que sous $\mathcal{H}_0$. Nous fixons une région de rejet de la forme $\{S > z\}$ avec z choisi de sorte que notre test soit de niveau α, c'est-à-dire

   $$\sup_{\theta \leq 5} \mathbb{P}_\theta(S > z) \leq \alpha.$$

   Puisque pour tout θ, $\mathbf{1}_{X_i > 5} \sim B(p(\theta))$, on peut l'écrire comme $\mathbf{1}_{X_i > 5} = \mathbf{1}_{U_i \leq p(\theta)}$ où $U_i \sim \mathrm{Unif}([0, 1])$. Par conséquent,

   $$\mathbb{P}_\theta(T > z) = \mathbb{P}\left(\sum_{i=1}^n \mathbf{1}_{U_i \leq p(\theta)} > z\right).$$

   Comme $p(\theta) = e^{-5/\theta}$ est croissante en θ, on en déduit que

   $$\sup_{\theta \leq 5} \mathbb{P}_\theta(S > z) = \mathbb{P}_{\theta=5}(S > z).$$

   Ainsi, nous choisissons z comme le quantile d'ordre 0.95 de la loi $\mathrm{Bin}(10, 1/e)$, ce qui donne la région de rejet $\{S > 6\}$. Avec nos données, nous observons $S(\omega) = 7$, donc nous rejetons $\mathcal{H}_0$. Nous concluons que le temps d'attente est supérieur à 5 minutes, avec au plus 5% de probabilité d'erreur de type I.

2. Proposer un test de niveau $\alpha = 0.05$ pour $\mathcal{H}_0 : \theta = 5$ contre $\mathcal{H}_1 : \theta \neq 5$ basé sur la statistique $S(X)$. Quelle est la décision du test avec nos données ?

   Solution. En suivant une approche similaire, puisque nous considérons maintenant une alternative bilatérale, nous fixons une région de rejet de la forme

   $$\{S < q_1\} \cup \{S > q_2\}$$

   avec $q_1 < q_2$, assurant un rejet pour des valeurs à la fois grandes et petites de S. Nous choisissons q_1 et q_2 tels que

   $$\alpha \geq \mathbb{P}_{\theta=5}(S < q_1) + \mathbb{P}_{\theta=5}(S > q_2).$$

   En prenant $q_1 = q_{0.025}$ et $q_2 = q_{0.975}$, l'inégalité ci-dessus est vérifiée pour $\alpha = 0.05$.

On obtient la région de rejet $\{S = 0\} \cup \{S > 7\}$. Or, comme nous observons $S(\omega) = 7$, nous ne rejetons pas $\mathcal{H}_0$. Nous concluons que le temps d'attente est de 5 minutes, avec une probabilité inconnue d'erreur de type II.

3. Discuter les résultats obtenus aux questions précédentes.

   Solution. À la question 1, nous avons conclu que $\theta > 5$, tandis qu'à la question 2 nous avons conclu que $\theta = 5$. Cela peut sembler contradictoire mais est en réalité cohérent. Soit ψ_1 le test de la question 1 et ψ_2 le test de la question 2. Le test ψ_2 est conçu pour les hypothèses $\mathcal{H}_0 : \theta = 5$ contre $\mathcal{H}_1 : \theta \neq 5$, et il est nécessairement moins puissant que ψ_1 lorsque $\theta > 5$. En effet, ψ_2 doit aussi être puissant lorsque $\theta < 5$, alors que ψ_1 n'en a pas besoin. Par conséquent, pour $\theta > 5$, ψ_2 a une probabilité plus élevée de commettre une erreur de type II que ψ_1. Il est probable que ψ_2 ait effectivement commis ici une erreur de type II.

Exercice 5.2 (Test du rapport de vraisemblance dans le modèle uniforme)**.** Nous considérons le modèle où $X_1, \ldots, X_n$ sont i.i.d. uniformément distribuées sur $[0, \theta]$. Nous cherchons à tester :

$$\mathcal{H}_0 : \theta = \theta_0 \quad \text{contre} \quad \mathcal{H}_1 : \theta \neq \theta_0.$$

1. Calculer la statistique du rapport de vraisemblance associée à ce test. Nous adoptons la convention que $\frac{1}{0} = +\infty$.

   Solution. Pour un θ donné, la vraisemblance de l'échantillon s'écrit

$$L(X_1, \ldots, X_n, \theta) = \frac{1}{\theta^n} \mathbb{1}_{0 \leq \max X_i \leq \theta}$$

   La statistique du rapport de vraisemblance (généralisé) est donc :

$$\begin{aligned} T &= \frac{\sup_{\theta \neq \theta_0} L(X_1, \ldots, X_n, \theta)}{L(X_1, \ldots, X_n, \theta_0)} = \frac{\frac{1}{(\max X_i)^n}}{\frac{1}{\theta_0^n} \mathbb{1}_{0 \leq \max X_i \leq \theta_0}} \\ &= \left(\frac{\theta_0}{\max X_i} \right)^n \mathbb{1}_{\max X_i \leq \theta_0} + (+\infty) \mathbb{1}_{\max X_i > \theta_0}. \end{aligned}$$

2. Soit $\alpha \in]0, 1[$. Montrer que le test du rapport de vraisemblance de niveau α pour $\mathcal{H}_0$ contre $\mathcal{H}_1$ s'écrit $\psi(X) = \mathbb{1}_{\max X_i < \tau_0} + \mathbb{1}_{\max X_i > \tau_1}$, pour $\tau_0 < \tau_1$ que l'on précisera. *Solution. Le test est de la forme $\psi = \mathbb{1}_{T > t}$ avec t déterminé par le niveau α. On a*

$$\begin{aligned} &\mathbb{P}_0(\psi = 1) \\ &= \mathbb{P}_0(+\infty > t) \mathbb{P}_0(\max X_i > \theta_0) + \mathbb{P}_0 \left(\left(\frac{\theta_0}{\max X_i} \right)^n > t \,|\, \max X_i \leq \theta_0 \right) \mathbb{P}_0(\max X_i \leq \theta_0) \\ &= 0 + \mathbb{P}_0 \left(\max X_i < \theta_0 t^{-1/n} \right) = 1/t, \end{aligned}$$

   ce qui est égal à α si $t = 1/\alpha$. Le test du rapport de vraisemblance est donc

$$\psi = \mathbb{1}_{T > 1/\alpha} = \mathbb{1}_{\max X_i < \theta_0 \alpha^{1/n}} + \mathbb{1}_{\max X_i > \theta_0}.$$

3. En utilisant la dualité entre tests d'hypothèses et régions de confiance, déduire une région de confiance pour θ de niveau $1 - \alpha$. Vérifier que l'on retrouve l'intervalle de confiance établi dans un exercice précédent. *Solution. Grâce à la dualité entre tests*

d'hypothèses et régions de confiance, on sait qu'une région de confiance pour θ de niveau $1-\alpha$ est donnée par

$$\left\{\theta \in \mathbb{R}_+, \theta\alpha^{1/n} \leq \max X_i \leq \theta_0\right\} = [\max X_i, (\max X_i)\alpha^{-1/n}],$$

qui est le même intervalle de confiance que celui obtenu dans un exercice précédent.

Exercice 5.3 (Test optimal pour la loi exponentielle)**.** Soient $X_1, \ldots, X_n$ des variables aléatoires i.i.d. de loi exponentielle de paramètre[3] $\lambda > 0$. On souhaite tester les hypothèses simples $\mathcal{H}_0 : \lambda = \lambda_0$ contre $\mathcal{H}_1 : \lambda = \lambda_1$ avec $\lambda_1 > \lambda_0$.

On donne la propriété suivante : la somme de n variables aléatoires indépendantes de loi exponentielle de paramètre $\lambda = 1$ suit une loi Gamma $\Gamma(n, 1)$, dont on notera $\gamma_{n,\beta}$ le quantile d'ordre β.

1. Déterminer un test uniformément plus puissant de niveau $\alpha \in]0, 1[$ (UPP(α)) pour ce problème (on montrera qu'il est p.p. unique). Montrer que c'est le test dont la région de rejet peut s'écrire
$$\mathcal{R} = \left\{\sum_{i=1}^n X_i < u\right\},$$
où u est une constante dépendant a priori de $\lambda_0, \lambda_1, \alpha$ et n, dont on ne demande pas l'expression dans cette question. hhhh *Solution. On est dans le cadre d'application du théorème de Neyman-Pearson: un test UPP(α) a une région de rejet de la forme $\mathcal{R} = \{T(X) > t\}$, où T est le rapport de vraisemblance, donné par :*
$$T(X) = \frac{L(\lambda_1, X)}{L(\lambda_0, X)} = \left(\frac{\lambda_1}{\lambda_0}\right)^n \exp\left(-(\lambda_1 - \lambda_0)\sum_{i=1}^n X_i\right).$$
La loi de T étant continue, t est uniquement déterminé par le fait que le test soit de taille α. Un tel test est donc p.p. unique. A λ_0, λ_1 fixé, T est une fonction décroissante de $\sum_{i=1}^n X_i$. On peut donc réexprimer la région de rejet :
$$\mathcal{R} = \{T(X) > t\} = \left\{\sum_{i=1}^n X_i < u\right\},$$
avec u dépendant de t, λ_0, λ_1 et donc de $\lambda_0, \lambda_1, \alpha$.

2. Montrer que sous $\mathcal{H}_0$, $\lambda_0 X_1 \sim \text{Exp}(1)$. En déduire la valeur de u en fonction de $\lambda_0, \lambda_1, \alpha$ et n. *Solution. L'égalité en loi se prouve classiquement via la fonction de répartition. Ensuite, sous $\mathcal{H}_0$, comme $\lambda_0 \sum_{i=1}^n X_i \sim \Gamma(n, 1)$, pour avoir un test de taille α, on doit avoir $\alpha = \mathbb{P}_0(\lambda_0 \sum_{i=1}^n X_i < \lambda_0 u)$, c'est-à-dire $\lambda_0 u = \gamma_{n,\alpha}$, d'où $u = \frac{1}{\lambda_0}\gamma_{n,\alpha}$.*

3. On notera F_n la fonction de répartition de la loi $\Gamma(n, 1)$. Exprimer la puissance $\pi(\lambda_1)$ du test précédent pour toute valeur de $\lambda_1 > \lambda_0$, en fonction de F_n. Commenter sa monotonie en λ_1.

   Solution. Rappelons que la puissance du test est l'inf des probabilités de rejeter $\mathcal{H}_0$ sous l'hypothèse alternative $\mathcal{H}_1$. Ici, $\mathcal{H}_1$ est une bypothèse simple. Cette puissance vaut :
$$\pi(\lambda_1) = \mathbb{P}_1\left(\sum_{i=1}^n X_i < \frac{\gamma_{n,\alpha}}{\lambda_0}\right) = \mathbb{P}_1\left(\lambda_1 \sum_{i=1}^n X_i < \frac{\lambda_1}{\lambda_0} \cdot \gamma_{n,\alpha}\right) = F_n\left(\frac{\lambda_1}{\lambda_0} \cdot \gamma_{n,\alpha}\right).$$

[3] on rappelle que c'est loi à densité $x \mapsto \mathbb{1}_{x \geq 0}\lambda e^{-\lambda x}$.

La dernière égalité est obtenue par un raisonnement similaire à la question 2 : sous $\mathcal{H}_1$, $\lambda_1 \sum X_i \sim \Gamma(n,1)$. Notons que cette puissance est croissante en λ_1, ce qui est cohérent avec le fait que la puissance augmente lorsque λ_1 s'éloigne de λ_0 (il est alors plus facile de les distinguer).

4. Montrer (à la main) que le test de la question précédente est en fait UPP(α) pour tester $\mathcal{H}_0 : \lambda = \lambda_0$ contre $\mathcal{H}_1' : \lambda > \lambda_0$.

   Solution. $\mathcal{H}_1'$ n'est plus une hypothèse simple, on peut pas appliquer Neyman-Pearson. On fait la démonstration à la main. Notons $\psi(X) = \mathbb{1}_{\sum_{i=1}^n X_i < \lambda_0/\gamma_{n,\alpha}}$ le test de la question 1. Soit ψ' un test pour $\mathcal{H}_0$ contre $\mathcal{H}_1'$, de niveau α. Fixons $\lambda_1 > \lambda_0$. Comme le niveau ne dépend que de $\mathcal{H}_0$, ψ' est encore de niveau α pour $\mathcal{H}_0$ contre $\mathcal{H}_1 : \lambda = \lambda_1$. Or, comme ψ est UPP(α) pour $\mathcal{H}_0$ contre $\mathcal{H}_1$, la puissance de ψ' est inférieure à celle de ψ dans ce nouveau problème :

$$\mathbb{E}_{\lambda_1}[\psi'(X)] \leq \mathbb{E}_{\lambda_1}[\psi(X)]$$

   On a montré que

$$\forall \lambda_1 > \lambda_0,\ \mathbb{E}_{\lambda_1}[\psi'(X)] \leq \mathbb{E}_{\lambda_1}[\psi(X)]$$

   ce qui montre bien que ψ est UPP(α) pour $\mathcal{H}_0$ contre $\mathcal{H}_1'$.

Exercice 5.4 (Théorème de Karlin-Rubin)**.** Dans cet exercice, on montre une extension du théorème de Neyman-Pearson au cas où le rapport de vraisemblance est monotone.

On se place dans le cadre du cours où $\mathcal{M}$ est un modèle où la vraisemblance $L(\theta, X)$ est bien définie. Soit $\preceq$ une relation d'ordre sur Θ. On suppose qu'il existe une statistique $T(X)$ à valeurs réelles, telle que pour tous $\theta, \theta' \in \Theta$ vérifiant $\theta \preceq \theta'$, il existe $A_{\theta,\theta'} : \mathbb{R} \to \mathbb{R}_+ \cup \{+\infty\}$ croissante[4] telle que

$$\forall x \in \mathcal{X},\ \frac{L(\theta', x)}{L(\theta, x)} = A_{\theta,\theta'}(T(x)),$$

avec la convention $1/0 = +\infty$. On dit que le modèle est *à rapport de vraisemblance monotone.*

Pour $t \in \mathbb{R}, c \in [0,1]$, on note $\psi_{t,c}$ le test randomisé :

$$\psi_{t,c}(X) = \mathbb{1}_{T(X)>t} + c\mathbb{1}_{T(X)=t},$$

Soient $t \in \mathbb{R}, c \in [0,1]$. On se donne d'abord θ dans Θ, tel que $0 < \mathbb{E}_\theta[\psi_{t,c}(X)] < 1$, ainsi que $\theta' \succeq \theta$.

1. Montrer que $\lambda := A_{\theta,\theta'}(t)$ est fini. *On montrera que l'ensemble $\{x : L(\theta, x) > 0\} \cap \{x : T(x) \geq t\}$ est non vide en utilisant que $\mathbb{E}_\theta[\psi_{t,c}(X)] > 0$. Solution. On a*

$$0 < \mathbb{E}_\theta[\psi_{t,c}(X)] \leq \mathbb{P}_\theta(T(X) \geq t) = \int_{\{x:L(\theta,x)>0\}\cap\{x:T(x)\geq t\}} L(\theta, x) d\nu,$$

   ce qui prouve que $\{x : L(\theta, x) > 0\} \cap \{x : T(x) \geq t\}$ est non vide. Pour un x dans cet ensemble, $\lambda = A_{\theta,\theta'}(t) \leq A_{\theta,\theta'}(T(x)) = \frac{L(\theta',x)}{L(\theta,x)} < +\infty$.

2. Déduire de la question précédente que $\psi_{t,c}$ défini précédemment est UPP($\mathbb{E}_\theta[\psi_{t,c}(X)]$) pour $\mathcal{H}_0 : \theta = \theta$ contre $\mathcal{H}_1 : \theta = \theta'$. *On montrera que $\psi_{t,c} \in$ NP($\mathbb{P}_\theta, \mathbb{P}_{\theta'}$). Solution. Reprenons $\lambda = A_{\theta,\theta'}(t)$. Notons que comme $\lambda < +\infty$, par croissance de $A_{\theta,\theta'}$,*

$$L(\theta', x) > \lambda L(\theta, x) \implies A_{\theta,\theta'}(T(x)) > A_{\theta,\theta'}(t) \implies T(x) > t \implies \psi_{t,c}(x) = 1,$$

[4] ou décroissante, quitte à changer T en $-T$. C'est la monotonie qui est importante ici, pas le sens de variation.

et de même,

$$L(\theta', x) < \lambda L(\theta, x) \implies A_{\theta,\theta'}(T(x)) < A_{\theta,\theta'}(t) \implies T(x) < t \implies \psi_{t,c}(x) = 0,$$

ce qui prouve que $\psi_{t,c} \in \mathrm{NP}(\mathbb{P}_\theta, \mathbb{P}_{\theta'})$. *On conclut en appliquant le théorème de Neyman-Pearson, le niveau étant ici* $\mathbb{E}_\theta[\psi_{t,c}(X)]$, *bien dans* $]0,1[$.

Dans la suite, fixons $\alpha \in]0,1[$ et $\theta_0 \in \Theta$.

3. Montrer qu'il existe $t \in \mathbb{R}, c \in [0,1]$ tel que $\mathbb{E}_{\theta_0}[\psi_{t,c}(X)] = \alpha$. *On raisonnera exactement comme dans la preuve du théorème de Neyman-Pearson, en considérant un bon quantile de* T. *Solution. Comme dans la preuve du théorème de Neyman-Pearson, on pose* t *le quantile d'ordre* $1-\alpha$ *de* T, *et*

$$c = \begin{cases} 0 & \text{si } \mathbb{P}_{\theta_0}(T = t) = 0, \\ \dfrac{\alpha - \mathbb{P}_{\theta_0}(T > t)}{\mathbb{P}_{\theta_0}(T = t)} & \text{sinon.} \end{cases}$$

Puisque $\alpha \in (0,1)$, *il est clair que* $t \in \mathbb{R}$, *comme annoncé. On vérifie que* $c \in [0,1]$. *Par définition de* t, *on a* $\mathbb{P}_{\theta_0}(T > t) \leq \alpha$ *ce qui donne* $c \geq 0$, *et* $\mathbb{P}_{\theta_0}(T \geq t) \geq \alpha$, *qui donne* $c \leq 1$. *Il reste à vérifier que pour ces valeurs de* t, c, ψ *vérifie bien:*

$$\mathbb{E}_\theta[\psi(X)] = \mathbb{P}_\theta(T(X) > t) + c\mathbb{P}_\theta(T(X) = t) = \alpha,$$

ce qui est vrai par définition de c *et parce que*

$$0 \leq \alpha - \mathbb{P}_\theta(T(X) > t) \leq \mathbb{P}_\theta(T(X) = t),$$

4. Montrer que $\psi_{t,c}$ défini précédemment est $\mathrm{UPP}(\alpha)$ pour $\mathcal{H}_0 : \theta = \theta_0$ contre $\mathcal{H}_1 : \theta \succ \theta_0$. *Solution. Comme dans un exercice précédent,* $\psi_{t,c}$ *ne dépend que de* θ_0 *et pas de* θ_1 *tant que* $\theta_1 \succ \theta_0$. *Le même raisonnement que précédemment montre que* $\psi_{t,c}$ *est UPP*(α) *pour* $\mathcal{H}_0 : \theta = \theta_0$ *contre* $\mathcal{H}_1 : \theta \succ \theta_0$.

5. Montrer enfin que la fonction $\theta \mapsto \mathbb{E}_\theta[\psi_{t,c}(X)]$ est croissante (au sens de l'ordre $\preceq$ sur Θ et de l'ordre usuel sur $\mathbb{R}$). *On pourra appliquer les questions 1 et 2. Solution. Soit* $\theta \preceq \theta'$. *Soit* $\mathbb{E}_\theta[\psi_{t,c}(X)] = 0$ *et il n'y a rien à prouver, soit, d'après la question 2,* $\psi_{t,c}$ *est UPP*$(\mathbb{E}_\theta[\psi_{t,c}(X)])$ *pour* $\mathcal{H}_0 : \theta = \theta$ *contre* $\mathcal{H}_1 : \theta = \theta'$, *ce qui implique qu'il est plus puissant que le test constant* $\psi_0 = \mathbb{E}_\theta[\psi_{t,c}(X)]$, *et ainsi* $\mathbb{E}_{\theta'}[\psi_{t,c}(X)] \geq \mathbb{E}_{\theta'}[\psi_0] = \mathbb{E}_\theta[\psi_{t,c}(X)]$. En déduire que $\psi_{t,c}$ est $\mathrm{UPP}(\alpha)$ pour $\mathcal{H}_0 : \theta \preceq \theta_0$ contre $\mathcal{H}_1 : \theta \succ \theta_0$. C'est le *Théorème de Karlin-Rubin. Solution.* $\psi_{t,c}$ *est donc bel et bien de niveau* α *(et même de taille* α*) pour* $\mathcal{H}_0 : \theta \preceq \theta_0$. *Il n'y a rien de plus à montrer pour montrer que* $\psi_{t,c}$ *est UPP*(α) *pour* $\mathcal{H}_0 : \theta \preceq \theta_0$ *contre* $\mathcal{H}_1 : \theta \succ \theta_0$.

6. *Application.* Considérons le modèle i.i.d. uniforme sur $[0,\theta]$, avec $\theta \geq 0$. Soit $\theta_0 > 0$. Construire un test uniformément plus puissant de niveau $\alpha \in]0,1[$ pour $\mathcal{H}_0 : \theta \leq \theta_0$ contre $\mathcal{H}_1 : \theta > \theta_0$. *Solution. Pour* $\theta_1 > \theta_0$, *le rapport de vraisemblance s'écrit*

$$\left(\frac{\theta_0}{\theta_1}\right)^n \mathbb{1}_{\max X_i \leq \theta_0} + (+\infty)\mathbb{1}_{\theta_1 \geq \max X_i > \theta_0}$$

dont on vérifie facilement qu'il est croissant en $T = \max X_i$. *Nous sommes dans le bon cadre pour appliquer le théorème de Karlin–Rubin. Ce théorème implique qu'un test UPP de niveau* $\alpha \in]0,1[$ *pour les hypothèses données est de la forme*

$$\psi = \mathbb{1}_{T>t} + c\mathbb{1}_{T=t},$$

avec $T = \max X_i$. Comme T est continue, on peut prendre $c = 0$ et se concentrer sur le choix de la bonne valeur de t, qui doit satisfaire

$$\alpha = \mathbb{E}_0[\psi] = \mathbb{P}_0(\max X_i > t) = 1 - (t/\theta_0)^n,$$

ce qui donne $t = \theta_0(1-\alpha)^{1/n}$. Un test cherché est donné par

$$\psi(X) = \mathbb{1}_{\max X_i > \theta_0(1-\alpha)^{1/n}}\,.$$

Exercice 5.5 (Test de variance symétrique à deux échantillons)**.** *On admettra dans cet exercice que si Z_1, Z_2 sont deux variables i.i.d. gaussiennes standard, alors Z_1/Z_2 suit une loi de Cauchy de densité sur $\mathbb{R}$ donnée par $x \mapsto \frac{1}{\pi(1+x^2)}$.*

On travaille avec deux échantillons indépendants, X_1 et X_2. On suppose que $0 < \sigma_1^2 < \sigma_2^2$, et on souhaite tester

$$\mathcal{H}_0 : X_1 \sim \mathcal{N}(0, \sigma_1^2),\ X_2 \sim \mathcal{N}(0, \sigma_2^2) \quad \text{vs.} \quad \mathcal{H}_1 : X_1 \sim \mathcal{N}(0, \sigma_2^2),\ X_2 \sim \mathcal{N}(0, \sigma_1^2)\,.$$

On souhaite travailler avec des tests symétriques ψ, tels que $\psi(x_1, x_2) = 1 - \psi(x_2, x_1)$ presque partout.

1. Montrer que si ψ est un test symétrique de taille α et de puissance $1-\beta$ pour ce problème, alors $\alpha = 1-\beta$. *Solution. Observer que si (X_1, X_2) sont tirés sous $\mathcal{H}_0$, alors (X_2, X_1) sont tirés sous $\mathcal{H}_1$. On utilise alors cette symétrie pour écrire*

$$\alpha = \mathbb{E}_0[\psi(X_1, X_2)] = \mathbb{E}_1[\psi(X_2, X_1)] = 1 - \mathbb{E}_1[\psi(X_1, X_2)] = 1 - \beta\,.$$

2. Écrire le rapport de vraisemblance T, et construire un estimateur symétrique ψ_0 basé sur T pour ce problème. *Solution. Le rapport de vraisemblance est donné par*

$$T = \frac{\frac{1}{2\pi}\exp(-\frac{X_1^2}{2\sigma_2^2} - \frac{X_2^2}{2\sigma_1^2})}{\frac{1}{2\pi}\exp(-\frac{X_1^2}{2\sigma_1^2} - \frac{X_2^2}{2\sigma_2^2})} = \exp\left((X_1^2 - X_2^2)\left(\frac{1}{2\sigma_1^2} - \frac{1}{2\sigma_2^2}\right)\right)$$

Ainsi, un test basé sur $T > \tau$ est de la forme $X_1^2 - X_2^2 > C$, ce qui est symétrique presque sûrement si et seulement si $C = 0$. Notons qu'il est symétrique presque sûrement car $X_1^2 - X_2^2 = 0$ a une probabilité nulle. On construit donc le test symétrique

$$\psi_0(X_1, X_2) = \mathbb{1}_{X_1^2 - X_2^2 > 0}\,.$$

3. Montrer que le niveau α_{ψ_0} et la puissance $1 - \beta_{\psi_0}$ de ψ_0 vérifient :

$$\alpha_{\psi_0} = 1 - \beta_{\psi_0} = \frac{2}{\pi}\tan^{-1}\left(\frac{\sigma_1}{\sigma_2}\right)\,.$$

Solution. Calculons le niveau :

$$\alpha_{\psi_0} = \mathbb{P}_0(X_1^2 > X_2^2) = \mathbb{P}_0(\sigma_1^2 Z_1^2 > \sigma_2^2 Z_2^2) = \mathbb{P}_0(|Z_2/Z_1| < \sigma_1/\sigma_2) = \frac{2}{\pi}\tan^{-1}(\sigma_1/\sigma_2),$$

car $\tan^{-1}$ est la fonction de répartion d'une loi de Cauchy. On remarque que cette expression est toujours $\leq 1/2$, avec égalité si et seulement si $\sigma_1 = \sigma_2$, et tend vers 0 lorsque $\sigma_1 \ll \sigma_2$.

Exercice 5.6 (Test de variance à deux échantillons, bis)**.** On se place dans le modèle de l'exercice précédent. On suppose que $0 < \sigma_1^2 < \sigma_2^2$, et on souhaite tester

$$\mathcal{H}_0 : X_1 \sim \mathcal{N}(0, \sigma_1^2),\ X_2 \sim \mathcal{N}(0, \sigma_2^2) \quad \text{vs.} \quad \mathcal{H}_1 : X_1 \sim \mathcal{N}(0, \sigma_2^2),\ X_2 \sim \mathcal{N}(0, \sigma_1^2)\,.$$

Calculer

$$\mathrm{TV}\left(\mathcal{N}\left(0, \begin{pmatrix} \sigma_1^2 & 0 \\ 0 & \sigma_2^2 \end{pmatrix}\right), \mathcal{N}\left(0, \begin{pmatrix} \sigma_2^2 & 0 \\ 0 & \sigma_1^2 \end{pmatrix}\right)\right)$$

et en déduire la valeur minimale de $\alpha_\psi + \beta_\psi$ pour tout test ψ. Comparer avec le test ψ_0 trouvé dans l'exercice précédent.

Exercice 5.7 (p-valeurs)**.** Supposons que nous ayons une famille de tests $(\psi_\alpha)_{\alpha \in [0,1]}$ telle que chaque ψ_α est de niveau α. Une telle famille est dite *emboîtée* si, de plus, pour presque tout $x \in \mathcal{X}$, $\psi_\alpha(x)$ est une fonction non décroissante de α. En présence d'une famille emboîtée de tests, on peut définir la *p-valeur* p comme suit :

$$\mathrm{p}(X) := \inf\{\alpha \in [0,1], \psi_\alpha(X) = 1\}\,.$$

Supposons maintenant que nous soyons dans un modèle paramétrique, où l'on teste $\mathcal{H}_0 : \theta \leq \theta_0$ contre $\mathcal{H}_1 : \theta > \theta_0$ et que les densités des données X possèdent un rapport de vraisemblance monotone dans la statistique T (cf exercice 5.4). On suppose que T admet une loi continue.

1. Montrer que la famille des tests uniformément les plus puissants (pour tous les niveaux $\alpha \in]0,1[$) est emboîtée au sens ci-dessus.

2. Montrer que la p-valeur s'écrit

$$\forall x \in \mathcal{X},\ \mathrm{p}(x) = \mathbb{P}_{\theta_0}(T(X) > T(x))\,.$$

3. Trouver la loi de la p-valeur $\mathrm{p}(X)$ lorsque $\theta = \theta_0$.

6. Modèle linéaire et modèle linéaire gaussien

Exercice 6.1 (La fonction de régression passe-t-elle par le barycentre?)**.** On considère un modèle linéaire $Y = X\theta + \varepsilon$. Soit $\bar{x} = (\frac{1}{n}\sum_{i=1}^n X_{i,\cdot})^\top$ et $\bar{y} = \frac{1}{n}\sum_{i=1}^n Y_i$.

On cherche une condition nécessaire et suffisante pour que la fonction de régression $f : x \in \mathbb{R}^p \mapsto \langle x, \widehat{\theta}_{MC}\rangle$ vérifie

$$\forall Y \in \mathbb{R}^n,\ f(\bar{x}) = \bar{y}\,.$$

1. Vérifier que $f(\bar{x}) = \frac{1}{n}\mathbf{1}_n^\top \Pi(Y)$, où Π désigne le projecteur orthogonal de $\mathbb{R}^n$ sur $\mathrm{Im}(X)$.
2. En déduire que
$$\forall Y \in \mathbb{R}^n,\ f(\bar{x}) = \bar{y}$$
si et seulement si $\mathbf{1}_n \in \mathrm{Im}(X)$.
3. Comment imposer cette condition en pratique ?

Exercice 6.2 (Equivalence Student/Fisher pour la nullité d'un coefficient)**.** Dans cet exercice souhaite montrer l'équivalence entre les tests de Student et de Fisher pour la nullité d'un paramètre. On considère donc le modèle linéaire Gaussien identifiable $Y = X\theta + \varepsilon$ pour lequel on veut tester la nullité du dernier coefficient θ_p.

1. Donner la statistique T du test de Student pour le test de nullité du dernier coefficient θ_p. *Solution. c'est* $T = \frac{(\widehat{\theta}_{MC})_p}{\hat{\sigma}\sqrt{(X^\top X)^{-1}_{i,i}}}$ *avec pour rappel* $\hat{\sigma} = \sqrt{\frac{SCR(\widehat{\theta}_{MC})}{n-p}}$.
2. Donner la statistique F du test de Fisher pour les modèles emboîtés correspondants. On fera apparaître $\hat{\sigma}^2$ au dénominateur. *Solution. Ici le modèle de plus faible dimension est* ω*, l'espace engendré par les* $p-1$ *premières colonnes de* X*. La statistique de Fisher s'écrit donc*
$$F = \frac{\|\hat{Y} - \hat{Y}_0\|^2}{\hat{\sigma}^2},$$
avec $\hat{Y}_0$ *le projecté orthogonal de* Y *sur* ω*.*
3. Soit T_d une variable suivant une loi de Student à d degrés de liberté. Rappeler sa définition et en déduire la loi suivie par la variable $F_d = T_d^2$. *Solution. On rappelle qu'en loi* T_d *est égale à* $\frac{Z}{\sqrt{K/d}}$ *où* $Z \sim \mathcal{N}(0,1)$ *et* $K \sim \chi^2(d)$ *sont indépendantes. En passant au carré il apparaît que* $F = \frac{Z^2/1}{K/d} \sim \mathcal{F}(1,d)$*.*
4. On note la matrice du plan d'expérience sous forme de bloc $X = [X_0 \,|\, X_p]$, où $X_0 = [X_1 \,|\, \ldots \,|X_{p-1}]$ est la matrice de taille $n \times (p-1)$ des $(p-1)$ premières colonnes de X, et X_p est sa dernière colonne. Ecrire la matrice $X^\top X$ sous forme de 4 blocs. *Solution. il vient*
$$X^\top X = \begin{bmatrix} X_0^\top X_0 & X_0^\top X_p \\ X_p^\top X_0 & X_p^\top X_p \end{bmatrix}$$
on pourra vérifier la cohérence des dimensions.
5. On donne (on on rappelle) le lemme suivant :

   Lemme. Soit A une matrice inversible s'écrivant par blocs $A = \begin{bmatrix} T & U \\ V & W \end{bmatrix}$ avec T inversible. Alors $Q = W - VT^{-1}U$ est inversible et l'inverse de A est :
$$A^{-1} = \begin{bmatrix} T^{-1} + T^{-1}UQ^{-1}VT^{-1} & -T^{-1}UQ^{-1} \\ -Q^{-1}VT^{-1} & Q^{-1} \end{bmatrix}.$$

Grâce à la formule d'inversion matricielle par blocs, en déduire que

$$[(X^\top X)^{-1}]_{i,i} = (X_p^\top (I_n - \Pi_0) X_p)^{-1},$$

où Π_0 est la matrice $n \times n$ de projection orthogonale sur l'esapce engendré par les colonnes de X_0. *Solution. On calcule Q dans le lemme en haut. $X_0^\top X_0$ est bien inversible par hypothèse d'indentifiabilité (les $p-1$ premières colonnes de X sont encore libres). Q s'écrit ici $X_p^\top X_p - X_p^\top X_0 (X_0^\top X_0)^{-1} X_0^\top X_p$ et on reconnait la matrice de projection Π_0 (cf cours sur l'estimateur des moindre carrés). $Q = X_p^\top (I_n - \Pi_0) X_p$ qui est un réel non nul d'après le Lemme, et donc inversible. On a le résultat en identifiant l'entrée en bas à droite.*

6. En reprenant les notations du cours $\hat{Y}$ et $\hat{Y}_0$, vérifier que $\hat{Y}_0 = \Pi_0 \hat{Y}$ puis montrer que

$$\hat{Y} - \hat{Y}_0 = (\widehat{\theta}_{MC})_p (I_n - \Pi_0) X_p \,.$$

Solution. Comme ω est un sous-espace de Ω, on a $\Pi_\Omega \Pi_0 = \Pi_0$. En effet, $\Pi_0(x) \in \omega \subset \Omega = Im(\Pi_\Omega)$, et un projecteur est constant sur son image. On obtient $\hat{Y} - \hat{Y}_0 = (I_n - \Pi_0)\hat{Y}$. Mais $\hat{Y} = X\theta_{MC} = (\theta_{MC})_1 X_1 + \ldots + (\theta_{MC})_p X_p$. Et poru tout $1 \leq j \leq p-1$, par définition $(I_n - \Pi_0) X_j = 0$. Cela donne bien $\hat{Y} - \hat{Y}_0 = (\widehat{\theta}_{MC})_p (I_n - \Pi_0) X_p$.

7. En déduire que dans ce cas $F = T^2$. Conclure. *Solution. En utilisant les questions précédentes on a que*

$$\begin{aligned} F &= \frac{\|\hat{Y} - \hat{Y}_0\|^2}{\hat{\sigma}^2} = \frac{(\widehat{\theta}_{MC})_p^2 \|(I_n - \Pi_0) X_p\|^2}{\hat{\sigma}^2} = \frac{(\widehat{\theta}_{MC})_p^2 X_p^\top (I_n - \Pi_0)(I_n - \Pi_0) X_p}{\hat{\sigma}^2} \\ &= \frac{(\widehat{\theta}_{MC})_p^2 X_p^\top (I_n - \Pi_0) X_p}{\hat{\sigma}^2} = \frac{(\widehat{\theta}_{MC})_p^2}{\hat{\sigma}^2 [(X^\top X)^{-1}]_{i,i}} = T^2 \end{aligned}$$

Conclusion, ici tester si $|T| > t_{1-\alpha/2}^{n-p}$ (test de Student) revient exactement à tester si $F > f_{1-\alpha}^{1,n-p}$ (test de Fisher).

Exercice 6.3 (Les eucalyptus)**.** On souhaite expliquer la hauteur y (en mètres) d'un eucalyptus en fonction de sa circonférence x (en centimètres) à 1 mètre 30 du sol, et de la racine carrée de celle-ci. On a relevé $n = 1429$ mesures de couples (x_i, y_i), le nuage de points étant représenté sur la figure 1 ci-contre.

On propose donc le modèle linéaire suivant : pour tout $1 \leq i \leq n$, $Y_i = \beta_1 + \beta_2 X_i + \beta_3 \sqrt{X_i} + \varepsilon_i$, où les ε_i sont gaussiennes i.i.d. $\mathcal{N}(0, \sigma^2)$. On pose

$$X = \begin{bmatrix} 1 & x_1 & \sqrt{x_1} \\ \vdots & \vdots & \vdots \\ 1 & x_n & \sqrt{x_n} \end{bmatrix} \quad \text{et} \quad Y = \begin{bmatrix} y_1 \\ \vdots \\ y_n \end{bmatrix}.$$

Nous avons observé

$$X^\top X = \begin{bmatrix} ? & ? & 9792 \\ ? & 3306000 & ? \\ ? & 471200 & 67660 \end{bmatrix}, \quad X^= \begin{bmatrix} 30310 \\ 1462000 \\ 209700 \end{bmatrix} \quad \text{et} \quad Y^= 651900.$$

1. Compléter la matrice $X^\top X$. *Solution. La norme au carré du vecteur des 1 c'est n. La norme au carré des $\sqrt{x_i}$ c'est juste la somme au carré des x_i. On complète par symétrie. D'où* $X^\top X = \begin{bmatrix} 1429 & 67660 & 9792 \\ 67660 & 3306000 & 471200 \\ 9792 & 471200 & 67660 \end{bmatrix}$

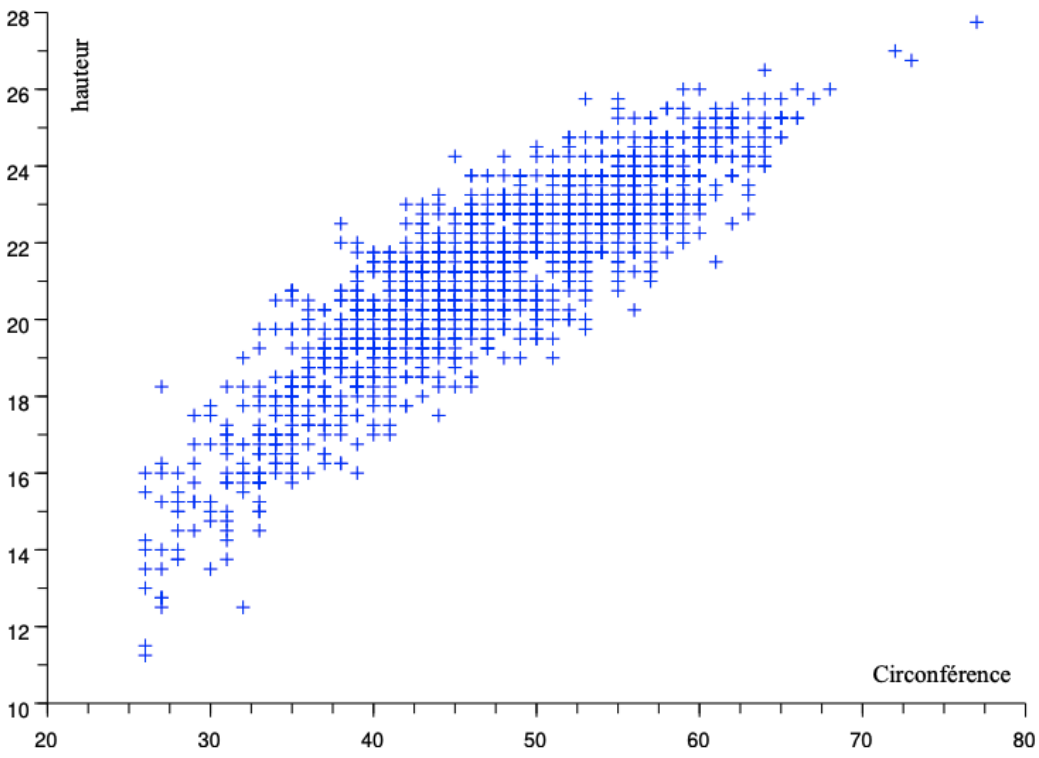

Figure 1 – *Données de hauteurs d'eucalyptus (m) en fonction de leur circonférence (cm).*

2. Que vaut la circonférence moyenne empirique $\overline{x}$? *Solution. C'est 67660/1429 = 47,3 cm*

3. Les calculs donnent en arrondissant :

$$(X^\top X)^{-1} = \begin{bmatrix} 4.646 & 0.101 & -1.379 \\ 0.101 & 0.002 & -0.030 \\ -1.379 & -0.030 & 0.411 \end{bmatrix} \quad \text{et} \quad (X^\top X)^{-1} X^\top Y = \begin{bmatrix} -16.8 \\ -0.30 \\ 7.62 \end{bmatrix}.$$

Que valent les estimateurs $\hat\beta_1, \hat\beta_2, \hat\beta_3$ par la méthode des moindres carrés ? Grâce au calcul de quelques points, représenter la courbe obtenue sur la figure 1.

4. Vérifier que $Y^\top X\hat\beta = \|X\hat\beta\|^2$. Calculer l'estimateur de σ^2 débiaisé et en donner une intervalle de confiance de niveau 95%. On utilisera l'approximation suivante : quand m est grand, une variable $\chi^2(m)$ est proche d'une variable $\mathcal{N}(m, 2m)$. On donne le quantile gaussien standard à 97.5% : $q = 1.96$. *Solution. Il suffit d'écrire :*

$$\begin{aligned} \|X\hat\beta\|^2 &= \hat\beta^\top X^\top X\hat\beta \\ &= ((X^\top X)^{-1}X^\top Y)^\top X^\top X\hat\beta \\ &= Y^\top X(X^\top X)^{-1}X^\top X\hat\beta = Y^\top X\hat\beta\,. \end{aligned}$$

Puis c'est $\hat\sigma^2 = \frac{\|Y-\hat\beta X\|^2}{n-3} = \frac{\|Y\|^2-\|\hat\beta X\|^2}{n-3}$. *Mais à nouveau* $\|\hat\beta X\|^2 = \hat\beta^\top X$ *qui se calcule avec les données : c'est* $-16.8 \times 30310 - 0.3 \times 1462000 + 7.62 \times 209700 = 650106$. *Au final on a* $\hat\sigma^2 = \frac{651900-650106}{1426} = 1.26$. *On a que* $\hat\sigma^2/\sigma^2 \sim \frac{\chi^2(n-p)}{n-p} \simeq 1 + \frac{\sqrt{2}}{\sqrt{n-p}}\mathcal{N}(0,1)$ *donc on prend l'intervalle bilatère* $\hat\sigma^2[(1 \mp \sqrt{2} * 1.96/\sqrt{1426})^{-1}] \simeq \hat\sigma^2[0.932, 1.079] = [1.174, 1.360]$.

5. Donner un IC(0.95) pour β_3. On approchera la loi $\mathcal{T}(m)$ par la loi $\mathcal{N}(0,1)$, quand m

est grand. *Solution. On a classiquement l'intervalle* $\left[\hat{\beta}_3 \pm q_{1-\alpha/2}^{(n-p)}\hat{\sigma}\sqrt{(X^\top X)^{-1}_{3,3}}\right]$ *qui ici vaut* $[7.62 - 1.96 \times \sqrt{1.26} \times \sqrt{0.411}, 7.62 + 1.96 \times \sqrt{1.26} \times \sqrt{0.411}] = [6.21, 9.03]$.

6. Tester l'hypothèse $\beta_2 = 0$ au niveau de risque 10%. On fera les mêmes approximations que précédemment. On donne le quantile gaussien standard à 95% : $z_{0.95} = 1.645$. Interpréter. *Solution. On sait que sous* H_0, $T = \frac{\hat{\beta}_2}{\hat{\sigma}\sqrt{(X^\top X)^{-1}_{2,2}}} \sim \mathcal{T}(n-p) \simeq \mathcal{N}(0,1)$. *Calculons la statistique* T *ici, elle donne*

$$T = \frac{-0.3}{\sqrt{1.26}\sqrt{0.002}} = -5.98\,.$$

On a $|T| > q$ *(et même vénère), on rejette absolument* H_0. *La dépendance en* x *est primordiale pour le modèle.*

Exercice 6.4 (Régression linéaire et projection dans L^2)**.** Soit $f \in L^2([0,1])$. On observe $Y_i = f(t_i) + \varepsilon_i$ aux points $t_i = \frac{i}{n}$ pour $1 \leq i \leq n$, avec ε_i bruits satisfaisant les hypothèses du modèle linéaire.

Soit $(\varphi_k)_{k\geq 0}$ une base orthonormée de fonctions continues de $L^2([0,1])$. Pour $K \geq 0$ fixé, on suppose que f est de la forme $f = \sum_{k=0}^{K} \theta_k \varphi_k$.

1. Ecrire ce modèle sous la forme matricielle $Y = X\theta + \varepsilon$. On précisera les dimensions, et les entrées de la matrice X. *Solution.* $X \in \mathbb{R}^{n\times(K+1)}$ *avec* $X_{i,k} = \varphi_k(t_i)$.

2. Montrer la convergence
$$\frac{1}{n}X^\top X \underset{n\to\infty}{\longrightarrow} I_{K+1}\,.$$
Solution. C'est dû à ce que pour tout k, ℓ,
$$\frac{1}{n}\sum_{i=1}^{n}\varphi_k(t_i)\varphi_\ell(t_i) \underset{n\to\infty}{\longrightarrow} \int_0^1 \varphi_k(t)\varphi_\ell(t)dt\,.$$
(intégrale de Riemann)

On note $\widehat{\theta}$ l'estimateur des moindres carrés.

3. Montrer que, pour tout $0 \leq k \leq K$,
$$\frac{1}{n}\sum_{i=1}^{n} Y_i\varphi_k(t_i) \underset{n\to\infty}{\longrightarrow} \int_0^1 f(t)\varphi_k(t),$$
dans L^2.

4. Montrer que si (C_n) est une suite de matrices déterministes telle que $C_n \to C$ et (Z une suite de vecteurs aléatoires tels que $Z_n \to Z$ dans L^2, alors $C_nZ_n \to CZ$ dans L^2. En déduire que, dans L^2.
$$\widehat{\theta}_k \underset{n\to\infty}{\longrightarrow} \int_0^1 f(t)\varphi_k(t)dt\,.$$
Interpréter. *Solution.*
$$\frac{1}{n}\sum_{i=1}^{n} Y_i\varphi_k(t_i) = \frac{1}{n}\sum_{i=1}^{n} f(t_i)\varphi_k(t_i) + \frac{1}{n}\sum_{i=1}^{n}\varepsilon_i\varphi_k(t_i)$$
, le premier terme se traite comme en question 3 et le second par la loi forte des grands nombres. NOOOOON variance tend vers 0 c'est mieux.

5. ($\star$) Montrer que dans le cas où le modèle est gaussien, la convergence de la question précédente tient presque sûrement. *On pourra commencer par établir que si* $Z_n \sim \mathcal{N}(0, \sigma_n^2)$ *avec* $\sigma_n^2 = o((\log n)^{-1})$, *alors* $Z_n \to 0$ *p.s.*

Exercice 6.5 (Régression ridge, I)**.** On considère le modèle linéaire classique $Y = X\theta + \varepsilon$ avec n observations et p variables explicatives. On ne suppose pas que ce modèle est gaussien et on ne le suppose pas identifiable a priori. Soit $\lambda > 0$. On considère l'estimateur Ridge défini par :

$$\widehat{\theta}_\lambda := \underset{\theta \in \mathbb{R}^p}{\arg\min} \left(\|Y - X\theta\|^2 + \lambda \|\theta\|^2 \right) .$$

Le paramètre λ est appelé paramètre de régularisation.

1. En écrivant proprement le gradient de la fonction à minimiser, monter que $\widehat{\theta}_\lambda$ est uniquement déterminé, et donner sa forme close en fonction de X, Y, et λ. *Solution. Le gradient s'écrit (on peut rappeler le gradient des formes linéaires et quadratiques) :* $\nabla_\theta(\|Y - X\theta\|^2 + \lambda\|\theta\|^2) = -2X^+2X^\top X\theta + 2\lambda\theta$ *qui est nul en un unique point*

$$\widehat{\theta}_\lambda = (X^\top X + \lambda I_p)^{-1} X^\top Y ,$$

car $X^\top X + \lambda I_p$ *est inversible.*

2. Quelle est la limite de $\widehat{\theta}_\lambda$ quand $\lambda \to +\infty$? Interpréter. *Solution. Quand* $\lambda \to +\infty$ *on a* $\widehat{\theta}_\lambda \to 0$. *En effet, dans ce cas tout se passe comme si la minimisation portait seulement sur le terme* $\|\theta\|^2$, *et* 0 *est l'optimal.*

3. Calculer la matrice de covariance de l'estimateur Ridge notée V_λ. *Solution. La variance vaut*

$$(X^\top X + \lambda I_p)^{-1} X^\top (\sigma^2 I_n) X (X^\top X + \lambda I_p)^{-1}$$

4. On se place dans le cas identifiable et on note V la matrice de covariance de l'estimateur des moindres carrés. En étudiant les valeurs propres de l'une en fonction de celles de l'autre, montrer que pour tout $\lambda > 0$, $V_\lambda \prec V$ au sens strict, pour l'ordre $\prec$ défini en cours. Commenter. *Solution. Plaçons nous selon le vecteur propre* u_i *de* V/σ^2 *pour la valeur propre* $\lambda_i > 0$. *Les espaces propres de* V_λ/σ^2 *sont les mêmes (les matrices commutent toutes), et selon le vecteur* u_i *la valeur propre associée est*

$$(1/\lambda_i + \lambda)^{-1}(1/\lambda_i)(1/\lambda_i + \lambda)^{-1} = \frac{\lambda_i}{(1 + \lambda\lambda_i)^2} < \lambda_i .$$

Les valeurs propres de V/σ^2 *sont alors toutes strictement plus petite que celles de* V, *et les vecteurs propres sont les mêmes. On a ainsi* $V_\lambda \prec V$. *Ainsi, l'estimateur ridge a meilleure covariance que l'estimateur des moindres carrés ordinaire, d'autant plus que* λ *grandit. Mais, il est biaisé a priori, d'autant plus que* λ *grandit. Il y a un compromis biais variance a trouver justement, en fonction de* λ.

Les pages suivantes contiennent quelques énoncés de problèmes supplémentaires, issus d'annales d'examen.

A. Plantons des étoiles

"Il faut porter encore en soi un chaos, pour pouvoir mettre au monde une étoile dansante"
(Nietzsche)

Dans ce problème, pour tout $n \geq 1$, $[n]$ désigne l'ensemble $\{1, \ldots, n\}$. On note $\mathbb{G}_n$ l'ensemble des graphes sur l'ensemble de sommets $V = [n]$, non orientés, simples et sans boucle[5]. Quand le graphe $g \in \mathbb{G}_n$ dont on parle est clair dans le contexte, on note $u \sim v$ (resp. $u \not\sim v$) si $u \in [n]$ et $v \in [n]$ sont reliés (resp. non reliés) dans g par une arête.

Pour $g \in \mathbb{G}_n$, on dit qu'un couple $\mathcal{E} = (u, W)$ où $u \in [n]$ et $W \subseteq [n] \setminus \{u\}$ est une *$k-$étoile de G centrée en u*, et l'on note $\mathcal{E} \in G$, si $|W| = k$ et si

$$\forall w \in W, \quad u \sim w\,.$$

Nous allons considérer des graphes aléatoires[6] . Pour $n \geq 1$, et deux paramètres $p \in [0, 1]$ et $k \geq 0$, *où p et k dépendent éventuellement de n*, on note :

- $\mathcal{G}(n, p)$ la loi d'un graphe aléatoire G dans $\mathbb{G}_n$ où, indépendamment pour toute paire $\{u, v\}$ de sommets avec $u \neq v \in [n]$, $u \sim v$ (resp. $u \not\sim v$) avec probabilité p (resp. $1 - p$).
- $\mathcal{G}(n, p, k)$ le modèle où G est obtenu de la façon suivante. On tire d'abord $H \sim \mathcal{G}(n, p)$, puis, indépendamment de H, on tire un noeud $u \in [n]$ uniformément au hasard, et un sous ensemble $W \subset [n] \setminus \{u\}$ de cardinal k uniformément au hasard. On note $\mathcal{E}(G) = (u, W)$ et on forme le graphe G en ajoutant à H les arêtes nécessaires de sorte que $\mathcal{E}(G) = (u, W)$ soit une $k-$étoile de G. *On dit qu'on a planté la $k-$étoile $\mathcal{E}(G)$ dans G.*

Notons que par définition, $\mathcal{G}(n, p, 0) = \mathcal{G}(n, p)$. Le but de ce problème est de détecter la présence de $k-$étoiles plantées dans des graphes, autrement dit, d'étudier le test d'hypothèses suivant :

$$\mathcal{H}_0 : G \sim \mathcal{G}(n, p) \quad \text{contre} \quad \mathcal{H}_1 : G \sim \mathcal{G}(n, p, k)\,. \tag{$\star$}$$

Lorsque les paramètres n, p, k sont clairs dans le contexte, on note $\mathbb{P}_0$ (resp. $\mathbb{P}_1$) la distribution de G sous $\mathcal{H}_0$ (resp. sous $\mathcal{H}_1$).

A – Premières questions

1. En donnant des arguments succints et informels, à votre avis, comment la difficulté du problème du test d'hypothèses $(\star)$ varie :
   - à p fixé, lorsque k augmente ?
   - à k fixé, lorsque p augmente ?

   Solution. Plus une étoile est grande, plus elle est facile à détecter. On s'attend à ce que le problème soit plus facile lorsque k augmente, à p fixé. Plus il y a d'arêtes dans G qui sont dues au 'hasard', plus l'étoile est difficile à détecter. On s'attend à ce que le problème soit plus difficile lorsque p augment, à k fixé.

[5] c'est-à-dire que toutes les arêtes de tels graphes sont de la forme $\{u, v\}$ avec $u, v \in [n]$ et $u \neq v$.

[6] si cela vous semble loin du contexte du cours, observez que l'on peut parfaitement encoder un graphe de $\mathbb{G}_n$ par un vecteur de $\mathbb{R}^{\binom{n}{2}}$ (et même de $\{0, 1\}^{\binom{n}{2}}$). Un graphe aléatoire peut ainsi être vu comme un vecteur aléatoire.

Dans toute la suite, on considère le régime où p dépend de n et s'écrit $p = p(n) = \lambda/n$ avec λ réel strictement positif.

2. Pour une telle paramétrisation de p, le modèle $\mathcal{G}(n,p)$ est dit *de degré moyen d'ordre constant en n*. Justifier cette appellation. *Solution. Calculons l'espérance du degré d'un noeud quelconque $u \in [n]$. Il y a $n-1$ voisins possibles, chacun avec probabilité λ/n, soit en espérance $(n-1)\lambda/n$ qui tend vers λ lorsque $n \to +\infty$ (une constante, donc).*

Pour tout $1 \leq k \leq n$, on note $\mathcal{E}(n,k)$ l'ensemble des $k-$étoiles du graphe complet[7] de taille n.

3. Montrer que
$$|\mathcal{E}(n,k)| = n\binom{n-1}{k}.$$
Solution. Il faut choisir le centre de l'étoile (n choix), puis les k voisins du centre, parmi les $n-1$ voisins possibles. Cela donne bien $|\mathcal{E}(n,k)| = n\binom{n-1}{k}$.

B – Calcul de L

4. On rappelle que $p = p(n) = \lambda/n$. Montrer que pour tout graphe $g \in \mathbb{G}_n$,
$$\mathbb{P}_1(G=g) = \frac{1}{|\mathcal{E}(n,k)|}\left(\frac{\lambda}{n}\right)^{-k}\mathbb{P}_0(G=g)\sum_{\mathcal{E}\in\mathcal{E}(n,k)}\mathbb{1}_{\mathcal{E}\in g}.$$
On pourra commencer par calculer $\mathbb{P}_0(G=g)$, puis écrire
$$\mathbb{P}_1(G=g) = \sum_{\mathcal{E}\in\mathcal{E}(n,k)}\mathbb{P}_1(G=g\,|\,\mathcal{E}(G)=\mathcal{E})\mathbb{P}_1(\mathcal{E}(G)=\mathcal{E}).$$
Solution. Notons $e(g)$ le nombre d'arêtes d'un graphe $g \in \mathbb{G}_n$. Par indépendance des arêtes, on a que
$$\mathbb{P}_0(G=g) = p^{e(g)}(1-p)^{\binom{n}{2}-e(g)} = \left(\frac{\lambda}{n}\right)^{e(g)}\left(1-\frac{\lambda}{n}\right)^{\binom{n}{2}-e(g)}.$$
En suivant l'indication, on écrit
$$\begin{aligned}\mathbb{P}_1(G=g) &= \sum_{\mathcal{E}\in\mathcal{E}(n,k)}\mathbb{P}_1(G=g\,|\,\mathcal{E}(G)=\mathcal{E})\mathbb{P}_1(\mathcal{E}(G)=\mathcal{E})\\ &= \sum_{\mathcal{E}\in\mathcal{E}(n,k)}\mathbb{1}_{\mathcal{E}\in g}\underbrace{\left(\frac{\lambda}{n}\right)^{e(g)-k}}_{k\text{ arêtes de }\mathcal{E}\text{ fixées}}\left(1-\frac{\lambda}{n}\right)^{\binom{n}{2}-e(g)}\underbrace{\frac{1}{|\mathcal{E}(n,k)|}}_{\text{proba uniforme sur }\mathcal{E}(n,k)}\\ &= \frac{1}{|\mathcal{E}(n,k)|}\left(\frac{\lambda}{n}\right)^{-k}\mathbb{P}_0(G=g)\sum_{\mathcal{E}\in\mathcal{E}(n,k)}\mathbb{1}_{\mathcal{E}\in g}.\end{aligned}$$

Pour tout graphe $g \in \mathbb{G}_n$, on note
$$L(g) := \frac{\mathbb{P}_1(G=g)}{\mathbb{P}_0(G=g)}$$
et $X_k(g)$ le nombre de $k-$étoiles de g.

[7] pour rappel, le graphe complet de taille n est le graphe de $\mathbb{G}_n$ dans lequel $u \sim v$ pour tous $u \neq v \in [n]$.

5. Déduire de la question précédente que pour tout graphe $g \in \mathbb{G}_n$,

$$L(g) = \frac{X_k(g)}{\mathbb{E}_0[X_k(G)]}\,.$$

Solution. *Notons que* $X_k(g) = \sum_{\mathcal{E}\in\mathcal{E}(n,k)} \mathbb{1}_{\mathcal{E}\in g}$. *Par linéarité de l'espérance,* $\mathbb{E}_0[X_k(G)] = |\mathcal{E}(n,k)| \left(\frac{\lambda}{n}\right)^k$. *Ainsi, d'après la question précédente,*

$$L(g) = \frac{\mathbb{P}_1(G=g)}{\mathbb{P}_0(G=g)} = \frac{1}{|\mathcal{E}(n,k)|}\left(\frac{\lambda}{n}\right)^{-k} \sum_{\mathcal{E}\in\mathcal{E}(n,k)} \mathbb{1}_{\mathcal{E}\in g} = \frac{X_k(g)}{\mathbb{E}_0[X_k(G)]}$$

6. Si l'on fixe un niveau α, quelle est la forme d'un test ϕ uniformément plus puissant pour le problème $(\star)$? *On ne demande pas de calculer les constantes qui apparaissent, mais juste de donner sa forme globale.* Au vu de la question 5, en quoi ce test ϕ a-t-il une expression intuitive pour répondre au problème $(\star)$? *Solution.* *D'après le théorème de Neyman-Pearson, un test (randomisé) UPP de niveau* α *est donné par*

$$\phi(G) = \mathbb{1}_{L(G)>t} + c\mathbb{1}_{L(G)=t}$$

où t *et* c *sont calibrées de sorte à satisfaire* $\mathbb{E}_0[\phi(G)] = \alpha$. *On ne détaille pas ces constantes, mais notons que d'après la forme de* L *établie à la question précédente,* ϕ *se réécrit sous la forme*

$$\phi(G) = \mathbb{1}_{X_g(G)>t} + c\mathbb{1}_{X_g(G)=t}\,.$$

Ce test est donc simplement basé sur le comptage du nombre de $k-$*étoiles dans* G*, ce qui est tout à fait naturel pour détecter leur présence !*

Dans toute la suite, on dit que

- *La détection forte d'une* $k-$*étoile est réalisable* si pour tout $n \geq 1$ il existe un test $\phi_n : \mathbb{G}_n \to \{0,1\}$ tel que

$$\mathbb{P}_0(\phi_n = 1) + \mathbb{P}_1(\phi_n = 0) \underset{n\to+\infty}{\longrightarrow} 0\,.$$

- *La détection faible d'une* $k-$*étoile est impossible* si pour toute famille de tests $(\phi_n)_{n\geq 1}$ avec $\phi_n : \mathbb{G}_n \to \{0,1\}$, on a

$$\mathbb{P}_0(\phi_n = 1) + \mathbb{P}_1(\phi_n = 0) \underset{n\to+\infty}{\longrightarrow} 1\,.$$

C – Un résultat positif

7. Montrer que

$$\mathbb{E}_0[X_k(G)] \leq n\frac{\lambda^k}{k!}\,.$$

Solution. *Nous avons déjà établi que* $\mathbb{E}_0[X_k(G)] = |\mathcal{E}(n,k)| \left(\frac{\lambda}{n}\right)^k$, *il suffit de conclure en utilisant la majoration classique* $\binom{n}{k} \leq \frac{n^k}{k!}$, *ce qui donne bien*

$$\mathbb{E}_0[X_k(G)] = n\binom{n-1}{k}\left(\frac{\lambda}{n}\right)^k \leq n\frac{\lambda^k}{k!}\left(\frac{n-1}{n}\right)^k \leq n\frac{\lambda^k}{k!}\,.$$

8. Soit $\varepsilon > 0$. On suppose que $n \geq 3$ et que

$$k = k(n) \geq (1+\varepsilon)\frac{\log n}{\log\log n}\,.$$

Montrer qu'alors la détection forte d'une $k-$étoile est réalisable pour un test ϕ_n très simple que vous expliciterez.

On commencera par montrer que sous ces conditions, $\mathbb{P}_0(X_k(G) \geq 1) \underset{n\to\infty}{\longrightarrow} 0$.

Solution. Suivons l'indication : on travaille à n et sous l'hypothèse sur k, $k \to \infty$. On a par Stirling,

$$\begin{aligned}\mathbb{P}_0(X_k(G) \geq 1) \leq n\frac{\lambda^k}{k!} &= \exp(\log n + k\log\lambda - \log(k!))\\ &= \exp(\log n + k\log\lambda - k\log(k) + k + o(k))\\ &= \exp(\log n - k\log(k) + O(k))\,.\end{aligned}$$

Il reste à voir que comme $k \geq (1+\varepsilon)\frac{\log n}{\log\log n}$, on a $k\log k \geq (1+\varepsilon)\frac{\log n}{\log\log n}\log\left(\frac{\log n}{\log\log n}\right) \geq (1+\varepsilon/2)\log n$ pour n assez grand. Pour n assez grand, on a donc $\mathbb{P}_0(X_k(G) \geq 1) \leq \exp(-(\varepsilon/2)\log n + O(k))$. On a envie de dire que ce dernier terme tend bien vers 0. Pour être tout à fair rigoureux, il faut comparer k à $\log n$. C'est vrai par exemple si $k > (\varepsilon/4)\log n$. Si $k \geq (\varepsilon/4)\log n$ alors l'hypothèse est encore plus forte et le terme dominant est $k\log k$ domine k et dépasse $C\log n\log\log n$ pour une certaine constante C, qui domine bien les termes en $\log n$. Dans tous les cas, le terme de droite tend vers 0.

D – Une inégalité informationnelle

Soient P_0 and P_1 deux mesures de probabilités définies sur un espace au plus dénombrable Γ. On notera, $P_0(\gamma) = P_0(\{\gamma\})$ pour tout $\gamma \in \Gamma$, et de même pour P_1. La *distance en variation totale entre P_0 et P_1* est définie par

$$d_{\mathrm{TV}}(P_0, P_1) := \sup_{B\subseteq\Gamma}(P_1(B) - P_0(B)).$$

9. Montrer que le sup dans la définition ci-dessus est atteint pour $B = B_{\mathrm{opt}}$ où

$$B_{\mathrm{opt}} := \{\gamma \in \Gamma,\ P_1(\gamma) > P_0(\gamma)\}$$

et en déduire que

$$d_{\mathrm{TV}}(P_0, P_1) = \frac{1}{2}\sum_{\gamma\in\Gamma}|P_1(\gamma) - P_0(\gamma)|\,.$$

Solution. Considérons un ensemble $B \subseteq \Gamma$. On va contrôler

$$\Delta := P_1(B_{opt}) - P_0(B_{opt}) - (P_1(B) - P_0(B))$$

et montrer que cette quantité est positive (pas besoin de strictement). On a

$$\begin{aligned}\Delta &= \sum_{\gamma\in B_{opt}}(P_1(\gamma) - P_0(\gamma)) - \sum_{\gamma\in B}(P_1(\gamma) - P_0(\gamma))\\ &= \sum_{\gamma\in B_{opt}\setminus B}(P_1(\gamma) - P_0(\gamma)) - \sum_{\gamma\in B\setminus B_{opt}}(P_1(\gamma) - P_0(\gamma))\,.\end{aligned}$$

Mais comme $P_1(\gamma) - P_0(\gamma) > 0$ si et seulement si $\gamma \in B_{opt}$, on a que

$$\sum_{\gamma \in B_{opt} \setminus B} (P_1(\gamma) - P_0(\gamma)) \geq 0 \quad \text{et} \quad \sum_{\gamma \in B \setminus B_{opt}} (P_1(\gamma) - P_0(\gamma)) \leq 0\,.$$

Cela montre que $\Delta \geq 0$, et prouve le résultat voulu.

10. Montrer que, pour X variable aléatoire à valeurs dans Γ,

$$\inf_{\phi} [P_0(\phi(X) = 1) + P_1(\phi(X) = 0)] = 1 - d_{\mathrm{TV}}(P_0, P_1),$$

où l'inf est pris sur toutes les fonctions mesurables $\phi : \Gamma \to \{0, 1\}$. Donner une interprétation de ce résultat. *Solution. Soit $\phi : \mathcal{X} \to \{0, 1\}$ mesurable. Les ensembles $B := \phi^{-1}(\{0\})$ et $B^c = \phi^{-1}(\{1\})$ sont mesurables et par définition de d_{TV},*

$$d_{\mathrm{TV}}(P_0, P_1) \geq P_1(B^c) - P_0(B^c) = 1 - P_1(B) - P_0(B^c) = 1 - P_1(\phi(X) = 0) - P_0(\phi(X) = 1)$$

ce qui entraîne

$$1 - d_{\mathrm{TV}}(P_0, P_1) \leq P_1(B^c) - P_0(B^c) = 1 - P_1(B) - P_0(B^c) = P_1(\phi(X) = 0) + P_0(\phi(X) = 1)\,.$$

Cette borne est atteinte lorsque $\phi = \mathbb{1}_{B_{opt}}$ d'après la question précédente. Ce résultat montre que $1 - d_{\mathrm{TV}}(P_0, P_1)$ est la meilleure somme des erreurs de type I et II possible pour tester P_0 contre P_1. En d'autres termes, cette quantité $1 - d_{\mathrm{TV}}(P_0, P_1)$ quantifie la difficulté de tester P_0 contre P_1.

11. On suppose que $P_0(\gamma) > 0$ pour tout $\gamma \in \Gamma$. Pour tout $\gamma \in \Gamma$ on note

$$\ell(\gamma) := \frac{P_1(\gamma)}{P_0(\gamma)}\,.$$

Soit X une variable aléatoire à valeurs dans Γ. On note E_0 l'espérance relative à P_0. En utilisant la question 9, montrer que

$$2d_{\mathrm{TV}}(P_0, P_1) \leq \sqrt{E_0[\ell^2(X)] - 1}\,.$$

Solution. La question 9 montre que $2d_{\mathrm{TV}}(P_0, P_1)$ s'écrit aussi

$$2d_{\mathrm{TV}}(P_0, P_1) = \sum_{\gamma \in \Gamma} |P_1(\gamma) - P_0(\gamma)| = \sum_{\gamma \in \Gamma} P_0(\gamma)|\ell(\gamma) - 1| = E_0[|\ell(X) - 1|] \leq \sqrt{E_0[(\ell(X) - 1)^2]},$$

par Cauchy-Schwarz. Notons de plus que $E_0[(\ell(X) - 1)^2] = E_0[\ell(X)^2] - 2E_0[\ell(X)] + 1$ et on conlcut en montrant que $E_0[\ell(X)] = 1$. En effet,

$$E_0[\ell(X)] = \sum_{\gamma \in \Gamma} P_0(\gamma) \frac{P_1(\gamma)}{P_0(\gamma)} = \sum_{\gamma \in \Gamma} P_1(\gamma) = 1\,.$$

E – Un résultat négatif

Soit $\varepsilon > 0$. On suppose dans toute cette partie que $n \geq 3$ et que

$$k = k(n) \leq (1 - \varepsilon) \frac{\log n}{\log \log n}\,.$$

12. Rappelons que X_k est définie dans la partie B. En écrivant

$$\mathbb{E}_0[X_k(G)^2] = M_1 + M_2 + M_3$$

avec

$$M_1 := \sum_{\mathcal{E}=(u,W)\in\mathcal{E}(n,k)} \sum_{\mathcal{E}'=(u,W')\in\mathcal{E}(n,k)} \mathbb{P}_0(\mathcal{E}\in G, \mathcal{E}'\in G),$$

$$M_2 := \sum_{\mathcal{E}=(u,W)\in\mathcal{E}(n,k)} \sum_{\substack{\mathcal{E}'=(u',W')\in\mathcal{E}(n,k)\\ u'\in W}} \mathbb{P}_0(\mathcal{E}\in G, \mathcal{E}'\in G),$$

et

$$M_3 := \sum_{\mathcal{E}=(u,W)\in\mathcal{E}(n,k)} \sum_{\substack{\mathcal{E}'=(u',W')\in\mathcal{E}(n,k)\\ u'\notin W}} \mathbb{P}_0(\mathcal{E}\in G, \mathcal{E}'\in G),$$

montrer que

$$\mathbb{E}_0[X_k(G)^2] = \mathbb{E}_0[X_k(G)]^2(1+o(1))\,,$$

où le $o(1)$ est pris lorsque $n\to+\infty$.

On montrera notamment que $M_1 = o(\mathbb{E}_0[X_k(G)]^2)$ et $M_2 = o(\mathbb{E}_0[X_k(G)]^2)$.

Solution. Comme on a toujours $\mathbb{E}_0[X_k(G)^2] \geq \mathbb{E}_0[X_k(G)]^2$, il nous faut une majoration de $\mathbb{E}_0[X_k(G)^2]$ pour prouver le résultat voulu. On a

$$\begin{aligned}
\mathbb{E}_0[X_k(G)^2] &= \mathbb{E}_0\left[\left(\sum_{\mathcal{E}\in\mathcal{E}(n,k)} \mathbb{1}_{\mathcal{E}\in G}\right)^2\right] \\
&= \mathbb{E}_0\left[\sum_{\mathcal{E}\in\mathcal{E}(n,k)}\sum_{\mathcal{E}'\in\mathcal{E}(n,k)} \mathbb{1}_{\mathcal{E}\in G,\mathcal{E}'\in G}\right] \\
&= \sum_{\mathcal{E}\in\mathcal{E}(n,k)}\sum_{\mathcal{E}'\in\mathcal{E}(n,k)} \mathbb{P}_0(\mathcal{E}\in G, \mathcal{E}'\in G) \\
&= M_1 + M_2 + M_3
\end{aligned}$$

comme annoncé dans l'indication, car les indices des sommations forment une partition de $\mathcal{E}(n,k)\times\mathcal{E}(n,k)$. Nous allons gérer les termes séparément. Notons que nous raisonnons à n grand et qu'en faisant les mêmes calculs qu'en question 8, on voit que dans ce régime de k,

$$\mathbb{E}_0[X_k(G)] \sim n\frac{\lambda^k}{k!} = \exp(o(\log n) - k\log k + \log n) \geq \exp((\varepsilon/2)\log n + o(\log n)) \to +\infty\,.$$

Pour l'instant, supposons $k\to\infty$. On a tout d'abord, en notant ℓ le nombre de noeuds commun à W et W',

$$\begin{aligned}
M_1 &\leq \sum_{\mathcal{E}\in\mathcal{E}(n,k)} (\lambda/n)^k \sum_{\ell=0}^{k} \binom{k}{\ell}\binom{n-k-1}{k-\ell}(\lambda/n)^{k-\ell} \\
&\leq \mathbb{E}_0[X_k(G)] \sum_{\ell=0}^{k} \binom{k}{\ell} n^{k-\ell}(\lambda/n)^{k-\ell} \\
&= \mathbb{E}_0[X_k(G)](1+\lambda)^k,
\end{aligned}$$

et il reste à montrer que $(1+\lambda)^k = o(\mathbb{E}_0[X_k(G)]) = o(n\lambda^k/k!)$. En passant au log et

en utilisant Stirling, il suffit de montrer que

$$k\log(1+\lambda) - k\log\lambda - \log n + k\log k - k \to -\infty,$$

ce qui est vrai car avec les hypothèses sur k a que ce terme est plus petit que $-(\varepsilon/2)\log n$ pour n assez grand. Cela est encore vrai si k ne tend pas vers $+\infty$. Passons à M_2, qui est plus facile : notons que les couples $\mathcal{E}, \mathcal{E}'$ présents dans la somme n'ont pas d'arête en commun si $u \notin W'$, et exactement une si $u \in W'$. En comptant ces possibilités, on obtient

$$\begin{aligned} M_2 &\leq |\mathcal{E}(n,k)|(\lambda/n)^k k \left[\binom{n-2}{k-1}(\lambda/n)^{k-1} + \binom{n-2}{k}(\lambda/n)^k\right] \\ &\leq \mathbb{E}_0[X_k(G)](k^2\lambda^{k-1}/k! + k\lambda^k/k!) \\ &\leq \mathbb{E}_0[X_k(G)]O\left(\frac{k^2}{n}\mathbb{E}_0[X_k(G)]\right) = o(\mathbb{E}_0[X_k(G)]^2). \end{aligned}$$

Enfin, comme les paires d'étoiles dans M_3 n'ont aucune arête en commun,

$$\begin{aligned} M_3 &= \sum_{\mathcal{E}=(u,W)\in\mathcal{E}(n,k)} \sum_{\substack{\mathcal{E}'=(u',W')\in\mathcal{E}(n,k) \\ u'\notin W}} \mathbb{P}_0(\mathcal{E}\in G)\mathbb{P}_0(\mathcal{E}'\in G) \\ &\leq \mathbb{E}_0[X_k(G)]^2\,. \end{aligned}$$

On a donc montré que $\mathbb{E}_0[X_k(G)]^2 \leq \mathbb{E}_0[X_k(G)^2] \leq \mathbb{E}_0[X_k(G)]^2 + o(\mathbb{E}_0[X_k(G)]^2)$ ce qui conclut la question.

13. En déduire que la détection faible d'une $k-$étoile est impossible.

    On pourra utiliser les questions 10 et 11.

    Solution. Nous avons montré à la question précédente que $\mathbb{E}_0[X_k(G)^2] = \mathbb{E}_0[X_k(G)]^2 + o(\mathbb{E}_0[X_k(G)]^2)$ et d'après l'expression de L question 5, cela implique

$$\mathbb{E}_0[L(G)^2] = \frac{\mathbb{E}_0[X_k(G)^2]}{\mathbb{E}_0[X_k(G)]^2} \to 1\,.$$

    En appliquant les résultats de la partie D à $\Gamma = \mathbb{G}_n$, $P_0 = \mathbb{P}_0$ et $P_1 = \mathbb{P}_1$, l'inégalité prouvée à la question 11 implique que, en explicitgant les dépendances en n,

$$d_{\mathrm{TV}}(\mathbb{P}_{0,n}, \mathbb{P}_{1,n}) \leq \frac{1}{2}\sqrt{\mathbb{E}_{0,n}[L^2(G)] - 1} \to 0,$$

    et par la question 10, que pour toute famille $(\phi_n)_{n\geq 1}$ de tests,

$$\mathbb{P}_0(\phi_n(G)=1) + \mathbb{P}_1(\phi_n(G)=0) \geq 1 - d_{\mathrm{TV}}(\mathbb{P}_{0,n}, \mathbb{P}_{1,n}) \to 1\,.$$

    Cela prouve que la détection faible d'une $k-$étoile est impossible.

14⋆. Avez-vous une idée d'application de ce problème ?

Grâce aux questions 8 et 13, nous avons établi que la difficulté du problème $(\star)$ change brutalement selon que $k \geq (1+\varepsilon)k^*(n)$ ou que $k \leq (1-\varepsilon)k^*(n)$, avec $k^*(n) = \frac{\log n}{\log\log n}$. Ce phénomène est communément appelé *transition de phase* et $k^*(n)$ est appelé *seuil critique*.

15⋆. A votre avis, que devient ce seuil critique $k^*(n)$ si on étudie le problème $(\star)$ cette fois-ci avec $p = p_0$ fixé constant dans $]0,1[$?

B. Minimisation de l'erreur de prédiction

Dans ce problème, on s'intéresse à l'erreur de prédiction dans le modèle linéaire. On travaille ici avec un modèle linéaire, non supposé gaussien, et on note σ^2 la variance (constante) du bruit.

Première partie : cas à une variable explicative. On cherche à apprendre le modèle linéaire suivant pour prédire le réel Y_i en fonction d'une variable explicative réelle z_i :

$$\forall 1 \leq i \leq n, \quad Y_i = \beta_0 + \beta_1 z_i + \varepsilon_i \,.$$

On notera $\overline{y}$ et $\overline{z}$ les moyennes empiriques de $z = (z_1, \ldots, z_n)^T$ et de $Y = (Y_1, \ldots, Y_n)^T$ (attention, elles dépendent de n). On suppose que le modèle est identifiable et on note $\hat{\beta} = (\hat{\beta}_0, \hat{\beta}_1)$ l'estimateur des moindres carrés de β.

Sous le même modèle, on observe une nouvelle valeur z_{n+1} de la variable explicative et on cherche à prédire la variable réponse Y_{n+1} avec l'estimateur

$$\hat{y}_{n+1} := \hat{\beta}_0 + \hat{\beta}_1 z_{n+1} = x_{n+1}^T \hat{\beta}, \quad \text{où } x_{n+1} := \begin{bmatrix} 1 \\ z_{n+1} \end{bmatrix} .$$

L'erreur de prédiction est définie par :

$$\mathrm{err}(z_{n+1}) := \mathbb{E}\left[(Y_{n+1} - \hat{y}_{n+1})^2\right] .$$

Notons que dans cette espérance, l'aléa vient du bruit ε_{n+1} dans Y_{n+1} ainsi que de l'aléa dans le $\hat{\beta}$.

1. Redémontrer que si S est un vecteur aléatoire de $\mathbb{R}^m$ de matrice de covariance (finie) C, alors pour tout vecteur $u \in \mathbb{R}^m$, $\mathrm{Var}(u^T S) = u^T C u$. *Solution. On peut développer pour voir que*

$$\begin{aligned} Var(u^T S) &= Var\left(\sum_{i=1}^m u_i S_i\right) \\ &= \sum_{1 \leq i,j \leq m} Cov(u_i S_i, u_j S_j) \\ &= \sum_{1 \leq i,j \leq m} u_i u_i C_{i,j} = u^T C u \,. \end{aligned}$$

2. Que vaut $\mathbb{E}\left[Y_{n+1} - \hat{y}_{n+1}\right]$? *Solution. Elle est égale à $\mathbb{E}\left[x_{n+1}^T(\beta - \hat{\beta}) + \varepsilon_{n+1}\right] = x_{n+1}^T 0 + 0 = 0$ par nullité du biais de $\hat{\beta}$ et d'après les hypothèses sur les ε_i.*

3. Ecrire la matrice X du plan d'expérience dans ce modèle (on mettra l'intercept dans la première colonne), et montrer que

$$(X^T X)^{-1} = \frac{1}{nv(z)} \begin{bmatrix} \frac{1}{n}\sum_{i=1}^n z_i^2 & -\overline{z} \\ -\overline{z} & 1 \end{bmatrix},$$

avec $v(z)$ la variance empirique de z. *Solution. Dans notre cas on a $X = \left[\begin{array}{c|c} \mathbf{1}_n & z \end{array}\right] \in \mathbb{R}^{n \times 2}$, et $X^T X = n \begin{bmatrix} 1 & \overline{z} \\ \overline{z} & \frac{1}{n}\sum_{i=1}^n z_i^2 \end{bmatrix}$ de déterminant $nv(z)$. Il vient donc $(X^T X)^{-1} = \frac{1}{nv(z)} \begin{bmatrix} \frac{1}{n}\sum_{i=1}^n z_i^2 & -\overline{z} \\ -\overline{z} & 1 \end{bmatrix}$.*

4. En utilisant les résultats des questions 1, 2 et 3, montrer que

$$\mathrm{err}(z_{n+1}) = \sigma^2 \left(1 + \frac{1}{n} + \frac{(z_{n+1} - \overline{z})^2}{\sum_{i=1}^n (z_i - \overline{z})^2}\right).$$

Solution. Comme la variable dont on prend le moment d'ordre deux est centré d'après la question 2, on calcule en fait une variance.

$$\begin{aligned}\mathrm{err}(z_{n+1}) &= \mathrm{Var}(\varepsilon_{n+1} + x_{n+1}^T(\beta - \hat{\beta})) \\ &= \sigma^2 + x_{n+1}^T(\sigma^2(X^TX)^{-1})x_{n+1}\,.\end{aligned}$$

D'après la question 3 on a $(X^TX)^{-1} = \frac{1}{nv(z)}\begin{bmatrix}\frac{1}{n}\sum_{i=1}^n z_i^2 & -\overline{z} \\ -\overline{z} & 1\end{bmatrix}$ *avec* $v(z)$ *variance empirique de* z*. Cela donne*

$$\begin{aligned}\mathrm{err}(z_{n+1}) &= \sigma^2 + x_{n+1}^T(\sigma^2(X^TX)^{-1})x_{n+1} \\ &= \sigma^2 + \frac{\sigma^2}{nv(z)}\left(\frac{1}{n}\sum_{i=1}^n z_i^2 - 2\overline{z}z_{n+1} + z_{n+1}^2\right) \\ &= \sigma^2 + \frac{\sigma^2}{nv(z)}\left(v(z) + \overline{z}^2 - 2\overline{z}z_{n+1} + z_{n+1}^2\right) \\ &= \sigma^2\left(1 + \frac{1}{n} + \frac{(z_{n+1} - \overline{z})^2}{nv(z)}\right).\end{aligned}$$

5. Pour quelle(s) valeur(s) de z_{n+1} l'erreur de prédiction est-elle minimale ? Interpréter ce résultat. *Solution. L'erreur est minimale en* $z_{n+1} = \overline{z}$ *et vaut* $\sigma^2 + \sigma^2/n$*. On est toujours meilleur pour prédire lorsqu'on observe le barycentre de ce qu'on a déjà observé. En effet, intuitivement, c'est le point le plus typique.*

6. Quelle est la limite de l'erreur de prédiction minimale lorsque $n \to \infty$? Interpréter cette valeur limite. *Solution. Cette erreur tend vers* σ^2 *lorsque* n *est grand, c'est l'erreur minimale de prédiction qu'on puisse faire, car la variable* Y_{n+1} *est bruitée avec un bruit indépendant et de variance* σ^2 *: on ne peut pas faire mieux.*

Deuxième partie : cas général. Nous considérons cette fois-ci le cas général à plusieurs covaraibles. Ici, pour tout $1 \leq i \leq n$,

$$Y_i = \beta_0 + \beta_1 z_{1,i} + \ldots + \beta_p z_{p,i} + \varepsilon_i\,.$$

On note

$$Z := \left[\begin{array}{c|c|c} z_1 & \ldots & z_p \end{array}\right] \in \mathbb{R}^{n\times p},$$

avec pour tout $1 \leq \ell \leq p$, $z_\ell := \begin{bmatrix} z_{\ell,1} & \ldots & z_{\ell,n}\end{bmatrix}^T \in \mathbb{R}^n$. On note $\overline{z}$ le vecteur des moyennes empiriques $\overline{z} := \begin{bmatrix}\overline{z_1} & \ldots & \overline{z_p}\end{bmatrix}^T \in \mathbb{R}^p$ (dont les entrées dépendent de n).

7. En notant $\beta = \begin{bmatrix}\beta_0 & \beta_1 & \ldots & \beta_p\end{bmatrix}^T$, écrire le modèle matriciellement sous la forme $Y = X\beta + \varepsilon$ en précisant X. *Solution. On l'a déjà fait,* X *s'écrit*

$$X = \left[\begin{array}{c|c|c|c} \mathbf{1}_n & z_1 & \ldots & z_p \end{array}\right] \in \mathbb{R}^{n\times(p+1)},$$

8. Ecrire la matrice X^TX sous forme de 4 blocs faisant intervenir Z, $\overline{z}$ et n. *Solution. Déjà fait en séance d'exercices. On a que* $X^TX = \begin{bmatrix} n & n\overline{z}^T \\ n\overline{z} & Z^TZ \end{bmatrix}$

Dans toute la suite, on suppose que le modèle est identifiable.

9. On donne la formule d'inversion matricielle par blocs : soit A une matrice inversible s'écrivant par blocs $A = \begin{bmatrix} T & U \\ V & W \end{bmatrix}$ avec T inversible. Alors $Q = W - VT^{-1}U$ est inversible et l'inverse de A est :

$$A^{-1} = \begin{bmatrix} T^{-1} + T^{-1}UQ^{-1}VT^{-1} & -T^{-1}UQ^{-1} \\ -Q^{-1}VT^{-1} & Q^{-1} \end{bmatrix}.$$

On note $\Gamma := \frac{1}{n}Z^TZ - \overline{z}\,\overline{z}^T$. Ecrire la matrice $(X^TX)^{-1}$ sous la forme d'une matrice par blocs en fonction de $n, \overline{z}$ et Γ^{-1}. *Solution. La formule donne directement* $Q = n\Gamma$ *et*

$$(X^TX)^{-1} = \frac{1}{n}\begin{bmatrix} 1 + \overline{z}^T\Gamma^{-1}\overline{z} & -(\Gamma^{-1}\overline{z})^T \\ -\Gamma^{-1}\overline{z} & \Gamma^{-1} \end{bmatrix}.$$

10. Comme dans la première partie, on observe désormais un vecteur

$$x_{n+1} = (1, z_{n+1}) = (1, z_{1,n+1}, \dots z_{\ell,n+1})$$

et l'on cherche à prédire la variable réponse Y_{n+1} avec l'estimateur $\hat{y}_{n+1} := x_{n+1}^T\hat{\beta}$. L'erreur de prédiction est définie comme précédemment.

Exprimer $\mathrm{err}(z_{n+1})$ en fonction de n, de σ^2, du vecteur $(z_{n+1} - \overline{z})$ et de la matrice Γ^{-1}. *Solution. On reprend les calculs de la question 3., et on a encore*

$$\begin{aligned} \mathrm{err}(z_{n+1}) &= \sigma^2 + x_{n+1}^T(\sigma^2(X^TX)^{-1})x_{n+1} \\ &= \sigma^2 + \frac{\sigma^2}{n}\left(1 + z^T\Gamma^{-1}z - 2z_{n+1}^T\Gamma^{-1}\overline{z} + z_{n+1}^T\Gamma^{-1}z_{n+1}\right) \\ &= \sigma^2\left(1 + \frac{1}{n} + (z_{n+1} - \overline{z})^T\Gamma^{-1}(z_{n+1} - \overline{z})\right). \end{aligned}$$

11. On admet dans cette question que Γ est symétrique définie positive. Pour quelle(s) valeur(s) de z_{n+1} l'erreur de prédiction est-elle minimale ? *Solution. Ben du coup c'est évident, il faut dire que* Γ^{-1} *est encore symétrique définie positive, et le minimum est donc atteint en* $z_{n+1} = \overline{z}$. *Le reste du temps, c'est au-dessus !*

12. ($\star$) Montrer que $\Gamma = \frac{1}{n}Z^TZ - \overline{z}\,\overline{z}^T$ est bien symétrique définie positive. *On pourra chercher à l'écrire sous la forme* $\frac{1}{n}WW^T$ *avec* W *une matrice bien choisie. Solution. Symétrie évidente. Ensuite, l'idée c'est de voir qu'elle ressemble fortement à une matrice de covariance. C'est même carrément une matrice de covariance empirique. Si on note* $\tilde{Z}$ *la matrice*

$$\tilde{Z} := \left[\begin{array}{c|c|c} z_1 - \overline{z_1}\mathbf{1}_n & \dots & z_p - \overline{z_p}\mathbf{1}_n \end{array}\right] \in \mathbb{R}^{n\times p},$$

on a que $\Gamma = \frac{1}{n}\tilde{Z}^T\tilde{Z}$. *On a donc la positivité qui en découle. On peut ensuite évoquer le résultat d'inversion par blocs qui implque que* Γ *est inversible, ou remarquer que* $\tilde{Z}$ *est*

injective. En effet, si $u \in \mathrm{Ker}\tilde{Z}$*, alors* $u_1 z_1 + \ldots + u_p z_p = \left(\sum_{\ell=1}^{p} u_\ell \overline{z_\ell}\right) \mathbf{1}_n$*, et comme* X *est de rang plein par hypothèse,* $u = 0$*.*