

STATISTIQUES (STA1) – RECUEIL D’EXERCICES

Luca Ganassali

ENSTA – Université Paris-Saclay

(Last update: August 24, 2026)

1. Rappels de statistiques : estimation, tests et intervalles de confiance

Objectifs : Retravailler les notions d'estimation, de tests et d'intervalles de confiance. Les exercices 1.1 à 1.3 sont à faire pendant le TD, les suivants sont à chercher de votre côté.

Exercice 1.1 (Estimation de la variance, moyenne inconnue). Soit un échantillon i.i.d. $(X_1, \dots, X_n)$ d'espérance μ et de variance $\sigma^2 > 0$ finie, toutes les deux inconnues. On s'intéresse à l'estimation de σ^2 . On note

$$\bar{X} := \frac{1}{n} \sum_{i=1}^n X_i \quad \text{et} \quad \hat{m}_2 := \frac{1}{n} \sum_{i=1}^n X_i^2.$$

On considère l'estimateur de σ^2 suivant :

$$V_n = \frac{1}{n} \sum_{i=1}^n (X_i - \bar{X})^2.$$

1. Montrer que $V_n = \hat{m}_2 - (\bar{X})^2$.
2. V_n est-il un estimateur sans biais de σ^2 ? Sinon, proposer un estimateur sans biais qu'on notera $\hat{\sigma}^2$.

Dans toute la suite de l'exercice, on suppose de plus que les X_i suivent la loi normale $\mathcal{N}(\mu, \sigma^2)$. On admet que cela implique que $K_{n-1} := \sum_{i=1}^n (X_i - \bar{X})^2 / \sigma^2$ suit une loi du khi-deux à $n-1$ degrés de libertés, loi dont la moyenne est $n-1$ et la variance est $2(n-1)$.

3. En déduire l'expression du risque quadratique de V_n .
4. En utilisant la loi forte des grands nombres, montrer que cet estimateur est fortement consistant ?

Exercice 1.2 (Intervalles de confiance dans le modèle uniforme). Supposons que $(X_n)_{n \geq 1}$ sont i.i.d. de loi uniforme sur $[0, \theta]$, avec $\theta > 0$. Pour tout $n \geq 1$, on définit

$$M_n := \max(X_1, \dots, X_n).$$

1. Montrer que $\left(\frac{M_n}{\theta}\right)^n$ est pivotale, et donner sa loi. On pourra calculer $\mathbb{P}_\theta((M_n/\theta)^n \leq u)$ pour tout $u \geq 0$.
2. Soit $\alpha \in]0, 1]$. En déduire un intervalle de confiance I de probabilité de couverture $1 - \alpha$ pour θ basé sur M_n .
3. Trouver un équivalent du diamètre de I lorsque $n \rightarrow \infty$, pour un α fixé dans $]0, 1]$.

Exercice 1.3 (Test gaussien, variance connue). On admet (ou on rappelle) dans cet exercice une propriété fondamentale des v.a. gaussiennes : si $(Z_j)_{1 \leq j \leq m}$ sont des v.a. réelles indépendantes et de loi respectives $(\mathcal{N}(\mu_j, \sigma_j^2))_{1 \leq j \leq m}$, alors pour tous réels $\alpha_0, \alpha_1, \dots, \alpha_m$, on a

$$\alpha_0 + \alpha_1 Z_1 + \dots + \alpha_m Z_m \sim \mathcal{N} \left(\alpha_0 + \sum_{j=1}^m \alpha_j \mu_j, \sum_{j=1}^m \alpha_j^2 \sigma_j^2 \right).$$

Soit $(X_1, \dots, X_{25})$ un échantillon de loi gaussienne d'espérance μ inconnue et de variance $\sigma^2 = 100$ connue.

On donne quelques quantiles de la loi $\mathcal{N}(0, 1)$:

$$q_{0.975} \sim 1.96, q_{0.95} \sim 1.65, q_{0.9} \sim 1.28, q_{0.8} \sim 0.84,$$

et quelques images de sa fonction de répartition Φ :

$$\Phi(1.21) \sim 0.89, \Phi(0.90) \sim 0.82, \Phi(0.53) \sim 0.70, \Phi(0.09) \sim 0.53.$$

1. Construire un test de niveau $\alpha = 0.10$ pour

$$\mathcal{H}_0 : \mu = 0 \quad \text{contre} \quad \mathcal{H}_1 : \mu = 1.5,$$

fondé sur la moyenne empirique $\bar{X} := \frac{1}{25} \sum_{i=1}^{25} X_i$, estimateur du paramètre μ .

2. On observe $\bar{x} = 1$. Quelle est la décision du test ? L'erreur que l'on fait peut-être ici est-elle de première espèce ? de seconde espèce ? La calculer.
3. Déterminer la taille minimum d'un échantillon dans le même cadre que ci-dessus si l'on souhaite que le test précédent ait des erreurs de première et de seconde espèce toutes deux inférieures à 0.1.

Exercice 1.4 (Des questions d'identifiabilité). On considère un modèle dans lequel l'observation X est une différence $X = Y - Z$ avec Y, Z deux variables gaussiennes indépendantes, de moyennes respectives μ_1, μ_2 et de variances respectives σ_1^2, σ_2^2 , toutes inconnues.

1. Ce modèle est-il identifiable ?
2. Supposons dans cette question que $\mu_2 = 3\mu_1 + 1$ et $\sigma_2 = 2\sigma_1$. Cela rend-il le modèle identifiable ?
3. Qu'en est-il d'un modèle où $X = Y - Z$ avec Y, Z deux variables exponentielles indépendantes à paramètres inconnus ? On pourra chercher une interprétation géométrique aux équations pour l'espérance et la variance de X .
4. Qu'en est-il d'un modèle où $X = \alpha(Y - Z)$ avec Y, Z deux variables exponentielles indépendantes à paramètres inconnus, et $\alpha \in \mathbb{R}$? Et si $\alpha > 0$?

Exercice 1.5 (Estimateur sans biais pour une Bernoulli). On considère un échantillon $(X_1, \dots, X_n)$ i.i.d. de loi de Bernoulli $\mathcal{B}(p)$.

1. Montrer que $\bar{X}$ (la moyenne empirique) est un estimateur sans biais de p .
2. Soit $g(\bar{X})$ un autre estimateur sans biais de p qui est une fonction (mesurable) de $\bar{X}$. Montrer que pour tout $x \in \mathbb{R}^+$:

$$\sum_{k=0}^n \left(g\left(\frac{k}{n}\right) - \frac{k}{n} \right) \binom{n}{k} x^k = 0$$

et en déduire que $\bar{X}$ est le seul estimateur sans biais de p qui est une fonction de $\bar{X}$.

Exercice 1.6. On reprend le cadre de l'exercice 1.3. Désormais on souhaite tester

$$\mathcal{H}_0 : \mu = 2 \quad \text{contre} \quad \mathcal{H}_1 : \mu < 2.$$

Bâtir un test approprié de niveau α donné. Exprimer la puissance de ce test en chaque $\mu < 2$ à l'aide de la fonction Φ , et commenter la dépendance de la puissance en fonction de μ , n et σ .

2. Information de Fisher, estimation par maximum de vraisemblance

Objectifs : Calculer une information de Fisher, l'interpréter. Savoir donner la borne de Cramer-Rao. Pratiquer l'estimation par maximum de vraisemblance. Les exercices 2.1 et 2.2 sont à faire pendant le TD, les autres sont à chercher de votre côté.

Exercice 2.1 (Information de Fisher dans un modèle à deux paramètres). On considère le modèle statistique où $X_1, \dots, X_n$ sont des variables réelles indépendantes, avec pour tout $1 \leq i \leq n$, $X_i \sim \mathcal{N}(\alpha + \beta t_i, 1)$, où les constantes $(t_i)_{1 \leq i \leq n}$ sont connues et $\alpha, \beta \in \mathbb{R}$ sont des paramètres inconnus. On admettra que ce modèle est régulier.

1. Montrer que la matrice d'information de Fisher $I(\alpha, \beta)$ s'écrit

$$I(\alpha, \beta) = \begin{pmatrix} n & \sum_{i=1}^n t_i \\ \sum_{i=1}^n t_i & \sum_{i=1}^n t_i^2 \end{pmatrix}.$$

2. Déterminer une condition nécessaire et suffisante sur les $(t_i)_{1 \leq i \leq n}$ pour que $I(\alpha, \beta)$ soit inversible. Interpréter cette condition.
3. Sous la condition de la question 2, donner une borne inférieure sur la variance de tout estimateur non biaisé de α . (On prendra donc $h(\alpha, \beta) = \alpha$).
4. Supposons que l'on connaît β . Reprendre les calculs pour trouver $\mathcal{I}(\alpha)$ et donner dans ce cas une borne inférieure sur la variance de tout estimateur non biaisé de α .
5. Comment les bornes inférieures des questions 3 et 4 se comparent-elles ? Interpréter.

Exercice 2.2 (Deux estimateurs dans le modèle uniforme). On considère le modèle dans lequel $X_1, \dots, X_n$ sont des variables i.i.d. suivant une loi uniforme sur $[0, \theta]$, où $\theta > 0$ est un paramètre inconnu.

1. Trouver un estimateur $\hat{\theta}_1$ de θ en utilisant la méthode des moments appliquée au premier moment.
2. Déterminer la vraisemblance dans ce modèle, et montrer qu'il existe un unique estimateur du maximum de vraisemblance $\hat{\theta}_2$. Donner son expression.
3. Calculer le biais, la variance et le risque quadratique de $\hat{\theta}_1$ et de $\hat{\theta}_2$. On calculera la densité de $\hat{\theta}_2$.
4. Quel est le meilleur estimateur ?

Exercice 2.3 (Estimation par maximum de vraisemblance dans le cas régulier). On considère un échantillon $X = (X_1, \dots, X_n)$ i.i.d. de loi η . Pour les modèles suivants, dont on admettra qu'ils sont réguliers, déterminer l'estimateur du maximum de vraisemblance, puis énoncer le théorème central limite associé.

1. η est la loi exponentielle de paramètre¹ $\lambda > 0$, et l'on veut estimer λ .
2. η est la loi de puissance à densité sur $\mathbb{R}$ donnée par $x \mapsto \mathbf{1}_{x \geq 1} \frac{a-1}{x^a}$ avec $a > 1$ paramètre et l'on veut estimer a .

Exercice 2.4 (Information de Fisher via reparamétrisation). Soit $\{\mathbb{P}_\theta\}_{\theta \in \Theta}$ un modèle régulier unidimensionnel. Considérons une fonction différentiable bijective $h : \Lambda \rightarrow \Theta$. La famille $\{\mathbb{P}_\theta\}_{\theta \in \Theta}$ peut ainsi être reparamétrisée par $\{\mathbb{Q}_\lambda\}_{\lambda \in \Lambda}$. On note $\tilde{I}(\lambda)$ l'information de Fisher dans ce modèle reparamétrisé. Pour λ tel que $h(\lambda) = \theta$, donner $\tilde{I}(\lambda)$ en fonction de $I(\theta)$. Donner une interprétation physique de ce résultat.

¹sa densité sur $\mathbb{R}_+$ est donnée par $x \mapsto \lambda e^{-\lambda x}$.

Exercice 2.5 (Un modèle autorégressif). Nous considérons un modèle avec $(X_1, \dots, X_n)$ tels que $X_1 = \theta + Z_1$, et récursivement, $X_{j+1} = \rho(X_j - \theta) + \theta + Z_{j+1}$ avec les Z_j i.i.d. de loi $\mathcal{N}(0, \sigma^2)$. Nous supposons que $\rho \in [0, 1]$ et qu'il est connu. On admettra la régularité de ce modèle.

1. Calculer la matrice d'information de Fisher $I(\theta, \sigma^2)$ en fonction de θ, σ^2, ρ et n .
2. Donner une borne inférieure pour la variance d'un estimateur sans biais de θ . Commenter et interpréter les valeurs de cette borne lorsque $\rho = 0$, et lorsque $\rho = 1$.

3. Théorèmes asymptotiques, Théorème de Neyman-Pearson

Objectifs : Savoir appliquer la loi des grands nombres, le théorème central limite, la méthode delta et le Lemme de Slutsky. Savoir appliquer le théorème de Neyman-Pearson pour des test d'hypothèses simples. Les exercices 3.1 à 3.2 sont à faire pendant le TD, les suivants sont à chercher de votre côté.

Exercice 3.1 (Théorèmes asymptotiques). Supposons que $X_1, \dots, X_n$ sont i.i.d., centrées, de variance finie $\sigma^2 > 0$ inconnue. On note classiquement $\bar{X}$ la moyenne empirique et $\hat{\sigma}^2$ l'estimateur non biaisé de la variance.

1. Écrire $\hat{\sigma}^2$ en fonction des X_i .
2. Étudier la convergence presque sûre de $\bar{X}$ et de $\hat{\sigma}^2$.
3. Montrer que

$$\frac{\sqrt{n}\bar{X}}{\sqrt{\hat{\sigma}^2}} \xrightarrow[n \rightarrow \infty]{(d)} \mathcal{N}(0, 1).$$

4. On suppose ici que $\sigma^2 = 1$ et qu'il est connu. Donner la limite en loi de

$$\sqrt{n}(e^{\bar{X}/2} - 1).$$

Exercice 3.2 (Test optimal pour la loi exponentielle). Soient $X_1, \dots, X_n$ des variables aléatoires i.i.d. de loi exponentielle de paramètre² $\lambda > 0$. On souhaite tester les hypothèses simples $\mathcal{H}_0 : \lambda = \lambda_0$ contre $\mathcal{H}_1 : \lambda = \lambda_1$ avec $\lambda_1 > \lambda_0$.

On rappelle la propriété suivante : la somme de n variables aléatoires indépendantes de loi exponentielle de paramètre $\lambda = 1$ suit une loi Gamma $\Gamma(n, 1)$, dont on notera $q_{\beta}^{\Gamma, n}$ le quantile d'ordre β .

1. Montrer que sous $\mathcal{H}_0$, $\lambda_0 X_1 \sim \text{Exp}(1)$.
2. A l'aide du Théorème de Neyman-Pearson et de la question précédente, montrer qu'il existe un test uniformément plus puissant (UPP) de niveau $\alpha \in]0, 1[$ pour ce problème, et qu'il peut s'écrire

$$\psi(X) = \mathbf{1}_{\{\sum_{i=1}^n X_i < (\lambda_0)^{-1} c(\alpha, n)\}},$$

où $c(\alpha, n)$ est une constante dépendant de α et de n est à déterminer.

3. On notera F_n la fonction de répartition de la loi $\Gamma(n, 1)$. Exprimer la puissance $\pi(\lambda_1)$ du test précédent pour toute valeur de $\lambda_1 > \lambda_0$, en fonction de F_n . Commenter sa monotonie en λ_1 .
4. Montrer par ailleurs que le test précédent est UPP(α) pour tester $\mathcal{H}_0 : \lambda = \lambda_0$ contre $\mathcal{H}'_1 : \lambda > \lambda_0$.

Exercice 3.3 (Asymptotique du maximum de vraisemblance). Reprenons le modèle où les $X_1, \dots, X_n$ sont i.i.d. et dont la loi est à densité sur $\mathbb{R}$ donnée par

$$x \mapsto \mathbf{1}_{x \geq 1} \frac{a-1}{x^a}$$

avec $a > 1$ un paramètre. On a établi que l'estimateur du maximum de vraisemblance de a est donné par

$$\hat{a}_{MV} = 1 + \left(\frac{1}{n} \sum_{i=1}^n \log X_i \right)^{-1}$$

²on rappelle que c'est loi à densité $x \mapsto \mathbf{1}_{x \geq 0} \lambda e^{-\lambda x}$.

dans l'exercice 2.3.

1. Etudier la distribution de $\log X_1$ en calculant sa fonction de répartition, et en déduire que $\hat{a}_{MV}$ est fortement consistant.
2. Calculer l'information de Fisher $I_1(a)$ de X_1 .
3. A l'aide de la méthode Delta, montrer que

$$\sqrt{n}(\hat{a}_{MV} - a) \xrightarrow[n \rightarrow \infty]{(d)} \mathcal{N}(0, (a-1)^2).$$

4. Interpréter les résultats des questions 2 et 3 à la lumière de la notion d'efficacité vue en cours. *On pourra admettre des résultats.*

Exercice 3.4 (Test de variance symétrique à deux échantillons). *On admettra dans cet exercice que si Z_1, Z_2 sont deux variables i.i.d. gaussiennes standard, alors Z_1/Z_2 suit une loi de Cauchy de densité sur $\mathbb{R}$ donnée par $x \mapsto \frac{1}{\pi(1+x^2)}$.*

On travaille avec deux échantillons indépendants, X_1 et X_2 . On suppose que $0 < \sigma_1^2 < \sigma_2^2$, et on souhaite tester

$$\mathcal{H}_0 : X_1 \sim \mathcal{N}(0, \sigma_1^2), X_2 \sim \mathcal{N}(0, \sigma_2^2)$$

contre

$$\mathcal{H}_1 : X_1 \sim \mathcal{N}(0, \sigma_2^2), X_2 \sim \mathcal{N}(0, \sigma_1^2).$$

On souhaite travailler avec des tests symétriques ψ , tels que $\psi(x_1, x_2) = 1 - \psi(x_2, x_1)$ presque partout.

1. Montrer que si ψ est un test symétrique de taille α pour ce problème, alors sa puissance est $\pi(\psi) = 1 - \alpha$.
2. Écrire le rapport de vraisemblance L , et construire un estimateur symétrique ψ_0 basé sur L pour ce problème.
3. Montrer que la taille α et la puissance de ψ_0 vérifient

$$\alpha = 1 - \pi(\psi_0) = \frac{2}{\pi} \tan^{-1} \left(\frac{\sigma_1}{\sigma_2} \right).$$

Exercice 3.5 (Plus vite que $\sqrt{n}$?). Reprenons l'exercice 3.1, en supposant que $\sigma^2 = 1$ et qu'il est connu.

1. Quelle est la limite en loi de $\sqrt{n}(\cos(\bar{X}) - 1)$?
2. Trouver une suite $(a_n)_{n \geq 1}$ telle que $a_n(\cos(\bar{X}) - 1)$ converge en loi vers une v.a. Z qui n'est pas presque sûrement constante, dont on précisera la loi.

Exercice 3.6. Reprenons l'exercice 3.2.

1. Sous quelle condition sur a ces variables sont-elles d'espérance finie ?
2. Sous la condition de la question 1, donner un estimateur $\hat{a}_{MM}$ de a via la méthode des moments. Prouver qu'il est consistant.
3. On suppose dans toute la suite que la condition de la question 1 est vérifiée. A l'aide du TCL et de la méthode Delta, montrer que $\hat{a}_{MM}$ est asymptotiquement normal et donner ses caractéristiques.
4. Pour n grand, quel est l'estimateur à privilégier selon vous, entre $\hat{a}_{MM}$ et $\hat{a}_{MV}$?

4. Voyage en pays gaussien

Objectifs : Se familiariser avec les vecteurs gaussiens, leurs propriétés et les calculs associés. Les exercices 4.1 à 4.3 sont à faire pendant le TD, le 4.4 est à chercher de votre côté.

Exercice 4.1 (Pour commencer). Soit $Z = (X, Y)$ un vecteur aléatoire sur $\mathbb{R}^2$ ayant une densité par rapport à la mesure de Lebesgue sur $\mathbb{R}^2$ donnée par

$$f(x, y) = C \exp(-x^2 + xy - y^2/2),$$

où C est une constante de normalisation que l'on ne demande pas de calculer.

1. Montrer que Z est un vecteur gaussien dont on précisera l'espérance et la matrice de covariance. *On pourra commencer par chercher $\mu \in \mathbb{R}^2$ et $M \in \mathbb{R}^{2 \times 2}$ symétrique telle que $-x^2 + xy - y^2/2 = \frac{1}{2}(z - \mu)^\top M(z - \mu)$ pour $z = (x, y)$.*
2. Quelle est la loi marginale de X ? de Y ? de $2X - Y + 5$?
3. Montrer que X et $Y - X$ sont indépendants.
4. Soit $B = \frac{\sqrt{5}}{5} \begin{pmatrix} 3 & -1 \\ -1 & 2 \end{pmatrix}$. Vérifier que $B^2 = \Sigma^{-1}$. Quelle est la loi du vecteur BZ ?

Exercice 4.2 (Un contre-exemple). Soit X variable réelle gaussienne $\mathcal{N}(0, 1)$, et S une variable aléatoire de Rademacher, i.e. telle que $\mathbb{P}(S = 1) = \mathbb{P}(S = -1) = 1/2$. On suppose S et X indépendantes. On définit le vecteur aléatoire $Z = (X, SX)$.

1. Montrer que les coordonnées de Z sont des gaussiennes $\mathcal{N}(0, 1)$. *On pourra montrer que la fonction de répartition de SX est encore celle d'une gaussienne standard.*
2. Montrer que pourtant, Z n'est pas un vecteur gaussien.

Exercice 4.3 (Indépendance entre moyenne et variance empiriques dans le modèle gaussien). On considère un échantillon $X = (X_1, \dots, X_n)$ i.i.d. de loi $\mathcal{N}(\mu, \sigma^2)$ avec μ et σ^2 inconnus.

1. On s'intéresse à la variance empirique de l'échantillon définie par $S_n := \frac{1}{n} \sum_{i=1}^n (X_i - \bar{X})^2$. En utilisant le théorème de Cochran, déterminer la loi de S_n et montrer que S_n et $\bar{X}$ sont indépendants. On pourra introduire le vecteur e de $\mathbb{R}^n$ dont toutes les coordonnées valent 1.
2. On s'intéresse à la variance empirique débiaisée, définie par $S'_n := \frac{1}{n-1} \sum_{i=1}^n (X_i - \bar{X})^2$. Quelle est la loi de $\sqrt{n} \frac{\bar{X} - \mu}{\sqrt{S'_n}}$?

Exercice 4.4 (Test des variances dans le modèle gaussien). Nous considérons deux échantillons gaussiens indépendants. Le premier, $X^{(1)}$, est de taille n_1 et i.i.d. de loi $\mathcal{N}(\mu_1, \sigma_1^2)$. Le second, $X^{(2)}$, est de taille n_2 et i.i.d. de loi $\mathcal{N}(\mu_2, \sigma_2^2)$. Tous les paramètres sont supposés inconnus. On note S'_1 (resp. S'_2) la variance empirique débiaisée pour l'échantillon $X^{(1)}$ (resp. $X^{(2)}$). On veut tester

$$\mathcal{H}_0 : \sigma_1^2 = \sigma_2^2 \quad \text{contre} \quad \mathcal{H}_1 : \sigma_1^2 \neq \sigma_2^2.$$

1. Sous l'hypothèse nulle, quelle est la loi de $\frac{S'_1}{S'_2}$?
2. En déduire un test de niveau $\alpha \in]0, 1[$ répondant au problème.
3. Exprimer sa puissance en fonction de σ_1^2, σ_2^2 et une certaine fonction de répartition.

5. Régression linéaire 1/2 : Modèles linéaire et linéaire gaussien, estimateur des moindres carrés, propriétés générales, tests de Student

Objectifs : Savoir faire mener les calculs de la régression linéaire, interpréter les résultats, donner des intervalles de confiance sur les coefficients, tester la nullité d'un coefficient. L'exercice 5.1 est à faire pendant le TD, les autres sont à chercher de votre côté.

Exercice 5.1 (Les eucalyptus). On souhaite expliquer la hauteur y (en mètres) d'un eucalyptus en fonction de sa circonférence x (en centimètres) à 1 mètre 30 du sol, et de la racine carrée de celle-ci. On a relevé $n = 1429$ mesures de couples (x_i, y_i) , le nuage de points étant représenté sur la figure 1 ci-contre.




Figure 1 – Données de hauteurs d'eucalyptus (m) en fonction de leur circonférence (cm).

On propose donc le modèle linéaire suivant : pour tout $1 \leq i \leq n$, $Y_i = \beta_1 + \beta_2 X_i + \beta_3 \sqrt{X_i} + \varepsilon_i$, où les ε_i sont gaussiennes i.i.d. $\mathcal{N}(0, \sigma^2)$. On pose

$$X = \begin{bmatrix} 1 & x_1 & \sqrt{x_1} \\ \vdots & \vdots & \vdots \\ 1 & x_n & \sqrt{x_n} \end{bmatrix} \quad \text{et} \quad Y = \begin{bmatrix} y_1 \\ \vdots \\ y_n \end{bmatrix}.$$

Nous avons observé

$$X^\top X = \begin{bmatrix} ? & ? & 9792 \\ ? & 3306000 & ? \\ ? & 471200 & 67660 \end{bmatrix}, \quad X^\top Y = \begin{bmatrix} 30310 \\ 1462000 \\ 209700 \end{bmatrix} \quad \text{et} \quad Y^\top Y = 651900.$$

1. Compléter la matrice $X^\top X$.
2. Que vaut la circonférence moyenne empirique $\bar{x}$?

3. Les calculs donnent en arrondissant :

$$(X^\top X)^{-1} = \begin{bmatrix} 4.646 & 0.101 & -1.379 \\ 0.101 & 0.002 & -0.030 \\ -1.379 & -0.030 & 0.411 \end{bmatrix} \quad \text{et} \quad (X^\top X)^{-1} X^\top Y = \begin{bmatrix} -16.8 \\ -0.30 \\ 7.62 \end{bmatrix}.$$

Que vaut ici l'estimateur des moindres carrés $\hat{\beta}$? Représenter la courbe de régression obtenue sur la Figure 1 via le calcul de quelques points.

4. Vérifier que pour tout modèle linéaire identifiable, $Y^\top X \hat{\beta} = \|X \hat{\beta}\|^2$.
5. En déduire la valeur de l'estimateur de σ^2 débiaisé et en donner une intervalle de confiance de niveau 95%. On utilisera l'approximation suivante : quand m est grand, une variable $\chi^2(m)$ est proche d'une variable $\mathcal{N}(m, 2m)$. On donne le quantile gaussien standard à 97.5% : $q = 1.96$.
6. Donner un intervalle de confiance pour β_3 de probabilité de couverture 95%. On approchera la loi $\mathcal{T}(m)$ par la loi $\mathcal{N}(0, 1)$, quand m est grand.
7. Tester l'hypothèse $\beta_2 = 0$ au niveau de risque 10%. On fera les mêmes approximations que précédemment. On donne le quantile gaussien standard à 95% : $q = 1.645$. Interpréter.

Exercice 5.2 (Exemple de régression linéaire à la main). On considère le modèle linéaire qui s'écrit matriciellement $Y = \theta_0 e + \theta_1 Z + \varepsilon$, avec $Y \in \mathbb{R}^n$, e le vecteur de $\mathbb{R}^n$ dont les coordonnées valent toutes 1, $Z = (z_1, z_2, \dots, z_n)^\top \in \mathbb{R}^n$, et ε un bruit centré.

1. Donner une condition nécessaire et suffisante explicite sur le vecteur Z pour que le modèle soit identifiable. Interpréter.

On se place sous la condition d'identifiabilité de la question 1. On introduit la covariance empirique entre Y et Z définie par $C(Y, Z) := \frac{1}{n} \sum_{i=1}^n z_i Y_i - \bar{Z} \times \bar{Y}$, ainsi que la variance empirique de Z définie par $V(Z) := \frac{1}{n} \sum_{i=1}^n z_i^2 - (\frac{1}{n} \sum_{i=1}^n z_i)^2$.

2. Calculer à la main l'estimateur des moindres carrés $\hat{\theta}_{MC} = (\hat{\theta}_0, \hat{\theta}_1)^\top$. On écrira $\hat{\theta}_1$ en fonction de C et V , puis $\hat{\theta}_0$ en fonction de θ_0 .
3. Montrer que le point moyen, de coordonnées $(\bar{Z}, \bar{Y})$, appartient à la droite de régression obtenue.

Exercice 5.3 (Théorème de Gauss-Markov). On note $\preceq$ la relation d'ordre dans $S_p(\mathbb{R})$ définie par :

$$A \preceq B \iff B - A \in S_p^+(\mathbb{R}).$$

Pour $\hat{\theta}_1$ et $\hat{\theta}_2$ deux estimateurs sans biais de $\theta \in \mathbb{R}^p$, on dira que $\hat{\theta}_1$ est meilleur que $\hat{\theta}_2$ si $\text{Var}(\hat{\theta}_1) \preceq \text{Var}(\hat{\theta}_2)$.

Le but de cet exercice est de démontrer le *théorème de Gauss-Markov*, dont l'énoncé est le suivant : *dans un modèle linéaire identifiable, parmi tous les estimateurs de θ linéaires en Y et sans biais, l'estimateur des moindres carrés est le meilleur (au sens de l'ordre $\preceq$).*

On considère donc $\tilde{\theta}$ un autre estimateur de θ , linéaire en Y et sans biais. On l'écrit $\tilde{\theta} = CY$ avec $C = (X^\top X)^{-1} X^\top + D$ avec $D \in \mathbb{R}^{p \times n}$.

1. Montrer que $DX = 0$.
2. Montrer que $\text{Var}(\tilde{\theta}) = \text{Var}(\hat{\theta}_{MC}) + \sigma^2 DD^\top$. Conclure.

6. Régression linéaire 2/2 : intervalle de confiance pour un coefficient, interprétation géométrique, modèles emboîtés, variable qualitative

Objectifs : Savoir lire les résultats d'une régression linéaire à la main, tester des modèles emboîtés, traiter le cas d'une variable quantitative. L'exercice 6.1 est à faire pendant le TD, le reste est à chercher de votre côté.

Exercice 6.1 (Régression avec une variable qualitative). Dans cet exercice, nous étudions la régression linéaire dans le cas où nous avons une variable qualitative. Imaginons qu'on veuille modéliser une variable réponse réelle Y_i d'un individu i en fonction d'une variable réelle continue Z_i et d'une variable qualitative G_i , assimilée à un groupe, entre 1 et k . Plus exactement, dans notre modèle, Y_i est la somme d'un paramètre réel α_{G_i} ne dépendant que de G_i , d'un terme linéaire en Z_i , et d'un bruit. On suppose que les groupes sont disjoints et que $n \geq k + 1$.

1. On supposera les bruits i.i.d. de loi $\mathcal{N}(0, \sigma^2)$. Ecrire le modèle correspondant pour chaque Y_i .
2. On note n_g le nombre d'individus i tels que $G_i = g$. Montrer que ce modèle se réécrit sous matriciellement sous la forme d'un modèle linéaire gaussien $Y = X\theta + \varepsilon$. On mettra Z dans la dernière colonne et on précisera la forme de θ et de X . Combien vaut p dans ce modèle ?
3. A quelle condition ce modèle est-il identifiable ?
4. Changeons de modèle et considérons $Y = X\theta + \varepsilon$ avec

$$\theta = \begin{pmatrix} \mu \\ \alpha_2 \\ \vdots \\ \alpha_k \\ \theta_1 \end{pmatrix} \quad \text{et} \quad X = \left(\begin{array}{cccc|c} \mathbf{1}_{n_1} & & & & Z \\ \mathbf{1}_{n_2} & \mathbf{1}_{n_2} & & & \\ \vdots & & \ddots & & \\ \vdots & & & \ddots & \\ \mathbf{1}_{n_k} & & & & \mathbf{1}_{n_k} \end{array} \right) \in \mathbb{R}^{n \times p},$$

et $\varepsilon \sim \mathcal{N}(0, \sigma^2 I_n)$. A quelle condition ce modèles est-il identifiable ? Quelle est la différence avec le modèle de la question 2. ?

Application : nous observons les poids Y_i de souris dont les mères sont de 4 génotypes différents pour un certain gène G : ce génotype est soit A, B, I ou J . Pour chaque individu i on note G_i le génotype de la mère. On a aussi accès à une variable Z_i mesurant la pression de l'air ambiant au moment de la mesure.

Nous nous posons la question suivante : est-ce que le gène G de la mère influe sur le poids de sa descendance ?

La figure ci-contre présente les résultats obtenus pour une régression linéaire avec (a) le modèle de la question 2 et (b) celui de la question 4:

	Modèle (a)			Modèle (b)	
	$\hat{\theta}_i$	$\hat{\sigma}_i \sqrt{[(X^\top X)^{-1}]_{i,i}}$		$\hat{\theta}_i$	$\hat{\sigma}_i \sqrt{[(X^\top X)^{-1}]_{i,i}}$
MotherA	55.4129	1.9191	Intercept	55.4129	1.9191
MotherB	58.6522	2.0526	MotherB	3.2393	2.8104
MotherI	53.4492	1.9230	MotherI	-1.9638	2.7159
MotherJ	48.7978	1.9890	MotherJ	-6.6151	2.7628
Z	-0.6534	0.9315	Z	-0.6534	0.9315

Ici, $n - p = 56$ et on donne quelques quantiles $t_{1-\alpha/2}$ de la loi de Student de paramètre $d = 56$: $t_{0.9995} = 3.4729$, $t_{0.995} = 2.6665$, $t_{0.95} = 1.6725$, $t_{0.85} = 1.0461$.

```
Call:
lm(formula = Wt ~ Mother + X1 - 1, data = data)

Residuals:
    Min       1Q   Median       3Q      Max
-18.423  -5.143   1.980   5.085  13.055

Coefficients:
            Estimate Std. Error t value Pr(>|t|)
MotherA    55.4129     1.9191  28.875  <2e-16 ***
MotherB    58.6522     2.0526  28.574  <2e-16 ***
MotherI    53.4492     1.9230  27.795  <2e-16 ***
MotherJ    48.7978     1.9890  24.534  <2e-16 ***
X1         -0.6534     0.9315  -0.701    0.486
---
Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

Residual standard error: 7.676 on 56 degrees of freedom
Multiple R-squared:  0.9818,    Adjusted R-squared:  0.9802
F-statistic: 605.8 on 5 and 56 DF,  p-value: < 2.2e-16
```

```
Call:
lm(formula = Wt ~ Mother + X1, data = data)

Residuals:
    Min       1Q   Median       3Q      Max
-18.423  -5.143   1.980   5.085  13.055

Coefficients:
            Estimate Std. Error t value Pr(>|t|)
(Intercept) 55.4129     1.9191  28.875  <2e-16 ***
MotherB      3.2393     2.8104   1.153   0.254
MotherI     -1.9638     2.7159  -0.723   0.473
MotherJ     -6.6151     2.7628  -2.394   0.020 *
X1          -0.6534     0.9315  -0.701   0.486
---
Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

Residual standard error: 7.676 on 56 degrees of freedom
Multiple R-squared:  0.1953,    Adjusted R-squared:  0.1378
F-statistic: 3.397 on 4 and 56 DF,  p-value: 0.01476
```

(a) – avec le modèle de la question 2

(b) – avec le modèle de la question 4

Figure 2 – Résultats obtenus (régression linéaire sur R)

- Que dire de la pertinence de la variable Z dans ces modèles ? (On attend un test de Student).
- Quel est le modèle le plus adapté pour répondre à la question posée ? Que répondez-vous à la question ?

Exercice 6.2 (Comparaison de modèles). On effectue une régression de y sur deux variables explicatives x et z à partir d'un échantillon de n individus, c'est-à-dire que $X = [\mathbf{1} \mid x \mid z]$, où $\mathbf{1}$ est le vecteur de taille n composé de 1. On a obtenu le résultat suivant :

$$X^T X = \begin{bmatrix} 5 & 3 & 0 \\ 3 & 3 & 1 \\ 0 & 1 & 1 \end{bmatrix}.$$

- Que vaut n ?
- Le coefficient de corrélation linéaire empirique $\hat{\rho}(a, b)$ entre deux réalisations a, b est défini par :

$$\hat{\rho}(a, b) := \frac{\sum_{i=1}^n a_i b_i - \bar{a} \times \bar{b}}{\sqrt{\sum_{i=1}^n a_i^2 - (\bar{a})^2} \sqrt{\sum_{i=1}^n b_i^2 - (\bar{b})^2}}.$$

Que vaut $\hat{\rho}(x, z)$?

- La régression par moindres carrés a donné le résultat suivant :

$$y_i = -1 + 3x_i + 4z_i + \varepsilon_i,$$

et la somme des carrés résiduels vaut $\|\hat{\varepsilon}\|^2 = 3$.

3.(a). En repartant de l'expression de $\hat{\theta}_{MC}$, exprimer $X^T Y$ en fonction de $X^T X$ et $\hat{\theta}_{MC}$. Calculer $X^T Y$ et en déduire la moyenne empirique $\bar{y}$.

3.(b). Vérifier que $\|X\hat{\theta}_{MC}\|^2 = Y^T X\hat{\theta}_{MC} = \hat{\theta}_{MC}^T X^T Y$. Calculer alors $\|\hat{Y}\|^2$ et en déduire $\|Y\|^2$.

3.(c). Calculer la somme des carrés totale $\|Y - \bar{y}\mathbf{1}\|^2$, puis déterminer le coefficient de détermination R^2 ainsi que le coefficient de détermination ajusté.

- On s'intéresse maintenant au modèle privé du régresseur z , c'est-à-dire $Y = X_0 \theta_0 + \varepsilon_0$ avec $X_0 = [\mathbf{1} \mid x]$.

4.(a). Déterminer $X_0^T X_0$ et $X_0^T Y$. En déduire $(\hat{\theta}_0)_{MC}$.

4.(b). Calculer $\|\hat{Y}_0\|^2$.

4.(c). Justifier l'égalité $\|\hat{Y}_0\|^2 + \|\varepsilon_0\|^2 = \|\hat{Y}\|^2 + \|\varepsilon\|^2$. En déduire la somme des carrés résiduels $\|\varepsilon_0\|^2$ dans ce nouveau modèle. Déterminer le coefficient de détermination R_0^2 ainsi que le coefficient de détermination ajusté.

5. On suppose désormais que le modèle est gaussien. On veut comparer les deux modèles précédents.

5.(a). Effectuer un test de Fisher entre ces deux modèles grâce aux coefficients de détermination. Montrer que la statistique de Fisher s'écrit aussi

$$F = \frac{n-p}{p-p_0} \frac{R^2 - R_0^2}{1 - R^2}.$$

Calculer F dans notre cas. Qu'en concluez-vous au niveau de risque 5% ? On donne $f^{1,2}(0.95) = 18.5$.

5.(b). Proposer un autre moyen d'arriver au même résultat.

Exercice 6.3 (Minimisation de l'erreur de prédiction). Dans cet exercice, on s'intéresse à l'erreur de prédiction dans le modèle linéaire. On cherche à apprendre le modèle suivant pour prédire le réel Y_i en fonction d'une variable explicative réelle z_i :

$$\forall 1 \leq i \leq n, \quad Y_i = \beta_0 + \beta_1 z_i + \varepsilon_i.$$

On notera $\bar{y}$ et $\bar{z}$ les moyennes empiriques de $z = (z_1, \dots, z_n)^\top$ et de $Y = (Y_1, \dots, Y_n)^\top$ (attention, elles dépendent de n). On suppose que le modèle est identifiable et on note $\hat{\beta} = (\hat{\beta}_0, \hat{\beta}_1)$ l'estimateur des moindres carrés de β . On note σ^2 la variance (constante) du bruit.

Sous le même modèle, on observe une nouvelle valeur z_{n+1} de la variable explicative et on cherche à prédire la variable réponse Y_{n+1} avec l'estimateur

$$\hat{y}_{n+1} := \hat{\beta}_0 + \hat{\beta}_1 z_{n+1} = x_{n+1}^\top \hat{\beta}, \quad \text{où } x_{n+1} := \begin{bmatrix} 1 \\ z_{n+1} \end{bmatrix}.$$

L'erreur de prédiction est définie par :

$$\text{err}(z_{n+1}) := \mathbb{E} [(Y_{n+1} - \hat{y}_{n+1})^2].$$

Notons que dans cette espérance, l'aléa vient du bruit ε_{n+1} dans Y_{n+1} ainsi que de l'aléa dans le $\hat{\beta}$.

1. Montrer que si S est un vecteur aléatoire de $\mathbb{R}^m$ de matrice de covariance (finie) C , alors pour tout vecteur $u \in \mathbb{R}^m$, $\text{Var}(u^\top S) = u^\top C u$.
2. Que vaut $\mathbb{E}[Y_{n+1} - \hat{y}_{n+1}]$?
3. Ecrire la matrice X du plan d'expérience dans ce modèle (on mettra l'intercept dans la première colonne), et montrer que

$$(X^\top X)^{-1} = \frac{1}{nv(z)} \begin{bmatrix} \frac{1}{n} \sum_{i=1}^n z_i^2 & -\bar{z} \\ -\bar{z} & 1 \end{bmatrix},$$

avec $v(z) := \frac{1}{n} \sum_{i=1}^n z_i^2 - (\bar{z})^2$ la variance empirique de z .

4. En utilisant les résultats des questions 1, 2 et 3, montrer que

$$\text{err}(z_{n+1}) = \sigma^2 \left(1 + \frac{1}{n} + \frac{(z_{n+1} - \bar{z})^2}{\sum_{i=1}^n (z_i - \bar{z})^2} \right).$$

5. Pour quelle(s) valeur(s) de z_{n+1} l'erreur de prédiction est-elle minimale ? Interpréter ce résultat.

-
6. Quelle est la limite de l'erreur de prédiction minimale lorsque $n \rightarrow \infty$? Interpréter cette valeur limite.

Exercice 6.4 (Equivalence Student/Fisher pour la nullité d'un coefficient). Dans cet exercice souhaite montrer l'équivalence entre les tests de Student et de Fisher pour la nullité d'un paramètre. On considère donc le modèle linéaire Gaussien identifiable $Y = X\theta + \varepsilon$ pour lequel on veut tester la nullité du dernier coefficient θ_p .

1. Donner la statistique T du test de Student pour le test de nullité du dernier coefficient θ_p .
2. Donner la statistique F du test de Fisher pour les modèles emboîtés correspondants. On fera apparaître $\hat{\sigma}^2$ au dénominateur.
3. Soit T_d une variable suivant une loi de Student à d degrés de liberté. Rappeler sa définition et en déduire la loi suivie par la variable $F_d = T_d^2$.
4. On note la matrice du plan d'expérience sous forme de bloc $X = [X_0 | X_p]$, où $X_0 = [X_1 | \dots | X_{p-1}]$ est la matrice de taille $n \times (p-1)$ des $(p-1)$ premières colonnes de X , et X_p est sa dernière colonne. Ecrire la matrice $X^\top X$ sous forme de 4 blocs.
5. On donne (ou on rappelle) le lemme suivant :

Lemme (Inversion par blocs). Soit A une matrice inversible s'écrivant par blocs $A = \begin{bmatrix} T & U \\ V & W \end{bmatrix}$ avec T inversible. Alors $Q = W - VT^{-1}U$ est inversible et l'inverse de A s'écrit :

$$A^{-1} = \begin{bmatrix} T^{-1} + T^{-1}UQ^{-1}VT^{-1} & -T^{-1}UQ^{-1} \\ -Q^{-1}VT^{-1} & Q^{-1} \end{bmatrix}.$$

Grâce à la formule d'inversion matricielle par blocs, en déduire que

$$[(X^\top X)^{-1}]_{i,i} = (X_p^\top (I_n - \Pi_0) X_p)^{-1},$$

où Π_0 est la matrice $n \times n$ de projection orthogonale sur l'espace engendré par les colonnes de X_0 .

6. En reprenant les notations du cours $\hat{Y}$ et $\hat{Y}_0$, vérifier que $\hat{Y}_0 = \Pi_0 \hat{Y}$ puis montrer que

$$\hat{Y} - \hat{Y}_0 = (\hat{\theta}_{MC})_p (I_n - \Pi_0) X_p.$$

7. En déduire que dans ce cas $F = T^2$. Conclure.