

Statistiques (STA1)

Cours I – Rappels de statistiques : estimation, tests et intervalles de confiance

Luca Ganassali

Laboratoire de Mathématiques d'Orsay, Université Paris-Saclay

Jeudi 3 septembre 2026

Introduction


Introduction : Statistiques vs Probabilités

- En **probabilités**, on cherche à étudier les propriétés d'une variable aléatoire qui suit une loi $\mathbb{P}$ connue :

$$\mathbb{P} \longrightarrow \text{propriétés de } X \sim \mathbb{P}$$

- En **statistiques**, à partir d'observations d'une loi $\mathbb{P}$ inconnue, on cherche à apprendre (inférer) des propriétés de cette loi pour répondre à une question :

$$\text{observations } x \text{ d'un } X \sim \mathbb{P} \longrightarrow \text{propriétés de } \mathbb{P}$$



- **Modélisation** : choisir convenablement un ensemble de lois $\mathbb{P}$ possibles, en adéquation avec (i) nos connaissances préalables, (ii) nos objectifs, (iii) les données, (iv) les capacités de calcul...
- **Estimation** : estimer la valeur d'un paramètre d'intérêt de la loi $\mathbb{P}$
- **Intervalle de confiance** : savoir encadrer la valeur du paramètre d'intérêt entre deux bornes
- **Test** : prendre une décision sur une hypothèse à l'aide des données
- **Prédiction** : pouvoir prédire la valeur prise par une nouvelle variable non encore observée

Enjeux:

- Comprendre comment construire, comparer, choisir des procédures
- Quantifier la fiabilité, le risque de l'information obtenue

- **Cours I – Rappels de statistiques : estimation, tests et intervalles de confiance**
- Cours II – Information de Fisher, estimation par maximum de vraisemblance
- Cours III – Théorèmes asymptotiques, Théorème de Neyman-Pearson
- Cours IV – Voyage en pays Gaussien
- Cours V – Régression linéaire 1/2 : Modèles linéaire et linéaire gaussien, estimateur des moindres carrés, propriétés générales, tests de Student
- Cours VI – Régression linéaire 2/2 : intervalle de confiance pour un coefficient, interprétation géométrique, modèles emboîtés, variable qualitative

Documents de support de cours

- Slides et TDs sur ma page
<https://lganassali.github.io/teaching.html>.
- Quizz à faire d'une session à l'autre (à faire chez vous, durée 5-10 min).
- **Disclaimer** : j'ai conscience que le format slides n'est pas optimal (mais pour faire un cours de stats en 6h, je n'ai pas le choix). Un polycopié "Mathematical Statistics" beaucoup plus exhaustif est disponible sur ma page (https://lganassali.github.io/pdfs/Mathematical_Statistics_Lecture_notes.pdf)

Evaluation : un examen le **jeudi 22 octobre 2026**, 10h-12h, qui pourra comporter des questions théoriques et des questions pratiques d'interprétation de résultats. Il n'y aura pas de code informatique à écrire.

Chargés de TDs : A. Janon, F. Mas, S.M. Giancola, G. Durand, L. Ganassali

Modélisation statistique

Modéliser l'expérience, c'est proposer un ensemble de lois théoriques pour la distribution possible des données observées z (échantillon).

- Un **modèle** est la donnée de $\mathcal{M} = (\mathcal{Z}, (\mathbb{P}_\theta)_{\theta \in \Theta})$ avec
 - $\mathcal{Z}$ espace mesurable muni d'une tribu $\mathcal{A}$ (on omettra $\mathcal{A}$ dans la suite)
 - $(\mathbb{P}_\theta)_{\theta \in \Theta}$ une famille de lois de probabilité sur $\mathcal{Z}$, indexées par un ensemble Θ .

Lorsque $\Theta \subset \mathbb{R}^d$, le modèle est dit **paramétrique**.

- Les **données** z sont une réalisation (valeur) particulière prises par la variable aléatoire Z dans $\mathcal{Z}$, et dont la loi appartient au modèle.
- Lorsque Z est de la forme $Z = (X_1, \dots, X_n)$ avec les X_i indépendantes et identiquement distribuées (i.i.d.), on dit que X est un **échantillon** de taille n , ou n -échantillon. Dans ce cas, $\mathcal{Z}$ s'écrit $\mathcal{Z} = \mathcal{X}^n$ et $\mathbb{P}_\theta$ s'écrit $\mathbb{P}_\theta = (\eta_\theta)^{\otimes n}$.
- Le modèle $\mathcal{M}$ est dit **identifiable** lorsque pour deux paramètres différents, la loi de Z est différente, i.e. $\theta \in \Theta \mapsto \mathbb{P}_\theta$ est injective.

Exemple : Étude de la moyenne (espérance) d'un temps de trajet :

$$\mathcal{M} = (\mathbb{R}^n, ((\mathcal{N}(\mu, \sigma^2))^{\otimes n})_{(\mu, \sigma^2) \in \mathbb{R} \times \mathbb{R}_+}).$$

Exemple : Estimation d'une proportion par sondage :

$$\mathcal{M} = (\{0, 1\}^n, (B(p)^{\otimes n})_{p \in [0;1]})$$

Exemple : Comparaison du rendement de maïs sous deux conditions de culture :

$$(X_1, \dots, X_n) \sim \mathcal{N}(\mu_x, \sigma_x^2)^{\otimes n} \text{ et } (Y_1, \dots, Y_m) \sim \mathcal{N}(\mu_y, \sigma_y^2)^{\otimes m} \text{ indépendants,}$$

avec $\mu_x, \mu_y \in \mathbb{R}$ et $\sigma_x, \sigma_y > 0$.

Tous ces modèles sont paramétriques et identifiables. Pour en savoir plus sur l'identifiabilité : cf quizz + TD.

Estimation ponctuelle

Soit $\theta \in \Theta$ paramètre d'une loi $\mathbb{P}_\theta$ et $Z = (X_1, \dots, X_n)$ un n -échantillon de cette loi.

Une **statistique** est une **variable aléatoire** T_n , fonction mesurable de l'échantillon et calculable à partir de l'échantillon :

$$T_n = F(X_1, \dots, X_n).$$

Un **estimateur** est une statistique utilisée pour estimer un paramètre ou une quantité d'intérêt $\varphi(\theta) \in \mathbb{R}^k$. On notera $T_n = \hat{\varphi}$.

Exemple : si Z est un n -échantillon de variables d'espérance finie μ , un estimateur de μ est par exemple $\hat{\mu} = \bar{X} := \frac{1}{n} \sum_{i=1}^n X_i$, appelée **moyenne empirique**.

Biais, variance, risque quadratique d'un estimateur

Soit $\hat{\varphi}$ un estimateur de $\varphi(\theta) \in \mathbb{R}^k$, fonction du paramètre d'une loi $\mathbb{P}_\theta$.

- On appelle (fonction de) **biais** de $\hat{\varphi}$ pour $\varphi(\theta)$ le vecteur

$$b_\theta(\hat{\varphi}) = \mathbb{E}_\theta[\hat{\varphi}] - \varphi(\theta) \in \mathbb{R}^k,$$

qui est **fonction du vrai paramètre θ** . Si $b_\theta(\hat{\varphi}) = \mathbf{0}_k$ pour tout $\theta \in \Theta$, $\hat{\varphi}$ est dit **sans biais** pour estimer $\varphi(\theta)$.

- On appelle **matrice de covariance** de $\hat{\varphi}$ la valeur (**fonction du paramètre θ**)

$$\text{Var}_\theta(\hat{\varphi}) = \mathbb{E}_\theta[(\hat{\varphi} - \mathbb{E}_\theta[\hat{\varphi}])(\hat{\varphi} - \mathbb{E}_\theta[\hat{\varphi}])^T] \in \mathbb{R}^{k \times k}$$

- On appelle **risque quadratique** de $\hat{\varphi}$ la valeur (**fonction du paramètre θ**)

$$R_\theta(\hat{\varphi}) = \mathbb{E}_\theta[\|\hat{\varphi} - \varphi(\theta)\|^2] \in \mathbb{R}_+,$$

où $\|\cdot\|$ est la norme euclidienne canonique sur $\mathbb{R}^k$.

Proposition (Pythagore du statisticien)

On a, pour tout $\theta \in \Theta$,

$$R_{\theta}(\hat{\varphi}) = \|b_{\theta}(\hat{\varphi})\|^2 + \text{Tr}(\text{Var}_{\theta}(\hat{\varphi})).$$

Preuve. Il suffit d'écrire, pour tout $\theta \in \Theta$,

$$\begin{aligned} R_{\theta}(\hat{\varphi}) &= \mathbb{E}_{\theta}[\|\hat{\varphi} - \mathbb{E}_{\theta}[\hat{\varphi}] + \mathbb{E}_{\theta}[\hat{\varphi}] - \varphi(\theta)\|^2] \\ &= \mathbb{E}_{\theta}[\|\hat{\varphi} - \mathbb{E}_{\theta}[\hat{\varphi}]\|^2] + \mathbb{E}_{\theta}[\|\mathbb{E}_{\theta}[\hat{\varphi}] - \varphi(\theta)\|^2] + 2(\mathbb{E}_{\theta}[\hat{\varphi}] - \varphi(\theta))^T \mathbb{E}_{\theta}[\hat{\varphi} - \mathbb{E}_{\theta}[\hat{\varphi}]] \\ &= \mathbb{E}_{\theta}[\|\hat{\varphi} - \mathbb{E}_{\theta}[\hat{\varphi}]\|^2] + \|b_{\theta}(\hat{\varphi})\|^2, \end{aligned}$$

et par cyclicité et linéarité de la trace, et linéarité de l'espérance,

$$\begin{aligned} \mathbb{E}_{\theta}[\|\hat{\varphi} - \mathbb{E}_{\theta}[\hat{\varphi}]\|^2] &= \mathbb{E}_{\theta}[\text{Tr}[(\hat{\varphi} - \mathbb{E}_{\theta}[\hat{\varphi}])^T (\hat{\varphi} - \mathbb{E}_{\theta}[\hat{\varphi}])] \\ &= \mathbb{E}_{\theta}[\text{Tr}[(\hat{\varphi} - \mathbb{E}_{\theta}[\hat{\varphi}]) (\hat{\varphi} - \mathbb{E}_{\theta}[\hat{\varphi}])^T]] \\ &= \text{Tr}[\mathbb{E}_{\theta}[(\hat{\varphi} - \mathbb{E}_{\theta}[\hat{\varphi}]) (\hat{\varphi} - \mathbb{E}_{\theta}[\hat{\varphi}])^T]] \\ &= \text{Tr}(\text{Var}_{\theta}(\hat{\varphi})). \end{aligned}$$

□

Prenons deux estimateurs $\hat{\varphi}_1$ et $\hat{\varphi}_2$ de $\varphi(\theta)$. On dit que $\hat{\varphi}_1$ domine $\hat{\varphi}_2$ si, pour tout $\theta \in \Theta$,

$$R_\theta(\hat{\varphi}_1) \leq R_\theta(\hat{\varphi}_2).$$

Remarque: il n'existe en général pas d'estimateur dominant tous les autres.

Dans le cas d'un modèle à échantillon i.i.d. de taille n , pour $\hat{\varphi} = \hat{\varphi}_n$ un estimateur de $\varphi(\theta)$, on dira que $\hat{\varphi}_n$ est fortement consistant si il converge $\mathbb{P}_\theta$ -presque sûrement vers $\varphi(\theta)$ pour tout θ , i.e.

$$\forall \theta \in \Theta, \quad \mathbb{P}_\theta\left(\lim_{n \rightarrow \infty} \hat{\varphi}_n = \varphi(\theta)\right) = 1$$

Tests statistiques

- Un constructeur automobile annonce une consommation $\mu_0 = 6.32\ell/100\text{ km}$, avec un écart type $\sigma = 0.21\ell/100\text{ km}$, pour des véhicules d'un type donné.
- Un organisme indépendant suspecte une sous-estimation de cette consommation et indique que la consommation s'élèverait à $\mu_1 = 6.45\ell/100\text{ km}$. Il ne remet pas en cause la variance.
- Sur un 30-échantillon, on observe $\bar{x} = 6.43\ell/100\text{ km}$.

Doit-on incriminer le constructeur?

1. **Définir un modèle** : Les individus sont les véhicules, $i = 1, \dots, n$, la variable observée Z_i est la consommation. On suppose les $Z_i \sim \mathcal{N}(\mu, \sigma^2)$ i.i.d., μ inconnue et variance connue $\sigma^2 = (0.21)^2$
2. **Définir les hypothèses**
 $\mathcal{H}_0$ conso. conforme au constructeur: $\mu = \mu_0 = 6.32$
 $\mathcal{H}_1$ conso. suspectée par l'organisme: $\mu = \mu_1 = 6.45$

Choisir, à partir de l'observation du n -échantillon, entre les deux hypothèses $\mathcal{H}_0$ et $\mathcal{H}_1$, tel que le risque de *choisir* $\mathcal{H}_1$ *alors que* $\mathcal{H}_0$ *est vrai* soit faible et maîtrisé. C'est le **risque de première espèce**. On dit que le test est de **niveau** α (5%, 10%, ...) si ce risque est (inférieur ou) égal à α .

3. Définir une statistique de test

- Travailler à partir de $\bar{X}$, moyenne des consommations de $n = 30$ véhicules
- Loi sous $\mathcal{H}_0$ (où $\mu = \mu_0$),

$$\bar{Z} \sim \mathcal{N}(\mu_0, \sigma^2/n) \text{ donc } T = \sqrt{n} \frac{\bar{Z} - \mu_0}{\sigma} \sim \mathcal{N}(0, 1)$$

4. Définir la région de rejet

- Choisir a priori un niveau α , calibrant la probabilité de rejet de $\mathcal{H}_0$ à tort ($\alpha = 5\%$ par exemple) (risque de type I)
- Chercher une région de rejet $\mathcal{R}$ telle que $\alpha = \mathbb{P}_{H_0}(T \in \mathcal{R})$. On remarque que comme $T \sim \mathcal{N}(0, 1)$ sous $\mathcal{H}_0$, alors $\mathbb{P}_{H_0}(T > q_{1-\alpha}^*) = \alpha$, avec $q_{1-\alpha}^*$ le quantile d'une loi $\mathcal{N}(0, 1)$ d'ordre $1 - \alpha$. On a donc

$$\begin{aligned} \alpha &= \underbrace{\mathbb{P}_{H_0}(T > q_{1-\alpha}^*)}_{\mathcal{R} =]q_{1-\alpha}^*; \infty[, \text{ Région de rejet pour } T} \\ &= \underbrace{\mathbb{P}_{H_0}(\bar{Z} > \mu_0 + q_{1-\alpha}^* \frac{\sigma}{\sqrt{n}})}_{\mathcal{R}' =]\mu_0 + q_{1-\alpha}^* \frac{\sigma}{\sqrt{n}}; \infty[, \text{ Région de rejet pour } \bar{Z}} \end{aligned}$$

5. Décider:

- si T est dans la région de rejet, on **rejette** $\mathcal{H}_0$
- sinon, on **ne rejette pas** $\mathcal{H}_0$ et on la conserve, faute de preuves suffisantes

Pour $\alpha = 5\%$, $q_{1-\alpha}^* \sim 1.64$.

Supposons que pour nos données, $\bar{z} = 6.43 \text{ } \ell/100 \text{ km}$,

$$t_{obs} = \frac{6.43 - 6.32}{0.21/\sqrt{30}} = 2.86 > 1.64 = q_{1-\alpha}^*$$

Ainsi, au niveau $\alpha = 5\%$, les données sont significatives pour rejeter $\mathcal{H}_0$. Conclusion : on peut affirmer que le constructeur a minimisé la consommation, avec une probabilité d'erreur (de première espèce) égal à 5%.

Imaginons le même test mais sur d'autres données.

- si la même consommation a été observée sur un échantillon de $n = 9$ véhicules

$$t_{obs} = \frac{6.43 - 6.32}{0.21/\sqrt{9}} = 1.57 < 1.64$$

on ne peut pas rejeter le fait que le constructeur a sous-estimé la consommation, on ne peut rejeter $\mathcal{H}_0$ qu'on accepte par défaut

- avec quelle erreur?

Une autre façon de se tromper: l'erreur de type II: ne pas rejeter $\mathcal{H}_0$ alors que $\mathcal{H}_1$ est vraie.

Sous $\mathcal{H}_1$, $\bar{Z} \sim \mathcal{N}(\mu_1, \frac{\sigma^2}{n})$ et le **risque de type II** est

$$\begin{aligned}\beta &= \mathbb{P}_{H_1}(T \notin \mathcal{R}) \\ &= \mathbb{P}_{H_1}(\bar{Z} < \mu_0 + q_{1-\alpha}^* \frac{\sigma}{\sqrt{n}}) \\ &= F^* \left(\sqrt{n} \frac{\mu_0 - \mu_1}{\sigma} + q_{1-\alpha}^* \right)\end{aligned}$$

A.N.: $n = 9$, $\beta \simeq 0.41$. La **puissance** du test $\pi = 1 - \beta$ n'est pas très grande.

Test : définition rigoureuse

On se place sur le modèle statistique $\mathcal{M} = (\mathcal{Z}, (\mathbb{P}_\theta)_{\theta \in \Theta})$. Pour définir les hypothèses $\mathcal{H}_0, \mathcal{H}_1$ rigoureusement, on se donne (Θ_0, Θ_1) une partition de Θ :

$$\Theta = \Theta_0 \cup \Theta_1 \quad \text{et} \quad \Theta_0 \cap \Theta_1 = \emptyset.$$

On considère alors le test d'hypothèses

$$\mathcal{H}_0 := \theta \in \Theta_0 \quad \text{vs} \quad \mathcal{H}_1 := \theta \in \Theta_1.$$

Un **test** de $\mathcal{H}_0$ contre $\mathcal{H}_1$ est alors une fonction $\psi : \mathcal{Z} \rightarrow \{0, 1\}$ de la forme

$$\psi(z) = \mathbf{1}_{\{T(z) \in \mathcal{R}\}},$$

où T est une statistique des données z , et $\mathcal{R}$ est une région fixée appelée **région de rejet**. Il appartient au statisticien de déterminer T et $\mathcal{R}$ pour construire ψ .

Exemple. Dans l'exemple précédent, $\theta = \mu$, $\mathbb{P}_\mu = \mathcal{N}(\mu, \sigma^2)^{\otimes n}$, $\Theta = \{\mu_0, \mu_1\}$, $\Theta_0 = \{\mu_0\}$, $\Theta_1 = \{\mu_1\}$. Le test construit correspond à $T(z) = \sqrt{n} \frac{\bar{z} - \mu_0}{\sigma}$ et $\mathcal{R} =]q_{1-\alpha}^*, +\infty[$. Lorsque Θ_0 et Θ_1 sont des singletons, on parle d'**hypothèses simples**.

Test : définition rigoureuse (suite)

La **taille** $\alpha_\psi \in [0, 1]$ du test ψ est la plus grande probabilité de rejeter $\mathcal{H}_0$ lorsque $\theta \in \Theta_0$:

$$\alpha_\psi := \sup_{\theta \in \Theta_0} \mathbb{P}_\theta(\psi(Z) = 1) = \sup_{\theta \in \Theta_0} \mathbb{P}_\theta(T(Z) \in \mathcal{R}).$$

Le test ψ est de **niveau** $\alpha \in [0, 1]$ lorsque $\alpha_\psi \leq \alpha$.

La **(fonction) puissance** du test en $\theta \in \Theta_1$ est

$\pi_\psi(\theta) = \mathbb{P}_\theta(\psi(Z) = 1) = \mathbb{P}_\theta(T \in \mathcal{R})$. La **plus grande erreur de type II** est définie par

$$\beta_\psi = \sup_{\theta \in \Theta_1} \mathbb{P}_\theta(\psi(Z) = 0) = \sup_{\theta \in \Theta_1} \mathbb{P}_\theta(T(Z) \notin \mathcal{R}).$$

	$\mathcal{H}_0$ vraie	$\mathcal{H}_0$ fausse
Ne pas rejeter $\mathcal{H}_0$	$\geq 1 - \alpha_\psi$ (✓)	$\leq \beta_\psi$ (erreur ✗ de type II)
Rejeter $\mathcal{H}_0$	$\leq \alpha_\psi$ (erreur ✗ de type I)	$\geq 1 - \beta_\psi$ (✓)

Issues possibles d'un test ψ , probabilités associées et types d'erreurs.

- Définir le **modèle**
- Définir les **hypothèses nulle** $\mathcal{H}_0$ et **alternative** $\mathcal{H}_1$
- Choisir une **statistique de test** $T(Z)$, calculer sa **loi sous** $\mathcal{H}_0$. On fera en sorte que la loi de $T(Z)$ sous $\mathcal{H}_0$ ne dépende plus d'aucun paramètre du modèle : c'est une variable **pivotal**.
- Fixer un niveau α souhaité pour le test. Définir la région de rejet $\mathcal{R}$ pour que le test

$$\varphi(Z) = \mathbf{1}_{\{T(Z) \in \mathcal{R}\}}$$

soit de niveau α prescrit.

- Application numérique : calcul de la statistique observée et **décision**: rejet ou acceptation de $\mathcal{H}_0$.

Remarque. Avec la construction ci-dessus, on ne contrôle l'erreur que sous $\mathcal{H}_0$ (proba au plus α de rejeter à tort $\mathcal{H}_0$). Si je ne rejette pas $\mathcal{H}_0$, je ne sais pas a priori quelle erreur je fais.

Remarque. Vu la remarque précédente, on a une asymétrie fondamentale dans les tests: les hypothèses $\mathcal{H}_0$ et $\mathcal{H}_1$ ne sont pas interchangeables.

Remarque. Pour bien choisir T et $\mathcal{R}$ à niveau α fixé, il faut prendre une statistique T dont on connaît la loi sous $\mathcal{H}_0$. Idéalement, cette loi est simple et $\mathcal{R}$ s'exprime alors à l'aide de quantiles simples (cf exemple précédent).

Remarque. Entre deux tests de même niveau α , il est toujours préférable de choisir le plus puissant.

Exemple. Dans l'exemple précédent, la région de rejet de la forme $\{T < q_{0.05}^*\}$ est aussi de niveau 5%, mais elle a une puissance bien plus faible pour détecter le cas $\mu_1 > \mu_0$.

- Hypothèses simples

$$\mathcal{H}_0 : \theta = \theta_0 \text{ contre } \mathcal{H}_1 : \theta = \theta_1$$

- Test unilatéral pour une hypothèse nulle composite

$$\mathcal{H}_0 : \theta \leq \theta_0 \text{ contre } \mathcal{H}_1 : \theta > \theta_0$$

ou

$$\mathcal{H}_0 : \theta \geq \theta_0 \text{ contre } \mathcal{H}_1 : \theta < \theta_0$$

- Test bilatéral pour une hypothèse nulle simple

$$\mathcal{H}_0 : \theta = \theta_0 \text{ contre } \mathcal{H}_1 : \theta \neq \theta_0$$

- De façon générale:

$$H_0 : \theta \in \Theta_0 \text{ contre } \mathcal{H}_1 : \theta \in \Theta_1 = \Theta \setminus \Theta_0$$

Régions de confiance

Contexte : on cherche à quantifier l'incertitude que l'on a au vu des données sur la valeur d'un paramètre d'intérêt $\varphi(\theta) \in \mathbb{R}^k$. Un ensemble aléatoire $C(Z) \subseteq \mathbb{R}^k$ est une **région de confiance** de **probabilité de couverture** $1 - \alpha$ pour $\varphi(\theta)$ si :

$$\forall \theta \in \Theta, \quad \mathbb{P}_\theta(\varphi(\theta) \in C(Z)) \geq 1 - \alpha.$$

Dans le cas d'un n -échantillon, un ensemble aléatoire $C_n(Z) \subseteq \mathbb{R}^k$ est une **région de confiance asymptotique** de probabilité de couverture $1 - \alpha$ pour si :

$$\forall \theta \in \Theta, \quad \liminf_n \mathbb{P}_\theta(\varphi(\theta) \in C_n(Z)) \geq 1 - \alpha.$$

Intervalle de confiance : cas $k = 1$.

Méthode pivotale : construire $C(Z)$ à partir d'une statistique pivotale dont la loi ne dépend pas de θ .

Proposition

Soit $C_\theta(Z)$ une région de confiance pour $\varphi(\theta)$ de probabilité de couverture $1 - \alpha$. Alors, pour tout t , le test rejetant $\mathcal{H}_0$ si et seulement si $t \notin C_\theta(Z)$ est de niveau α pour $\mathcal{H}_0 : \varphi(\theta) = t$ (et $\mathcal{H}_1$ quelconque).

Preuve.

Par définition,

$$\begin{aligned} \sup_{\theta \in \Theta_0} \mathbb{P}_\theta(t \notin C_\theta(Z)) &= \sup_{\theta \in \varphi^{-1}(t)} \mathbb{P}_\theta(t \notin C_\theta(Z)) \\ &= \sup_{\theta \in \varphi^{-1}(t)} \underbrace{\mathbb{P}_\theta(\varphi(\theta) \notin C_\theta(Z))}_{\leq \alpha} \leq \alpha. \end{aligned}$$

□

Proposition

Réciproquement, pour tout $a \in \varphi(\Theta)$, soit T_a un test de niveau α pour $\mathcal{H}_0 : \varphi(\theta) = a$ (et $\mathcal{H}_1$ quelconque). Alors

$$C(Z) := \{a : T_a(Z) = 0\}$$

définit une région de confiance pour $\varphi(\theta)$ de probabilité de couverture $1 - \alpha$.

Preuve.

Par définition, pour tout $\theta \in \Theta$,

$$\mathbb{P}_\theta(\varphi(\theta) \in C(Z)) = \mathbb{P}_\theta(T_{\varphi(\theta)}(Z) = 0) \geq 1 - \alpha.$$



Rappels de résultats asymptotiques

Theorem (**Loi forte des grands nombres (LGN)**)

Soient $X_1, \dots, X_n$ i.i.d. d'espérance $\mu = \mathbb{E}[X_1]$ finie. Alors, lorsque $n \rightarrow \infty$,

$$\bar{X} = \frac{1}{n} \sum_{i=1}^n X_i \xrightarrow{p.s.} \mu.$$

Ce résultat permet notamment de **prouver la consistance forte d'un estimateur**.

Theorem (**Théorème central limite (TCL)**)

Soient $X_1, \dots, X_n$ i.i.d. avec espérance finie μ et variance finie σ^2 . Alors, lorsque $n \rightarrow \infty$,

$$\sqrt{n}(\bar{X}_n - \mu) \xrightarrow{d} \mathcal{N}(0, \sigma^2).$$

Ce résultat permet notamment de **construire des intervalles de confiance asymptotiques**.

Merci !

Rdv en TD pour les questions et la pratique de
ce qui vient d'être (re)vu.

(contenu du cours et quizz : lganassali.github.io)