

Statistiques (STA1)

Cours II – Information de Fisher, estimation par maximum de vraisemblance

Luca Ganassali

Laboratoire de Mathématiques d'Orsay, Université Paris-Saclay

Jeudi 17 septembre 2026

Previously in STA1...

On effectue un test pour l'hypothèse nulle H_0 contre l'hypothèse alternative H_1 avec statistique de test T , au niveau α . Après calcul, la région de rejet est choisie à $\mathcal{R} = [0.45, 0.87]$ de sorte que $\mathbb{P}_{H_0}(T \in \mathcal{R}) = \alpha$.

1. La statistique de test observée vaut $t = 0.68$. Notre décision est de **A**: ne pas rejeter H_0 ; **B**: rejeter H_0 ; **C**: on ne peut pas conclure. Ici $t = 0.68 \in \mathcal{R}$, donc on rejette H_0 . Réponse B.
2. La probabilité d'erreur de cette décision vaut **A**: α ; **B**: t ; **C**: $1 - \alpha$; **D**: inconnue avec les données dont on dispose. L'erreur faite ici serait de rejeter H_0 a tort (erreur de première espèce), et $\mathbb{P}_{H_0}(\text{rejeter } H_0) = \mathbb{P}_{H_0}(T \in \mathcal{R}) = \alpha$. Réponse A.
3. Si t avait valu 0.03, la probabilité d'erreur de notre décision aurait été **A**: α ; **B**: t' ; **C**: $1 - \alpha$; **D**: inconnue avec les données dont on dispose. L'erreur faite ici serait de ne pas rejeter H_0 a tort (erreur de seconde espèce), et $\mathbb{P}_{H_1}(\text{ne pas rejeter } H_0) = \mathbb{P}_{H_1}(T \notin \mathcal{R})$ n'est pas calculable car on ne connaît pas H_1 . Réponse D.

- Cours I – Rappels de statistiques : estimation, tests et intervalles de confiance
- **Cours II – Information de Fisher, estimation par maximum de vraisemblance**
- Cours III – Théorèmes asymptotiques, Théorème de Neyman-Pearson
- Cours IV – Voyage en pays Gaussien
- Cours V – Régression linéaire 1/2 : Modèles linéaire et linéaire gaussien, estimateur des moindres carrés, propriétés générales, tests de Student
- Cours VI – Régression linéaire 2/2 : intervalle de confiance pour un coefficient, interprétation géométrique, modèles emboîtés, variable qualitative

Vraisemblance et information de Fisher

Vraisemblance dans les modèles dominés

Un modèle paramétrique $\mathcal{M} = (\mathcal{Z}, \mathbb{P}_\theta)$ est **dominé** si toutes les lois $\mathbb{P}_\theta$ admettent une **densité** f_θ par rapport à une mesure commune “de référence” ξ sur $\mathcal{Z}$ (mesure de Lebesgue, mesure de comptage).

Dans un modèle paramétrique dominé, on appelle **vraisemblance** d'une réalisation z la fonction de θ :

$$\theta \mapsto L(\theta; z) = f_\theta(z) .$$

Pour un échantillon i.i.d., $z = (x_1, \dots, x_n)$, la vraisemblance s'écrit :

$$L(\theta; x_1, \dots, x_n) = \prod_{i=1}^n f_\theta(x_i) .$$

Remarque. Bien que vraisemblance et densité aient même expression, on utilise le mot **densité** pour parler de la fonction des données à paramètre fixé (terminologie probabiliste), et le mot **vraisemblance** pour parler de la fonction du paramètre pour des données fixées (terminologie de statistiques).

Exemple du jour. modèle de Bernoulli i.i.d. de paramètre $\theta \in [0, 1]$, $\mathcal{Z} = \{0, 1\}^n$. Dans ce modèle la vraisemblance s'écrit :

$$L(\theta; x_1, \dots, x_n) = \prod_{i=1}^n \theta^{x_i} (1 - \theta)^{1-x_i} = (1 - \theta)^n \prod_{i=1}^n \left(\frac{\theta}{1 - \theta} \right)^{x_i}.$$

Un modèle paramétrique $\mathcal{M} = (\mathcal{Z}, (\mathbb{P}_\theta)_{\theta \in \Theta})$, dominé par ξ , et où Θ est un ouvert de $\mathbb{R}^d$ est **régulier** si:

- Le support des lois $\mathbb{P}_\theta$ est indépendant de $\theta \in \Theta$.
- La **log-vraisemblance** $\theta \mapsto \log L(\theta; z) =: \ell(\theta; z)$ est deux fois continûment différentiable sur Θ , pour tout $z \in \mathcal{Z}$.
- Pour tout A mesurable, l'intégrale $\int_A f_\theta(z) d\xi(z)$ est deux fois dérivable en θ sous le signe d'intégration et on peut permuter intégration (sur z) et dérivation (sur θ).

Exemples : échantillon Bernoulli, gaussien...

Contre-exemple : Loi uniforme sur $[0, \theta]$.

Remarque. Faute de temps, on n'étudiera pas ici les conditions sous lesquelles un modèle est régulier; cette propriété sera explicitement admise lorsqu'utile.

Dans un modèle dominé, on appelle **fonction de score** la fonction

$$\dot{\ell}(\theta; \mathbf{z}) := \nabla_{\theta} \ell(\theta; \mathbf{z}) = \left(\frac{\partial}{\partial \theta_1} \ell(\theta; \mathbf{z}), \dots, \frac{\partial}{\partial \theta_d} \ell(\theta; \mathbf{z}) \right)^{\top}.$$

Le score, c'est le gradient de la log-vraisemblance.

Proposition (Propriétés du score)

Dans un modèle paramétrique régulier,

- Le score est **additif** : pour $Z = (X, Y)$ avec X, Y i.i.d.,

$$\dot{\ell}(\theta; x, y) = \dot{\ell}(\theta; x) + \dot{\ell}(\theta; y)$$

- Le score est un vecteur aléatoire **centré** : $\mathbb{E}[\dot{\ell}(\theta; Z)] = 0$.

En effet,

$$\begin{aligned}\mathbb{E}[\dot{\ell}(\theta; Z)] &= \mathbb{E}[\nabla_{\theta} \log L(\theta; Z)] = \mathbb{E} \left[\frac{\nabla_{\theta} L(\theta; Z)}{L(\theta; Z)} \right] \\ &= \int \frac{\nabla_{\theta} L(\theta; z)}{L(\theta; z)} L(\theta; z) d\xi(z) = \int \nabla_{\theta} L(\theta; z) d\xi(z) \\ &= \nabla_{\theta} \underbrace{\int L(\theta; z) d\xi(z)}_{=1} = 0.\end{aligned}$$

Dans un modèle paramétrique régulier, on appelle **information de Fisher** au point $\theta \in \Theta \subset \mathbb{R}^d$ la matrice de covariance du score :

$$\mathcal{I}(\theta) = \text{Var}_\theta(\dot{\ell}(\theta; Z)) = \mathbb{E}_\theta[\dot{\ell}(\theta; Z)\dot{\ell}(\theta; Z)^\top].$$

C'est une matrice de taille $d \times d$, **symétrique définie positive**.

Retour à l'exemple du jour: modèle i.i.d. Bernoulli(θ) avec $\theta \in [0, 1]$.

$$\ell(\theta; x_1, \dots, x_n) = n \log(1 - \theta) + (\log(\theta) - \log(1 - \theta)) \times \sum_{i=1}^n x_i$$

donc

$$\dot{\ell}(\theta; x_1, \dots, x_n) = -\frac{n}{1 - \theta} + \left(\frac{1}{\theta} + \frac{1}{1 - \theta}\right) \times \sum_{i=1}^n x_i = \frac{-n\theta + \sum_{i=1}^n x_i}{\theta(1 - \theta)}.$$

On a bien $\mathbb{E}_\theta[\dot{\ell}(\theta; X_1, \dots, X_n)] = \frac{-n\theta + n\theta}{\theta(1 - \theta)} = 0$, et

$$\mathcal{I}(\theta) = \text{Var}_\theta(\dot{\ell}(\theta; X_1, \dots, X_n)) = \frac{1}{\theta^2(1 - \theta)^2} \times n\theta(1 - \theta) = \frac{n}{\theta(1 - \theta)}.$$

Proposition (Propriétés de $\mathcal{I}(\theta)$)

Dans un modèle paramétrique régulier,

- Pour $\ddot{\ell}(\theta; z) = \nabla^2 \ell(\theta; z)$ (hessienne, dérivée seconde), on a une **seconde expression**

$$\mathcal{I}(\theta) = \mathbb{E}_{\theta}[\dot{\ell}(\theta; Z)\dot{\ell}(\theta; Z)^{\top}] = -\mathbb{E}_{\theta}[\ddot{\ell}(\theta; Z)].$$

- $\mathcal{I}(\theta)$ est **additive** : en notant $\mathcal{I}_n(\theta)$ l'information de Fisher pour un n -échantillon $Z = (X_1, \dots, X_n)$, on a

$$\mathcal{I}_n(\theta) = n\mathcal{I}_1(\theta).$$

Preuve. 1. On a vu que

$$\mathbf{o} = \mathbb{E}_\theta[\dot{\ell}(\theta; Z)] = \int \nabla_\theta \ell(\theta; z) f_\theta(z) d\xi(z).$$

En dérivant encore sous l'intégrale par rapport à θ , on obtient

$$\begin{aligned}\mathbf{o} &= \int \nabla_\theta^2 \ell(\theta; z) f_\theta(z) d\xi(z) + \int \nabla_\theta \ell(\theta; z) (\nabla_\theta f_\theta(z))^\top d\xi(z) \\ &= \int \ddot{\ell}(\theta; z) f_\theta(z) d\xi(z) + \int \dot{\ell}(\theta; z) \dot{\ell}(\theta; z)^\top f_\theta(z) d\xi(z) \\ &= \mathbb{E}_\theta[\dot{\ell}(\theta; Z) \dot{\ell}(\theta; Z)^\top] + \mathbb{E}_\theta[\ddot{\ell}(\theta; Z)].\end{aligned}$$

2. Pour un n -échantillon indépendant $Z = (X_1, \dots, X_n)$, on a

$$\ell_n(\theta; Z) = \sum_{i=1}^n \ell(\theta; X_i), \quad \dot{\ell}_n(\theta; Z) = \sum_{i=1}^n \dot{\ell}(\theta; X_i).$$

Donc

$$\mathcal{I}_n(\theta) = \mathbb{E}_\theta \left[\dot{\ell}_n(\theta; Z) \dot{\ell}_n(\theta; Z)^\top \right] = \sum_{i=1}^n \mathbb{E}_\theta \left[\dot{\ell}(\theta; X_i) \dot{\ell}(\theta; X_i)^\top \right] = n\mathcal{I}_1(\theta),$$

où l'indépendance des X_i fait disparaître les termes croisés.

□

Intuition : $\mathcal{I}(\theta)$ donne une idée de l'information apportée la variable aléatoire Z sur l'estimation du paramètre du modèle, i.e. la **précision** avec laquelle le paramètre peut être estimé.

Théorème (Borne inférieure de Cramér-Rao)

On se place dans un modèle est paramétrique, régulier, et tel que $\mathcal{I}(\theta)$ soit toujours inversible.

Soit $h : \Theta \subseteq \mathbb{R}^d \rightarrow \mathbb{R}$. Alors, pour tout estimateur T de $h(\theta)$, **sans biais et de carré intégrable**, en notant $\dot{h}(\theta) = \nabla_{\theta} h(\theta) \in \mathbb{R}^d$, on a

$$\text{Var}_{\theta}(T) \geq [\dot{h}(\theta)]^{\top} \mathcal{I}(\theta)^{-1} \dot{h}(\theta).$$

Remarque. Cette borne inférieure est un rapport de vitesses au carré (cf cas 1D).

Remarque. Attention, la borne de CR ne dit rien sur les estimateurs biaisés !

Borne inférieure de Cramér-Rao: preuve (cas 1D)

Preuve dans le cas 1D ($\Theta = \mathbb{R}$). Par hypothèse, T est sans biais pour $h(\theta)$, donc $\mathbb{E}_\theta[T(z) - h(\theta)] = 0$ ce qui s'écrit

$$\forall \theta \in \Theta, \int (T(z) - h(\theta))f_\theta(z)d\xi(z) = 0.$$

On dérive par rapport à θ , en utilisant $\frac{d}{d\theta}f_\theta(z) = \dot{\ell}(\theta; z)f_\theta(z)$:

$$\int (T(z) - h(\theta))\dot{\ell}(\theta; z)f_\theta(z)d\xi(z) - \underbrace{\int \dot{h}(\theta)f_\theta(z)d\xi(z)}_{=\dot{h}(\theta) \times 1} = 0.$$

On met au carré et on applique Cauchy-Schwarz:

$$\begin{aligned}(\dot{h}(\theta))^2 &= \left(\int (T(z) - h(\theta))\dot{\ell}_\theta(z)f_\theta(z)d\xi(z) \right)^2 \\&\leq \left(\int (T(z) - h(\theta))^2 f_\theta(z)d\xi(z) \right) \left(\int (\dot{\ell}_\theta(z))^2 f_\theta(z)d\xi(z) \right) \\&= \text{Var}_\theta(T) \times \mathcal{I}(\theta).\end{aligned}$$

□

Un estimateur sans biais $T(Z)$ est dit **efficace** pour estimer $h(\theta)$ s'il atteint la borne de Cramér-Rao, i.e. si pour tout $\theta \in \Theta$,

$$\text{Var}_{\theta}(T) = [\dot{h}(\theta)]^{\top} \mathcal{I}(\theta)^{-1} \dot{h}(\theta).$$

Un tel estimateur est alors **Uniformément de Variance Minimale** parmi les estimateurs sans **Biais** (**UVMB** ou **UMVE** en anglais).

Retour à l'exemple du jour. Modèle i.i.d. Bernoulli(θ) avec $\theta \in [0, 1]$. On avait calculé $\mathcal{I}(\theta) = \frac{n}{\theta(1-\theta)}$. L'estimateur $\bar{X} = \frac{1}{n} \sum_{i=1}^n X_i$ pour $h(\theta) = \theta$ est sans biais. Sa variance vaut $\frac{\theta(1-\theta)}{n} = \mathcal{I}^{-1}(\theta)$: il est efficace.

Remarque. Il peut ne pas exister d'estimateurs efficaces, et il peut y avoir des estimateurs sans biais optimaux (UVMB) non efficaces (dans le cas où la borne inf de Cramér-Rao n'est pas atteinte).

Remarque. On peut s'intéresser également à la construction d'estimateurs sans biais qui atteignent **asymptotiquement** la borne de Cramér-Rao, quand la taille d'échantillon n tend vers $+\infty$.

Estimation par maximum de vraisemblance

On se place dans le cas d'un n – échantillon $Z = (X_1, \dots, X_n)$. La **méthode des moments** pour construire un estimateur de $h(\theta)$ consiste à :

- écrire $h(\theta)$ sous la forme $h(\theta) = g(m_1, \dots, m_k)$ où $m_\ell = \mathbb{E}_\theta[X_1^\ell]$.
- remplacer les m_ℓ par leurs estimateurs empiriques dans la formule:

$$\hat{h}(\theta) = g(\hat{m}_1, \dots, \hat{m}_k), \quad \text{où } \hat{m}_\ell = \frac{1}{n} \sum_{i=1}^n X_i^\ell.$$

Méthode du maximum de vraisemblance

On appelle **estimateur du maximum de vraisemblance**, une valeur θ maximisant la (log-)vraisemblance :

$$\hat{\theta}_{MV} \in \arg \max_{\theta \in \Theta} L(\theta; Z) = \arg \max_{\theta \in \Theta} \ell(\theta; Z).$$

Retour à l'exemple du jour. Modèle i.i.d. Bernoulli(θ) avec $\theta \in [0, 1]$.

On avait calculé

$$\ell(\theta; Z) = \log(1 - \theta) \times \left(n - \sum_{i=1}^n X_i \right) + \log(\theta) \times \sum_{i=1}^n X_i,$$

de dérivée

$$\dot{\ell}(\theta; Z) = -\frac{1}{1 - \theta} \times \left(n - \sum_{i=1}^n X_i \right) + \frac{1}{\theta} \times \sum_{i=1}^n X_i,$$

et

$$\dot{\ell}(\theta; Z) = 0 \iff \theta \times \left(n - \sum_{i=1}^n X_i \right) = (1 - \theta) \times \sum_{i=1}^n X_i \iff \theta = \frac{1}{n} \sum_{i=1}^n X_i.$$

Il n'y a bien qu'un seul maximum (étude de la fonction) d'où $\hat{\theta}_{MV} = \frac{1}{n} \sum_{i=1}^n X_i$.

Pourquoi l'EMV ? Dans le cas d'un n -échantillon, on a

$$\ell_n(\theta; \mathbf{z}) = \sum_{i=1}^n \log f_{\theta}(x_i)$$

et en notant θ^* le vrai paramètre, par la LGN, pour tout θ , quand $n \rightarrow \infty$,

$$\frac{1}{n} \ell_n(\theta; \mathbf{z}) = \frac{1}{n} \sum_{i=1}^n \log f_{\theta}(x_i) \longrightarrow \mathbb{E}_{\theta^*} [\log f_{\theta}(X)] =: F(\theta).$$

Pour tout θ ,

$$\begin{aligned} F(\theta^*) - F(\theta) &= \int (\log f_{\theta^*}(x) - \log f_{\theta}(x)) f_{\theta^*}(x) d\xi(x) \\ &= \int \log \frac{f_{\theta^*}(x)}{f_{\theta}(x)} f_{\theta^*}(x) d\xi(x) = \int \left(\log \frac{f_{\theta^*}(x)}{f_{\theta}(x)} \times \frac{f_{\theta^*}(x)}{f_{\theta}(x)} \right) f_{\theta}(x) d\xi(x) \\ &= \mathbb{E}_{\theta} \left[\log \frac{f_{\theta^*}(X)}{f_{\theta}(X)} \times \frac{f_{\theta^*}(X)}{f_{\theta}(X)} \right] \geq \log \mathbb{E}_{\theta} \left[\frac{f_{\theta^*}(X)}{f_{\theta}(X)} \right] \times \mathbb{E}_{\theta} \left[\frac{f_{\theta^*}(X)}{f_{\theta}(X)} \right] = 0 \end{aligned}$$

Donc θ^* est un maximum global de la fonction F , cela motive le choix de l'EMV.

Inconvénients :

- Si la vraisemblance n'est pas strictement concave pour tout θ , il peut exister des optima locaux.
- L'EMV n'est pas forcément unique.
- L'EMV peut ne pas exister.
- On peut avoir des problèmes de dérivabilité dans des modèles dominés non réguliers, par ex $\text{Unif}(0, \theta)$.

Avantages:

- Pour toute bijection g de Θ dans Θ' (reparamétrisation), si $\hat{\theta}$ est l'EMV de θ , alors $g(\hat{\theta})$ est l'EMV de $g(\theta)$. L'EMV est équivariant par reparamétrisation bijective.
- De bonnes propriétés asymptotiques dans les modèles ayant suffisamment de conditions de régularité (cf TD).

Merci !

Rdv en TD pour les questions et la pratique de ces notions.

(contenu du cours et quizz : lganassali.github.io)