

Statistiques (STA1)

Cours V – Régression linéaire 1/2 : Modèles linéaire et linéaire gaussien, estimateur des moindres carrés, propriétés générales, tests de Student

Luca Ganassali

Laboratoire de Mathématiques d'Orsay, Université Paris-Saclay

Vendredi 2 octobre 2026

- Cours I – Rappels de statistiques : estimation, tests et intervalles de confiance
- Cours II – Information de Fisher, estimation par maximum de vraisemblance
- Cours III – Théorèmes asymptotiques, Théorème de Neyman-Pearson
- Cours IV – Voyage en pays Gaussien
- **Cours V – Régression linéaire 1/2 : Modèles linéaire et linéaire gaussien, estimateur des moindres carrés, propriétés générales, tests de Student**
- Cours VI – Régression linéaire 2/2 : intervalle de confiance pour un coefficient, interprétation géométrique, modèles emboîtés, variable qualitative

Objectif : expliquer ou prédire une variable aléatoire réponse $Y \in \mathbb{R}$ en fonction de variables explicatives $x_1, \dots, x_p \in \mathbb{R}$.

Objectif : **expliquer ou prédire** une variable aléatoire réponse $Y \in \mathbb{R}$ en fonction de **variables explicatives** $x_1, \dots, x_p \in \mathbb{R}$.

Modélisation : par exemple, modèle à bruit additif :

Objectif : **expliquer ou prédire** une variable aléatoire réponse $Y \in \mathbb{R}$ en fonction de **variables explicatives** $x_1, \dots, x_p \in \mathbb{R}$.

Modélisation : par exemple, modèle à bruit additif :

$$Y = f(x_1, \dots, x_p) + \varepsilon, \quad \text{avec } \mathbb{E}[\varepsilon] = 0.$$

Objectif : **expliquer ou prédire** une variable aléatoire réponse $Y \in \mathbb{R}$ en fonction de **variables explicatives** $x_1, \dots, x_p \in \mathbb{R}$.

Modélisation : par exemple, modèle à bruit additif :

$$Y = f(x_1, \dots, x_p) + \varepsilon, \quad \text{avec } \mathbb{E}[\varepsilon] = 0.$$

f est appelée **fonction de régression** du modèle et est inconnue.

Objectif : **expliquer ou prédire** une variable aléatoire réponse $Y \in \mathbb{R}$ en fonction de **variables explicatives** $x_1, \dots, x_p \in \mathbb{R}$.

Modélisation : par exemple, modèle à bruit additif :

$$Y = f(x_1, \dots, x_p) + \varepsilon, \quad \text{avec } \mathbb{E}[\varepsilon] = 0.$$

f est appelée **fonction de régression** du modèle et est inconnue.

Exemple. Y = label de l'image (chat/chien), x = tous les pixels de l'image.
(ex: $28 \times 28 \times 3$ couleurs $\rightarrow p = 2352$).

Objectif : **expliquer ou prédire** une variable aléatoire réponse $Y \in \mathbb{R}$ en fonction de **variables explicatives** $x_1, \dots, x_p \in \mathbb{R}$.

Modélisation : par exemple, modèle à bruit additif :

$$Y = f(x_1, \dots, x_p) + \varepsilon, \quad \text{avec } \mathbb{E}[\varepsilon] = 0.$$

f est appelée **fonction de régression** du modèle et est inconnue.

Exemple. Y = label de l'image (chat/chien), x = tous les pixels de l'image.
(ex: $28 \times 28 \times 3$ couleurs $\rightarrow p = 2352$).

Remarques.

- *Le choix de la fonction de régression et des variables explicatives repose sur la connaissance du phénomène (physique, biologique, empirique) et doit toujours être critiqué.*
- *Y est aléatoire à cause du bruit ε , mais les x sont considérées ici comme fixées.*

Objectif : **expliquer ou prédire** une variable aléatoire réponse $Y \in \mathbb{R}$ en fonction de **variables explicatives** $x_1, \dots, x_p \in \mathbb{R}$.

Modélisation : par exemple, modèle à bruit additif :

$$Y = f(x_1, \dots, x_p) + \varepsilon, \quad \text{avec } \mathbb{E}[\varepsilon] = 0.$$

f est appelée **fonction de régression** du modèle et est inconnue.

Exemple. Y = label de l'image (chat/chien), x = tous les pixels de l'image.
(ex: $28 \times 28 \times 3$ couleurs $\rightarrow p = 2352$).

Remarques.

- *Le choix de la fonction de régression et des variables explicatives repose sur la connaissance du phénomène (physique, biologique, empirique) et doit toujours être critiqué.*
- *Y est aléatoire à cause du bruit ε , mais les x sont considérées ici comme fixées.*

Objectifs de l'apprentissage supervisé :

Objectifs de l'apprentissage supervisé :

- (i) Estimer f à partir de données observées $(x_{i,1}, \dots, x_{i,p}, y_i)_{1 \leq i \leq n}$
(expliquer Y : **train**).

Objectifs de l'apprentissage supervisé :

- (i) Estimer f à partir de données observées $(x_{i,1}, \dots, x_{i,p}, y_i)_{1 \leq i \leq n}$
(expliquer Y : **train**).
- (ii) Prédire Y pour de nouvelles valeurs de $x_1, \dots, x_p$ jamais vues, avec une erreur minimale (prédire Y : **test**).

Cadre général de l'apprentissage supervisé

Objectifs de l'apprentissage supervisé :

- (i) Estimer f à partir de données observées $(x_{i,1}, \dots, x_{i,p}, y_i)_{1 \leq i \leq n}$ (expliquer Y : **train**).
- (ii) Prédire Y pour de nouvelles valeurs de $x_1, \dots, x_p$ jamais vues, avec une erreur minimale (prédire Y : **test**).




Illustration de l'apprentissage supervisé. (i) $\leftrightarrow$ 1, (ii) $\leftrightarrow$ 2 & 3

Cadre général de l'apprentissage supervisé

Objectifs de l'apprentissage supervisé :

- (i) Estimer f à partir de données observées $(x_{i,1}, \dots, x_{i,p}, y_i)_{1 \leq i \leq n}$ (expliquer Y : **train**).
- (ii) Prédire Y pour de nouvelles valeurs de $x_1, \dots, x_p$ jamais vues, avec une erreur minimale (prédire Y : **test**).




Illustration de l'apprentissage supervisé. (i) $\leftrightarrow$ 1, (ii) $\leftrightarrow$ 2 & 3

Définition des modèles linéaire et linéaire gaussien

Le **modèle linéaire** est un modèle pour chaque $Y_i \in \mathbb{R}$ étant donné des covariables $x_i = (x_{i,1}, \dots, x_{i,p}) \in \mathbb{R}^p$. $Y_i \in \mathbb{R}$ est modélisée de la façon suivante :

$$Y_i = \theta_1 x_{i,1} + \dots + \theta_p x_{i,p} + \varepsilon_i = x_i^T \theta + \varepsilon_i,$$

où les ε_i sont des v.a. appelées **résidus** ou **bruits** qui satisfont :

- (i) $\mathbb{E}[\varepsilon_i] = 0$ (bruits **centrés**),
- (ii) $\text{Var}(\varepsilon_i) = \sigma^2$ (bruits de **variance constante**),
- (iii) pour tous $i \neq j$, $\text{Cov}(\varepsilon_i, \varepsilon_j) = 0$ (bruits **décorrelés**).

Les **paramètres (inconnus)** de ce modèle sont $\theta \in \mathbb{R}^p$ et la variance $\sigma^2 > 0$.

Modèle linéaire : définition

Le **modèle linéaire** est un modèle pour chaque $Y_i \in \mathbb{R}$ étant donné des covariables $x_i = (x_{i,1}, \dots, x_{i,p}) \in \mathbb{R}^p$. $Y_i \in \mathbb{R}$ est modélisée de la façon suivante :

$$Y_i = \theta_1 x_{i,1} + \dots + \theta_p x_{i,p} + \varepsilon_i = x_i^T \theta + \varepsilon_i,$$

où les ε_i sont des v.a. appelées **résidus** ou **bruits** qui satisfont :

- (i) $\mathbb{E}[\varepsilon_i] = 0$ (bruits **centrés**),
- (ii) $\text{Var}(\varepsilon_i) = \sigma^2$ (bruits de **variance constante**),
- (iii) pour tous $i \neq j$, $\text{Cov}(\varepsilon_i, \varepsilon_j) = 0$ (bruits **décorrelés**).

Les **paramètres (inconnus)** de ce modèle sont $\theta \in \mathbb{R}^p$ et la variance $\sigma^2 > 0$.

La fonction $f_\theta : x \in \mathbb{R}^p \mapsto x^T \theta \in \mathbb{R}$ est la **fonction de régression** du modèle.

Modèle linéaire : définition

Le **modèle linéaire** est un modèle pour chaque $Y_i \in \mathbb{R}$ étant donné des covariables $x_i = (x_{i,1}, \dots, x_{i,p}) \in \mathbb{R}^p$. $Y_i \in \mathbb{R}$ est modélisée de la façon suivante :

$$Y_i = \theta_1 x_{i,1} + \dots + \theta_p x_{i,p} + \varepsilon_i = x_i^T \theta + \varepsilon_i,$$

où les ε_i sont des v.a. appelées **résidus** ou **bruits** qui satisfont :

- (i) $\mathbb{E}[\varepsilon_i] = 0$ (bruits **centrés**),
- (ii) $\text{Var}(\varepsilon_i) = \sigma^2$ (bruits de **variance constante**),
- (iii) pour tous $i \neq j$, $\text{Cov}(\varepsilon_i, \varepsilon_j) = 0$ (bruits **décorrelés**).

Les **paramètres (inconnus)** de ce modèle sont $\theta \in \mathbb{R}^p$ et la variance $\sigma^2 > 0$.

La fonction $f_\theta : x \in \mathbb{R}^p \mapsto x^T \theta \in \mathbb{R}$ est la **fonction de régression** du modèle.



Ici, l'aléa dans Y_i provient uniquement de ε_i et non pas de x_i : **seul ε_i est aléatoire.**

Matriciellement, le modèle linéaire s'écrit :

$$\underbrace{Y}_{\in \mathbb{R}^{n \times 1}} = \underbrace{X}_{\in \mathbb{R}^{n \times p}} \cdot \underbrace{\theta}_{\in \mathbb{R}^{p \times 1}} + \underbrace{\varepsilon}_{\in \mathbb{R}^{n \times 1}} .$$

Matriciellement, le modèle linéaire s'écrit :

$$\underbrace{Y}_{\in \mathbb{R}^{n \times 1}} = \underbrace{X}_{\in \mathbb{R}^{n \times p}} \cdot \underbrace{\theta}_{\in \mathbb{R}^{p \times 1}} + \underbrace{\varepsilon}_{\in \mathbb{R}^{n \times 1}} .$$

Modèle linéaire $\Leftrightarrow Y$ est linéaire en X , à bruit additif près.

Matriciellement, le modèle linéaire s'écrit :

$$\underbrace{Y}_{\in \mathbb{R}^{n \times 1}} = \underbrace{X}_{\in \mathbb{R}^{n \times p}} \cdot \underbrace{\theta}_{\in \mathbb{R}^{p \times 1}} + \underbrace{\varepsilon}_{\in \mathbb{R}^{n \times 1}} .$$

Modèle linéaire $\Leftrightarrow Y$ est linéaire en X , à bruit additif près.

X : matrice du plan d'expérience (ou matrice de design). Souvent $x_{i,1} = 1$ pour tout i (X a une première colonne avec des 1). Dans ce cas, θ_1 est appelé **intercept** : on représente une relation affine et non juste linéaire.

Matriciellement, le modèle linéaire s'écrit :

$$\underbrace{Y}_{\in \mathbb{R}^{n \times 1}} = \underbrace{X}_{\in \mathbb{R}^{n \times p}} \cdot \underbrace{\theta}_{\in \mathbb{R}^{p \times 1}} + \underbrace{\varepsilon}_{\in \mathbb{R}^{n \times 1}} .$$

Modèle linéaire $\Leftrightarrow Y$ est linéaire en X , à bruit additif près.

X : matrice du plan d'expérience (ou matrice de design). Souvent $x_{i,1} = 1$ pour tout i (X a une première colonne avec des 1). Dans ce cas, θ_1 est appelé **intercept** : on représente une relation affine et non juste linéaire.



Cela ne veut pas dire qu'on ne peut pas représenter une dépendance non linéaire de Y en une variable z : il suffit d'ajouter des termes comme z^2, z^3 dans X (régression polynomiale).

Matriciellement, le modèle linéaire s'écrit :

$$\underbrace{Y}_{\in \mathbb{R}^{n \times 1}} = \underbrace{X}_{\in \mathbb{R}^{n \times p}} \cdot \underbrace{\theta}_{\in \mathbb{R}^{p \times 1}} + \underbrace{\varepsilon}_{\in \mathbb{R}^{n \times 1}} .$$

Modèle linéaire $\leftrightarrow$ Y est linéaire en X , à bruit additif près.

X : matrice du plan d'expérience (ou matrice de design). Souvent $x_{i,1} = 1$ pour tout i (X a une première colonne avec des 1). Dans ce cas, θ_1 est appelé **intercept** : on représente une relation affine et non juste linéaire.



Cela ne veut pas dire qu'on ne peut pas représenter une dépendance non linéaire de Y en une variable z : il suffit d'ajouter des termes comme z^2, z^3 dans X (régression polynomiale). **La régression linéaire, ce n'est pas que des droites.**

Matriciellement, le modèle linéaire s'écrit :

$$\underbrace{Y}_{\in \mathbb{R}^{n \times 1}} = \underbrace{X}_{\in \mathbb{R}^{n \times p}} \cdot \underbrace{\theta}_{\in \mathbb{R}^{p \times 1}} + \underbrace{\varepsilon}_{\in \mathbb{R}^{n \times 1}} .$$

Modèle linéaire $\leftrightarrow$ Y est linéaire en X , à bruit additif près.

X : matrice du plan d'expérience (ou matrice de design). Souvent $x_{i,1} = 1$ pour tout i (X a une première colonne avec des 1). Dans ce cas, θ_1 est appelé **intercept** : on représente une relation affine et non juste linéaire.



Cela ne veut pas dire qu'on ne peut pas représenter une dépendance non linéaire de Y en une variable z : il suffit d'ajouter des termes comme z^2, z^3 dans X (régression polynomiale). **La régression linéaire, ce n'est pas que des droites.**

Exemple.

Exemple. Prenons le modèle où $Y_i = \alpha + \beta x_i + \gamma x_i^3 + \varepsilon_i$.

Exemple. Prenons le modèle où $Y_i = \alpha + \beta x_i + \gamma x_i^3 + \varepsilon_i$. On a

$$X = \begin{pmatrix} 1 & x_1 & x_1^3 \\ 1 & x_2 & x_2^3 \\ \vdots & \vdots & \vdots \\ 1 & x_n & x_n^3 \end{pmatrix}, \quad \theta = \begin{pmatrix} \alpha \\ \beta \\ \gamma \end{pmatrix}, \quad Y = \begin{pmatrix} y_1 \\ y_2 \\ \vdots \\ y_n \end{pmatrix}.$$

Exemple. Prenons le modèle où $Y_i = \alpha + \beta x_i + \gamma x_i^3 + \varepsilon_i$. On a


$$X = \begin{pmatrix} 1 & x_1 & x_1^3 \\ 1 & x_2 & x_2^3 \\ \vdots & \vdots & \vdots \\ 1 & x_n & x_n^3 \end{pmatrix}, \quad \theta = \begin{pmatrix} \alpha \\ \beta \\ \gamma \end{pmatrix}, \quad Y = \begin{pmatrix} y_1 \\ y_2 \\ \vdots \\ y_n \end{pmatrix}.$$

Ici, α est l'intercept.


Exemple. Prenons le modèle où $Y_i = \alpha + \beta x_i + \gamma x_i^3 + \varepsilon_i$. On a

$$X = \begin{pmatrix} 1 & x_1 & x_1^3 \\ 1 & x_2 & x_2^3 \\ \vdots & \vdots & \vdots \\ 1 & x_n & x_n^3 \end{pmatrix}, \quad \theta = \begin{pmatrix} \alpha \\ \beta \\ \gamma \end{pmatrix}, \quad Y = \begin{pmatrix} y_1 \\ y_2 \\ \vdots \\ y_n \end{pmatrix}.$$

Ici, α est l'intercept.



(a) bruit gaussien: $\varepsilon_i \sim \mathcal{N}(0, 0.1^2)$




(b) bruit uniforme: $\varepsilon_i \sim \mathcal{U}(-0.15, 0.15)$


Exemple. Prenons le modèle où $Y_i = \alpha + \beta x_i + \gamma x_i^3 + \varepsilon_i$. On a

$$X = \begin{pmatrix} 1 & x_1 & x_1^3 \\ 1 & x_2 & x_2^3 \\ \vdots & \vdots & \vdots \\ 1 & x_n & x_n^3 \end{pmatrix}, \quad \theta = \begin{pmatrix} \alpha \\ \beta \\ \gamma \end{pmatrix}, \quad Y = \begin{pmatrix} y_1 \\ y_2 \\ \vdots \\ y_n \end{pmatrix}.$$

Ici, α est l'intercept.



(a) bruit gaussien: $\varepsilon_i \sim \mathcal{N}(0, 0.1^2)$



(b) bruit uniforme: $\varepsilon_i \sim \mathcal{U}(-0.15, 0.15)$

Le **modèle linéaire gaussien** est un modèle linéaire où les bruits sont de plus supposés gaussiens :

$$Y = X\theta + \varepsilon,$$

avec $\varepsilon \sim \mathcal{N}(0_n, \sigma^2 I_n)$. Dans ce cas, Y est donc un vecteur gaussien de loi

$$Y \sim \mathcal{N}(X\theta, \sigma^2 I_n).$$

Modèle linéaire : ce qu'il (ne) permet (pas) de faire

Modèle linéaire : ce qu'il (ne) permet (pas) de faire

Permet de détecter et quantifier via θ une **corrélacion** entre une variable explicative Z et la réponse Y ✓

Modèle linéaire : ce qu'il (ne) permet (pas) de faire


Permet de détecter et quantifier via θ une **corrélacion** entre une variable explicative Z et la réponse Y ✓

Ne permet pas (sans autres hypothèses) de mettre en lumière un **lien de cause à effet** entre une variable explicative Z et la réponse Y ✗

Modèle linéaire : ce qu'il (ne) permet (pas) de faire

Permet de détecter et quantifier via θ une **corrélacion** entre une variable explicative Z et la réponse Y ✓

Ne permet pas (sans autres hypothèses) de mettre en lumière un **lien de cause à effet** entre une variable explicative Z et la réponse Y ✗



(source : <https://www.bradyneal.com/causal-inference-course>)

Rappel : un modèle $\mathcal{M} = (\mathcal{X}, (\mathbb{P}_\theta)_{\theta \in \Theta})$ est **identifiable** si deux paramètres θ, θ' différents définissent deux lois $\mathbb{P}_\theta, \mathbb{P}_{\theta'}$ différentes, i.e. si l'application $\theta \in \Theta \longmapsto \mathbb{P}_\theta$ est injective.

Rappel : un modèle $\mathcal{M} = (\mathcal{X}, (\mathbb{P}_\theta)_{\theta \in \Theta})$ est **identifiable** si deux paramètres θ, θ' différents définissent deux lois $\mathbb{P}_\theta, \mathbb{P}_{\theta'}$ différentes, i.e. si l'application $\theta \in \Theta \mapsto \mathbb{P}_\theta$ est injective.

Proposition (Identifiabilité du modèle linéaire). Les propositions suivantes sont équivalentes :

- (i) Le modèle linéaire $Y = X\theta + \varepsilon$ est identifiable ;
- (ii) Les p colonnes de X forment une famille libre de $\mathbb{R}^n$ (on dit que X est de *rang plein*) ;
- (iii) $\text{Ker}(X) = \{0_p\}$ (i.e. X est injective) ;
- (iv) La matrice $X^T X \in \mathbb{R}^{p \times p}$ est inversible.

Rappel : un modèle $\mathcal{M} = (\mathcal{X}, (\mathbb{P}_\theta)_{\theta \in \Theta})$ est **identifiable** si deux paramètres θ, θ' différents définissent deux lois $\mathbb{P}_\theta, \mathbb{P}_{\theta'}$ différentes, i.e. si l'application $\theta \in \Theta \mapsto \mathbb{P}_\theta$ est injective.

Proposition (Identifiabilité du modèle linéaire). Les propositions suivantes sont équivalentes :

- (i) Le modèle linéaire $Y = X\theta + \varepsilon$ est identifiable ;
- (ii) Les p colonnes de X forment une famille libre de $\mathbb{R}^n$ (on dit que X est de *rang plein*) ;
- (iii) $\text{Ker}(X) = \{0_p\}$ (i.e. X est injective) ;
- (iv) La matrice $X^T X \in \mathbb{R}^{p \times p}$ est inversible.

Remarque. En particulier, $p \leq n$ est nécessaire pour l'identifiabilité du modèle linéaire.

Preuve.

Preuve. $(ii) \iff (iii)$: c'est le

Preuve. $(ii) \iff (iii)$: c'est le théorème du rang.

Preuve. $(ii) \iff (iii)$: c'est le théorème du rang.

$(iii) \iff (iv)$:

Preuve. (ii) $\iff$ (iii) : c'est le théorème du rang.

(iii) $\iff$ (iv) : vient de ce que $\text{Ker}(X^T X) = \text{Ker}(X)$.

Preuve. $(ii) \iff (iii)$: c'est le théorème du rang.

$(iii) \iff (iv)$: vient de ce que $\text{Ker}(X^T X) = \text{Ker}(X)$.

Le seul point restant à prouver est $(i) \iff (iii)$ (noyau nul $\iff$ identifiabilité).

Preuve. (ii) $\iff$ (iii) : c'est le théorème du rang.

(iii) $\iff$ (iv) : vient de ce que $\text{Ker}(X^T X) = \text{Ker}(X)$.

Le seul point restant à prouver est (i) $\iff$ (iii) (noyau nul $\iff$ identifiabilité).

Supposons $\text{Ker}(X) = \{0_p\}$. Soient $\theta_1, \theta_2 \in \mathbb{R}^p$ et $\varepsilon_1, \varepsilon_2$ des bruits centrés tels que, en loi, $Y = X\theta_1 + \varepsilon_1 = X\theta_2 + \varepsilon_2$. On passe à l'espérance : $X\theta_1 = X\theta_2$. On a $\theta_1 - \theta_2 \in \text{Ker}(X)$ donc $\theta_1 = \theta_2$.

Preuve. (ii) $\iff$ (iii) : c'est le théorème du rang.

(iii) $\iff$ (iv) : vient de ce que $\text{Ker}(X^T X) = \text{Ker}(X)$.

Le seul point restant à prouver est (i) $\iff$ (iii) (noyau nul $\iff$ identifiabilité).

Supposons $\text{Ker}(X) = \{0_p\}$. Soient $\theta_1, \theta_2 \in \mathbb{R}^p$ et $\varepsilon_1, \varepsilon_2$ des bruits centrés tels que, en loi, $Y = X\theta_1 + \varepsilon_1 = X\theta_2 + \varepsilon_2$. On passe à l'espérance : $X\theta_1 = X\theta_2$. On a $\theta_1 - \theta_2 \in \text{Ker}(X)$ donc $\theta_1 = \theta_2$.

Prouvons la contraposée de réciproque. Supposons $\text{Ker}(X) \neq \{0_p\}$ et prenons $\eta \in \text{Ker}(X) \setminus \{0_p\}$. Alors $Y = X\theta + \varepsilon = X(\theta + \eta) + \varepsilon$ et pourtant $\theta \neq \theta + \eta$. Le modèle n'est pas identifiable. $\square$

Régression linéaire : l'estimateur des moindres carrés

Estimateur des moindres carrés : définition et forme close

Dans le modèle linéaire, on observe Y et cherche à estimer θ . Cette tâche est connue sous le nom de **régression linéaire**.

Estimateur des moindres carrés : définition et forme close

Dans le modèle linéaire, on observe Y et cherche à estimer θ . Cette tâche est connue sous le nom de **régression linéaire**. Pour tout $\theta \in \mathbb{R}^p$, on définit la **somme des carrés résiduels** :

$$\text{SCR}(\theta) := \|Y - X\theta\|^2.$$

Estimateur des moindres carrés : définition et forme close

Dans le modèle linéaire, on observe Y et cherche à estimer θ . Cette tâche est connue sous le nom de **régression linéaire**. Pour tout $\theta \in \mathbb{R}^p$, on définit la **somme des carrés résiduels** :

$$\text{SCR}(\theta) := \|Y - X\theta\|^2.$$

L'**estimateur des moindres carrés** est défini par

$$\hat{\theta}_{MC} \in \arg \min_{\theta \in \mathbb{R}^p} \text{SCR}(\theta) = \arg \min_{\theta \in \mathbb{R}^p} \|Y - X\theta\|^2.$$

Estimateur des moindres carrés : définition et forme close

Dans le modèle linéaire, on observe Y et cherche à estimer θ . Cette tâche est connue sous le nom de **régression linéaire**. Pour tout $\theta \in \mathbb{R}^p$, on définit la **somme des carrés résiduels** :

$$\text{SCR}(\theta) := \|Y - X\theta\|^2.$$

L'**estimateur des moindres carrés** est défini par

$$\hat{\theta}_{MC} \in \arg \min_{\theta \in \mathbb{R}^p} \text{SCR}(\theta) = \arg \min_{\theta \in \mathbb{R}^p} \|Y - X\theta\|^2.$$

Intuition : on cherche la valeur de θ qui rend les **résidus** $Y - X\theta$ aussi petits que possible en norme euclidienne.

Estimateur des moindres carrés : définition et forme close

Dans le modèle linéaire, on observe Y et cherche à estimer θ . Cette tâche est connue sous le nom de **régression linéaire**. Pour tout $\theta \in \mathbb{R}^p$, on définit la **somme des carrés résiduels** :

$$\text{SCR}(\theta) := \|Y - X\theta\|^2.$$

L'**estimateur des moindres carrés** est défini par

$$\hat{\theta}_{MC} \in \arg \min_{\theta \in \mathbb{R}^p} \text{SCR}(\theta) = \arg \min_{\theta \in \mathbb{R}^p} \|Y - X\theta\|^2.$$

Intuition : on cherche la valeur de θ qui rend les **résidus** $Y - X\theta$ aussi petits que possible en norme euclidienne.

Proposition (Forme close de l'EMC). Dans un modèle linéaire identifiable, on a :

$$\hat{\theta}_{MC} = (X^T X)^{-1} X^T Y.$$

Interprétation géométrique.

Interprétation géométrique. On a

$$\widehat{X\theta}_{MC} = X \underbrace{(X^T X)^{-1} X^T}_{\Pi_{\text{Im}(X)}} Y .$$

Interprétation géométrique. On a

$$\widehat{X\theta}_{MC} = X \underbrace{(X^T X)^{-1} X^T}_{\Pi_{\text{Im}(X)}} Y.$$

Le vecteur $\widehat{Y} = \widehat{X\theta}_{MC}$ est la **projection orthogonale de Y sur l'espace image de X .**

Estimateur des moindres carrés : forme close et interprétation géométrique

Interprétation géométrique. On a

$$\widehat{X\theta}_{MC} = \underbrace{X(X^T X)^{-1} X^T}_{\Pi_{\text{Im}(X)}} Y.$$

Le vecteur $\widehat{Y} = \widehat{X\theta}_{MC}$ est la **projection orthogonale de Y sur l'espace image de X .**




Illustration de la régression linéaire : les vecteurs $\widehat{X\theta}_{MC}$ (bleu) et $Y - \widehat{X\theta}_{MC}$ (rouge) sont orthogonaux.

Preuve.

Preuve. On prend le gradient de

$$\theta \mapsto \text{SCR}(\theta) = \|Y - X\theta\|^2 = (Y - X\theta)^T(Y - X\theta) :$$

$$\begin{aligned}\nabla_{\theta} \text{SCR}(\theta) &= \nabla_{\theta} (Y - X\theta)^T(Y - X\theta) \\ &= \nabla_{\theta} \left(Y^T Y - 2(X^T Y)^T \theta + \theta^T X^T X \theta \right) \\ &= -2X^T Y + 2X^T X \theta.\end{aligned}$$

Puis $\nabla_{\theta} \text{SCR}(\theta) = 0 \iff X^T X \hat{\theta}_{MC} = X^T Y \iff \hat{\theta}_{MC} = (X^T X)^{-1} X^T Y$, car $X^T X$ est inversible.

La hessienne de $\theta \mapsto \text{SCR}(\theta)$ vaut $2X^T X$ est est symétrique définie positive. La fonction est strictement convexe. Le point critique est donc un minimum global. □

Proposition (Propriétés générales de $\hat{\theta}_{MC}$). Dans un modèle linéaire identifiable, l'estimateur des moindres carrés de θ :

- (i) est toujours sans biais : $\mathbb{E}_{\theta}[\hat{\theta}_{MC}] = \theta$.
- (ii) a pour matrice de covariance $\text{Var}_{\theta}(\hat{\theta}_{MC}) = \sigma^2(X^T X)^{-1}$.
- (iii) De plus, la somme des carrés résiduels en $\hat{\theta}_{MC}$, $\text{SCR}(\hat{\theta}_{MC})$, peut être utilisée pour estimer σ^2 . On a $\text{SCR}(\hat{\theta}_{MC})/n$ qui est biaisé, et $\text{SCR}(\hat{\theta}_{MC})/(n - p)$ qui est sans biais.

Proposition (Propriétés générales de $\hat{\theta}_{MC}$). Dans un modèle linéaire identifiable, l'estimateur des moindres carrés de θ :

- (i) est toujours sans biais : $\mathbb{E}_{\theta}[\hat{\theta}_{MC}] = \theta$.
- (ii) a pour matrice de covariance $\text{Var}_{\theta}(\hat{\theta}_{MC}) = \sigma^2(X^T X)^{-1}$.
- (iii) De plus, la somme des carrés résiduels en $\hat{\theta}_{MC}$, $\text{SCR}(\hat{\theta}_{MC})$, peut être utilisée pour estimer σ^2 . On a $\text{SCR}(\hat{\theta}_{MC})/n$ qui est biaisé, et $\text{SCR}(\hat{\theta}_{MC})/(n - p)$ qui est sans biais.

Interprétation de (ii) : on paye le bruit en σ^2 (logique) + la transformation par X dans Y (qu'il faut en quelque sorte inverser).

Proposition (Propriétés générales de $\hat{\theta}_{MC}$). Dans un modèle linéaire identifiable, l'estimateur des moindres carrés de θ :

- (i) est toujours sans biais : $\mathbb{E}_{\theta}[\hat{\theta}_{MC}] = \theta$.
- (ii) a pour matrice de covariance $\text{Var}_{\theta}(\hat{\theta}_{MC}) = \sigma^2(X^T X)^{-1}$.
- (iii) De plus, la somme des carrés résiduels en $\hat{\theta}_{MC}$, $\text{SCR}(\hat{\theta}_{MC})$, peut être utilisée pour estimer σ^2 . On a $\text{SCR}(\hat{\theta}_{MC})/n$ qui est biaisé, et $\text{SCR}(\hat{\theta}_{MC})/(n - p)$ qui est sans biais.

Interprétation de (ii) : on paye le bruit en σ^2 (logique) + la transformation par X dans Y (qu'il faut en quelque sorte inverser).

Remarque. Supposons que les p colonnes de X sont orthogonales, et tous les coefficients sont d'ordre 1. Alors $X^T X$ est proche de $n \times I_p$, et

$$\text{Tr}(\sigma^2(X^T X)^{-1}) \simeq \sigma^2 p/n.$$



Si la dimension p est constante, pas de souci. Mais si p scale avec n , on a des problèmes pour estimer θ ...

Preuve. Pour (i), on utilise la linéarité de l'espérance:

$$\mathbb{E}_\theta[\widehat{\theta}_{MC}] = \mathbb{E}_\theta[(X^T X)^{-1} X^T Y] = (X^T X)^{-1} X^T \mathbb{E}_\theta[Y] = (X^T X)^{-1} X^T X \theta = \theta.$$

Pour (ii), par bilinéarité de la covariance :

$$\begin{aligned}\text{Var}_\theta(\widehat{\theta}_{MC}) &= \text{Var}_\theta((X^T X)^{-1} X^T Y) = (X^T X)^{-1} X^T \text{Var}_\theta(Y) ((X^T X)^{-1} X^T)^T \\ &= (X^T X)^{-1} X^T \sigma^2 I_n X (X^T X)^{-1} = \sigma^2 (X^T X)^{-1}.\end{aligned}$$

Pour (iii), on calcule $\mathbb{E}_\theta[\|Y - X\widehat{\theta}_{MC}\|^2] = \mathbb{E}_\theta[\|(I_n - \Pi_{\text{Im}(X)})Y\|^2]$. En notant Π le projecteur orthogonal sur $\text{Im}^\perp(X)$:

$$\begin{aligned}\mathbb{E}_\theta[\|Y - X\widehat{\theta}_{MC}\|^2] &= \mathbb{E}_\theta[\|\Pi Y\|^2] = \mathbb{E}_\theta[\|\Pi(X\theta + \varepsilon)\|^2] \\ &= \mathbb{E}_\theta[\|\Pi \varepsilon\|^2] = \mathbb{E}_\theta[\varepsilon^T \Pi^T \Pi \varepsilon] \\ &= \sigma^2 \text{Tr}(\Pi^T \Pi) = \sigma^2 \text{Tr}(\Pi) = (n - p)\sigma^2. \quad \square\end{aligned}$$

Proposition (Moindres carrés dans le modèle gaussien). Dans le modèle linéaire gaussien, supposé identifiable, l'estimateur du MV de (θ, σ^2) noté $(\hat{\theta}_{MV}, \hat{\sigma}_{MV}^2)$ est donné par

$$\hat{\theta}_{MV} = \hat{\theta}_{MC}, \quad \text{et} \quad \hat{\sigma}_{MV}^2 = \frac{\|Y - X\hat{\theta}_{MC}\|^2}{n} = \frac{\text{SCR}(\hat{\theta}_{MC})}{n}.$$

De plus, $\hat{\theta}_{MV}$ et $\hat{\sigma}_{MV}^2$ sont indépendants, et

$$\hat{\theta}_{MV} \sim \mathcal{N}(\theta, \sigma^2(X^T X)^{-1}) \quad \text{et} \quad \hat{\sigma}_{MV}^2 \sim \frac{\sigma^2}{n} \chi^2(n - p).$$

Proposition (Moindres carrés dans le modèle gaussien). Dans le modèle linéaire gaussien, supposé identifiable, l'estimateur du MV de (θ, σ^2) noté $(\hat{\theta}_{MV}, \hat{\sigma}_{MV}^2)$ est donné par

$$\hat{\theta}_{MV} = \hat{\theta}_{MC}, \quad \text{et} \quad \hat{\sigma}_{MV}^2 = \frac{\|Y - X\hat{\theta}_{MC}\|^2}{n} = \frac{\text{SCR}(\hat{\theta}_{MC})}{n}.$$

De plus, $\hat{\theta}_{MV}$ et $\hat{\sigma}_{MV}^2$ sont indépendants, et

$$\hat{\theta}_{MV} \sim \mathcal{N}(\theta, \sigma^2(X^T X)^{-1}) \quad \text{et} \quad \hat{\sigma}_{MV}^2 \sim \frac{\sigma^2}{n} \chi^2(n - p).$$

Remarque. En particulier, l'estimateur du max de vraisemblance de θ à l'élégance de coïncider avec l'EMC.

Preuve.

Résultats spécifiques au modèle linéaire gaussien, preuve

Preuve. Dans le modèle linéaire gaussien, sous $\mathbb{P}_{\theta, \sigma^2}$, on a $Y \sim \mathcal{N}(X\theta, \sigma^2 I_n)$, de densité

$$\begin{aligned} f_{\theta, \sigma^2}(y) &= \frac{1}{(2\pi)^{n/2} \sqrt{\det(\sigma^2 I_n)}} \exp\left(-\frac{1}{2}(y - X\theta)^T \frac{1}{\sigma^2} I_n (y - X\theta)\right) \\ &= \text{cste} \times (\sigma^2)^{-n/2} \exp\left(-\frac{1}{2\sigma^2} \|y - X\theta\|^2\right). \end{aligned}$$

Ainsi l'estimateur du MV est ici

$$(\hat{\theta}_{MV}, \hat{\sigma}_{MV}^2) := \arg \max_{(\theta, \sigma^2) \in \mathbb{R}^p \times \mathbb{R}_+} \log f_{\theta, \sigma^2}(Y) = \arg \min_{(\theta, \sigma^2) \in \mathbb{R}^p \times \mathbb{R}_+} \left(\frac{n}{2} \log(\sigma^2) + \frac{1}{2\sigma^2} \|Y - X\theta\|^2 \right).$$

Pour tout σ^2 , on minimise d'abord en θ :

$$\hat{\theta}_{MV} = \arg \min_{\theta \in \mathbb{R}^p} \|Y - X\theta\|^2 = \hat{\theta}_{MC}.$$

Puis, on dérive la fonction

$$g : \sigma^2 \mapsto \frac{n}{2} \log(\sigma^2) + \frac{1}{2\sigma^2} \text{SCR}(\hat{\theta}_{MC}).$$

$$\text{On a } g'(\sigma^2) = \frac{n}{2\sigma^2} - \frac{1}{2\sigma^4} \text{SCR}(\hat{\theta}_{MC}), \quad g'(\sigma^2) > 0 \iff \sigma^2 > \frac{\text{SCR}(\hat{\theta}_{MC})}{n} = \hat{\sigma}_{MV}^2.$$

Ensuite, comme $Y \sim \mathcal{N}(X\theta, \sigma^2 I_n)$, $\hat{\theta}_{MC} = (X^T X)^{-1} X^T Y$ est encore gaussien, de moyenne et de variance déjà établie auparavant.

De plus, par le Théorème de Cochran, $X\hat{\theta}_{MC}$ (proj. de Y sur $\text{Im}(X)$) et $Y - X\hat{\theta}_{MC}$ (proj. de Y sur $\text{Im}(X)^\perp$) sont indépendantes, et comme $\|Y - X\hat{\theta}_{MC}\|^2 \sim \sigma^2 \chi^2(\dim(\text{Im}(X)^\perp)) = \sigma^2 \chi^2(n - p)$.

Il reste à voir que le $\hat{\sigma}_{MV}^2$ est une fonction mesurable de $Y - X\hat{\theta}_{MC}$ (c'est clair) et que $\hat{\theta}_{MC}$ est une fonction mesurable de $X\hat{\theta}_{MC}$: c'est le cas car $\hat{\theta}_{MC} = ((X^T X)^{-1} X^T) X\hat{\theta}_{MC}$. □

Tests et intervalles de confiance dans le modèle Gaussien (1/2)

On se place dans le modèle linéaire gaussien identifiable, et on note $\hat{\theta} = \hat{\theta}_{MC}$, et $\hat{\sigma}^2 = \frac{SCR(\hat{\theta})}{n-p}$ l'estimateur de σ^2 débiaisé.

On se place dans le modèle linéaire gaussien identifiable, et on note $\hat{\theta} = \hat{\theta}_{MC}$, et $\hat{\sigma}^2 = \frac{SCR(\hat{\theta})}{n-p}$ l'estimateur de σ^2 débiaisé.

Objectif : tester ou estimer la valeur de composantes ou combinaisons linéaires de θ .

On se place dans le modèle linéaire gaussien identifiable, et on note $\hat{\theta} = \hat{\theta}_{MC}$, et $\hat{\sigma}^2 = \frac{SCR(\hat{\theta})}{n-p}$ l'estimateur de σ^2 débiaisé.

Objectif : tester ou estimer la valeur de composantes ou combinaisons linéaires de θ .

Résultats clés (à savoir retrouver) : Pour tout $a \in \mathbb{R}^p$:

$$(a^T(X^T X)^{-1}a)^{-1/2} \frac{a^T \hat{\theta} - a^T \theta}{\sigma} \sim \mathcal{N}(0, 1)$$

On se place dans le modèle linéaire gaussien identifiable, et on note $\hat{\theta} = \hat{\theta}_{MC}$, et $\hat{\sigma}^2 = \frac{SCR(\hat{\theta})}{n-p}$ l'estimateur de σ^2 débiaisé.

Objectif : tester ou estimer la valeur de composantes ou combinaisons linéaires de θ .

Résultats clés (à savoir retrouver) : Pour tout $a \in \mathbb{R}^p$:

$$(a^T(X^T X)^{-1}a)^{-1/2} \frac{a^T \hat{\theta} - a^T \theta}{\sigma} \sim \mathcal{N}(0, 1)$$

et

$$(a^T(X^T X)^{-1}a)^{-1/2} \frac{a^T \hat{\theta} - a^T \theta}{\sqrt{\hat{\sigma}^2}} \sim \mathcal{T}(n-p).$$

Intervalle de confiance de formes linéaires en θ

On se place dans le modèle linéaire gaussien identifiable, et on note $\hat{\theta} = \hat{\theta}_{MC}$, et $\hat{\sigma}^2 = \frac{\text{SCR}(\hat{\theta})}{n-p}$ l'estimateur de σ^2 débiaisé.

Objectif : tester ou estimer la valeur de composantes ou combinaisons linéaires de θ .

Résultats clés (à savoir retrouver) : Pour tout $a \in \mathbb{R}^p$:

$$(a^T(X^T X)^{-1}a)^{-1/2} \frac{a^T \hat{\theta} - a^T \theta}{\sigma} \sim \mathcal{N}(0, 1)$$

et

$$(a^T(X^T X)^{-1}a)^{-1/2} \frac{a^T \hat{\theta} - a^T \theta}{\sqrt{\hat{\sigma}^2}} \sim \mathcal{T}(n-p).$$

Conséquence : un IC de niveau $1 - \alpha$ pour $a^T \theta$ est :

Intervalle de confiance de formes linéaires en θ

On se place dans le modèle linéaire gaussien identifiable, et on note $\hat{\theta} = \hat{\theta}_{MC}$, et $\hat{\sigma}^2 = \frac{\text{SCR}(\hat{\theta})}{n-p}$ l'estimateur de σ^2 débiaisé.

Objectif : tester ou estimer la valeur de composantes ou combinaisons linéaires de θ .

Résultats clés (à savoir retrouver) : Pour tout $a \in \mathbb{R}^p$:

$$(a^T(X^T X)^{-1}a)^{-1/2} \frac{a^T \hat{\theta} - a^T \theta}{\sigma} \sim \mathcal{N}(0, 1)$$

et

$$(a^T(X^T X)^{-1}a)^{-1/2} \frac{a^T \hat{\theta} - a^T \theta}{\sqrt{\hat{\sigma}^2}} \sim \mathcal{T}(n-p).$$

Conséquence : un IC de niveau $1 - \alpha$ pour $a^T \theta$ est :

$$\left[a^T \hat{\theta} \pm t_{1-\alpha/2}^{(n-p)} \hat{\sigma} \sqrt{a^T(X^T X)^{-1}a} \right],$$

avec $t_{\beta}^{(n-p)}$ quantile de $\mathcal{T}(n-p)$ d'ordre β .

Remarque. On a aussi une solution pour tester $H_0 : a^T \theta = c$ contre $H_1 : a^T \theta \neq c$

Remarque. On a aussi une solution pour tester $H_0 : a^T \theta = c$ contre $H_1 : a^T \theta \neq c$ en considérant la statistique

$$T := (a^T (X^T X)^{-1} a)^{-1/2} \frac{a^T \hat{\theta} - c}{\hat{\sigma}}$$

et en appliquant les résultats ci-dessus.

Remarque. On a aussi une solution pour tester $H_0 : a^T \theta = c$ contre $H_1 : a^T \theta \neq c$ en considérant la statistique

$$T := (a^T (X^T X)^{-1} a)^{-1/2} \frac{a^T \hat{\theta} - c}{\hat{\sigma}}$$

et en appliquant les résultats ci-dessus. C'est le **test de Student**.

Remarque. On a aussi une solution pour tester $H_0 : a^T \theta = c$ contre $H_1 : a^T \theta \neq c$ en considérant la statistique

$$T := (a^T (X^T X)^{-1} a)^{-1/2} \frac{a^T \hat{\theta} - c}{\hat{\sigma}}$$

et en appliquant les résultats ci-dessus. C'est le **test de Student**.

Exemples.

- IC/test pour **un coefficient particulier** θ_j : prendre $a = e_j$. Dans ce cas,
 $(a^T (X^T X)^{-1} a)^{-1/2} = \frac{1}{\sqrt{[(X^T X)^{-1}]_{j,j}}}$
- IC/test pour la **différence entre deux coefficients** : prendre $a = e_i - e_j$.

Merci !

Rdv en TD pour les questions et la pratique de ces notions.

(contenu du cours et quizz : lganassali.github.io)