

1. Rappels de statistiques : estimation, tests et intervalles de confiance

Objectifs : Retravailler les notions d'estimation, de tests et d'intervalles de confiance. Les exercices 1.1 à 1.3 sont à faire pendant le TD, les suivants sont à chercher de votre côté.

Exercice 1.1 (Estimation de la variance, moyenne inconnue). Soit un échantillon i.i.d. $(X_1, \dots, X_n)$ d'espérance μ et de variance $\sigma^2 > 0$ finie, toutes les deux inconnues. On s'intéresse à l'estimation de σ^2 . On note

$$\bar{X} := \frac{1}{n} \sum_{i=1}^n X_i \quad \text{et} \quad \hat{m}_2 := \frac{1}{n} \sum_{i=1}^n X_i^2.$$

On considère l'estimateur de σ^2 suivant :

$$V_n = \frac{1}{n} \sum_{i=1}^n (X_i - \bar{X})^2.$$

1. Montrer que $V_n = \hat{m}_2 - (\bar{X})^2$. *Solution. Par simple calcul, on a*

$$V_n = \frac{1}{n} \sum_{i=1}^n (X_i - \bar{X})^2 = \frac{1}{n} \sum_{i=1}^n (X_i^2 - 2X_i\bar{X} + \bar{X}^2) = \frac{1}{n} \sum_{i=1}^n X_i^2 - 2\bar{X} \cdot \bar{X} + \bar{X}^2 = \hat{m}_2 - (\bar{X})^2.$$

2. V_n est-il un estimateur sans biais de σ^2 ? Sinon, proposer un estimateur sans biais qu'on notera $\hat{\sigma}^2$. *Solution. Calculons le biais de V_n . Reprenons l'expression de l'énoncé :*

$$\begin{aligned} \mathbb{E}[V_n] &= \mathbb{E}[\hat{m}_2] - \mathbb{E}[(\bar{X})^2] \\ &= \frac{1}{n} \sum_{i=1}^n (\text{Var}(X_i) + \mathbb{E}[X_i]^2) - (\text{Var}(\bar{X}) + \mathbb{E}[\bar{X}]^2) \\ &= \sigma^2 + \mu^2 - \frac{1}{n^2}(n\sigma^2) - \mu^2 = \frac{n-1}{n}\sigma^2, \end{aligned}$$

et le biais de V_n vaut donc $\mathbb{E}[V_n] - \sigma^2 = -\frac{1}{n}\sigma^2 < 0$, V_n est donc biaisé (avec un biais légèrement négatif). En posant :

$$\hat{\sigma}^2 = \frac{n}{n-1} V_n = \frac{1}{n-1} \sum_{i=1}^n (X_i - \bar{X})^2,$$

on obtient un estimateur sans biais.

Dans toute la suite de l'exercice, on suppose de plus que les X_i suivent la loi normale $\mathcal{N}(\mu, \sigma^2)$. On admet que cela implique que $K_{n-1} := \sum_{i=1}^n (X_i - \bar{X})^2 / \sigma^2$ suit une loi du khi-deux à $n-1$ degrés de libertés, loi dont la moyenne est $n-1$ et la variance est $2(n-1)$.

3. En déduire l'expression du risque quadratique de V_n . *Solution. On a le biais, il nous manque la variance. $V_n = \frac{\sigma^2}{n} K_{n-1}$, donc $\text{Var}(V_n) = \frac{\sigma^4}{n^2} \cdot 2(n-1)$. D'où le risque quadratique :*

$$R(V_n) = \text{Var}(V_n) + (\mathbb{E}[V_n] - \sigma^2)^2 = \frac{2(n-1)}{n^2} \sigma^4 + \left(\frac{n-1}{n} \sigma^2 - \sigma^2 \right)^2 = \frac{2n-1}{n^2} \sigma^4.$$

On a $R(V_n) \rightarrow 0$ quand $n \rightarrow \infty$.

4. En utilisant la loi forte des grands nombres, montrer que cet estimateur est fortement consistant ? *Solution.* Oui, grâce à la loi des grands nombres. Les X_i étant i.i.d., de moment d'ordre 2 fini, $\hat{m}_2 \rightarrow \mathbb{E}[X_1^2]$, et $\bar{X} \rightarrow \mathbb{E}[X_1]$ p.s. quand $n \rightarrow \infty$. On réinjecte dans l'expression de V_n pour conclure que p.s., V_n converge vers $\mathbb{E}[X_1^2] - \mathbb{E}[X_1]^2 = \text{Var}(X_1) = \sigma^2$. V_n est donc fortement consistant.

Exercice 1.2 (Intervalle de confiance dans le modèle uniforme). Supposons que $(X_n)_{n \geq 1}$ sont i.i.d. de loi uniforme sur $[0, \theta]$, avec $\theta > 0$. Pour tout $n \geq 1$, on définit

$$M_n := \max(X_1, \dots, X_n).$$

- Montrer que $(\frac{M_n}{\theta})^n$ est pivotale, et donner sa loi. On pourra calculer $\mathbb{P}_\theta((M_n/\theta)^n \leq u)$ pour tout $u \geq 0$. *Solution.* Trouvons la loi de $T := (\frac{M_n}{\theta})^n$. Remarquons que presque sûrement, $0 \leq T \leq 1$. Pour tout $0 \leq u \leq 1$, $\mathbb{P}_\theta(T \leq u) = \mathbb{P}_\theta(M_n \leq u^{1/n}\theta) = (u^{1/n}\theta/\theta)^n = u$, donc $T \sim \text{Unif}([0, 1])$, loi qui ne dépend pas de θ : elle est pivotale.
- Soit $\alpha \in]0, 1]$. En déduire un intervalle de confiance I de probabilité de couverture $1 - \alpha$ pour θ basé sur M_n . *Solution.* On applique la méthode pivotale : pour tout $\theta > 0$, $1 - \alpha = \mathbb{P}_\theta(T \in [\alpha, 1]) = \mathbb{P}_\theta([M_n, M_n\alpha^{-1/n}] \ni \theta)$, ce qui donne l'intervalle de confiance $I = [M_n, M_n\alpha^{-1/n}]$ avec les propriétés désirées.
- Trouver un équivalent du diamètre de I lorsque $n \rightarrow \infty$, pour un α fixé dans $]0, 1]$. *Solution.* Le diamètre de I est $M_n(\alpha^{-1/n} - 1) \sim \frac{M_n}{n} \log(1/\alpha)$.

Exercice 1.3 (Test gaussien, variance connue). On admet (ou on rappelle) dans cet exercice une propriété fondamentale des v.a. gaussiennes : si $(Z_j)_{1 \leq j \leq m}$ sont des v.a. réelles indépendantes et de loi respectives $(\mathcal{N}(\mu_j, \sigma_j^2))_{1 \leq j \leq m}$, alors pour tous réels $\alpha_0, \alpha_1, \dots, \alpha_m$, on a

$$\alpha_0 + \alpha_1 Z_1 + \dots + \alpha_m Z_m \sim \mathcal{N}\left(\alpha_0 + \sum_{j=1}^m \alpha_j \mu_j, \sum_{j=1}^m \alpha_j^2 \sigma_j^2\right).$$

Soit $(X_1, \dots, X_{25})$ un échantillon de loi gaussienne d'espérance μ inconnue et de variance $\sigma^2 = 100$ connue.

On donne quelques quantiles de la loi $\mathcal{N}(0, 1)$:

$$q_{0.975} \sim 1.96, q_{0.95} \sim 1.65, q_{0.9} \sim 1.28, q_{0.8} \sim 0.84,$$

et quelques images de sa fonction de répartition Φ :

$$\Phi(1.21) \sim 0.89, \Phi(0.90) \sim 0.82, \Phi(0.53) \sim 0.70, \Phi(0.09) \sim 0.53.$$

- Construire un test de niveau $\alpha = 0.10$ pour

$$\mathcal{H}_0 : \mu = 0 \quad \text{contre} \quad \mathcal{H}_1 : \mu = 1.5,$$

fondé sur la moyenne empirique $\bar{X} := \frac{1}{25} \sum_{i=1}^{25} X_i$, estimateur du paramètre μ . *Solution.* On suit les étapes classiques de construction d'un test (cf cours). On les détaille ci-après :

- *Modèle* : $(\mathbb{R}^{25}, \mathcal{N}(\mu, 100)^{\otimes 25})$.
- *Hypothèses* : $\mathcal{H}_0 : \mu = 0$ contre $\mathcal{H}_1 : \mu = 1.5$.
- *Statistique de test* :

$$T = \frac{\bar{X} - 0}{\sigma/\sqrt{n}} = \frac{\bar{X}}{2} \sim \mathcal{N}(0, 1) \text{ sous } \mathcal{H}_0.$$

- Région de rejet : $\mathcal{R} =]q_{0.9} \approx 1.28, +\infty[$, qui vérifie bien $\mathbb{P}(T \in \mathcal{R}) = 0.10 = \alpha$ sous $\mathcal{H}_0$. La forme de la région de rejet est cohérente avec l'hypothèse $\mathcal{H}_1$ (on veut tester si μ est "plus grand"). Notons qu'on pourrait prendre aussi $\mathcal{R} =]-\infty, q_{0.1}[$ ou $\mathcal{R} =]-\infty, q_{0.05}[\cup]q_{0.95}, +\infty[$, mais celles-ci sont moins adaptées pour $\mathcal{H}_1$, et les tests associés seront moins puissants (sans même faire de calcul).

- On observe $\bar{x} = 1$. Quelle est la décision du test ? L'erreur que l'on fait peut-être ici est-elle de première espèce ? de seconde espèce ? La calculer. *Solution.* La valeur observée est $t^{obs} = \frac{1}{2} = 0.5 < 1.28$, donc on ne rejette pas $\mathcal{H}_0$. Si on fait une erreur en ne rejetant pas $\mathcal{H}_0$, c'est qu'on a pas détecté $\mathcal{H}_1$, c'est donc une erreur de seconde espèce. Calculons-la. Sous $\mathcal{H}_1$, on a $T = \frac{\bar{X}}{2} \sim \mathcal{N}(0.75, 1)$, donc l'erreur de seconde espèce est :

$$\beta = \mathbb{P}_1(T \leq 1.28) = \mathbb{P}_1(T - 0.75 \leq 1.28 - 0.75) = \mathbb{P}(Z \leq 0.53) \approx 0.7,$$

où Z est une v.a. de loi $\mathcal{N}(0, 1)$. Il y a donc environ 70% de probabilité de ne pas rejeter $\mathcal{H}_0$ alors que $\mathcal{H}_1$ est vraie. Ce test n'est pas très puissant.

- Déterminer la taille minimum d'un échantillon dans le même cadre que ci-dessus si l'on souhaite que le test précédent ait des erreurs de première et de seconde espèce toutes deux inférieures à 0.1. *Solution.* Rappelons que la statistique de test s'écrit $T = \frac{1}{10} \bar{X} \sqrt{n}$. Sous $\mathcal{H}_0$, $T \sim \mathcal{N}(0, 1)$ et le test est bien de niveau 0.10 par construction dans la question 1. Pour l'erreur de seconde espèce, on veut $\mathbb{P}_1(T \leq q_{0.9}) \leq 0.1$, et sous $\mathcal{H}_1$, après calcul, $T \sim \mathcal{N}(0.15\sqrt{n}, 1)$. On a $\mathbb{P}_1(T \leq q_{0.9}) \leq 0.1$ ssi $q_{0.9} - 0.15\sqrt{n} \leq q_{0.1} = -1.28$. (On utilisera la symétrie des quantiles gaussiens!). Cela équivaut après calcul à $n \geq 291.27$. Il faut donc au minimum un échantillon de taille $n = 292$.

Exercice 1.4 (Des questions d'identifiabilité). On considère un modèle dans lequel l'observation X est une différence $X = Y - Z$ avec Y, Z deux variables gaussiennes indépendantes, de moyennes respectives μ_1, μ_2 et de variances respectives σ_1^2, σ_2^2 , toutes inconnues.

- Ce modèle est-il identifiable ? *Solution.* On a $Y \sim \mathcal{N}(\mu_1, \sigma_1^2)$ et $Z \sim \mathcal{N}(\mu_2, \sigma_2^2)$. On a $X \sim \mathcal{N}(\mu_1 - \mu_2, \sigma_1^2 + \sigma_2^2)$, et donc, en raison de l'invariance par translation, le modèle n'est pas identifiable, par exemple on peut arbitrairement modifier μ_1, μ_2 sans changer leur différence, et le statisticien ne saura pas faire la différence.
- Supposons dans cette question que $\mu_2 = 3\mu_1 + 1$ et $\sigma_2 = 2\sigma_1$. Cela rend-il le modèle identifiable ? *Solution.* Si $Y \sim \mathcal{N}(\mu_1, \sigma_1^2)$ et $Z \sim \mathcal{N}(\mu_2, \sigma_2^2)$, alors $X \sim \mathcal{N}(\mu_1 - \mu_2, \sigma_1^2 + \sigma_2^2)$, il y a donc deux degrés de liberté supplémentaires dans le modèle. Sous les hypothèses en plus, $X \sim \mathcal{N}(1 - 2\mu_1, 5\sigma_1^2)$, les moments d'ordre 1 et 2 suffisent pour identifier le modèle.
- Qu'en est-il d'un modèle où $X = Y - Z$ avec Y, Z deux variables exponentielles indépendantes à paramètres inconnus ? On pourra chercher une interprétation géométrique aux équations pour l'espérance et la variance de X . *Solution.* On obtient un système toujours soluble (il est plus simple de raisonner avec les inverses des paramètres). En posant $b = 1/\lambda$ et $c = 1/\mu$, les équations sont $b - c = \mathbb{E}[X] =: A$ et $b^2 + c^2 = \text{Var}(X) =: B$. Il s'agit de trouver un point (b, c) sur le cercle centré d'équation $x^2 + y^2 = B$ à l'intersection avec la droite $y = x - A$. On voit facilement que si cette droite et ce cercle s'intersectent, ils le font au plus une fois dans le quadrant positif ; comme $b = 1/\lambda$ et $c = 1/\mu$ doivent être des solutions, il y a une solution unique. Le modèle est identifiable.
- Qu'en est-il d'un modèle où $X = \alpha(Y - Z)$ avec Y, Z deux variables exponentielles indépendantes à paramètres inconnus, et $\alpha \in \mathbb{R}$? Et si $\alpha > 0$? *Solution.* Quand $\alpha \in \mathbb{R}$, il existe une symétrie $(\alpha, \lambda, \mu) \mapsto (-\alpha, \mu, \lambda)$, donc le modèle n'est pas identifiable. Lorsque $\alpha > 0$, l'espérance vaut $\alpha(b - c)$ et la variance vaut $\alpha^2(b^2 + c^2)$. Les quantités αb et αc peuvent être déterminées de façon unique à partir de ces deux équations. Mais pas davantage : en effet, $\alpha Y \sim \text{Exp}(\lambda/\alpha)$, il y a donc une symétrie $(\alpha, \lambda, \mu) \mapsto (1, \lambda/\alpha, \mu/\alpha)$.

Exercice 1.5 (Estimateur sans biais pour une Bernoulli). On considère un échantillon $(X_1, \dots, X_n)$ i.i.d. de loi de Bernoulli $\mathcal{B}(p)$.

1. Montrer que $\bar{X}$ (la moyenne empirique) est un estimateur sans biais de p .
2. Soit $g(\bar{X})$ un autre estimateur sans biais de p qui est une fonction (mesurable) de $\bar{X}$. Montrer que pour tout $x \in \mathbb{R}^+$:

$$\sum_{k=0}^n \left(g\left(\frac{k}{n}\right) - \frac{k}{n} \right) \binom{n}{k} x^k = 0$$

et en déduire que $\bar{X}$ est le seul estimateur sans biais de p qui est une fonction de $\bar{X}$.
Solution. Il est clair que $\bar{X} \sim \frac{1}{n} \text{Bin}(n, p)$. Par hypothèse, $g(\bar{X})$ est un estimateur sans biais de p et donc

$$\mathbb{E}_p[g(\bar{X})] = \sum_{k=0}^n g\left(\frac{k}{n}\right) \binom{n}{k} p^k (1-p)^{n-k} = p$$

D'autre part, en écrivant $\mathbb{E}[\text{Bin}(n, p)/n] = p$, il vient que

$$p = \frac{1}{n} \sum_{k=0}^n k \binom{n}{k} p^k (1-p)^{n-k}$$

On a donc

$$\sum_{k=0}^n \left(g\left(\frac{k}{n}\right) - \frac{k}{n} \right) \binom{n}{k} p^k (1-p)^{n-k} = 0$$

et ceci pour tout $p \in [0, 1]$. En posant $x = \frac{p}{1-p}$ (valable pour $p \in [0, 1[$), alors pour tout $x \in \mathbb{R}^+$,

$$\sum_{k=0}^n \left(g\left(\frac{k}{n}\right) - \frac{k}{n} \right) \binom{n}{k} x^k = 0$$

Cette égalité est un polynôme de degré n nul pour une infinité de valeurs de $x \in \mathbb{R}^+$, donc il est identiquement nul. Par linéarité des coefficients, pour tout $1 \leq k \leq n$,

$$g\left(\frac{k}{n}\right) = \frac{k}{n}$$

d'où $g(\bar{X}) = \bar{X}$. Ainsi, $\bar{X}$ est l'unique estimateur sans biais de p qui soit fonction de $\bar{X}$.

Exercice 1.6. On reprend le cadre de l'exercice 1.3. Désormais on souhaite tester

$$\mathcal{H}_0 : \mu = 2 \quad \text{contre} \quad \mathcal{H}_1 : \mu < 2.$$

Bâtir un test approprié de niveau α donné. Exprimer la puissance de ce test en chaque $\mu < 2$ à l'aide de la fonction Φ , et commenter la dépendance de la puissance en fonction de μ , n et σ .

Solution. On prend une statistique de test proche de celle du début de l'exercice : $T = \frac{\bar{X}-2}{\sigma/\sqrt{n}}$, qui a loi $\mathcal{N}(0, 1)$ sous $\mathcal{H}_0$. Vu la forme du test (on veut tester si μ est petit), on prendra logiquement comme région de rejet au niveau α

$$\mathcal{R} =]-\infty, q_\alpha[.$$

Calculons la puissance de ce test. Elle va dépendre bien sûr de μ . Sous $\mathcal{H}_1$, X_1 est de moyenne $\mu < 2$ et $T \sim \mathcal{N}\left(\frac{\mu-2}{\sigma/\sqrt{n}}, 1\right)$, donc en notant Z une v.a. gaussienne standard, la

puissance est donnée par

$$\pi(\mu) = \mathbb{P}_\mu \left(\frac{\mu - 2}{\sigma/\sqrt{n}} + Z < q_\alpha^* \right) = \Phi \left(q_\alpha^* + \sqrt{n} \frac{2 - \mu}{\sigma} \right) .$$

On remarque tout d'abord que $\pi(\mu) \rightarrow 1$ lorsque $n \rightarrow \infty$: le test est asymptotiquement de puissance 1 (logique, on va avoir plein d'information pour distinguer les hypothèses). Plus généralement, la puissance augmente avec n (logique) et diminue avec σ (logique aussi : pourquoi?). Lorsque $\mu = 2$, on retrouve l'erreur de type 1, qui est exactement de α .