

4. Voyage en pays gaussien

Objectifs : Se familiariser avec les vecteurs gaussiens, leurs propriétés et les calculs associés. Les exercices 4.1 à 4.3 sont à faire pendant le TD, le 4.4 est à chercher de votre côté.

Exercice 4.1 (Pour commencer). Soit $Z = (X, Y)$ un vecteur aléatoire sur $\mathbb{R}^2$ ayant une densité par rapport à la mesure de Lebesgue sur $\mathbb{R}^2$ donnée par

$$f(x, y) = C \exp(-x^2 + xy - y^2/2),$$

où C est une constante de normalisation que l'on ne demande pas de calculer.

1. Montrer que Z est un vecteur gaussien dont on précisera l'espérance et la matrice de covariance. On cherchera $\mu \in \mathbb{R}^2$ et $\Sigma \in \mathbb{R}^{2 \times 2}$ symétrique définie positive telle que $-x^2 + xy - y^2/2 = -\frac{1}{2}(z - \mu)^\top \Sigma^{-1}(z - \mu)$ pour $z = (x, y)$. *Solution. Comme $\exp(-x^2 + xy - y^2/2)$ n'a pas de terme constant non nul, on présume qu'on peut prendre $\mu = (0, 0)^\top$. Ensuite, on remarque que*

$$-x^2 + xy - y^2/2 = -\frac{1}{2}z^\top \begin{pmatrix} 2 & -1 \\ -1 & 1 \end{pmatrix} z,$$

pour $z = (x, y)^\top$. La matrice $\begin{pmatrix} 2 & -1 \\ -1 & 1 \end{pmatrix}$ est inversible d'inverse $\Sigma = \begin{pmatrix} 1 & 1 \\ 1 & 2 \end{pmatrix}$ qui est bien symétrique, et également définie positive : en effet pour tout $z = (x, y)^\top \in \mathbb{R}^2$, $z^\top \Sigma z = x^2 + 2xy - 2xy = (x - y)^2 + y^2$, qui est positif (somme de carré) et nul ssi $(x - y, y) = (0, 0)$ i.e. $z = 0$. On a donc $Z \sim \mathcal{N}(0_2, \Sigma)$.

2. Quelle est la loi marginale de X ? de Y ? de $2X - Y + 5$? *Solution. On lit dans Σ les paramètres d'intérêt :*

$$\Sigma = \begin{pmatrix} 1 & 1 \\ 1 & 2 \end{pmatrix} = \begin{pmatrix} \text{Var}(X) & \text{Cov}(X, Y) \\ \text{Cov}(X, Y) & \text{Var}(Y) \end{pmatrix}.$$

Ainsi, grâce à la stabilité par linéarité des vecteurs gaussiens par exemple, on lit que $X \sim \mathcal{N}(0, 1)$, $Y \sim \mathcal{N}(0, 2)$. Pour $2X - Y + 5$, qui est gaussienne, son espérance vaut 5, et soit (i) on utilise la formule de transformation linéaire avec $a = (2, -1)^\top$, ou alors (ii) l'on calcule directement la variance : $\text{Var}(2X - Y + 5) = 4\text{Var}(X) + \text{Var}(Y) - 2 \times 2\text{Cov}(X, Y) = 4 + 2 - 4 = 2$. D'où $2X - Y + 5 \sim \mathcal{N}(5, 2)$.

3. Montrer que X et $Y - X$ sont indépendants. *Solution. On a $\text{Cov}(X, Y - X) = 1 - 1 = 0$: on conclut à l'indépendance.*

4. Soit $B = \frac{\sqrt{5}}{5} \begin{pmatrix} 3 & -1 \\ -1 & 2 \end{pmatrix}$. Vérifier que $B^2 = \Sigma^{-1}$ et que $B\Sigma = \Sigma B$. Quelle est la loi du vecteur BZ ? *Solution. On utilise la linéarité, on a que $BZ \sim \mathcal{N}(0, B\Sigma B^\top) = \mathcal{N}(0, I_2)$ car $\Sigma = B^{-1}(B^\top)^{-1}$ (B est symétrique). On pourra refaire le dessin de la transformation du nuage de points via B (ellipse vers cercle, comme dans les slides du cours)*

Exercice 4.2 (Un contre-exemple). Soit X variable réelle gaussienne $\mathcal{N}(0, 1)$, et S une variable aléatoire de Rademacher, i.e. telle que $\mathbb{P}(S = 1) = \mathbb{P}(S = -1) = 1/2$. On suppose S et X indépendantes. On définit le vecteur aléatoire $Z = (X, SX)$.

1. Montrer que les coordonnées de Z sont des gaussiennes $\mathcal{N}(0, 1)$. On pourra montrer que la fonction de répartition de SX est encore celle d'une gaussienne standard. *Solution.*

On a que SX est encore une gaussienne standard, via la fonction de répartition. Pour tout réel t , par la formule des probabilités totales,

$$\begin{aligned}\mathbb{P}(SX \leq t) &= \mathbb{P}(SX \leq t | S = -1)\mathbb{P}(S = -1) + \mathbb{P}(SX \leq t | S = 1)\mathbb{P}(S = 1) \\ &= \frac{1}{2}\mathbb{P}(X \geq -t) + \frac{1}{2}\mathbb{P}(X \leq t) \\ &= \frac{1}{2}\mathbb{P}(X \leq t) + \frac{1}{2}\mathbb{P}(X \leq t) = \mathbb{P}(X \leq t),\end{aligned}$$

où l'on a utilisé le fait que la loi d'une gaussienne standard est symétrique en 0 (i.e. $X = -X$ en loi). SX et X ont mêmes fonction de répartition, donc même loi : $SX \sim \mathcal{N}(0, 1)$.

2. Montrer que pourtant, Z n'est pas un vecteur gaussien. *Solution.* Pour montrer que Z n'est pas un vecteur gaussien, il y a plusieurs façons de faire. *Solution 1.* On remarque que $\text{Cov}(X, SX) = \mathbb{E}[SX^2] - 0 = 0$. Par l'absurde, si Z est un vecteur gaussien, alors X et SX sont indépendantes. Or, par la formule des probabilités totales,

$$\begin{aligned}\mathbb{P}(SX \geq 10 | X \geq 10) &= \frac{1}{2}\mathbb{P}(SX \geq 10 | X \geq 10, S = 1) + \frac{1}{2}\mathbb{P}(SX \geq 10 | X \geq 10, S = -1) = \frac{1}{2},\end{aligned}$$

qui n'est vraiment pas égal à $\mathbb{P}(SX \geq 10)$ où $SX \sim \mathcal{N}(0, 1)$. *Solution 2.* Regardons la somme des deux coordonnées, $X + SX$. On a que

$$\begin{aligned}\mathbb{P}(SX + X = 0) &= \mathbb{P}(SX + X = 0 | S = -1)\mathbb{P}(S = -1) + \mathbb{P}(SX + X = 0 | S = 1)\mathbb{P}(S = 1) \\ &= \frac{1}{2} + \frac{1}{2}\mathbb{P}(X = 0) = \frac{1}{2}.\end{aligned}$$

Si $X + SX$ est gaussienne, alors elle n'admet pas de densité par rapport à Lebesgue puisque elle a un atome en 0. Mais dans ce cas elle est nulle ps, contradiction avec $\mathbb{P}(SX + X = 0) = 1/2 \neq 1$. Conclusion (importante) : des gaussiennes ne forment pas forcément un vecteur gaussien. Bonus : Mais elles en forment toujours un quand elles sont indépendantes. On pourra juste démontrer qu'une somme de deux gaussiennes indépendantes forme une gaussienne.

Exercice 4.3 (Indépendance entre moyenne et variance empiriques dans le modèle gaussien). On considère un échantillon $X = (X_1, \dots, X_n)$ i.i.d. de loi $\mathcal{N}(\mu, \sigma^2)$ avec μ et σ^2 inconnus.

- On s'intéresse à la variance empirique de l'échantillon définie par $S_n := \frac{1}{n} \sum_{i=1}^n (X_i - \bar{X})^2$. En utilisant le théorème de Cochran, déterminer la loi de S_n et montrer que S_n et $\bar{X}$ sont indépendants. On pourra introduire le vecteur e de $\mathbb{R}^n$ dont toutes les coordonnées valent 1. *Solution.* On voit tout ça comme une norme d'un projecteur. Regardons le projecteur orthogonal sur $E_1 = \text{Vect}(e) = \mathbb{R}e$. $e/\sqrt{n}$ est une base orthonormée triviale de E_1 et pour $x \in \mathbb{R}^d$. On a $\Pi_1 X = \langle X, e/\sqrt{n} \rangle e/\sqrt{n} = \bar{X}e$. Prenons E_2 l'orthogonal de E_1 dans $\mathbb{R}^n$, on a $\Pi_2 = I_n - \Pi_1$ et donc $\|\Pi_2(X - \mu e)\|^2 = \|X - \mu e - (\bar{X} - \mu)e\|^2 = \|X - \bar{X}e\|^2$ et $S_n = \frac{1}{n} \|\Pi_2(X - \mu e)\|^2$. Cochran nous dit que S_n est donc indépendant de $\bar{X}$ et que $S_n \sim \frac{\sigma^2}{n} \chi^2(n-1)$. On a d'ailleurs une moyenne pas tout à fait égale à σ^2 (S_n est biaisée pour l'estimation de σ^2), et une variance qui tend sans surprise vers 0.
- On s'intéresse à la variance empirique débiaisée, définie par $S'_n := \frac{1}{n-1} \sum_{i=1}^n (X_i - \bar{X})^2$. Quelle est la loi de $\sqrt{n} \frac{\bar{X} - \mu}{\sqrt{S'_n}}$? *Solution.* application directe du cours, après avoir sorti le σ en haut et en bas : loi de Student à $n-1$ degrés de liberté.

Exercice 4.4 (Test des variances dans le modèle gaussien). Nous considérons deux échantillons gaussiens indépendants. Le premier, $X^{(1)}$, est de taille n_1 et i.i.d. de loi $\mathcal{N}(\mu_1, \sigma_1^2)$. Le second, $X^{(2)}$, est de taille n_2 et i.i.d. de loi $\mathcal{N}(\mu_2, \sigma_2^2)$. Tous les paramètres sont supposés inconnus. On note S_1' (resp. S_2') la variance empirique débiaisée pour l'échantillon $X^{(1)}$ (resp. $X^{(2)}$). On veut tester

$$\mathcal{H}_0 : \sigma_1^2 = \sigma_2^2 \quad \text{contre} \quad \mathcal{H}_1 : \sigma_1^2 \neq \sigma_2^2.$$

1. Sous l'hypothèse nulle, quelle est la loi de $\frac{S_1'}{S_2'}$? *Solution. application directe du cours, on a deux variables indépendantes avec $\frac{S_1'}{S_2'} = \frac{\sigma_1^2 \chi^2(n_1-1)/(n_1-1)}{\sigma_2^2 \chi^2(n_2-1)/(n_2-1)} = \mathcal{F}(n_1-1, n_2-1)$ (égalité en loi).*
2. En déduire un test de niveau $\alpha \in]0, 1[$ répondant au problème. *Solution. Au vu de la question précédente, on va se baser sur la statistique de test $T = \frac{S_1'}{S_2'}$. Vu la forme de $\mathcal{H}_1$, T sous l'hypothèse alternative $\mathcal{H}_1$ sera soit plus grande soit plus petite, typiquement. On va donc prendre ici une région de rejet bilatère de la forme $\mathcal{R} =]-\infty, c_1] \cup]c_2, +\infty[$, et on calibre $c_1, c_2 > 0$ de sorte que $\mathbb{P}_0(T \in \mathcal{R}) = \alpha$. Si l'on répartit cette probabilité équitablement entre les événements $\{T < c_1\}$ et $\{T > c_2\}$, on prend $c_1 = f_{\alpha/2}^{n_1-1, n_2, 2}$ et $c_2 = f_{1-\alpha/2}^{n_1-1, n_2, 2}$, avec $f_{\beta}^{d_1, d_2}$ le quantile d'ordre β d'une loi de Fisher $\mathcal{F}(d_1, d_2)$.*
3. Exprimer sa puissance en fonction de σ_1^2, σ_2^2 et une certaine fonction de répartition. *Solution. $\mathcal{H}_1$ étant composite, la puissance dépend des paramètres $\sigma_1^2 \neq \sigma_2^2$ sous $\mathcal{H}_1$. Sous $\mathcal{H}_1$, étant donné $\sigma_1^2 \neq \sigma_2^2$, on a $\frac{S_1'}{S_2'} = \frac{\sigma_1^2 \chi^2(n_1-1)/(n_1-1)}{\sigma_2^2 \chi^2(n_2-1)/(n_2-1)} = \frac{\sigma_1^2}{\sigma_2^2} \mathcal{F}(n_1-1, n_2-1)$ (égalité en loi). En notant X une variable de loi $\mathcal{F}(n_1-1, n_2-1)$ et F sa fonction de répartition, la puissance s'écrit*

$$\begin{aligned} \mathbb{P}_{\sigma_1^2, \sigma_2^2}(T \in \mathcal{R}) &= \mathbb{P}\left(\frac{\sigma_1^2}{\sigma_2^2} X < c_1\right) + \mathbb{P}\left(\frac{\sigma_1^2}{\sigma_2^2} X > c_2\right) \\ &= F\left(f_{\alpha/2}^{n_1-1, n_2, 2} \frac{\sigma_2^2}{\sigma_1^2}\right) + 1 - F\left(f_{1-\alpha/2}^{n_1-1, n_2, 2} \frac{\sigma_2^2}{\sigma_1^2}\right). \end{aligned}$$

(on retrouve que cette puissance vaut α si $\sigma_1^2 = \sigma_2^2$).