

5. Régression linéaire 1/2 : Modèles linéaire et linéaire gaussien, estimateur des moindres carrés, propriétés générales, tests de Student

Objectifs : Savoir faire mener les calculs de la régression linéaire, interpréter les résultats, donner des intervalles de confiance sur les coefficients, tester la nullité d'un coefficient. L'exercice 5.1 est à faire pendant le TD, les autres sont à chercher de votre côté.

Exercice 5.1 (Les eucalyptus). On souhaite expliquer la hauteur y (en mètres) d'un eucalyptus en fonction de sa circonférence x (en centimètres) à 1 mètre 30 du sol, et de la racine carrée de celle-ci. On a relevé $n = 1429$ mesures de couples (x_i, y_i) , le nuage de points étant représenté sur la figure 1 ci-contre.




Figure 1 – Données de hauteurs d'eucalyptus (m) en fonction de leur circonférence (cm).

On propose donc le modèle linéaire suivant : pour tout $1 \leq i \leq n$, $Y_i = \beta_1 + \beta_2 x_i + \beta_3 \sqrt{x_i} + \varepsilon_i$, où les ε_i sont gaussiennes i.i.d. $\mathcal{N}(0, \sigma^2)$. On pose

$$X = \begin{bmatrix} 1 & x_1 & \sqrt{x_1} \\ \vdots & \vdots & \vdots \\ 1 & x_n & \sqrt{x_n} \end{bmatrix} \quad \text{et} \quad Y = \begin{bmatrix} Y_1 \\ \vdots \\ Y_n \end{bmatrix}.$$

Nous avons observé

$$X^\top X = \begin{bmatrix} ? & ? & 9792 \\ ? & 3306000 & ? \\ ? & 471200 & 67660 \end{bmatrix}, \quad X^\top Y = \begin{bmatrix} 30310 \\ 1462000 \\ 209700 \end{bmatrix} \quad \text{et} \quad Y^\top Y = 651900.$$

1. Compléter la matrice $X^\top X$. *Solution. La norme au carré de la première colonne de X vaut n , que l'on retrouve dans $(X^\top X)_{1,1}$. La norme au carré des $\sqrt{x_i}$ dans $(X^\top X)_{3,3}$ c'est juste la somme des x_i que l'on retrouve dans $(X^\top X)_{1,2}$. On complète par symétrie.*

$$D'où $X^\top X = \begin{bmatrix} 1429 & 67660 & 9792 \\ 67660 & 3306000 & 471200 \\ 9792 & 471200 & 67660 \end{bmatrix}$$$

2. Que vaut la circonférence moyenne empirique $\bar{x}$? *Solution.* C'est $\frac{1}{n} \sum_{i=1}^n x_i$. Application numérique : $67660/1429 = 47,3$ cm.

3. Les calculs donnent en arrondissant :

$$(X^\top X)^{-1} = \begin{bmatrix} 4.646 & 0.101 & -1.379 \\ 0.101 & 0.002 & -0.030 \\ -1.379 & -0.030 & 0.411 \end{bmatrix} \quad \text{et} \quad (X^\top X)^{-1} X^\top Y = \begin{bmatrix} -16.8 \\ -0.30 \\ 7.62 \end{bmatrix}.$$

Que vaut ici l'estimateur des moindres carrés $\hat{\beta}$? Représenter la courbe de régression obtenue sur la Figure 1 via le calcul de quelques points. *Solution.* On lit $\hat{\beta} = \begin{bmatrix} -16.8 \\ -0.30 \\ 7.62 \end{bmatrix}$, puis on met des petits points et on interpole.

4. Vérifier que pour tout modèle linéaire identifiable, $Y^\top X \hat{\beta} = \|X \hat{\beta}\|^2$. *Solution.* Il suffit d'écrire :

$$\begin{aligned} \|X \hat{\beta}\|^2 &= \hat{\beta}^\top X^\top X \hat{\beta} \\ &= ((X^\top X)^{-1} X^\top Y)^\top X^\top X \hat{\beta} \\ &= Y^\top X (X^\top X)^{-1} X^\top X \hat{\beta} = Y^\top X \hat{\beta}. \end{aligned}$$

5. En déduire la valeur de l'estimateur de σ^2 débiaisé et en donner une intervalle de confiance de niveau 95%. On utilisera l'approximation suivante : quand m est grand, une variable $\chi^2(m)$ est proche d'une variable $\mathcal{N}(m, 2m)$. On donne le quantile gaussien standard à 97.5% : $q = 1.96$. *Solution.* En utilisant la question 4, on obtient

$$\hat{\sigma}^2 = \frac{\|Y - X \hat{\beta}\|^2}{n-3} = \frac{\|Y\|^2 - \|X \hat{\beta}\|^2}{n-3}.$$

Mais à nouveau $\|X \hat{\beta}\|^2 = \hat{\beta}^\top X^\top Y$ qui se calcule avec les données : c'est $-16.8 \times 30310 - 0.3 \times 1462000 + 7.62 \times 209700 = 650106$. Au final on a $\hat{\sigma}^2 = \frac{651900 - 650106}{1426} =$

1.26. On a que $\hat{\sigma}^2/\sigma^2 \sim \frac{\chi^2(n-p)}{n-p} \simeq 1 + \frac{\sqrt{2}}{\sqrt{n-p}} \mathcal{N}(0, 1)$ donc on prend l'intervalle bilatère $\hat{\sigma}^2[(1 \mp \sqrt{2} \times 1.96/\sqrt{1426})^{-1}] \simeq \hat{\sigma}^2[0.932, 1.079] = [1.174, 1.360]$.

6. Donner un intervalle de confiance pour β_3 de probabilité de couverture 95%. On approchera la loi $\mathcal{T}(m)$ par la loi $\mathcal{N}(0, 1)$, quand m est grand. *Solution.* On a classiquement l'intervalle $\left[\hat{\beta}_3 \pm q_{1-\alpha/2}^{(n-p)} \hat{\sigma} \sqrt{(X^\top X)^{-1}_{3,3}} \right]$ qui ici vaut $[7.62 - 1.96 \times \sqrt{1.26} \times \sqrt{0.411}, 7.62 + 1.96 \times \sqrt{1.26} \times \sqrt{0.411}] = [6.21, 9.03]$.

7. Tester l'hypothèse $\beta_2 = 0$ au niveau de risque 10%. On fera les mêmes approximations que précédemment. On donne le quantile gaussien standard à 95% : $q = 1.645$. Interpréter. *Solution.* On sait que sous H_0 , $T = \frac{\hat{\beta}_2}{\hat{\sigma} \sqrt{(X^\top X)^{-1}_{2,2}}} \sim \mathcal{T}(n-p) \simeq \mathcal{N}(0, 1)$.

Calculons la statistique T ici, elle donne

$$T = \frac{-0.3}{\sqrt{1.26} \sqrt{0.002}} = -5.98.$$

On a $|T| > q$ (et même vénère), on rejette absolument H_0 . Interprétation : la dépendance de y en x (et pas que en $\sqrt{x}$) est donc primordiale pour le modèle.

Exercice 5.2 (Exemple de régression linéaire à la main). On considère le modèle linéaire qui s'écrit matriciellement $Y = \theta_0 e + \theta_1 Z + \varepsilon$, avec $Y \in \mathbb{R}^n$, e le vecteur de $\mathbb{R}^n$ dont les coordonnées valent toutes 1, $Z = (z_1, z_2, \dots, z_n)^\top \in \mathbb{R}^n$, et ε un bruit centré.

1. Donner une condition nécessaire et suffisante explicite sur le vecteur Z pour que le modèle soit identifiable. Interpréter. *Solution. On a, dans notre cas $X \in \mathbb{R}^{n \times p}$ qui s'écrit $X = [e \mid Z]$ avec $p = 2$. X est de rang plein ssi Z n'est pas colinéaire à e , c'est-à-dire de coordonnées non toutes égales. Intuitivement, pour déterminer l'équation de la droite de régression, il faut au moins deux points d'abscisses distinctes.*

On se place sous la condition d'identifiabilité de la question 1. On introduit la covariance empirique entre Y et Z définie par $C(Y, Z) := \frac{1}{n} \sum_{i=1}^n z_i Y_i - \bar{Z} \times \bar{Y}$, ainsi que la variance empirique de Z définie par $V(Z) := \frac{1}{n} \sum_{i=1}^n z_i^2 - (\frac{1}{n} \sum_{i=1}^n z_i)^2$.

2. Calculer à la main l'estimateur des moindres carrés $\hat{\theta}_{MC} = (\hat{\theta}_0, \hat{\theta}_1)^\top$. On écrira $\hat{\theta}_1$ en fonction de C et V , puis $\hat{\theta}_0$ en fonction de $\hat{\theta}_1$. *Solution. On applique la formule explicite du cours. Notons que l'EMC est toujours défini même si le modèle n'est pas gaussien. On a*

$$X^\top X = \begin{pmatrix} e^\top e & e^\top Z \\ e^\top Z & Z^\top Z \end{pmatrix} = \begin{pmatrix} n & \sum_{i=1}^n z_i \\ \sum_{i=1}^n z_i & \sum_{i=1}^n z_i^2 \end{pmatrix}$$

et

$$(X^\top X)^{-1} = \frac{1}{n^2 V(Z)} \begin{pmatrix} \sum_{i=1}^n z_i^2 & -\sum_{i=1}^n z_i \\ -\sum_{i=1}^n z_i & n \end{pmatrix}$$

et de plus

$$X^\top Y = \begin{pmatrix} e^\top Y \\ Z^\top Y \end{pmatrix} = \begin{pmatrix} \sum_{i=1}^n Y_i \\ \sum_{i=1}^n z_i Y_i \end{pmatrix}.$$

On obtient finalement

$$\begin{aligned} \hat{\theta}_{MC} &= (X^\top X)^{-1} X^\top Y = \begin{pmatrix} e^\top Y \\ Z^\top Y \end{pmatrix} = \frac{1}{n^2 V(Z)} \begin{pmatrix} (\sum_{i=1}^n z_i^2)(\sum_{i=1}^n Y_i) - (\sum_{i=1}^n z_i)(\sum_{i=1}^n z_i Y_i) \\ n \sum_{i=1}^n z_i Y_i - (\sum_{i=1}^n z_i)(\sum_{i=1}^n Y_i) \end{pmatrix} \\ &= \frac{1}{V(Z)} \begin{pmatrix} (V(Z) + \bar{Z}^2) \bar{Y} - \bar{Z}(\sum_{i=1}^n z_i Y_i) \\ C(Y, Z) \end{pmatrix} \\ &= \begin{pmatrix} \bar{Y} - \bar{Z}(\sum_{i=1}^n z_i Y_i - \bar{Z} \bar{Y}) / V(Z) \\ C(Y, Z) / V(Z) \end{pmatrix} = \begin{pmatrix} \hat{\theta}_0 = \bar{Y} - \bar{Z} \hat{\theta}_1 \\ \hat{\theta}_1 = C(Y, Z) / V(Z) \end{pmatrix} \end{aligned}$$

3. Montrer que le point moyen, de coordonnées $(\bar{Z}, \bar{Y})$, appartient à la droite de régression obtenue.

Exercice 5.3 (Théorème de Gauss-Markov). On note $\preceq$ la relation d'ordre dans $S_p(\mathbb{R})$ définie par :

$$A \preceq B \iff B - A \in S_p^+(\mathbb{R}).$$

Pour $\hat{\theta}_1$ et $\hat{\theta}_2$ deux estimateurs sans biais de $\theta \in \mathbb{R}^p$, on dira que $\hat{\theta}_1$ est meilleur que $\hat{\theta}_2$ si $\text{Var}(\hat{\theta}_1) \preceq \text{Var}(\hat{\theta}_2)$.

Le but de cet exercice est de démontrer le *théorème de Gauss-Markov*, dont l'énoncé est le suivant : dans un modèle linéaire identifiable, parmi tous les estimateurs de θ linéaires en Y et sans biais, l'estimateur des moindres carrés est le meilleur (au sens de l'ordre $\preceq$).

On considère donc $\tilde{\theta}$ un autre estimateur de θ , linéaire en Y et sans biais. On l'écrit $\tilde{\theta} = CY$ avec $C = (X^\top X)^{-1}X^\top + D$ avec $D \in \mathbb{R}^{p \times n}$.

1. Montrer que $DX = 0$. *Solution. Le biais doit être nul et on a $\mathbb{E}_\theta[\tilde{\theta}] = \theta + DX\theta$. On doit avoir $DX\theta = 0$ et ce pour tout θ , donc $DX = 0$.*
2. Montrer que $\text{Var}(\tilde{\theta}) = \text{Var}(\hat{\theta}_{MC}) + \sigma^2 DD^\top$. Conclure. *Solution. On a*

$$\begin{aligned}\text{Var}_\theta(\tilde{\theta}) &= C\text{Var}_\theta(Y)C^\top = ((X^\top X)^{-1}X^\top + D)\sigma^2 I_p((X^\top X)^{-1}X^\top + D)^\top \\ &= \sigma^2((X^\top X)^{-1}X^\top + D)(X(X^\top X)^{-1} + D^\top) \\ &= \text{Var}(\hat{\theta}_{MC}) + \sigma^2 DD^\top + \underbrace{\sigma^2(X^\top X)^{-1}X^\top D^\top}_{=0} + \underbrace{\sigma^2 DX(X^\top X)^{-1}}_{=0}.\end{aligned}$$

On conclut car $0 \preceq DD^\top$.