6. Régression linéaire 2/2 : intervalle de confiance pour un coefficient, interprétation géométrique, modèles emboités, variable qualitative

Objectifs : Savoir lire les résultats d'une régression linéaire à la main, tester des modèles emboités, traiter le cas d'une variable quantitative. L'exercice 6.1 est à faire pendant le TD, le reste est à chercher de votre côté.

Exercice 6.1 (Régression avec une variable qualitative)**.** Dans cet exercice, nous étudions la régression linéaire dans le cas où nous avons une variable qualitative. Imaginons qu'on veuille modéliser une variable réponse réelle Y_i d'un individu i en fonction d'une variable réelle continue Z_i et d'une variable qualitative G_i, assimilée à un groupe, entre 1 et k. Plus exactement, dans notre modèle, Y_i est la somme d'un paramètre réel α_{G_i} ne dépendant que de G_i, d'un terme linéaire en Z_i, et d'un bruit. On suppose que les groupes sont disjoints et que $n \geq k+1$.

1. Ecrire le modèle correspondant pour chaque Y_i. *Solution.*

$$Y_i = \alpha_{G_i} + \theta_1 Z_i + \varepsilon_i,$$

avec les ε_i i.i.d., $\mathcal{N}(0, \sigma^2)$.

On note n_g le nombre d'individus i tels que $G_i = g$. Classons les n individus selon leur groupe : on suppose que les n_1 premiers sont dans le groupe 1, les n_2 suivants dans les groupe 2, etc. jusqu'au groupe k, en dernier.

2. Montrer que ce modèle se réécrit sous matriciellement sous la forme d'un modèle linéaire gaussien $Y = X\theta + \varepsilon$. On mettra Z dans la dernière colonne et on précisera la forme de θ et de X. Combien vaut p dans ce modèle ? *Solution. On répètera ce qu'on a dit dans le cours : cette variable G est qualitative et il n'y a pas de raison de la représenter par une valeur chiffrée : en effet, combien vaut un groupe ? Ce n'est pas clair. L'idée, donc, c'est juste de dire que pour une variable qualititative à k modalités, on va créer k variables quantititatives qui prennent des valeurs 0 ou 1 selon le cas dans lequel on est. Ainsi, on s'en sort, cf slides. On a le modèle linéaire gaussien $Y = X\theta + \varepsilon$ avec*

$$\theta = \begin{pmatrix} \alpha_1 \\ \vdots \\ \alpha_k \\ \theta_1 \end{pmatrix} \quad \text{et} \quad X = \left(\begin{array}{ccc|c} \mathbf{1}_{n_1} & & & \\ & \ddots & & Z \\ & & \mathbf{1}_{n_k} & \end{array}\right) \in \mathbb{R}^{n \times p},$$

et on a $n = \sum_{g=1}^{k} n_z$ et $p = k+1$.

3. A quelle condition ce modèle est-il identifiable ? *Solution. Il l'est si et seulement si Z n'est pas constant sur chaque sous-groupe : c'est logique, Z doit fournir une information supplémentaire par rapport au groupe, si on veut l'inclure de façon pertinente dans le modèle. En particulier si $n_g = 1$ pour tout g, le modèle n'est pas identifiable (logique, il n'y a pas vraiment de groupe du coup). Mathématiquement, si Z est constant sur chaque sous groupe, on voit qu'on peut écrire notre modèle $Y_i = \alpha_{G_i} + \theta_1 Z_i + \varepsilon_i$ sous la forme $Y_i = \alpha_{G_i} + \theta_1 \beta_{G_i} + 0 \times Z_i + \varepsilon_i$. On a alors une symétrie $(\alpha, \theta_1) \to (\alpha + \theta_1 \beta, 0)$ qui rend le modèle non identifiable. On pourra dire aux étudiants qu'une interprétation soignée comme celle de la première phrase est une réponse totalement valide à la question (en exam, par exemple).*

4. Changeons de modèle et considérons $Y = X\theta + \varepsilon$ avec

$$\theta = \begin{pmatrix} \mu \\ \alpha_2 \\ \vdots \\ \alpha_k \\ \theta_1 \end{pmatrix} \quad \text{et} \quad X = \left(\begin{array}{cccc|c} \mathbf{1}_{n_1} & & & & \\ \mathbf{1}_{n_2} & \mathbf{1}_{n_2} & & & \\ \vdots & & \ddots & & \\ \vdots & & & \ddots & \\ \mathbf{1}_{n_k} & & & \mathbf{1}_{n_k} & \end{array} \middle| \; Z \right) \in \mathbb{R}^{n \times p},$$

et $\varepsilon \sim \mathcal{N}(0, \sigma^2 I_n)$. A quelle condition ce modèles est-il identifiable ? Quelle est la différence avec le modèle de la question 2. ? *Solution. Même condition d'identifiabilité en faisant les calculs par exemple : le modèle est non-indentifiable ssi la dernière colonne est combinaison linéaire des premières, ssi Z est constant sur chaque sous groupe. Cette fois ci le groupe 1 est une référence et on compare un peu tous les coeff à celui du groupe 1.*

Application : nous observons les poids Y_i de souris dont les mères sont de 4 génotypes différents pour un certain gène G : ce génotype est soit A, B, I ou J. Pour chaque individu i on note G_i le génotype de la mère. On a aussi accès à une variable Z_i mesurant la pression de l'air ambiant au moment de la mesure.

Nous nous posons la question suivante : *le gène G de la mère influe-t-il sur le poids de sa descendance ?*

La figure ci-contre présente les résultats obtenus pour une régression linéaire avec (a) le modèle de la question 2 et (b) celui de la question 4:

Modèle (a)		
	$\widehat{\theta}_i$	$\widehat{\sigma}_i\sqrt{[(X^\top X)^{-1}]_{i,i}}$
MotherA	55.4129	1.9191
MotherB	58.6522	2.0526
MotherI	53.4492	1.9230
MotherJ	48.7978	1.9890
Z	-0.6534	0.9315

Modèle (b)		
	$\widehat{\theta}_i$	$\widehat{\sigma}_i\sqrt{[(X^\top X)^{-1}]_{i,i}}$
Intercept	55.4129	1.9191
MotherB	3.2393	2.8104
MotherI	-1.9638	2.7159
MotherJ	-6.6151	2.7628
Z	-0.6534	0.9315

Ici, $n - p = 56$ et on donne quelques quantiles $t_{1-\alpha/2}$ de la loi de Student de paramètre $d = 56$: $t_{0.9995} = 3.4729$, $t_{0.995} = 2.6665$, $t_{0.95} = 1.6725$, $t_{0.85} = 1.0461$.

5. Que dire de la pertinence de la variable Z dans ces modèles ? (On attend un test de Student). *Solution. Peu importe le modèle utilisé ((a) ou (b)), le test de Student associé a pour statistique $T = \frac{-0.6534}{0.9315} \sim -0.70$ qui est toujours au quantiles donnés en valeur absolue. Avec niveau $\alpha = 0.05$ par exemple, on ne rejette pas l'hypothèse nulle : Z ne sembel pas pertinente dans ces modèles.*

6. Quel est le modèle le plus adapté pour répondre à la question posée ? Que répondez-vous à la question de départ ? *Solution. Il faut faire des test de Student afin de comparer les groupes entre eux. Pour ce faire, comme vu dans le cours, on doit choisir un modèeo de référence. C'est le modèle (b) qui est donc utile pour répondre à notre question. Faisons les test de Student associés : les stats de Student valent, pour MotherB : 1.15, MotherI : -0.72, MotherJ : $-2,39$. Avec les quantiles donnés, on fixera un seuil voulu et on concluera différemment : par exemple à $\alpha = 0.01$, on a $A \sim B$, $A \sim I$ et $A \sim J$ (on ne peut pas conclure sur les autres équivalences, il faudrait relancer des régressions avec un nouveau groupe de référence), tandis qu'à $\alpha = 0.1$, on a $A \sim B$, $A \sim I$ et $A \not\sim J$: le gêne J est statistiquement différent du gêne A.*

Exercice 6.2 (Comparaison de modèles)**.** On effectue une régression de y sur deux variables explicatives x et z à partir d'un échantillon de n individus, c'est-à-dire que $X = [\mathbf{1} \,|\, x \,|\, z]$, où $\mathbf{1}$ est le vecteur de taille n composé de 1. On a obtenu le résultat suivant :

$$X^\top X = \begin{bmatrix} 5 & 3 & 0 \\ 3 & 3 & 1 \\ 0 & 1 & 1 \end{bmatrix}.$$

1. Que vaut n ? *Solution. On lit $n = 5$.*

2. Le coefficient de corrélation linéaire empirique $\widehat{\rho}(a, b)$ entre deux réalisations a, b est défini par :
$$\widehat{\rho}(a,b) := \frac{\frac{1}{n}\sum_{i=1}^n a_i b_i - \bar{a} \times \bar{b}}{\sqrt{\frac{1}{n}\sum_{i=1}^n a_i^2 - (\bar{a})^2}\sqrt{\frac{1}{n}\sum_{i=1}^n b_i^2 - (\bar{b})^2}}.$$
Que vaut $\widehat{\rho}(x, z)$? *Solution. On lit ce qu'on veut dans $X^\top X$. La cov empirique vaut $\frac{1}{5} \times 1 - \frac{3}{5} \times \frac{0}{5} = 1/5$. Les écarts types non débiaisés pour x et z sont respectivement $\sqrt{3/5 - (3/5)^2} = \sqrt{6}/5$ et $\sqrt{1/5 - (0/5)^2} = 1/\sqrt{5}$. On trouve au final*
$$\widehat{\rho}(x,z) = \frac{1/5}{(\sqrt{6}/5) \times (1/\sqrt{5})} = \sqrt{5/6}.$$

3. La régression par moindres carrés a donné le résultat suivant :
$$y_i = -1 + 3x_i + 4z_i + \varepsilon_i,$$
et la somme des carrés résiduels vaut $\|\hat{\varepsilon}\|^2 = 3$.

3.(a). En repartant de l'expression de $\widehat{\theta}_{MC}$, exprimer $X^\top Y$ en fonction de $X^\top X$ et $\widehat{\theta}_{MC}$. Calculer $X^\top Y$ et en déduire la moyenne emprique $\overline{y}$. *Solution. On a $\widehat{\theta}_{MC} = (X^\top X)^{-1} X^\top Y$, donc $X^\top Y = X^\top X \widehat{\theta}_{MC}$. Ici cela donne $X^\top Y = \begin{bmatrix} 5 & 3 & 0 \\ 3 & 3 & 1 \\ 0 & 1 & 1 \end{bmatrix} \begin{bmatrix} -1 \\ 3 \\ 4 \end{bmatrix} = \begin{bmatrix} 4 \\ 10 \\ 7 \end{bmatrix}$ mais par ailleurs $X = [\mathbf{1}, x, z]$ donc $X^\top Y = \begin{bmatrix} n\overline{y} \\ \sum_{i=1}^n x_i y_i \\ \sum_{i=1}^n x_i z_i \end{bmatrix}$. On lit donc $\overline{y} = 4/5 = 0.8$.*

3.(b). Vérifier que $\|X\widehat{\theta}_{MC}\|^2 = Y^\top X \widehat{\theta}_{MC} = \widehat{\theta}_{MC}^\top X^\top Y$. Calculer alors $\|\widehat{Y}\|^2$ et en déduire $\|Y\|^2$. *Solution. Il suffit d'écrire :*
$$\begin{aligned} \|X\widehat{\theta}_{MC}\|^2 &= \widehat{\theta}_{MC}^\top X^\top X \widehat{\theta}_{MC} \\ &= ((X^\top X)^{-1} X^\top Y)^\top X^\top X \widehat{\theta}_{MC} \\ &= Y^\top X (X^\top X)^{-1} X^\top X \widehat{\theta}_{MC} = Y^\top X \widehat{\theta}_{MC}. \end{aligned}$$
On en déduit $\|\widehat{Y}\|^2 = \langle \widehat{\theta}_{MC}, X^\top Y \rangle = -4 + 30 + 28 = 54$. De plus par Pythagore $\|Y\|^2 = \|\widehat{Y}\|^2 + \|\varepsilon\|^2 = 57$.

3.(c). Calculer la somme des carrés totale $\|Y - \overline{y}\mathbf{1}\|^2$, puis déterminer le coefficient de détermination R^2 ainsi que le coefficient de détermination ajusté. *Solution. Par Pythagore $\|Y - \overline{y}\mathbf{1}\|^2 = \|Y\|^2 - \|\overline{y}\mathbf{1}\|^2 = 57 - n \times \overline{y}^2 = 57 - 16/5 = 57 - 3.2 = 53.8$. On a ainsi $R^2 = 1 - \frac{3}{53.8} \sim 0.94$ et $R_a^2 = 1 - \frac{3/(5-3)}{53.8/(5-1)} \sim 0.89$.*

4. On s'intéresse maintenant au modèle privé du régresseur z, c'est-à-dire $Y = X_0\theta_0 + \varepsilon_0$ avec $X_0 = [\mathbf{1}\,|\,x]$.

   4.(a). Déterminer $X_0^\top X_0$ et $X_0^\top Y$. En déduire $(\widehat{\theta_0})_{MC}$. *Solution. $X_0^\top X_0$ se déduit de $X^\top X$ et vaut $X_0^\top X_0 = \begin{bmatrix} 5 & 3 \\ 3 & 3 \end{bmatrix}$. On a aussi $X_0^\top Y = \begin{bmatrix} 4 \\ 10 \end{bmatrix}$ et comme*

$$(X_0^\top X_0)^{-1} = \frac{1}{6}\begin{bmatrix} 3 & -3 \\ -3 & 5 \end{bmatrix}$$

et le calcul donne $(\widehat{\theta_0})_{MC} = \begin{bmatrix} -3 \\ 19/3 \end{bmatrix}$.

   4.(b). Calculer $\|\widehat{Y}_0\|^2$. *Solution. Comme précédemment, $\|\widehat{Y}_0\|^2 = -12 + 190/3 \sim 51.3$.*

   4.(c). Justifier l'égalité $\|\widehat{Y}_0\|^2 + \|\varepsilon_0\|^2 = \|\widehat{Y}\|^2 + \|\varepsilon\|^2$. En déduire la somme des carrés résiduels $\|\varepsilon_0\|^2$ dans ce nouveau modèle. Déterminer le coefficient de détermination R_0^2 ainsi que le coefficient de détermination ajusté. *Solution. C'est encore le bon vieux Pythagore pour chaque modèle. On a donc $\|\varepsilon_0\|^2 = 57 - 51.3 = 5.7$. Il vient $R_0^2 = 1 - \frac{5.7}{53.8} = 0.8941$ et $R_{0,a}^2 = 1 - \frac{5.7/(5-2)}{53.8/(5-1)} \sim 0.8587$.*

5. On suppose désormais que le modèle est gaussien. On veut comparer les deux modèles précédents.

   5.(a). Effectuer un test de Fisher entre ces deux modèles grâce aux coefficients de détermination. Montrer que la statistique de Fisher s'écrit aussi

$$F = \frac{n-p}{p-p_0}\frac{R^2 - R_0^2}{1-R^2}\,.$$

   Calculer F dans notre cas. Qu'en concluez-vous au niveau de risque 5% ? On donne $f^{1,2}(0.95) = 18.5$. *Solution. On applique le test de Fisher avec comme statistique de test :*

$$F := \frac{\|\widehat{Y} - \widehat{Y}_0\|^2/(p-p_0)}{\|Y - \widehat{Y}\|^2/(n-p)} = \frac{n-p}{p-p_0}\frac{R^2 - R_0^2}{1-R^2},$$

qui ici vaut $F = \frac{5-3}{3-2} \times \frac{0.94-0.9}{1-0.94} = 2 \times \frac{2}{3} \sim 1.3 \ll 18.5$ donc ne rejette pas H_0 : on valide le fait que $\theta_z = 0$.

   5.(b). Proposer un autre moyen d'arriver au même résultat. *Solution. Avec un test de Student !*

Exercice 6.3 (Minimisation de l'erreur de prédiction)**.** Dans cet exercice, on s'intéresse à l'erreur de prédiction dans le modèle linéaire. On cherche à apprendre le modèle suivant pour prédire le réel Y_i en fonction d'une variable explicative réelle z_i :

$$\forall 1 \le i \le n, \quad Y_i = \beta_0 + \beta_1 z_i + \varepsilon_i\,.$$

On notera $\overline{y}$ et $\overline{z}$ les moyennes empiriques de $z = (z_1, \ldots, z_n)^\top$ et de $Y = (Y_1, \ldots, Y_n)^\top$ (attention, elles dépendent de n). On suppose que le modèle est identifiable et on note $\widehat{\beta} = (\widehat{\beta}_0, \widehat{\beta}_1)$ l'estimateur des moindres carrés de β. On note σ^2 la variance (constante) du bruit.

Sous le même modèle, on observe une nouvelle valeur z_{n+1} de la variable explicative et on cherche à prédire la variable réponse Y_{n+1} avec l'estimateur

$$\widehat{y}_{n+1} := \widehat{\beta}_0 + \widehat{\beta}_1 z_{n+1} = x_{n+1}^\top \widehat{\beta}, \quad \text{où } x_{n+1} := \begin{bmatrix} 1 \\ z_{n+1} \end{bmatrix}\,.$$

L'erreur de prédiction est définie par :

$$\mathrm{err}(z_{n+1}) := \mathbb{E}\left[(Y_{n+1} - \widehat{y}_{n+1})^2\right] .$$

Notons que dans cette espérance, l'aléa vient du bruit ε_{n+1} dans Y_{n+1} ainsi que de l'aléa dans le $\hat{\beta}$.

1. Montrer que si S est un vecteur aléatoire de $\mathbb{R}^m$ de matrice de covariance (finie) C, alors pour tout vecteur $u \in \mathbb{R}^m$, $\mathrm{Var}(u^\top S) = u^\top C u$. *Solution. On peut développer pour voir que*

$$\begin{aligned}\mathrm{Var}(u^\top S) &= \mathrm{Var}\left(\sum_{i=1}^m u_i S_i\right) \\ &= \sum_{1\le i,j\le m} \mathrm{Cov}(u_i S_i, u_j S_j) \\ &= \sum_{1\le i,j\le m} u_i u_j C_{i,j} = u^\top C u\,.\end{aligned}$$

2. Que vaut $\mathbb{E}\left[Y_{n+1} - \widehat{y}_{n+1}\right]$? *Solution. Elle est égale à $\mathbb{E}\left[x_{n+1}^\top(\beta - \widehat{\beta}) + \varepsilon_{n+1}\right] = x_{n+1}^\top 0 + 0 = 0$ par nullité du biais de $\widehat{\beta}$ et d'après les hypothèses sur les ε_i.*

3. Ecrire la matrice X du plan d'expérience dans ce modèle (on mettra l'intercept dans la première colonne), et montrer que

$$(X^\top X)^{-1} = \frac{1}{nv(z)} \begin{bmatrix} \frac{1}{n}\sum_{i=1}^n z_i^2 & -\overline{z} \\ -\overline{z} & 1 \end{bmatrix},$$

avec $v(z) := \frac{1}{n}\sum_{i=1}^n z_i^2 - (\overline{z})^2$ la variance empirique de z. *Solution. Dans notre cas on a $X = \left[\begin{array}{c|c} \mathbf{1}_n & z \end{array}\right] \in \mathbb{R}^{n\times 2}$, et $X^\top X = n \begin{bmatrix} 1 & \overline{z} \\ \overline{z} & \frac{1}{n}\sum_{i=1}^n z_i^2 \end{bmatrix}$ de déterminant $n^2 v(z)$. Il vient donc $(X^\top X)^{-1} = \frac{1}{nv(z)} \begin{bmatrix} \frac{1}{n}\sum_{i=1}^n z_i^2 & -\overline{z} \\ -\overline{z} & 1 \end{bmatrix}$.*

4. En utilisant les résultats des questions 1, 2 et 3, montrer que

$$\mathrm{err}(z_{n+1}) = \sigma^2\left(1 + \frac{1}{n} + \frac{(z_{n+1} - \overline{z})^2}{\sum_{i=1}^n (z_i - \overline{z})^2}\right) .$$

Solution. Comme la variable dont on prend le moment d'ordre deux est centré d'après la question 2, on calcule en fait une variance.

$$\begin{aligned}\mathrm{err}(z_{n+1}) &= \mathrm{Var}(\varepsilon_{n+1} + x_{n+1}^\top(\beta - \widehat{\beta})) \\ &= \sigma^2 + x_{n+1}^\top(\sigma^2 (X^\top X)^{-1}) x_{n+1}\,.\end{aligned}$$

D'après la question 3 on a $(X^\top X)^{-1} = \frac{1}{nv(z)} \begin{bmatrix} \frac{1}{n}\sum_{i=1}^n z_i^2 & -\overline{z} \\ -\overline{z} & 1 \end{bmatrix}$ avec $v(z)$ variance empirique de z. Cela donne

$$\begin{aligned}\mathrm{err}(z_{n+1}) &= \sigma^2 + x_{n+1}^\top(\sigma^2 (X^\top X)^{-1}) x_{n+1} \\ &= \sigma^2 + \frac{\sigma^2}{nv(z)}\left(\frac{1}{n}\sum_{i=1}^n z_i^2 - 2\overline{z} z_{n+1} + z_{n+1}^2\right)\end{aligned}$$

$$= \sigma^2 + \frac{\sigma^2}{nv(z)}\left(v(z) + \overline{z}^2 - 2\overline{z}z_{n+1} + z_{n+1}^2\right)$$
$$= \sigma^2\left(1 + \frac{1}{n} + \frac{(z_{n+1} - \overline{z})^2}{nv(z)}\right).$$

5. Pour quelle(s) valeur(s) de z_{n+1} l'erreur de prédiction est-elle minimale ? Interpréter ce résultat. *Solution. L'erreur est minimale en $z_{n+1} = \overline{z}$ et vaut $\sigma^2 + \sigma^2/n$. On est toujours meilleur pour prédire lorsqu'on observe le barycentre de ce qu'on a déjà observé. En effet, intuitivement, c'est le point le plus typique.*

6. Quelle est la limite de l'erreur de prédiction minimale lorsque $n \to \infty$? Interpréter cette valeur limite. *Solution. Cette erreur tend vers σ^2 lorsque n est grand, c'est l'erreur minimale de prédiction qu'on puisse faire, car la variable Y_{n+1} est bruitée avec un bruit indépendant et de variance σ^2 : on ne peut pas faire mieux.*

Exercice 6.4 (Equivalence Student/Fisher pour la nullité d'un coefficient)**.** Dans cet exercice souhaite montrer l'équivalence entre les tests de Student et de Fisher pour la nullité d'un paramètre. On considère donc le modèle linéaire Gaussien identifiable $Y = X\theta + \varepsilon$ pour lequel on veut tester la nullité du dernier coefficient θ_p.

1. Donner la statistique T du test de Student pour le test de nullité du dernier coefficient θ_p. *Solution. c'est $T = \frac{(\widehat{\theta}_{MC})_p}{\widehat{\sigma}\sqrt{(X^\top X)^{-1}_{i,i}}}$ avec pour rappel $\widehat{\sigma} = \sqrt{\frac{SCR(\widehat{\theta}_{MC})}{n-p}}$.*

2. Donner la statistique F du test de Fisher pour les modèles emboîtés correspondants. On fera apparaître $\widehat{\sigma}^2$ au dénominateur. *Solution. Ici le modèle de plus faible dimension est ω, l'espace engendré par les $p-1$ premières colonnes de X. La statistique de Fisher s'écrit donc*
$$F = \frac{\|\widehat{Y} - \widehat{Y}_0\|^2}{\widehat{\sigma}^2},$$
avec $\widehat{Y}_0$ le projecté orthogonal de Y sur ω.

3. Soit T_d une variable suivant une loi de Student à d degrés de liberté. Rappeler sa définition et en déduire la loi suivie par la variable $F_d = T_d^2$. *Solution. On rappelle qu'en loi T_d est égale à $\frac{Z}{\sqrt{K/d}}$ où $Z \sim \mathcal{N}(0,1)$ et $K \sim \chi^2(d)$ sont indépendantes. En passant au carré il apparaît que $F = \frac{Z^2/1}{K/d} \sim \mathcal{F}(1,d)$.*

4. On note la matrice du plan d'expérience sous forme de bloc $X = [X_0 \,|\, X_p]$, où $X_0 = [X_1 \,|\, \ldots \,|X_{p-1}]$ est la matrice de taille $n \times (p-1)$ des $(p-1)$ premières colonnes de X, et X_p est sa dernière colonne. Ecrire la matrice $X^\top X$ sous forme de 4 blocs. *Solution. il vient*
$$X^\top X = \begin{bmatrix} X_0^\top X_0 & X_0^\top X_p \\ X_p^\top X_0 & X_p^\top X_p \end{bmatrix}$$
on pourra vérifier la cohérence des dimensions.

5. On donne (ou on rappelle) le lemme suivant :

Lemme (Inversion par blocs). Soit A une matrice inversible s'écrivant par blocs $A = \begin{bmatrix} T & U \\ V & W \end{bmatrix}$ avec T inversible. Alors $Q = W - VT^{-1}U$ est inversible et l'inverse de A s'écrit :
$$A^{-1} = \begin{bmatrix} T^{-1} + T^{-1}UQ^{-1}VT^{-1} & -T^{-1}UQ^{-1} \\ -Q^{-1}VT^{-1} & Q^{-1} \end{bmatrix}.$$

Grâce à la formule d'inversion matricielle par blocs, en déduire que

$$[(X^\top X)^{-1}]_{i,i} = (X_p^\top (I_n - \Pi_0) X_p)^{-1},$$

où Π_0 est la matrice $n \times n$ de projection orthogonale sur l'espace engendré par les colonnes de X_0. *Solution. On calcule Q dans le lemme en haut. $X_0^\top X_0$ est bien inversible par hypothèse d'indentifiabilité (les $p-1$ premières colonnes de X sont encore libres). Q s'écrit ici $X_p^\top X_p - X_p^\top X_0 (X_0^\top X_0)^{-1} X_0^\top X_p$ et on reconnait la matrice de projection Π_0 (cf cours sur l'estimateur des moindre carrés). $Q = X_p^\top (I_n - \Pi_0) X_p$ qui est un réel non nul d'après le Lemme, et donc inversible. On a le résultat en identifiant l'entrée en bas à droite.*

6. En reprenant les notations du cours $\widehat{Y}$ et $\widehat{Y}_0$, vérifier que $\widehat{Y}_0 = \Pi_0 \widehat{Y}$ puis montrer que

$$\widehat{Y} - \widehat{Y}_0 = (\widehat{\theta}_{MC})_p (I_n - \Pi_0) X_p \,.$$

Solution. Comme ω est un sous-espace de Ω, on a $\Pi_\Omega \Pi_0 = \Pi_0$. En effet, $\Pi_0(x) \in \omega \subset \Omega = Im(\Pi_\Omega)$, et un projecteur est constant sur son image. On obtient $\widehat{Y} - \widehat{Y}_0 = (I_n - \Pi_0)\widehat{Y}$. Mais $\widehat{Y} = X\theta_{MC} = (\theta_{MC})_1 X_1 + \ldots + (\theta_{MC})_p X_p$. Et poru tout $1 \leq j \leq p-1$, par définition $(I_n - \Pi_0) X_j = 0$. Cela donne bien $\widehat{Y} - \widehat{Y}_0 = (\widehat{\theta}_{MC})_p (I_n - \Pi_0) X_p$.

7. En déduire que dans ce cas $F = T^2$. Conclure. *Solution. En utilisant les questions précédentes on a que*

$$F = \frac{\|\widehat{Y} - \widehat{Y}_0\|^2}{\widehat{\sigma}^2} = \frac{(\widehat{\theta}_{MC})_p^2 \|(I_n - \Pi_0) X_p\|^2}{\widehat{\sigma}^2} = \frac{(\widehat{\theta}_{MC})_p^2 X_p^\top (I_n - \Pi_0)(I_n - \Pi_0) X_p}{\widehat{\sigma}^2}$$
$$= \frac{(\widehat{\theta}_{MC})_p^2 X_p^\top (I_n - \Pi_0) X_p}{\widehat{\sigma}^2} = \frac{(\widehat{\theta}_{MC})_p^2}{\widehat{\sigma}^2 [(X^\top X)^{-1}]_{i,i}} = T^2$$

Conclusion, ici tester si $|T| > t_{1-\alpha/2}^{n-p}$ (test de Student) revient exactement à tester si $F > f_{1-\alpha}^{1,n-p}$ (test de Fisher).